中国科学技术大学

硕士学位论文

基于多智能体强化学习的多无人机路径规划和资源分配问题研究

作者姓名： 庄晨

学科专业： 信息与通信工程

导　　师： 周武旸 教授

完成时间： 二〇二五年五月二十六日

中国知网 https://www.cnki.net

University of Science and Technology of China

A dissertation for master's degree

Multi-UAV Trajectory Optimization and Resource Allocation based on Multi-Agent Reinforcement Learning

Author: Zhuang Chen

Speciality: Information and Communication Engineering

Supervisor: Prof. Zhou Wuyang

Completion date: May 26, 2025

中国知网 https://www.cnki.net

摘　要

随着用户设备数量的持续增长，高密度用户热点区域不断涌现，使得提供高质量的通信覆盖变得愈发困难。同时，频繁发生的自然灾害和突发事故可能导致通信覆盖空洞，进一步加剧了对快速恢复通信网络的需求。无人机技术的发展使其凭借低成本、易部署的优势成为提升无线通信覆盖的关键方案。然而，受能量与覆盖范围限制，如何优化路径规划与资源分配，以在能量受限条件下提升用户覆盖率，仍是亟待解决的挑战。相较于传统基于最优化理论的凸近似方法，强化学习无需显式建模即可高效应对复杂动态环境与优化决策，在灵活性和适应性上更具优势。尤其是在多无人机协作的场景中，多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）能够基于本地观测数据自主决策，通过合作提升用户整体覆盖率。

本文的创新性工作主要包括：

1. 针对应急通信场景中的用户覆盖缺失问题，提出了一种基于全局协作 MARL 的多无人机路径优化方法。该方法将无人机建模为智能体，综合考虑飞行、悬停和通信过程中的能量消耗，特别是离散动作空间中频繁路径调整导致的非必要转向能耗。通过引入无人机起止点约束，并以最大化用户覆盖率为目标，构建马尔科夫决策过程模型，最后利用 QMIX 网络进行全局协同优化。仿真结果表明，与最大化和速率为目标的方法相比，该方法能够显著提升用户覆盖率和服务效率。
2. 针对热点通信场景中基站因过载导致的覆盖不足问题，本文利用非正交多址接入（Non-Orthogonal Multiple Access, NOMA）技术提升覆盖效率，并提出一种基于改进 Actor-Critic 网络的多无人机路径规划与资源分配优化方法。该方法在综合考虑无人机能量消耗模型的基础上，联合优化无人机路径规划与功率控制，并基于部分可观测马尔可夫决策过程进行建模。针对 NOMA 引入的额外用户分配需求导致的动作空间维度扩增问题，本文采用扩展加权二分图建模无人机与用户之间的潜在关系，并利用最大权重匹配算法求解用户分配方案，并将其从动作空间中解耦，以降低动作空间维度。最后，本文基于联合扩展加权二分图的 Actor-Critic 网络对多无人机路径规划和资源分配进行求解。仿真结果表明，相较于仅支持单用户服务的路径规划方法和以最大化和速率为目标的方法，所提方案进一步提升了用户覆盖率。

关键词：无人机; 路径规划; 多智能体强化学习

中国知网　https://www.cnki.net

ABSTRACT

With the continuous growth in the number of user devices, high-density user hotspot areas are emerging, making it increasingly challenging to provide high-quality communication coverage. Additionally, frequent natural disasters and sudden incidents can create communication coverage gaps, further intensifying the demand for rapid network recovery. The development of unmanned aerial vehicle (UAV) technology has positioned it as a key solution for enhancing wireless communication coverage due to its low cost and easy deployment. However, given energy and coverage limitations, optimizing trajectory design and resource allocation to maximize user coverage under energy constraints remains a critical challenge. Compared to traditional convex approximation methods based on optimization theory, reinforcement learning can efficiently handle complex dynamic environments and optimize decision-making without explicit modeling, offering greater flexibility and adaptability. In particular, in multi-UAV cooperative scenarios, Multi-Agent Reinforcement Learning (MARL) enables UAVs to make autonomous decisions based on local observations, thereby improving overall user coverage through collaboration.

The main contributions of this thesis include:

1. To address the issue of user coverage gaps in emergency communication scenarios, a multi-UAV trajectory optimization method based on globally coordinated MARL is proposed. In this approach, UAVs are modeled as intelligent agents, and energy consumption in flight, hovering, and communication processes is considered. Special attention is given to unnecessary turning energy consumption caused by frequent path adjustments in discrete action spaces. By introducing constraints on UAV start and end positions and formulating a Markov decision process (MDP) to maximize user coverage, the QMIX network is utilized for global cooperative optimization. Simulation results demonstrate that, compared to methods of maximizing the sum-rate, the proposed method significantly improves user coverage and service efficiency.
2. To mitigate coverage deficiencies caused by base station overload in hotspot communication scenarios, this thesis leverages Non-Orthogonal Multiple Access (NOMA) technology to enhance coverage efficiency and proposes an improved Actor-Critic-based multi-UAV trajectory design and resource allocation optimization method. This approach jointly optimizes UAV trajectory design and

中国知网 https://www.cnki.net

power control while considering the UAV energy consumption model, and it is formulated as a Partially Observable Markov Decision Process (POMDP). To address the action space expansion problem introduced by the additional user allocation requirements in NOMA, an extended weighted bipartite graph is employed to model the potential relationships between UAVs and users, and a maximum-weight matching algorithm is used to solve the user allocation problem. This decouples user allocation from the action space, reducing its dimensionality. Finally, an Actor-Critic network based on the joint extended weighted bipartite graph is used to solve the multi-UAV trajectory design and resource allocation problem. Simulation results show that, compared to single-user trajectory optimization methods and sum-rate maximization approaches, the proposed scheme further enhances user coverage.

KEY WORDS: UAV，Trajectory Optimization，MARL

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.3 研究内容与组织架构.....5
1.3.1 研究内容简述.....5
1.3.2 组织架构.....7
1.4 本章小结.....8
第 2 章 强化学习基础.....9
2.1 基本概念.....9
2.2 深度强化学习.....10
2.2.1 基于价值的强化学习.....10
2.2.2 基于策略的强化学习.....11
2.2.3 演员-评论家方法.....12
2.3 多智能体强化学习.....14
2.4 本章小结.....15
第 3 章 应急通信场景中能量受限多 UAV 路径规划.....17
3.1 引言.....17
3.2 场景简述.....17
3.3 系统模型.....18
3.3.1 信道模型.....18
3.3.2 能量损耗模型.....19
3.4 问题建模.....20
3.5 基于 MARL 的能量受限多 UAV 路径规划.....22
3.6 仿真结果与分析.....27
3.7 本章小结.....35
第 4 章 热点场景中能量受限多 UAV 路径规划与资源分配.....36
4.1 引言.....36
4.2 场景简述.....36
4.3 问题建模.....37
4.4 基于部分观测 MARL 的多 UAV 路径规划与资源分配.....41
4.4.1 状态、动作与奖励设计.....41
4.4.2 基于扩展二分图的用户分配.....43
4.4.3 基于 AC 网络的联合路径规划与功率分配.....51
4.5 仿真结果与分析.....53

中国知网 https://www.cnki.net

4.6 本章小结.....59
第 5 章 总结与展望 60
5.1 本文工作总结.....60
5.2 未来研究展望.....61
参考文献.....62

中国知网 https://www.cnki.net

插图和附表清单

图 1.1 研究内容架构图 6

图 2.1 强化学习基本架构 9
图 2.2 演员-评论家网络结构图 13
图 2.3 多智能体强化学习基本架构 14

图 3.1 应急通信场景 UAV 工作示意图 17
图 3.2 不同转向策略下的路径示意图 22
图 3.3 受约束的 MDP 架构图 25
图 3.4 基于 QMIX 的混合网络架构图 26
图 3.5 UAV 执行不同动作时的功率示意图 28
图 3.6 不同速率需求下的用户覆盖率 29
图 3.7 不同时长需求下的用户覆盖率 29
图 3.8 不同用户数下的用户覆盖率 30
图 3.9 不同速率需求、服务时长需求下的服务时间比率 30
图 3.10 无人机路径单次仿真示意图（4 角度） 31
图 3.11 无人机路径单次仿真示意图（16 角度） 33
图 3.12 不同转向控制策略下的用户覆盖率与用户需求速率的关系 34
图 3.13 不同转向控制策略下的用户覆盖率与角度可选集的关系 34

图 4.1 热点通信场景 UAV 工作示意图 37
图 4.2 配对用户功率可选集示意图 43
图 4.3 UAV 与用户的潜在连接关系示意图 45
图 4.4 符合二分图的扩展连接关系示意图 46
图 4.5 改进的最大权重匹配算法流程示意图 48
图 4.6 瞬时状态用户选择及可达速率仿真 52
图 4.7 中心式训练-分布式执行的 AC 网络架构 53
图 4.8 引入加权二分图的网络架构 54
图 4.9 不同分簇用户速率需求分布下的平均用户覆盖率 54
图 4.10 不同分簇用户服务时长需求下的平均用户覆盖率 56
图 4.11 无人机路径单次仿真示意图（16 角度） 57
图 4.12 不同角度可选集下的平均用户覆盖率 58
图 4.13 不同用户簇服务时长需求与速率需求下的服务时间比率 58

中国知网 https://www.cnki.net

表 4.1　用户分簇及各簇速率需求 51
表 4.2　用户已完成传输数据量比率状态 51

中国知网　https://www.cnki.net

第 1 章　绪论

1.1　研究背景与意义

随着通信技术的发展和智能设备的普及，无线通信需求已成为人们的基本需求之一。然而，在地面无线通信场景中，由于用户设备（User Equipment, UE）数量的持续增长，满足用户覆盖需求变得愈发困难。例如，在大型赛事或演唱会等高密度人群聚集的场馆中，移动用户往往会遭遇信号较弱甚至完全无服务的情况。这种情况下，通常需要额外部署基站车进行临时覆盖增强，但其成本较高，且服务质量难以令人满意。这一现象本质上体现了高密度用户环境下的覆盖空洞问题[1]，即现有网络难以满足所有用户的通信需求，从而在特定区域形成信号覆盖盲区。此外，自然灾害（如地震、洪水、飓风等）可能导致通信基础设施严重损坏，使得部分区域出现通信中断。在这种情况下，局部区域可能形成大范围的覆盖空洞。虽然卫星通信可用于应急通信保障，但由于卫星通信容量受限且终端设备成本高昂，且仍会存在一定的通信盲区，难以满足大规模灾害场景下的持续性通信需求[2]。另外，在第五代移动通信技术（5th Generation Mobile Communication Technology, 5G）标准化协议中[3]，毫米波（Millimeter Wave, mmWave）频段被纳入标准，以提升数据传输速率和频谱利用效率。然而，由于毫米波信号的传播特性，其对天气条件和障碍物极为敏感，稍有遮挡便可能导致严重的信号衰减，从而形成新的覆盖空洞。而在第六代移动通信技术（6th Generation Mobile Communication Technology, 6G）研究规划中，开发一个覆盖整个世界甚至太空的网络，实现各种环境、各类场景下的无缝覆盖，也是 6G 的重要目标之一[4]。综上所述，覆盖空洞问题广泛存在于高密度人群、灾害应急通信以及毫米波通信等应用场景中。如何有效填补这些覆盖空洞，满足当前乃至未来网络中用户的基本通信需求，仍然是无线通信领域的重要研究方向。

在设备小型化和无人机（Unmanned Aerial Vehicle, UAV）技术快速发展的推动下，UAV 辅助无线通信成为解决通信覆盖问题的重要方案。凭借低成本、快速部署和灵活覆盖等优势，UAV 可作为中继节点或空中基站（Base Station, BS），为特定区域提供按需通信覆盖[5]，在灾害应急通信[6]、偏远地区网络覆盖[7]及高流量需求场景[8]中展现出广阔应用前景。进一步地，在未来 6G 移动网络的应用中，UAV 可作为空中移动中继，在增强型移动宽带（enhanced Mobile BroadBand, eMBB）、超可靠低时延通信（ultra-Reliable Low Latency Communication, uRLLC）和大规模机器类通信（massive Machine-Type Communication, mMTC）等多种典型场景中都能提供灵活有效的无线连接支持[9]。此外，UAV 相关的无线通信技术已被视为未来 6G 网络的关键支撑之一，不仅有助于提升无线覆盖率与系统整

中国知网　https://www.cnki.net

体性能，还可通过与机器学习（Machine Learning, ML）的深度融合，进一步拓展其在智能调度、资源优化等方面的应用潜力[10]。

研究表明，得益于 UAV 灵活部署与快速机动的特性，通过动态调整其位置与飞行状态，不仅能够提升通信链路质量，还可提高频谱与能量利用效率，进而增强网络的整体服务能力[11]。在 UAV 的轨迹设计与功率分配等应用中，引入 ML 不仅有助于提升网络效能与系统容量，还能有效降低计算复杂度[12]。然而，UAV 的最大局限性在于其有限的续航能力，电池容量的物理限制使其无法长时间持续飞行[13]。在任务执行过程中，如果频繁或无序地调整位置与飞行状态，不仅会加剧能量消耗，还会显著缩短其实际工作时间，从而影响通信服务的持续性和稳定性。此外，由于单架 UAV 的无线覆盖范围相对较小，其一次可服务的用户数量有限[14]。因此，在实际任务中，需要根据用户分布和通信需求合理规划 UAV 的服务顺序和飞行路径，以提升整体任务效率，避免资源浪费。进一步地，在多 UAV 场景中，除了要避免相互碰撞和规避干扰，还需要确保各个 UAV 能够在有限的资源和空间内实现有效的协同工作。这便要求 UAV 在动态调整飞行路径的同时，合理分配无线通信资源，从而避免系统性能损失和资源浪费。除此之外，UAV 之间的信息共享机制也需要优化。全局协作虽然能提升系统整体性能，但其交互开销较高，而部分协作则对 UAV 的策略设计提出了更高的要求，需要在效率和灵活性之间找到平衡。在此背景下，针对前述覆盖空洞场景，如何在能量受限的条件下设计合理且高效的路径规划与资源分配策略，使 UAV 能够在电量耗尽前为尽可能多的用户提供服务，依然是无人机辅助通信系统亟需解决的关键挑战之一。

1.2　国内外研究现状

在现有的 UAV 辅助无线通信研究中，路径规划与资源分配问题通常被建模为非凸优化问题。为求解此类问题，常采用连续凸近似（Successive Convex Approximation, SCA）等方法将原问题近似拆解为一系列凸子问题并分别求解。例如，在 UAV 中继场景中，联合路径规划和资源分配下的非凸问题，被解耦为子载波分配、路径优化、功率分配、用户调度等多个子问题并逐步求解[15-17]。在移动边缘计算（Mobile Edge Computing, MEC）场景中，基于比特分配、发射功率、频带分配和 UAV 路径的联合优化非凸问题也被分解为两个等效的凸优化子问题再求解[18]。为了实现基于 UAV 的非正交多址接入（Non-Orthogonal Multiple Access, NOMA）无线网络中的服务质量（Quality of Service, QoS）保障，作者将其建模为以能量效率为目标的非凸优化问题，通过 SCA 将原问题变换分解为多个凸优化子问题，对用户调度、功率分配、路径规划进行联合求解[19]。然而，随

中国知网　https://www.cnki.net

着问题复杂度的不断提升，非凸优化的近似求解不仅会使计算复杂度显著增加，还不可避免地导致算法性能下降，难以满足实际应用需求。

强化学习（Reinforcement Learning, RL）的出现为这一难题提供了新的解决思路。相比于传统的优化方法，RL 能够在无需对系统进行显式建模的情况下，自适应地优化决策，并有效应对动态环境[20-21]。这一特性使得基于 RL 的路径规划方法在 UAV 辅助无线通信中受到广泛关注，特别是在处理复杂、多变的无线通信环境时展现出优越的性能[22]。例如，有研究基于双深度 Q 网络（Dueling Deep Q-Network, DDQN）的 UAV 路径规划算法，实现 UAV 对地面用户的追踪[23]。进一步地，在多 UAV 协作场景下，多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）逐渐成为国内外的研究热点[24-26]。在由多智能体组成的通信系统中，由控制中心集中式地收集全部信息再进行决策是不切实际的，MARL 通过建模多个 UAV 之间的交互协作，使其能够自主学习最优策略，以优化路径规划和资源分配。这不仅能提升 UAV 群体的整体效率，还能够在不确定环境中实现更好的资源利用率[27]。

针对因自然灾害造成的应急通信场景覆盖空洞中的用户覆盖需求满足问题，现有的研究建模较为简单，且约束条件较为片面，只能得到理论上的可行解，而难以在实际系统中应用。例如，考虑到 UAV 在电量耗尽前需要回到充电站，有研究提出了将最后工作时刻的位置作为强约束条件，以最大化和速率为目标，基于 MARL 设计了多 UAV 的路径规划策略[28]。然而，将优化目标设定为最大化和速率时，很容易使 UAV 盘旋于最优信道用户附近，而这会使用户之间的公平性失衡，信道条件一般用户的 QoS 则难以保证，甚至出现无服务情况。考虑到 UAV 在飞行、悬停和通信时的不同功率消耗[29]，亦有研究设计了兼顾 UAV 能耗和用户 QoS 的基于 MARL 算法的多 UAV 路径规划策略[30-31]。此类方法虽然在用户公平性上有所保证，却没有对 UAV 的起点和终点作约束，既不关心 UAV 在完成任务后的去向，更无法避免 UAV 能量耗尽时的坠机。在 UAV 有明确的起点和终点时，可以将多 UAV 路径规划问题建模为多旅行商问题（Multiple Traveling Salesman Problem, MTSP）进行求解[32]。此方法虽然可以保证 UAV 按照既定路径工作，且不会在任务完成后失联或坠机，却无视了 UAV 的能量限制，而这会使能量受限的 UAV 无法完成已分配的最优路径。尽管有研究在给定 UAV 能量限制的条件下，给出了基于 MTSP 的路径规划中接续完成全用户覆盖的最小 UAV 数量和相应的接力路线[33]，但接力任务需要在特定位置依序部署多个 UAV 以满足全覆盖需求，这无疑带来了更长的时间消耗和更高的成本开销。综上所述，在联合考虑 UAV 能量受限、用户 QoS 公平性以及 UAV 路径起止点约束的前提下，以最大化用户覆盖率为目标的 UAV 路径规划方法仍待深入研究。

在面向多 UAV 路径规划问题的研究中，已有研究基于深度确定性策略梯度

中国知网　https://www.cnki.net

（Deep Deterministic Policy Gradient, DDPG）实现了 UAV 在速度和角度上的连续动作决策[34-35]。然而，这些方法均未考虑到 UAV 的能耗问题，连续决策中的频繁变速和转向将带来不可忽视的额外能耗。对于能量受限的 UAV，现有研究中的动作空间通常设计为有限的离散动作空间，例如，在二维路径规划中，UAV 的飞行方向可选集被设计为均匀且离散的角度集合[36]；在三维路径规划问题中，UAV 的飞行方向被进一步简化为在三维坐标轴上的任一维度前进、后退或保持不变[37]。当最优路径无法与预设动作空间精准匹配时，UAV 在整个决策过程中会频繁出现非必要的转向，进而产生不可忽视的额外能量消耗。然而，现有研究大多忽略了转向能量损耗的影响，这将使能量受限的 UAV 在实际场景中的表现远低于预期。因此，将转向能量损耗纳入决策过程，并设计相应的优化策略以限制非必要转向，能够进一步提升 UAV 的能量利用率，使 UAV 的能量可以更多的应用于有效路径的飞行和满足用户覆盖的服务。

针对因海量用户聚集而造成基站过载场景中的用户覆盖缺失问题，利用 UAV 建立额外的通信链路是一种有效提升通信质量并满足覆盖需求的手段。然而，除了功率控制、用户分配等传统资源管理问题外，UAV 及用户数量的增加进一步加剧了有限资源下的同频干扰，而这也是影响无线通信质量的关键因素。鉴于仅依靠 UAV 路径规划难以全面解决上述问题，在兼顾用户公平性的前提下，有必要对 UAV 路径规划与资源分配进行联合优化。在现有的研究中，通过综合考虑 UAV 飞行轨迹、资源调度以及干扰管理，建立以最小化 UAV 与地面用户成本加权和[38]、兼顾功率控制并最优化 UAV 飞行速度与高度[39]、在数据速率与总发射功率等约束条件下最大化总吞吐量[40]等为目标的非凸问题，并通过 SCA 近似求解的方法被广泛应用。然而，此类方法的主要局限在于对实时环境状态的动态响应能力较弱，导致其在高密度用户场景中的适应性受限。相比之下，基于 RL 的优化方法[41-42]则不受限于全局求解，能够动态适应环境变化，并提供更加灵活的路径规划与资源分配方案。

进一步地，基于用户聚集成簇的需求特性，对于具有一定速率需求差异且信道状态满足条件的用户簇，可利用 NOMA 进行分组，从而在同一时间内支持更多用户的接入。已有研究证明，NOMA 技术可以显著提升物联网（Internet of Things, IoT）设备的接入数量[43]。在与正交多址接入（Orthogonal Multiple Access, OMA）对比的研究中，无人机辅助非正交多址接入（UAV-NOMA）通过功率域复用提升频谱资源利用效率，不仅有效增强系统容量，还因用户间信号可控叠加而具备更低的小区间干扰，进而支持更多用户的同时接入与服务[44]。已有研究实现 UAV-NOMA 系统中 UAV 位置的静态部署优化[45]，这使得针对兼容 NOMA 系统的多 UAV 路径规划策略的进一步研究成为可能。在最近的研究中，针对基于 NOMA 的多 UAV 协同缓存网络，已有工作提出了一种联合缓存决策、三维轨

中国知网　https://www.cnki.net

迹规划和频谱资源分配的 MARL 优化方法[46]。该方法能够通过优化 UAV 的轨迹控制，实现对热点区域用户的动态跟踪覆盖，并在优化频谱资源利用的同时，最小化系统的内容获取延迟。亦有研究通过联合优化所有 UAV 的轨迹设计和功率分配，提出了一种基于 DDPG 的算法来最大化 UAV-NOMA 系统的下行吞吐量[47]。然而，以上方法均未考虑 UAV 的能量受限特性，而 UAV 的飞行能耗对整体网络性能具有重要影响。因此，在能量受限 UAV 的实际应用场景中，有必要进一步探索面向兼容 NOMA 系统且兼顾能量约束的路径规划和资源分配的联合优化策略。

此外，随着用户数量的增加，UAV 与用户之间的连接关系将变得更加复杂，使得基于全局状态的 MARL 算法难以直接应用。因此，需要进一步研究每个 UAV 仅基于部分观测信息的联合路径规划和资源分配算法，以实现更高效的决策。在此基础上，该问题的动作空间不仅包括 UAV 的移动状态，还涉及 UAV 与用户簇之间是否存在 NOMA 连接关系及其组内功率分配策略。如何在保持 MARL 算法性能的前提下，对高维动作空间进行合理的低维拆分近似，是亟待解决的关键问题。有效的动作空间降维策略能够减少计算复杂度，提高训练效率，并增强算法在大规模 UAV-NOMA 网络中的适应性。

1.3　研究内容与组织架构

1.3.1　研究内容简述

本研究旨在解决特定场景下的无线通信覆盖不足问题。针对覆盖空洞区域，利用多 UAV 中继技术建立无线通信链路，为无服务用户提供通信资源，尽可能地满足更多用户的通信需求。如何在 UAV 能量受限的条件下，设计高效、可靠的路径规划与资源管理策略，以达到用户覆盖率最大化，是本研究的核心目标。

本文的研究内容架构及研究点间的关系如图1.1所示。

面向应急通信场景中因基站损坏而产生的覆盖空洞，且区域内无服务用户的分布较为分散的情景，为了给用户提供无线通信覆盖、满足其通信需求，采用多个 UAV 作为中继，通过区域外的基站建立有效的通信链路。考虑到可部署的 UAV 能量受限，建立了 UAV 的能量损耗模型。在对 UAV 起止点也进行约束的前提下，通过对状态、动作及奖励值的合理设计，建立以 QMIX 网络为基础的 MARL 架构，基于全局合作 MARL 来优化 UAV 的飞行路径，最终实现用户覆盖率的最大化。特别地，将 UAV 转向时的额外能耗一同纳入考量，尽量保证 UAV 在长期动作决策中的一致性，减少因频繁转向产生的额外能量消耗，使 UAV 可以将更多的能量用于有效路径飞行和满足用户覆盖。

面向热点通信场景中因基站过载而导致大量用户通信需求难以满足的情形，

中国知网　https://www.cnki.net

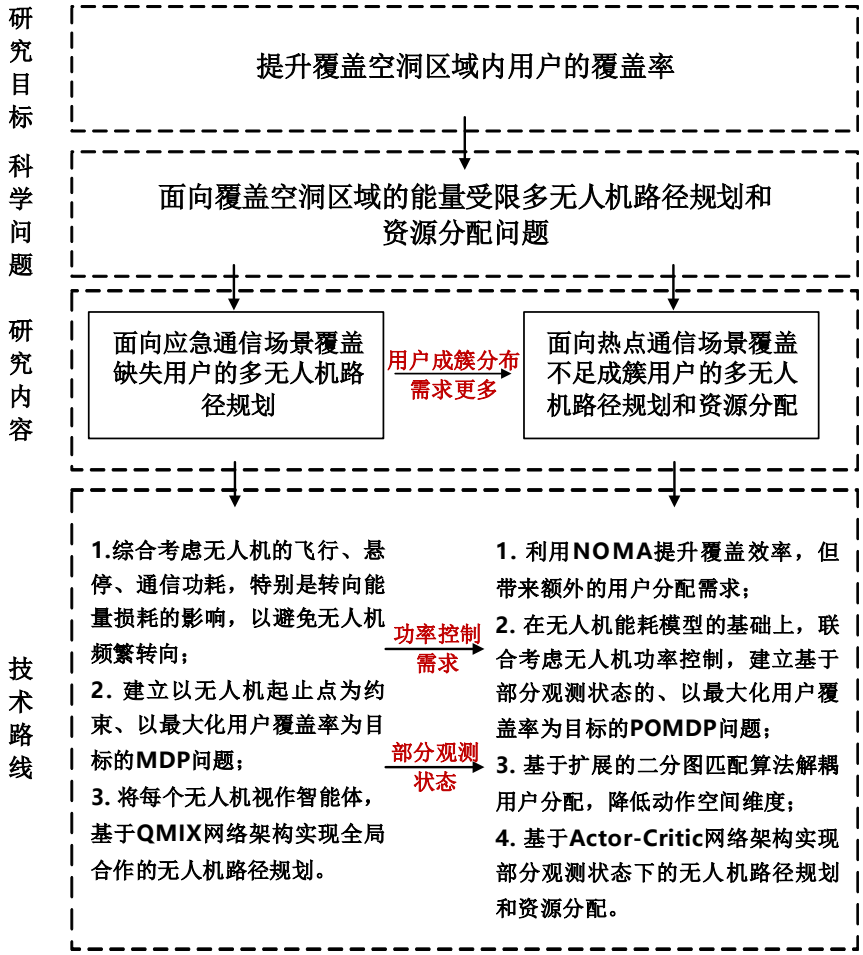

图 1.1　研究内容架构图

在 UAV 能量受限的前提下，引入 NOMA 技术以提升频谱资源利用效率，通过功率域复用实现同一时隙内对两名用户的并行接入与服务，从而在满足成簇分布用户差异化速率需求的同时，进一步提高整体用户覆盖效率。然而，引入 NOMA 也会带来额外的用户分配需求。此外，针对 UAV 间的同频干扰，本研究还通过对 UAV 的功率控制来实现干扰的有效抑制。由于用户数量显著增加，UAV 间难以共享全局信息，通过对部分观测状态、动作和奖励值的设计，以及 Actor-Critic 网络架构的建立，基于部分观测状态信息 MARL 来进行联合路径规划与资源分配策略设计，以在相同的 UAV 能量约束条件下实现更多用户的覆盖。值得注意的是，在该场景下，由于涉及的决策因素较多，待选择的动作数量急剧增长，从而导致动作空间维度过大，而高维动作空间不仅加剧了策略搜索的难度，也显著提升了计算复杂度，给优化算法的设计与实现带来了挑战。为此，本研究引入扩展的加权二分图匹配算法，以实现 UAV 与用户间服务关系的高效匹配，并将该分配过程从整体动作空间中剥离，从而有效降低决策维度，缓解高维动作空间带来的计算压力，提升算法的训练效率与在线决策性能。

中国知网　https://www.cnki.net

1.3.2　组织架构

本论文的组织架构如下：

第一章为绪论。首先阐明了覆盖空洞问题的背景，指出灾害应急和热点区域中覆盖缺失用户对通信保障的迫切需求。随后，分析了利用无人机灵活部署与快速响应的优势，并结合强化学习在复杂动态环境下的高效决策能力，论证了其在该问题中的应用潜力。接着，对国内外相关问题的研究现状进行了综述，归纳了已有工作的主要成果与不足之处，进一步明确了本研究的切入点与创新点。在此基础上，提出了本文的研究目标与研究思路，并概述了研究的整体框架以及各部分内容之间的逻辑关系。

第二章介绍强化学习的基本方法。首先阐述了强化学习的基本概念，着重分析了深度强化学习中价值学习、策略学习以及演员-评论家方法的基本架构，并给出了对应的数学模型。随后，进一步引入多智能体强化学习的定义，比较其与单智能体方法在模型建构上的主要区别，讨论了多智能体系统中策略制定所依赖的纳什均衡等博弈论基准，并概述了其典型的算法架构。

第三章为针对应急通信场景中能量受限多无人机的路径规划方法。在本章中，首先对应急通信场景的特点进行了描述；之后，基于无人机的信道模型与能耗模型，以及无人机位置、能量、与用户连接关系等约束，将目标为最大化用户覆盖率的无人机路径规划问题建模为非凸的优化问题；而后，基于受约束的马尔科夫决策过程，对无人机的状态空间、动作空间、瞬时奖励、约束代价等进行相应地设计，并利用基于联合多无人机价值网络的 QMIX 算法来优化无人机的路径；最后，给出了所提算法的仿真结果。

第四章为针对热点通信场景中能量受限多无人机的路径规划与资源分配方法。在本章中，首先描述了热点通信场景的场景特点，并基于第三章中的研究，针对热点场景内无人机同频干扰和用户成簇分布特性，以及无人机位置、能量等约束，特别是引入 NOMA 后的用户连接关系约束，将目标为最大化用户覆盖率的无人机路径规划与功率分配问题建模为相应的非凸问题；针对此问题，基于分布式部分观测的马尔科夫决策过程，对无人机的状态空间、观测空间、动作空间、瞬时奖励、约束代价、观测概率等进行相应地设计；针对动作空间维度过高的问题，引入扩展的加权二分图来进行用户分配决策，并仿真验证了加权二分图权重设计的合理性；而后，联合扩展的加权二分图，对网络架构进行了相应的改进，并基于此提出了基于 Actor-Critic 网络架构的联合路径规划与资源分配算法；仿真结果验证了所提算法的有效性，并于本章的最后给出。

第五章为总结与展望，对本文的工作进行了总结整理，并对所研究内容的未来发展进行了前瞻性预测。

中国知网　https://www.cnki.net

1.4　本章小结

本章首先介绍了覆盖空洞问题的研究背景，指出典型应用场景中覆盖缺失用户的通信需求，并阐明了将 UAV 与强化学习技术结合以应对该问题的现实意义与应用前景。接着，分析了在能量受限条件下进行多 UAV 路径规划与资源分配所面临的主要挑战。围绕上述问题，系统梳理了国内外相关研究进展，论述了采用 MARL 方法进行优化的合理性与优势。针对应急通信和热点通信两个典型场景，进一步指出了现有 MARL 方法在多 UAV 路径规划中存在的不足，明确了本文的研究目标与技术路线。随后，通过研究内容组织结构图对研究内容进行了整体概述，并对全文结构进行了简要说明。

中国知网　https://www.cnki.net

第 2 章　强化学习基础

2.1　基本概念

强化学习是机器学习的重要分支，主要研究环境中的智能体如何执行动作以获得最大化累计奖励的过程[48]。智能体的强化学习一般可以用马尔科夫决策过程（Markov Decision Process, MDP）来表示，通常由四元组 $\langle S, A, P, R\rangle$ 构成。强化学习的基本架构如图2.1所示，体现出智能体与环境的交互过程：智能体通过观测环境获得状态 s_t，并基于其策略执行动作 a_t，之后环境状态会更新为 s_{t+1}，同时环境会给智能体奖励 R_t。智能体执行动作的概率由策略函数 $A \sim \pi(\cdot|s)$ 决定，而环境状态转移概率 $S' \sim p(\cdot|s,a)$ 则决定了环境的下一个状态。将每个时刻的环境状态、智能体动作、相应奖励保存下来，就会得到智能体的轨迹 $\left\{\left(s_1, a_1, R_1\right), \left(s_2, a_2, R_2\right), \cdots, \left(s_T, a_T, R_T\right)\right\}$。

在任意时刻 t，有累积折扣奖励 U_t：

$$U_t = \tilde{R}_t + \gamma \tilde{R}_{t+1} + \gamma^2 \tilde{R}_{t+2} + \gamma^3 \tilde{R}_{t+3} + \cdots, \tag{2.1}$$

其中，$\tilde{R}_t$ 为时刻 t 的奖励，由于时刻 t 及之后的时刻都没有进行，因此 $\tilde{R}_t$ 为随机变量。γ 为折扣系数，有 $0 \leqslant \gamma \leqslant 1$，使当前的奖励权重最高。基于此，定义智能体策略 π 的动作值函数 Q_π 为当前时刻累积折扣奖励函数的期望值，有：

$$Q_\pi\left(s_t, a_t\right) = \boldsymbol{E}\left[U_t \middle| S_t = s_t, A_t = a_t\right], \tag{2.2}$$

其中，时刻 t 之后的动作与状态均在计算期望的过程中被积分，只有当前时刻的状态 s_t 与动作 a_t 被保留，即动作值函数 Q_π 的值依赖于当前的 s_t 与 a_t；此外，Q_π 的值还受策略 π 的影响，不同的策略下得到的期望也不尽相同。在此基础上，将最优动作值函数定义为：

$$Q^\star\left(s_t, a_t\right) = \max_\pi Q_\pi\left(s_t, a_t\right), \tag{2.3}$$

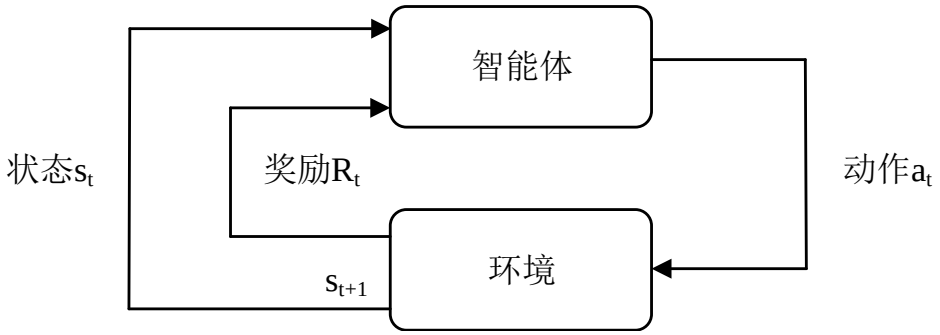

图 2.1　强化学习基本架构

中国知网　https://www.cnki.net

$Q^\star$ 表示了当前期望得分最高的策略。此外，若对动作值函数 $Q_\pi\left(s_t, a_t\right)$ 中的动作求期望，则可以得到状态值函数 V_π，有：

$$\begin{aligned} V_\pi\left(s_t\right) &= \boldsymbol{E}_A\left[Q_\pi\left(s_t, A\right)\right] \\ &= \sum_a \pi\left(a \middle| s_t\right) Q_\pi\left(s_t, a\right), \end{aligned} \tag{2.4}$$

其中，求和符号对应了离散动作的状态值函数，若动作为连续变量则需将其换为积分。$V_\pi\left(s_t\right)$ 用来评价在执行策略 π 时，当前状态 s_t 的得分。进一步地，再对随机状态 S 求期望 $\boldsymbol{E}_S\left[V_\pi(S)\right]$，则可以用来衡量策略 π 的好坏。

2.2　深度强化学习

2.2.1　基于价值的强化学习

基于价值的强化学习的目标为通过神经网络来学习最优动作值函数，从而获得最佳动作并实现最大化整体奖励回报。当可以得到式(2.3)中的最优动作值函数 $Q^\star(s, a)$ 时，即通过期望的角度得到的最高得分，如何通过 $Q^\star$ 获得最佳动作便成为了首要目标。具体而言，最佳动作 $a^\star$ 可以通过以下方式获得：

$$a^\star = \arg\max_a Q^\star(s, a), \tag{2.5}$$

这表示在给定状态 s 下，选择能够最大化最优动作值函数 $Q^\star$ 的动作 $a^\star$。然而，最优动作值函数 $Q^\star(s, a)$ 并不能够轻易地获得，需要通过深度 Q 神经网络（Deep Q-Network, DQN），即 $Q(s, a; \mathbf{w})$ 来近似得到。其中神经网络的参数为 $\mathbf{w}$，输入为状态 s，输出为对执行所有可能动作 a 的得分。DQN 基于执行动作得到的奖励来进行深度学习，使其对动作的打分愈来愈准，从而最终达到近似最优动作值函数的目标。

时序差分（Temporal-Difference, TD）学习是最常用的 DQN 训练算法[49-50]。在训练的开始，可以通过初始模型得到预测值 $q = Q(\mathbf{w})$，而实际执行过程中的得分则为 y，TD 学习算法的目标是训练预测值尽可能地接近实际得分，因此将 y 定义为 TD 目标（TD target），有损失函数：

$$L = \frac{1}{2}(q - y)^2, \tag{2.6}$$

对网络参数 $\mathbf{w}$ 求梯度可得到：

$$\frac{\partial L}{\partial \mathbf{w}} = (q - y)\frac{\partial Q(\mathbf{w})}{\partial \mathbf{w}}, \tag{2.7}$$

再通过梯度下降法可以计算得到更新后的网络参数 $\mathbf{w_{t+1}}$：

$$\mathbf{w_{t+1}} = \mathbf{w}_t - \alpha \cdot \frac{\partial L}{\partial \mathbf{w}}\bigg|_{\mathbf{w}=\mathbf{w}_t}, \tag{2.8}$$

中国知网　https://www.cnki.net

其中 α 为学习率。然而，上述方法必须执行完整个过程才能获得 TD 目标 y，导致其训练效率较低。针对此问题，可以通过一部分实际执行时的得分与剩余过程的预测得分之和作为 TD 目标，将预测值与 TD 目标之间的差值 $\delta = Q - y$ 定义为 TD 误差（TD error），TD 误差越小说明预测值越准确。基于此，在深度学习的过程中，相邻时刻预测值间的关系为：

$$Q\left(s_t, a_t; \mathbf{w}\right) \approx R_t + \gamma \cdot Q\left(s_{t+1}, a_{t+1}; \mathbf{w}\right), \tag{2.9}$$

其中，$Q\left(s_t, a_t; \mathbf{w}\right)$ 为 t 时刻的预测值，而 $Q\left(s_{t+1}, a_{t+1}; \mathbf{w}\right)$ 则为 $t+1$ 时刻的预测值，当前观测到的真实奖励为 R_t，γ 为折扣系数。结合式(2.5)，得到 t 时刻的 TD 目标 y_t 为：

$$\begin{aligned} y_t &= R_t + \gamma \cdot Q\left(s_{t+1}, a_{t+1}; \mathbf{w}_t\right) \\ &= R_t + \gamma \cdot \max_a Q\left(s_{t+1}, a; \mathbf{w}_t\right), \end{aligned} \tag{2.10}$$

即将使 Q 值最大的动作选为 $t+1$ 时刻的预测动作 a_{t+1}，结合式(2.6)可以得到 t 时刻的损失函数为：

$$L_t = \frac{1}{2}\left[Q\left(s_t, a_t; \mathbf{w}\right) - y_t\right]^2, \tag{2.11}$$

而后利用式(2.7)通过梯度下降来更新神经网络的参数 $\mathbf{w_{t+1}}$。

2.2.2　基于策略的强化学习

基于策略的强化学习的目标为通过神经网络学习当前策略，以获得智能体在任一状态时执行各种动作的概率分布，并使智能体以此概率分布为基准进行动作决策。由于策略 $\pi(a|s)$ 的概率分布无法直接获得，需要通过神经网络 $\pi(a|s;\boldsymbol{\theta})$ 来近似得到。其中神经网络的参数为 $\boldsymbol{\theta}$，输入为状态 s，输出为执行所有可能动作 a 的概率分布，且有 $\sum_{a\in\mathcal{A}} \pi(a|s;\boldsymbol{\theta}) = 1$。

基于式(2.4)中定义的状态值函数，将策略 π 用神经网络 $\pi(a|s;\boldsymbol{\theta})$ 来近似替换，可以得到近似状态值函数：

$$V(s;\boldsymbol{\theta}) = \sum_a \pi(a|s;\boldsymbol{\theta})\, Q_\pi(s,a), \tag{2.12}$$

用来描述当前状态的好坏。基于此，将目标函数定义为：

$$J(\boldsymbol{\theta}) = \boldsymbol{E}_S\left[V(s;\boldsymbol{\theta})\right], \tag{2.13}$$

通过最大化 $J(\boldsymbol{\theta})$ 来学习网络参数 $\boldsymbol{\theta}$，$\boldsymbol{\theta}$ 的更新则依赖于策略梯度：

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \beta \cdot \frac{\partial V(s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}, \tag{2.14}$$

中国知网　https://www.cnki.net

其中 β 为学习率，策略梯度则可推导为：

$$\begin{aligned}\frac{\partial V(s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} &= \sum\nolimits_a \frac{\partial \pi(a|s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \cdot Q_\pi(s,a) \\ &= \sum\nolimits_a \pi(a|s;\boldsymbol{\theta}) \cdot \frac{\partial \log \pi(a|s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \cdot Q_\pi(s,a),\end{aligned} \tag{2.15}$$

由于 $\pi(a|s;\boldsymbol{\theta})$ 为概率分布，因此策略梯度也可以用期望的形式表示：

$$\frac{\partial V(s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \boldsymbol{E}_{A\sim\pi(\cdot|s;\boldsymbol{\theta})}\left[\frac{\partial \log \pi(A|s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \cdot Q_\pi(s,A)\right], \tag{2.16}$$

基于式(2.15)的策略梯度可用于离散动作空间，通过将所有动作枚举的方法进行策略梯度的计算。对于连续的动作空间则需要用式(2.16)来计算。然而，由于 $\pi(A|s;\boldsymbol{\theta})$ 为神经网络实现，无法通过积分的形式直接计算出来，因此需要通过蒙特卡洛近似得到期望。首先，通过概率密度函数 $\pi(\cdot|s;\boldsymbol{\theta})$ 来随机抽样，得到确定的动作 $\hat{a}$，并基于 $\hat{a}$ 计算：

$$\mathbf{g}(\hat{a},\boldsymbol{\theta}) = \frac{\partial \log \pi(\hat{a}|s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \cdot Q_\pi(s,\hat{a}), \tag{2.17}$$

从式(2.17)中不难看出，有 $\boldsymbol{E}_A\left[\mathbf{g}(A,\boldsymbol{\theta})\right] = \frac{\partial V(s;\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$，这说明了 $\mathbf{g}(\hat{a},\boldsymbol{\theta})$ 可以作为策略梯度的无偏估计。通过一次或多次抽样得到的 $\mathbf{g}(\hat{a},\boldsymbol{\theta})$ 来近似策略梯度的方法即为蒙特卡洛近似。此方法使得在更新参数时，无需计算精确的策略梯度，也可进行网络训练，且在离散动作空间时亦可应用。

联合式(2.14)与式(2.17)，便可得到策略网络参数的更新：

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \beta \cdot \mathbf{g}\left(a_t,\boldsymbol{\theta}_t\right). \tag{2.18}$$

其中，β 为学习率。然而，在策略梯度的更新过程中，还需要得到动作值函数的估计值 $q_t \approx Q_\pi\left(s_t,a_t\right)$，而这可以通过将游戏全程轨迹记录下来，即所有时刻的状态、动作与奖励，并通过轨迹对应累积折扣奖励的观测值 $u_t = \sum_{\tau=t}^{T} \gamma^{\tau-t} \cdot r_\tau$ 来替代其期望，即 $q_t = u_t$。除此之外，还可用另一个神经网络来近似动作值函数 Q_π，而这种用两个网络分别近似策略和价值的方法也被称为演员-评论家（Actor-Critc, AC）方法。

2.2.3　演员-评论家方法

演员-评论家方法是将基于价值的强化学习与基于策略的强化学习结合起来的方法[51]。基于式(2.4)中的状态值函数定义，策略函数 $\pi(a|s)$ 用来计算动作的概率分布从而控制智能体的动作，而动作价值函数 $Q_\pi(s,a)$ 可以用来评价动作的好坏程度。然而，由于策略 π 未知，上述两个函数均无法直接计算。将两个神经网络分别用于近似策略函数与动作价值函数，演员-评论家方法可以做到同时学习两个网络，以最终实现状态值函数的近似。

中国知网　https://www.cnki.net

在演员-评论家方法中，采用演员网络 $\pi(a|s;\boldsymbol{\theta})$ 来近似策略函数 $\pi(a|s)$，其目的为控制智能体的动作；而通过 $q(s,a;\mathbf{w})$ 来近似动作价值函数 $Q_\pi(s,a)$ 的网络则被称为评论家网络，评论家网络不控制智能体的运动，只负责评价当前动作的好坏。同时训练两个网络的状态值函数可被近似为：

$$V_\pi(s;\boldsymbol{\theta},\mathbf{w}) = \sum_a \pi(a|s;\boldsymbol{\theta}) \cdot q(s,a;\mathbf{w}). \tag{2.19}$$

在演员网络的训练过程中，策略网络 $\pi(a|s;\boldsymbol{\theta})$ 进行学习时的监督由评论家网络的价值 q 来提供，目标为提高当前的状态价值函数 $V_\pi(s;\boldsymbol{\theta},\mathbf{w})$；而在训练评论家网络时，价值网络 $q(s,a;\mathbf{w})$ 的监督则由环境中的奖励来给出，目标为提高其评价的准确度，使之更为接近真实的累积奖励，从而更好地估计未来累积奖励之和。演员-评论家网络的基本结构如图2.2所示。

基于2.2.1节中的 TD 算法，评论家网络 $q(s,a;\mathbf{w})$ 的 TD 目标为：

$$y_t = R_t + \gamma \cdot q\left(s_t, a_t; \mathbf{w}_t\right), \tag{2.20}$$

相应的损失函数为：

$$L(\mathbf{w}) = \frac{1}{2}\left[q\left(s_t, a_t; \mathbf{w}\right) - y_t\right]^2, \tag{2.21}$$

基于式(2.14)，评论家网络参数的更新 $\mathbf{w}_{t+1}$ 可由梯度下降法得到。

基于2.2.2节中的策略梯度算法，演员网络的策略 $\pi(a|s;\boldsymbol{\theta})$ 所对应的无偏估计函数 $\mathbf{g}(a,\boldsymbol{\theta})$ 为：

$$\mathbf{g}(a,\boldsymbol{\theta}) = \frac{\partial \log \pi\left(a \middle| s_t; \boldsymbol{\theta}\right)}{\partial \boldsymbol{\theta}} \cdot q\left(s_t, a; \mathbf{w}\right), \tag{2.22}$$

采用基于概率分布 $a \sim \pi\left(\cdot \middle| s_t; \boldsymbol{\theta}_t\right)$ 一次抽样的 $\mathbf{g}(a,\boldsymbol{\theta})$ 作为策略梯度的蒙特卡罗近似，可基于式(2.18)来得到演员网络的参数更新 $\boldsymbol{\theta}_{t+1}$。

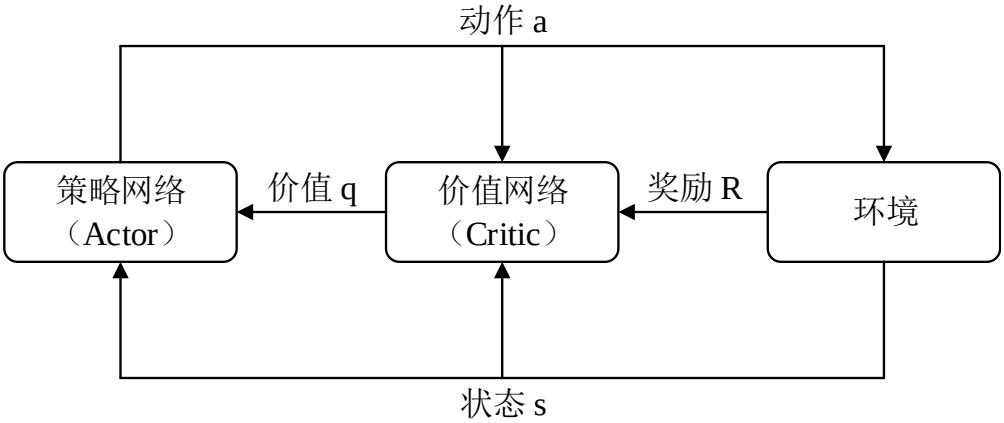

图 2.2　演员-评论家网络结构图

中国知网　https://www.cnki.net

2.3　多智能体强化学习

相比于前述面向单智能体的深度强化学习，多智能体系统则更为复杂。多智能体之间的关系一般可分为完全合作、完全竞争、竞争与合作混合关系以及利己主义[52]。在完全合作关系中，多个智能体相互协作，完成共同的目标或配合完成任务；完全竞争关系则相反，智能体之间相互博弈，智能体获得利益时会造成其他智能体的损失；竞争与合作混合关系则是以上两者的部分结合，如机器人足球赛，同队的智能体为合作关系，而与对手的队伍又是竞争关系；利己主义则是指多智能体中的每个智能体都只关心如何最大化自己的收益，而不关心其动作带来的环境状态改变造成其他智能体的损失，但与完全竞争关系不同的是，其他智能体的损失并不一定会给当前智能体带来收益。

与单智能体强化学习所采用基于 MDP 的四元组 $\langle \mathcal{S}, \mathcal{A}, \boldsymbol{P}, \mathcal{R} \rangle$ 不同，多智能体强化学习利用马尔科夫博弈（Markov Game, MG）的五元组 $\langle \boldsymbol{N}, \mathcal{S}, \mathcal{A}, \boldsymbol{P}, \mathcal{R} \rangle$ 来表示，其中 $\boldsymbol{N}$ 为系统中智能体的数目，状态 $\mathcal{S} = \mathcal{S}_1 \times \cdots \times \mathcal{S}_N$ 为当前所有智能体的状态集合，动作 $\mathcal{A} = A_1 \times \cdots \times A_N$ 为所有智能体的动作集合，所有智能体的奖励集合则为 $\mathcal{R} = R_1 \times \cdots \times R_N$，对状态转移概率 $\boldsymbol{P}$ 而言，也是由所有智能体执行动作后状态转移的联合概率。

基于 MG 的多智能体系统的状态转移概率为：

$$p\left(s' \,\middle|\, s, a^1, \cdots, a^n\right) = \mathbf{P}\left(S' = s' \,\middle|\, S = s, A^1 = a^1, \cdots, A^n = a^n\right), \tag{2.23}$$

其中，每个动作的上标为智能体的编号，所有智能体的动作决策决定了当前的状态转移，也影响着每个智能体自身的奖励。基于(2.1)的累计折扣奖励对每个智能体有：

$$U_t^i = \tilde{R}_t^i + \gamma \tilde{R}_{t+1}^i + \gamma^2 \tilde{R}_{t+2}^i + \gamma^3 \tilde{R}_{t+3}^i + \cdots, \tag{2.24}$$

其中随机变量 $\tilde{R}_t^i$ 取决于当前状态和所有智能体的动作。多智能体中的状态价值

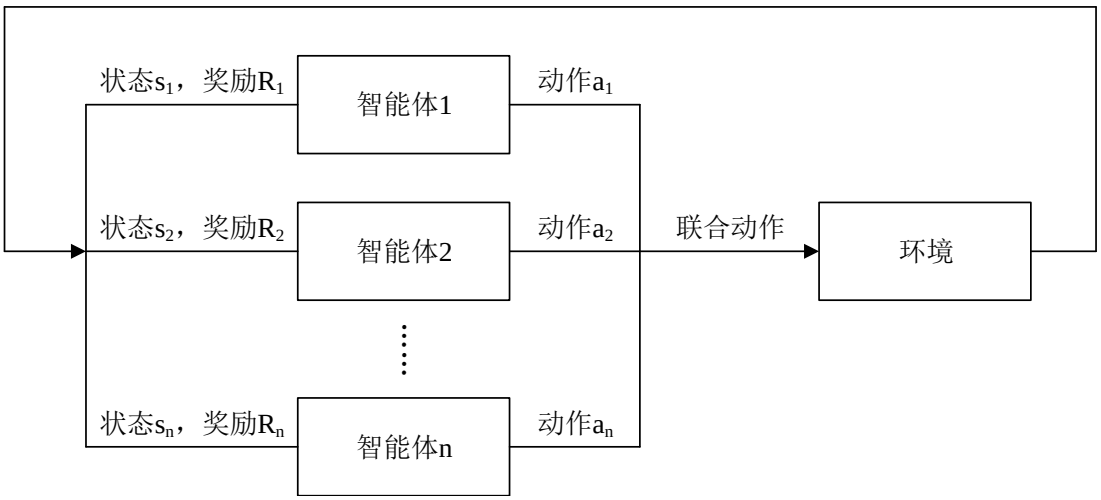

图 2.3　多智能体强化学习基本架构

中国知网　https://www.cnki.net

函数也取决于所有智能体网络，基于式(2.4)有：

$$V^i\left(s_t;\boldsymbol{\theta}^1,\cdots,\boldsymbol{\theta}^n\right)=\mathbf{E}\left[U_t^i\left|S_t=s_t\right.\right],\tag{2.25}$$

进一步地，在实际场景中，当智能体无法获得全局状态信息时，深度强化学习算法往往采用基于部分可观测的马尔科夫决策过程（Partially Observable Markov Decision Process, POMDP）来解决单智能体的决策问题[53]。POMDP 的五元组为 $\langle S,A,O,P,R\rangle$，与 MDP 相比多出来的维度 O 为部分观测空间。相应的，在多智能体强化学习中则利用分布式部分可观测马尔科夫决策过程（Decentralized Partially Observable Markov Decision Process, Dec-POMDP）来解决网络的决策问题。Dec-POMDP 由八元组 $\langle N,S,A,P,R,\gamma,O,Z\rangle$ 构成，其中 N 为智能体数量，γ 为折扣系数，Z 为基于联合部分可观测空间的概率分布。

在其他智能体都不改变策略的前提下，一个智能体单独改变策略，也不会得到更高的回报时，被称为纳什均衡。此时，每个智能体都在用最优方式来应对其他各方策略，且没有智能体会主动去改变自己的策略。多智能体能够达到纳什均衡状态时，算法便能收敛。然而，智能体数量越多，达成纳什均衡的目标就越困难，若直接套用单智能体强化学习算法，让每个智能体独立进行动作决策，很可能会出现不收敛的情况。

基于多智能体系统的强化学习基本架构如图2.3所示，根据其训练和执行时的不同架构可以分为以下三种[52]：去中心化、中心化和中心化训练与分布式执行（Centralized training with decentralized execution, CTDE）。去中心化架构下的智能体互不交互，仅用自身观测到的状态、动作和奖励来独立训练策略网络和价值网络，每个智能体的训练过程与单智能体相同，故很有可能不收敛。中心化架构则由中心控制器来收集所有智能体的观测状态与奖励，而后对智能体的动作做出决策，即使训练完毕，到执行阶段时，也需要由中心控制器进行决策；中心控制器可以分别训练出结构相似但参数不同多个智能体网络，其缺点在于需要等待中心控制器进行全局决策，智能体之间的信息交互和同步也需要额外的开销。CTDE 架构则是在训练时由中心控制器决定，而训练完毕后，每个智能体利用自己的策略网络、基于局部观测状态来做决策。在基于 AC 网络的 CTDE 架构中[54]，每个智能体都有自己独立的策略网络 $\pi\left(a^i\left|o^i;\boldsymbol{\theta}^i\right.\right)$，其中 o^i 为智能体 i 的部分观测状态；中心控制器则有 n 个价值网络 $q\left(\mathbf{o},\mathbf{a};\mathbf{w}^i\right)$，每个价值网络都由当前全部观测状态和全部动作决定。

2.4　本章小结

在本章中，系统整理了后续研究所需的强化学习相关数学工具，为后续研究提供理论支持。首先，详细介绍了强化学习的基本概念，以及累计折扣奖励、动

中国知网　https://www.cnki.net

作值函数和状态值函数的定义。随后，给出了深度强化学习的数学模型，并分析了基于价值的强化学习、基于策略的强化学习以及演员-评论家方法中网络参数的更新过程。此外，还概述了多智能体强化学习的核心概念、工作模式、基本数学模型和组织架构，为后续研究奠定了数学基础。

中国知网　https://www.cnki.net

第 3 章　应急通信场景中能量受限多 UAV 路径规划

3.1　引言

针对应急通信场景中覆盖空洞区域用户的通信需求，本文采用多架 UAV 协同工作，为受影响区域内的用户提供稳定的通信覆盖。综合考虑 UAV 的能量受限特性、路径规划的起始与终止约束以及用户服务满足率，本章将 UAV 路径规划问题建模为一个受约束的马尔可夫决策过程。在此基础上，提出一种基于多智能体强化学习的优化算法，以提升整体用户覆盖率并提高通信效率。此外，针对 UAV 在路径决策过程中频繁转向可能带来的能量浪费与执行复杂度问题，在奖励与代价函数中引入了转向控制因子，从而引导 UAV 在完成覆盖任务的同时实现更平滑、能效更优的路径规划。

3.2　场景简述

在应急通信场景中，受灾区域内的通信基础设施损坏，产生了覆盖空洞区域，需要经由 UAV 中继与区域外的未损坏基站进行通信。如图3.1所示，M 个用户分散在整个区域中，其位置固定不动，由 N 个 UAV 作为中继为其建立通信链路。UAV 工作在高度为 H 的水平面上，受其接入能力所限，以时分的方式服务当前用户，即每个时隙只能对可覆盖范围内的一个用户进行服务，而用户有基本服务速率 r_0 的要求。UAV 配置了神经网络模块，可被视作智能体，几个 UAV 同时进行工作。UAV 的电池容量有限，运动轨迹如图所示，在电量耗尽前必须返回充电站（图示为区域边缘位置）。UAV 与区域外基站间存在前返向链路，以实现中继之功能。

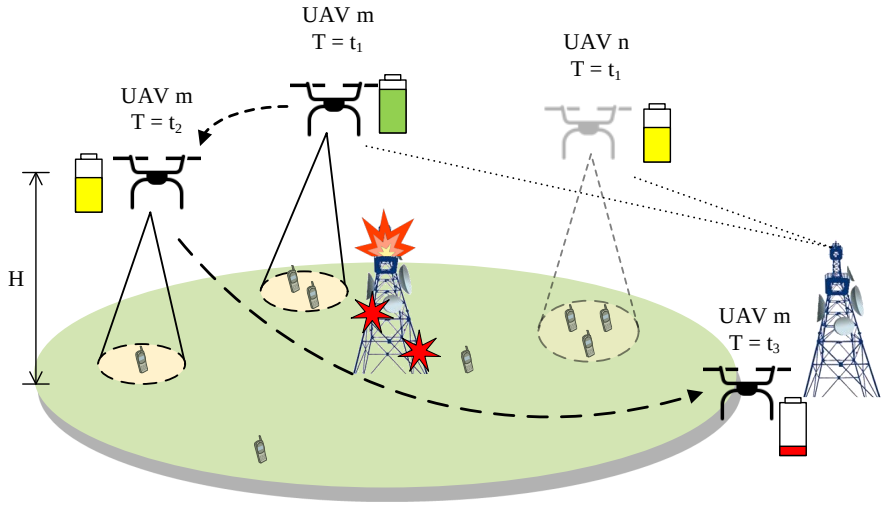

图 3.1　应急通信场景 UAV 工作示意图

中国知网　https://www.cnki.net

为了给应急通信场景中覆盖空洞区域内的用户建立无线通信覆盖，采用多个 UAV 作为中继，通过区域外的基站建立有效的通信链路。针对 UAV 的能量受限特性，以 UAV 的总能量为约束，联合其飞行、悬停、通信时的能量损耗，在 UAV 工作时的起止点加以限制的条件下，以满足更多用户覆盖需求为主要目标，利用全局信息，基于 MARL 算法设计并实现多 UAV 的路径规划与用户分配策略。特别地，将 UAV 转向时的额外能耗一同纳入考量，以保证 UAV 决策过程中的连续性和一致性，从而避免频繁转向带来过多的能量损耗。

3.3　系统模型

3.3.1　信道模型

受复杂环境和 UAV 移动性的影响，UAV 与用户之间不一定存在直射径（Line of Sight, LoS），基于现有的研究[55]，直射径的概率为：

$$\Pr(\mathrm{LoS}) = \frac{1}{1+\omega\exp\left(-\beta\left[\frac{180}{\pi}\arctan\left(\frac{H}{d}\right)-\omega\right]\right)}, \tag{3.1}$$

基于此，非直射径（Non Line of Sight, NLoS）的概率为：

$$\Pr(\mathrm{NLoS}) = 1-\Pr(\mathrm{LoS}), \tag{3.2}$$

其中，H 为 UAV 的飞行高度，d 为 UAV 与用户的水平距离，ω 与 β 为与环境有关的常数。基于自由空间损耗模型，LoS 径与 NLoS 路径的路径损失分别为：

$$PL_{\mathrm{LoS}} = 20\log_{10}\left(\frac{4\pi f_c\sqrt{d^2+H^2}}{c}\right)+\xi_{\mathrm{LoS}}, \tag{3.3}$$

$$PL_{\mathrm{NLoS}} = 20\log_{10}\left(\frac{4\pi f_c\sqrt{d^2+H^2}}{c}\right)+\xi_{\mathrm{NLoS}}, \tag{3.4}$$

其中，PL_{LoS} 和 PL_{NLoS} 为 LoS 径与 NLoS 径的平均路径损失，ξ_{LoS} 和 ξ_{NLoS} 则是由环境决定的额外损失参数，c 为光速，f_c 则表示载波的中心频率。基于此，可以得到从第 n 个 UAV 到第 m 个用户的传输速率为：

$$r_{n,m} = W\log_2\left(1+\frac{p_n G_{n,m}}{N_0 W}\right), \tag{3.5}$$

其中，W 为带宽，p_n 为 UAVn 的发射功率，N_0 为高斯白噪声的功率谱密度，而对路径损失参数 $G_{n,m}$，有：

$$G_{n,m} = 10^{-\overline{PL}_{n,m}/10}, \tag{3.6}$$

其中，$\overline{PL}_{n,m}$ 为平均路径损失，可以由式(3.1)-(3.4)计算得到，有：

$$\overline{PL}_{n,m} = 10\log_{10}\left(10^{PL_{\mathrm{LoS}}/10}\Pr(\mathrm{LoS})+10^{PL_{\mathrm{NLoS}}/10}\Pr(\mathrm{NLoS})\right). \tag{3.7}$$

中国知网　https://www.cnki.net

3.3.2　能量损耗模型

在 t 时刻，四旋翼 UAV 以速度 v_t 进行匀速直线运动，其飞行能量损耗 P_t^f 可表示为[29]：

$$P_t^f = |F|\, v_t = c_1 v_t^3 + \frac{c_2 \kappa^2}{v_t}, \tag{3.8}$$

其中，F 为 UAV 的推力，$c_1 v_t^3$ 为 UAV 飞行时的推进功率，$c_2\kappa^2/v_t$ 则为 UAV 抵抗重力所需要的功率，κ 为负载系数，$\kappa \geqslant 1$ 以保证 UAV 足够的升力以避免坠机，系数 c_1 和 c_2 为根据飞行器的质量、旋翼面积、空气密度等参数决定的常数。

当 UAV 速度改变或进行转向时，其加速度也会带来额外的功率损耗，而加速度源自于 UAV 的受力。对一个飞行中的 UAV 而言，主要受到重力 W_U、升力 L、由发动机产生的推力 F、与运动方向相反的阻力 D 的影响[56]。当 UAV 倾角为 ϕ 时，对 UAV 进行受力分析可以得到：

$$\begin{cases} L\sin\phi = m_U a_\perp \\ L\cos\phi = W_U \\ F - D = m_U a_\parallel \end{cases} \tag{3.9}$$

其中加速度 a 被分解为两部分，即改变推进功率的切向加速度 $a_\parallel$，和为转向提供额外功率的向心加速度 $a_\perp$；重力 $W_U = m_U g$，m_U 为 UAV 的质量，g 为重力加速度；阻力 $D = c_1 v_t^2 + c_2\kappa^2/{v_t}^2$，而 $\kappa = L/W_U$ 为升力与重力的比值。联立以上受力分析公式可以得到：

$$\tan\phi = \frac{a_\perp}{g}, \tag{3.10}$$

而向心加速度受到 UAV 最大倾角 $\phi_{\max}$ 的限制，有 $a_\perp^{\max} = g\tan\phi_{\max}$，而这将限制 UAV 旋转时的半径和角速度。通过式(3.9)与(3.10)可以计算出负载系数 $\kappa = \sqrt{1 + a_\perp^2/g^2}$，进而得到 UAV 在进行变速运动时所需的推力：

$$F = c_1 v_t^2 + \frac{c_2}{v_t^2}\left(1 + \frac{a_\perp^2}{g^2}\right) + m_U a_\parallel. \tag{3.11}$$

据此，包含 UAV 加速度的飞行功率 P_t^f 为：

$$P_t^f\left(v_t, a_\perp, a_\parallel\right) = \left| c_1 v_t^3 + \frac{c_2}{v_t}\left(1 + \frac{a_\perp^2}{g^2}\right) + m a_\parallel v_t \right|. \tag{3.12}$$

无人机的悬停功率 P_{hov} 可以表示为[57]：

$$P_{hov} = \sqrt{\frac{\left(m_U g\right)^3}{2\pi r_p^2 n_p \rho}}, \tag{3.13}$$

中国知网　https://www.cnki.net

其中 r_p 为 UAV 旋翼半径，n_p 为旋翼数量，ρ 为空气密度。

此外，无人机的无线通信功率 P_{comm} 也不可忽视，对 UAV n 而言，$P_{comm} = p_n$。考虑以上所有影响因素，任意 UAV 到 T_0 时刻的总能量消耗为：

$$e_{T_0} = \left(\sum_{t=1}^{T_0} P_t^f \left(v_t, a_\perp, a_\parallel \right) + P_{hov} t_2 + P_{comm} t_3 \right) \Delta, \tag{3.14}$$

其中，Δ 为时隙间隔，P_t^f 由每个时刻 UAV 的速度和加速度决定，t_2 表示到 T_0 时刻时悬停总时隙数，而 t_3 则表示通信总时隙数。

3.4　问题建模

在现有的研究中，针对 UAV 能量受限的特性，通常是采用减少服务时长、提高传输速率来达到节能的目标。例如，在有限任务量的物联网网络中，以最小化完成所有任务的总时间为目标，以此来间接达到降低能量消耗的目标[58]；或是以用户最低需求速率为门限，最大化超过此门限的用户数、同时最小化能量消耗，来实现用户 QoS 的满足[31]；抑或是将用户视作需求无限的节点，即不论速率多高都照单全收，通过最大化所有无人机的和速率来证明其算法能传输更多的总数据量，或维持更久的服务时间[28]。然而，若以有限任务量中减少服务时长为主要目标，则会让 UAV 的能量消耗趋于保守，且当 UAV 能量不足以支持完成所有任务时，优化问题可能会趋于无解；若只从提高传输效率的角度来进行路径规划，则忽略了用户的公平性，容易陷在局部最优之中，只服务速率最好的部分用户，使得其他用户得不到基本需求的满足。除此之外，还有研究提出利用可存储较多能量的 UAV，通过射频链路为直接服务用户的能量受限 UAV 进行充电，并通过 Q 学习优化“空中加电”UAV 的轨迹，以最大化能量传输并延长“服务用户”UAV 的工作时间[59]。然而，由于射频链路的充电能量效率极低，其实际应用价值受限，因此本文不将此方案纳入问题考量范围。

综上所述，在用户有基本数据需求的前提下，为了使 UAV 在能量耗尽之前尽可能满足更多用户的需要，将优化目标聚焦于提高用户的覆盖率。假设 UAV 完成一次飞行过程，即从起点出发最后返回终点充电站的总工作时间为 T。在到达时间 T 时，若满足用户基本速率 r_0 的服务时隙数大于或等于用户服务时长需求门限 λ，则认为在本次 UAV 的服务过程中，该用户的服务需求被满足，也就是在 T 时间内该用户被成功覆盖，故对用户 m，定义成功覆盖标识 b_m 为：

$$b_m = I \left(\sum_{t=1}^{T} \sum_{n=1}^{N} I \left(r_{n,m,t} \geqslant r_0 \right) x_{n,m,t} \geqslant \lambda \right), \tag{3.15}$$

其中，$I(\cdot) \in \{0, 1\}$ 为示性函数，$x_{n,m,t}$ 表示 UAVn 在当前时刻 t 和用户 m 之间

中国知网　https://www.cnki.net

是否存在无线链路，$r_{n,m,t}$ 为 UAVn 在时刻 t 对用户 m 的可达传输速率，可以基于 UAV 与用户的相对位置关系，通过式(3.5)计算得到，有：

$$r_{n,m,t} = W\log_2\left(1+\frac{p_{n,t}G_{n,m,t}}{N_0W}\right), \tag{3.16}$$

其中 $p_{n,t}$ 为 UAV n 在时刻 t 的发射功率，$G_{n,m,t}$ 可由式(3.6)获得。

基于此，得到目标为最大化用户覆盖率的多无人机路径规划优化问题 P1：

$$\begin{aligned}
\text{P1:}\quad & \max_{\boldsymbol{\Theta}} \frac{1}{M}\sum_{m=1}^{M} b_m, \\
\text{s.t.}\quad & \text{C1: } e_{n,T} \leqslant E_{\max}, \forall n \in \mathcal{N}, \\
& \text{C2: } \mathbf{p}_{n,0} = \mathbf{p}_{n,T} = \mathbf{p}_0, \forall n \in \mathcal{N}, \\
& \text{C3: } \textstyle\sum_{n=1}^{N} x_{n,m,t} \leqslant 1, \forall m \in \mathcal{M}, \forall t \in \mathcal{T}, \\
& \text{C4: } \textstyle\sum_{m=1}^{M} x_{n,m,t} \leqslant 1, \forall n \in \mathcal{N}, \forall t \in \mathcal{T}, \\
& \text{C5: } V_{\min} \leqslant \frac{(\mathbf{p}_{n,t}-\mathbf{p}_{n,t-1})}{\Delta} \leqslant V_{\max}, \forall n \in \mathcal{N}, \forall t \in \mathcal{T}, \\
& \text{C6: } \left\|\mathbf{p}_{n,t}-\mathbf{p}_{n',t}\right\|_2 \geqslant d_0, \forall n' \neq n \text{ and } n, n' \in \mathcal{N},
\end{aligned} \tag{3.17}$$

其中，$\mathcal{N}$ 为 UAV 集合，$\mathcal{M}$ 为用户集合，$\mathcal{T}$ 为工作时间集合，$\boldsymbol{\Theta}$ 为优化变量的集合，有 $\boldsymbol{\Theta} = \left\{\left[\mathbf{p}_{n,t}\right], \left[\mathbf{x}_{n,t}\right] \middle| n \in \mathcal{N}, t \in \mathcal{T}\right\}$。在这之中，$\mathbf{p}_{n,t}$ 为 UAV n 在时隙 t 的位置，$\mathbf{p}_0$ 表示初始和结束位置，$\mathbf{x}_{n,t} = \left[x_{n,1,t}, \cdots, x_{n,M,t}\right]^T$ 为 UAV n 与所有 M 个用户之间的连接关系向量，$V_{\min}$ 与 $V_{\max}$ 为 UAV 可达速度的下界与上界，d_0 则为 UAV 间避免碰撞的距离限制。

对于式(3.17)中的优化问题 P1，对任一 UAV 而言，约束条件 C1 为总能量约束，其中 $e_{n,T}$ 可以通过式(3.14)得到，而 $E_{\max}$ 为 UAV 的总能量；C2 则保证了 UAV 能在结束时间时返回充电站，并假设充电站位置与初始位置 $\mathbf{p}_0$ 相同；C3 与 C4 为 UAV 和用户之间的连接约束，在单位时间内，一个用户最多可以被一个 UAV 服务，且一个 UAV 只能服务一个用户；C5 对无人机的速度进行了约束；而 C6 则是限制两个 UAV 之间的最小间距 d_0，以限制 UAV 选取相似路线或 UAV 之间发生碰撞。

不难看出，式(3.17)中的多无人机路径规划优化问题 P1 为非凸问题，主要是因为每个 UAV 的状态空间都很大，而上述优化问题又必须依赖于全局信息，导致传统的凸优化方法很难求解。采用基于强化学习的方法可以更有效地处理类似问题：将每个 UAV 视作独立的强化学习智能体，从环境中获得当前状态后，通过最大化累计奖励来进行动作决策，即优化 UAV 的路径并反馈给环境，以此来提高系统性能。

中国知网　https://www.cnki.net

3.5　基于 MARL 的能量受限多 UAV 路径规划

将式(3.17)中的约束条件 C1-C6 纳入考量，本节提出了基于 MARL 的能量受限多 UAV 路径规划方法。基于马尔科夫决策过程，可以设计得到相应的五元组，即 N 个智能体由状态集合为 $\mathcal{S}$ 开始，在每个时隙执行动作 $\mathcal{A}$，得到相应的奖励 $\mathcal{R}$，并基于状态转移矩阵 P 来改变环境状态。在此基础上，针对 UAV 的能量受限特性，通过瞬时约束代价 $\mathcal{C}$ 来约束其动作决策，以避免 UAV 在电量耗尽时坠机。

受约束的 MDP 架构可以用六元组 $\langle N, \mathcal{S}, \mathcal{A}, P, \mathcal{R}, \mathcal{C}\rangle$ 来表示，在这之中：

- N 为 UAV 的数量。
- $\mathcal{S}$ 为所有 UAV 的状态空间。UAV n 在时隙 t 的状态空间为：$S_{n,t} = \{\mathbf{p}_{n,t}, E_{n,t}^{res}, \mathbf{k}_{n,t}\}$, 其中，$\mathbf{p}_{n,t}$ 为 UAV 当前所处位置；$E_{n,t}^{res}$ 为 UAV 的剩余能量, 有 $E_{n,t}^{res} = E_{\max} - e_{n,T}$；$\mathbf{k}_{n,t}$ 则用来标识在当前 UAV 动作空间的可选行进方向上其他 UAV 的数量，以避免不同的 UAV 之间距离过近。
- $\mathcal{A}$ 为离散的动作空间。UAV n 在时隙 t 的可选动作空间为：$a_{n,t} = \{v_{n,t}, \theta_{n,t}, \mathbf{x}_{n,t}\}$，其中，$v_{n,t} \in \{v_1, \cdots, v_L\}$ 为 UAV 的可选速度；$\theta_{n,t} \in \{\theta_1, \cdots, \theta_K\}$ 为均匀分布的离散行进方向，即 UAV 的可选角度；$\mathbf{x}_{n,t}$ 则为在当前时刻 t，UAV n 与全部用户之间的连接状态向量。
- P 为状态转移矩阵，很难直接得到其显式解，因此通过基于 MARL 的方法来解决上述受约束的 MDP 问题。
- $\mathcal{R}$ 为瞬时奖励，有 $R_{n,t}\left(S_{n,t}, a_{n,t}\right)$。考虑到可选角度 $a \in A$ 为有限的离散集合，UAV 不能在任意两点之间都以最短距离的直线飞行，而是要以可选角度集进行逼近。然而，UAV 的频繁转向既会影响其速度，又会带来额外的

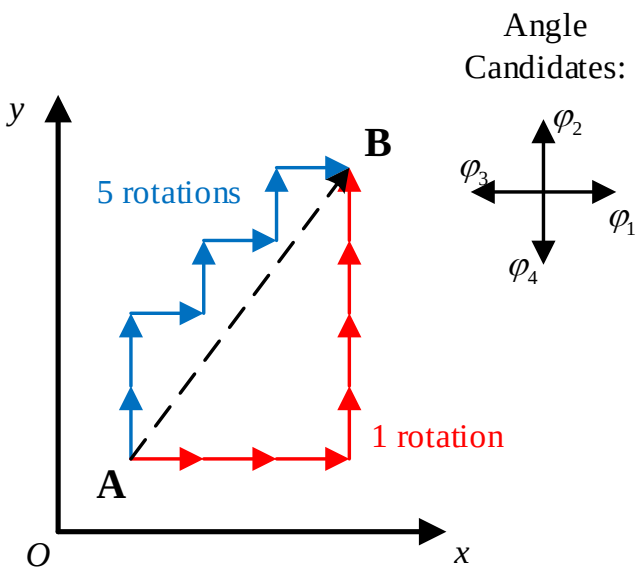

图 3.2　不同转向策略下的路径示意图

中国知网　https://www.cnki.net

能量消耗。因此，受电子鼠大赛的启发[60]，特别是 2017 年冠军的比赛策略：通过减少转向次数来更好地保持电子鼠的行进速度，从而使其能在更短时间内实现目标，即使所选路径的总行程更长[61]。类比到 UAV 路径规划问题中，通过减少转向次数，UAV 能更好地实现速度保持，避免频繁加减速，还能减少每次转向带来的额外能量消耗。不同转向策略下的路径示意图如图3.2所示，其中虚线表示从点A到点B的直线路径，而 UAV 的行进方向只能从角度可选集 $\{\varphi_1, \varphi_2, \varphi_3, \varphi_4\}$ 中进行选择。可以看到，若每次决策时都选择最优方向，将会变换 5 次行进方向（如左上方蓝色路径所示），这需要 UAV 消耗 5 倍能量用于转向。若能在长期目标中限制 UAV 频繁转向，即 UAV 仅进行 1 次转向亦可到达目标位置（如右下方红色路径所示），而这仅需消耗 1 倍的能量用来转向。不难看出，两种路线匀速直线运动所走过的路程是相同的，即匀速运动的能量损耗也是完全相同的，因此，到达相同目标点时的总能耗差异与转向次数息息相关。综上所述，将奖励函数设计为：

$$\begin{aligned} R_{n,t}\left(S_{n,t}, a_{n,t}\right) &= \mu_1\left(-\left|\theta_{n,t}-\theta_{n,t-1}\right| / \Delta\theta_0\right) \\ &- \mu_2 k_{n,k,t} + \mu_3 \sum_{m=1}^{M}\left[I\left(r_{n,m,t} \geqslant r_0\right) - b_{m,t}\right] x_{n,m,t}, \end{aligned} \tag{3.18}$$

其中，$\Delta\theta_0$ 是均匀分布离散可选角度集中相邻元素的角度之差；$k_{n,k,t}$ 则是在当前动作中可决策角度 $\theta_{n,t} = \theta_k$ 方向上可感知范围 βd_0 内的其他 UAV 数量，有：

$$k_{n,k,t} = \sum_{n'} I\left(\left\|\mathbf{p}_{n',t} - \mathbf{p}_{n,t}\right\| \leqslant \beta d_0\right), \forall n' \neq n \text{ and } n, n' \in N_s, \tag{3.19}$$

其中，N_s 为可感知范围内其他 UAV 的集合，且系数 $\beta > 1$，以此来降低 UAV 之间距离过近的可能性；$b_{m,t}$ 则为截止到当前时隙 t，用户 m 是否已成功覆盖的标识，基于式(3.15)可得到

$$b_{m,t} = I\left(\sum_{\tau=1}^{t}\sum_{n=1}^{N} I\left(r_{n,m,\tau} \geqslant r_0\right) x_{n,m,\tau} \geqslant \lambda\right), \tag{3.20}$$

此标识可以在用户通过 UAV 中继与区域外基站建立连接后，由控制中心记录的服务器历史反馈给 UAV 得到。由于只作为是或否的标识，故仅用 1 比特便可表征，从而不会为 UAV 中继系统造成大量额外负担；μ_1，μ_2 和 μ_3 则分别为转向控制、碰撞惩罚和完成奖励的权重系数。

- C 为瞬时约束代价，有 $C_{n,t}\left(S_{n,t}, a_{n,t}\right)$，主要由式(3.17)中的总能量约束条件 C1 决定，包括 UAV 的飞行、悬停和通信能量损耗，特别是在 UAV 转弯时，

中国知网　https://www.cnki.net

又要额外考虑转向带来的额外能量损耗。当 UAV 匀速转弯时，其切向加速度 $a_{\parallel}=0$，对向心加速度，有：

$$a_{\perp}=\frac{v_{n,t}^{2}}{r}, \tag{3.21}$$

其中，r 为转弯半径，有 $r=v_{n,t}\Delta t_{turn}/\Delta\theta$，$\Delta t_{turn}$ 为转向所需时间，$\Delta\theta$ 为转向角度。当角度备选集为均匀分布时，由式(3.10)可知，向心加速度受到 UAV 最大倾角 $\phi_{\max}$ 所限，有 $a_{\perp}\leqslant g\tan\phi_{\max}$。因此，UAV 的转弯半径限制为：

$$r\geqslant\frac{v_{n,t}^{2}}{g\tan\phi_{\max}}, \tag{3.22}$$

进而对 UAV 的角速度 $\omega_{n,t}$ 有：

$$\omega_{n,t}=\frac{\Delta\theta}{\Delta_{turn}}\leqslant\frac{g\tan\phi_{\max}}{v_{n,t}}, \tag{3.23}$$

而这也限制了 UAV 一个时隙内的最大转向角度。基于式(3.12), 与匀速直线运动相比，匀速转弯的额外功率为：

$$P_{n,t}^{\text{turn}}=\frac{c_2}{v_{n,t}}\times\frac{a_{\perp}^{2}}{g^{2}}, \tag{3.24}$$

经由匀速圆周运动转向后的位置坐标变化为：

$$\Delta\mathbf{p}_{n,t}=\begin{bmatrix}\Delta p_{n,t}^{x}\\ \Delta p_{n,t}^{y}\end{bmatrix}=\begin{bmatrix}r_{n,t}\sin\theta_{n,t-1}+r_{n,t}\cos\theta_{n,t}\\ -r_{n,t}\cos\theta_{n,t-1}+r_{n,t}\sin\theta_{n,t}\end{bmatrix}, \tag{3.25}$$

此外，若 UAV 速度也产生变化，还会消耗额外的变速功率：

$$P_{n,t}^{\text{acc}}=\frac{mv_{n,t}\left|v_{n,t}-v_{n,t-1}\right|}{\Delta_{turn}}, \tag{3.26}$$

其对匀变速直线运动也适用。由于每个时隙内时间较短，将转向和变速的功率独立计算，则 UAV n 在时隙 t 的飞行能量损耗可近似为：

$$e_{n,t}^{f}\approx P_{n,t}^{f}\left(v_{n,t}\right)\Delta+\left(P_{n,t}^{\text{turn}}I_1+P_{n,t}^{\text{acc}}I_2\right)\Delta_{\text{turn}}, \tag{3.27}$$

其中，$P_{n,t}^{f}\left(v_{n,t}\right)$ 可以通过式(3.8)得到，而 $I_1=I\left(\theta_{n,t}\neq\theta_{n,t-1}\right)$ 和 $I_2=I\left(v_{n,t}\neq v_{n,t-1}\right)$ 分别为当前 UAV 是否转向或变速的标识。因此，基于式(3.14)可以得到 UAVn 截止到当前时刻 t 的总功耗为：

$$e_{n,t}=\sum_{\tau=1}^{t}e_{n,\tau}^{f}+\left(P_{hov}t_2+P_{comm}t_3\right)\Delta, \tag{3.28}$$

中国知网　https://www.cnki.net

基于此，将瞬时约束代价设计为：

$$C_{n,t}\left(S_{n,t},a_{n,t}\right)=\begin{cases}-\left|R_{n,t}\left(S_{n,t},a_{n,t}\right)\right|, & \text{C7},\\ 0, & \text{otherwise},\end{cases} \tag{3.29}$$

其中的条件 C7 则为：

$$\text{C7}:\ E_{n,t}^{res}\leqslant\rho\hat{E}_{n,t}^{res}\ \text{and}\ \left|\theta_{n,t}-\hat{\theta}\right|>\theta_{th}, \tag{3.30}$$

其中，剩余能量为 $E_{n,t}^{res}=E_{\max}-e_{n,t}$，而 $\hat{E}_{n,t}^{res}$ 为 UAV 在当前时刻通过最短路径、以最节能的速度返回充电站所需的最小能量，并通过能量控制系数 ρ 来限制 UAV 强制返回充电站的剩余能量，有 $\rho>1$；$\hat{\theta}$ 则表示返回充电站最优路径所对应的角度，而 θ_{th} 则是当前动作决策角度 $\theta_{n,t}$ 与 $\hat{\theta}$ 之差的角度选择门限。上述瞬时代价约束的设计可以确保 UAV 安全返回充电站，从而有效降低其坠毁风险。

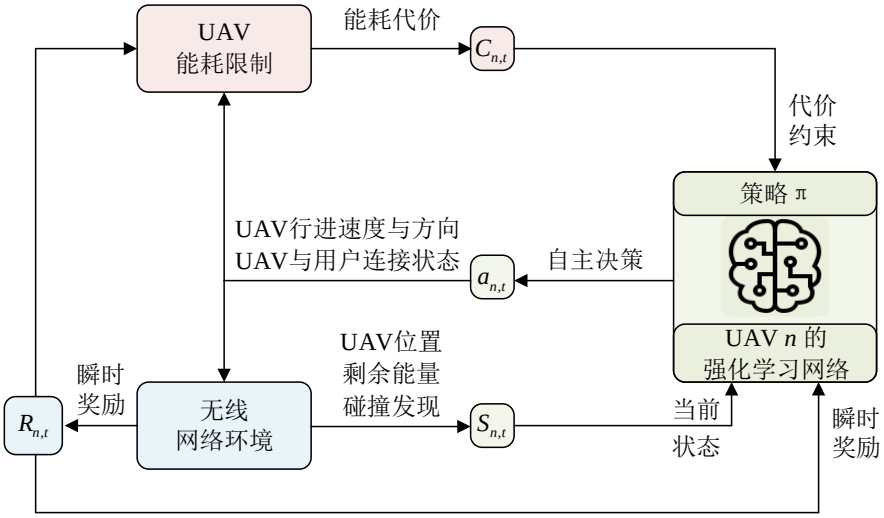

图 3.3　受约束的 MDP 架构图

基于前述状态与动作空间、奖励与代价函数的设计，得到受约束的 MDP 架构，如图3.3所示。部署在 UAV 上强化学习网络从无线环境中获取状态 $S_{n,t}$，通过瞬时奖励 $R_{n,t}$ 与约束代价 $C_{n,t}$ 来评价所决策的动作 $a_{n,t}$。上述 MDP 问题的最优策略为：

$$\pi^{*}(s)=\arg\max_{\pi}E_{\pi}\left[\sum_{n=1}^{N}\sum_{t=1}^{T}\eta^{t}\left(R_{n,t}+C_{n,t}\right)\right], \tag{3.31}$$

中国知网　https://www.cnki.net

其中 η 为折扣系数。对单智能体 Q 值的更新，可以由贝尔曼最优方程得到，有：

$$\begin{aligned} Q_n^{new}\left(S_{n,t}, a_{n,t}\right) = &(1-\alpha) Q_n\left(S_{n,t}, a_{n,t}\right) \\ &+\alpha\left\{R_n\left(S_{n,t}, a_{n,t}\right)+C_n\left(S_{n,t}, a_{n,t}\right)\right. \\ &\left.+\eta \max_{a_{n,t}^{'}} Q_n\left(S_{n,t}^{'}, a_{n,t}^{'}\right)\right\}, \end{aligned} \tag{3.32}$$

其中 α 为学习率，$\max\limits_{a'_{n,t}} Q_n\left(S_{n,t}^{'}, a_{n,t}^{'}\right)$ 是在下一个状态变为 $S_{n,t}^{'}$ 时所有可选动作中的最大 Q 值。

在 Q 学习过程中，为了避免陷入局部最优点，在训练智能体时采用 Epsilon-贪婪算法来平衡探索与优化，即基于概率 ε 选择随机策略，基于概率 $1-\varepsilon$ 选择最优 Q 值的策略，即:

$$a_{n,t} = \begin{cases} \arg\max\limits_{a_{k,t}} Q_n\left(S_{n,t}^{'}, a_{k,t}\right), & \text{with probability } 1-\varepsilon \\ a_{k,t} \in A, \text{for } k = \text{randint}\left(1, |A|\right), & \text{with probability } \varepsilon \end{cases}, \tag{3.33}$$

其中概率 ε 随着训练次数的增加而衰减，其指数衰减形式为 $\varepsilon = \varepsilon \exp(-\eta)$。

对多 UAV 场景而言，需要在单智能体各自独立获得 Q 值的基础上，通过额外的网络来整合信息以实现全局最优。基于 QMIX 算法[62]，以最大化全局最优值 Q_{tot} 为目标，有：

$$\arg\max_{\mathbf{a}} Q_{tot}(\mathbf{S}, \mathbf{a}) = \begin{pmatrix} \arg\max\limits_{a_1} Q_1\left(S_1, a_1\right) \\ \vdots \\ \arg\max\limits_{a_N} Q_N\left(S_N, a_N\right) \end{pmatrix}, \tag{3.34}$$

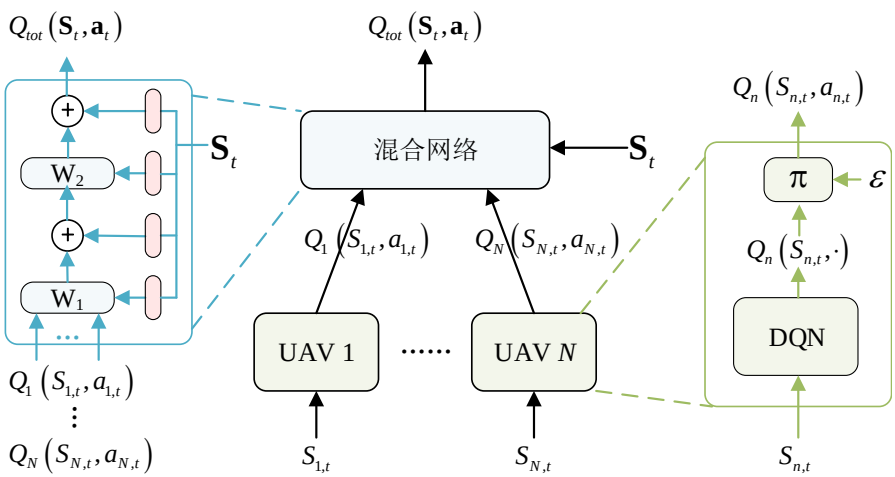

图 3.4　基于 QMIX 的混合网络架构图

中国知网　https://www.cnki.net

其中，Q_{tot} 满足对任意 Q_n 有 $\frac{\partial Q_{tot}}{\partial Q_n} \geqslant 0$。基于 QMIX 的混合网络架构图如图3.4所示，每个 UAV 上部署一个 DQN 网络，通过式(3.33)中的 Epsilon-贪婪算法来选取动作，并计算当前的动作值函数 $Q_n\left(S_{n,t}, a_{n,t}\right)$；而混合网络中的每个超网络（图中红色模块所示）位于由两个具有 ReLU 非线性的全连接层组成，后接绝对值激活函数，以确保混合网络中的权重为非负，混合网络通过收集所有 UAV 的 Q_n，结合当前全局状态 $\mathbf{S}_t$，计算得到全局动作值函数 Q_{tot}。基于式(2.10)，可以得到全局 TD 目标为：

$$y^{tot} = R + \gamma \max_{\mathbf{a}} Q_{tot}\left(\mathbf{S}, \mathbf{a}; \theta^{-}\right), \tag{3.35}$$

其中，R 为瞬时奖励，γ 为折扣系数，θ^{-} 为目标网络的超参数，基于此得到的全程损失函数为：

$$L(\theta) = \sum_{i=1}^{b} \left[\left(y_i^{tot} - Q_{tot}\left(\mathbf{S}, \mathbf{a}; \theta\right)\right)^2\right], \tag{3.36}$$

其中 b 为从回放缓冲区重采样之批量的大小，基于式(2.8)，使用梯度下降来进行网络超参数的更新。

QMIX 算法简要流程为：①在回放缓冲区 D 内存储 T 个时刻的状态、动作与奖励元组，其中随机动作由式(3.33)中的 Epsilon-贪婪算法确定，在 t 时刻有 $D = D \cup \left\{\left(s_t, a_t, R_t, s_{t+1}\right)\right\}$；②当回放缓冲区 D 收集到足够多的数据时，随机选取长度为 b 的缓存进行重采样，并通过缓存对应的所有 $Q_n\left(S_{n,t}, a_{n,t}\right)$ 与全局状态 $\mathbf{S}_t$ 来计算瞬时全局动作值函数 Q_{tot}；③通过当前超参数 θ^{-} 来计算 TD 目标 y^{tot}；④基于式(3.36)的损失函数，使用梯度下降法对网络超参数进行更新，有 $\theta = \theta - \alpha\Delta\theta$；⑤由更新后的 θ 替换掉当前超参数 θ^{-}，往复循环直至收敛。算法的具体流程如算法3.1所示。

3.6　仿真结果与分析

60 个用户均匀分布在 2000m × 2000m 的范围中，由 3 个 UAV 进行服务。UAV 工作于 300m 高的平面上，下行发送信号中心频率 20GHz，带宽为 40MHz，用户最小需求速率为 100Mbps，最小服务时间为 60 秒。噪声的功率谱密度为-174dBm/Hz，UAV 的发射功率为 20dBm。UAV 的飞行功率与转向功率由式(3.12)得到，其中 $c_1 = 9.26 \times 10^{-4}$，$c_2 = 2250$；基于式(3.13)，可以得到质量为 500g 的四旋翼 UAV 的悬停功率约为 10W，因此 UAV 匀速飞行、转向、悬停和通信功耗如图3.5所示。可以看到，UAV 主要能量消耗用于其匀速飞行，且转向所需能量也不容忽视。假设每个 UAV 携带的总能量为 100 千焦。对神经网络的训练参数而言，为了得到更好的长期奖励，折扣系数 γ 为 0.9，初始学习率 α 设置为 0.008，并根据情况在训练中进行调整。

中国知网　https://www.cnki.net

算法 3.1　QMIX 算法训练过程

初始化：QMIX 网络参数 θ，设定学习率 α，批量大小 B 和回放缓冲区 $\mathcal{D}=\{\}$；
while $step < step_{max}$ **do**
　while $t <$ 周期门限 **do**
　　for $n \in \mathcal{N}$ **do**
　　以概率 ε 选择随机动作，或以概率 $1-\varepsilon$ 选择最优动作：
　　$a_{n,t} = \max_{a'_{n,t}} Q_n\left(S_{n,t}, a'_{n,t}\right)$；
　　end
　　得到奖励 $R_{n,t}$，约束代价 $C_{n,t}$ 和下一状态 $S_{n,t+1}$；
　　将以上经验存入回放缓冲区：$\mathcal{D}_n = \mathcal{D}_n \cup \{S_{n,t}, a_{n,t}, R_{n,t}, C_{n,t}, S_{n,t+1}\}$；
　　$t = t+1$；
　　$step = step+1$；
　end
　if $|\mathcal{D}| > B$ **then**
　　从 $\mathcal{D}$ 中随机抽样 b 长度的回放周期；
　　while t 为 b 中的一个周期 **do**
　　利用 $Q_1\left(\mathbf{S}_1, \mathbf{a}_1\right)$，…，$Q_N\left(\mathbf{S}_N, \mathbf{a}_N\right)$ 和超网络 Hypernet$(\mathbf{S}_t, \theta^-)$，对目标 $Q_{tot}(\mathbf{S}_t, \mathbf{a}_t)$ 进行计算；
　　$t = t+1$；
　　end
　　$\Delta Q_{tot} = y^{tot} - Q_{tot}$；
　　$\Delta\theta = \nabla_\theta\left(\Delta Q_{tot}\right)^2$；
　　$\theta = \theta - \alpha\Delta\theta$；
　end
end

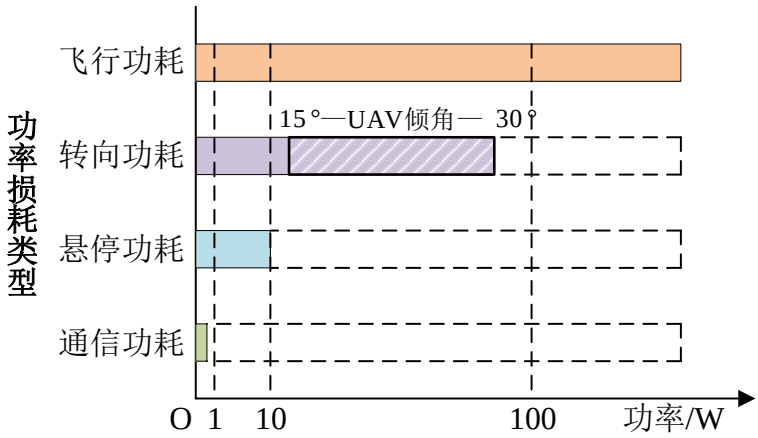

图 3.5　UAV 执行不同动作时的功率示意图

将动作空间中的速度设置为 0m/s、10m/s 两档，角度设置为均匀分布的 16 个离散角度。在不考虑转向功耗时，不同速率需求、不同时长需求、不同用户数下的用户覆盖率如图3.6-3.8所示。其中，对比算法参考了基于最大和速率的优化算法[28-29]，以及基于 MTSP 的路径规划算法[32-33]。由于前述算法都没有对 UAV 的起止点进行限制，故在其基本算法的基础上做了修正，以用户接入时间需求与

中国知网　https://www.cnki.net

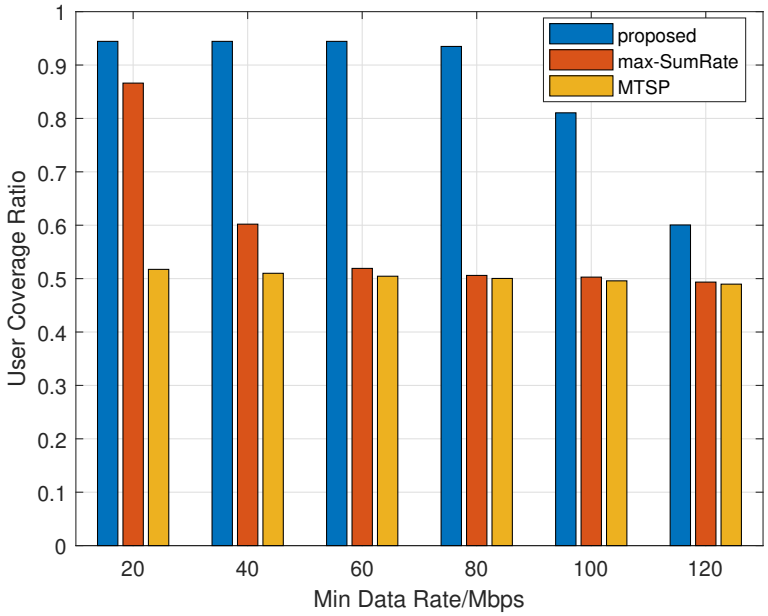

图 3.6　不同速率需求下的用户覆盖率

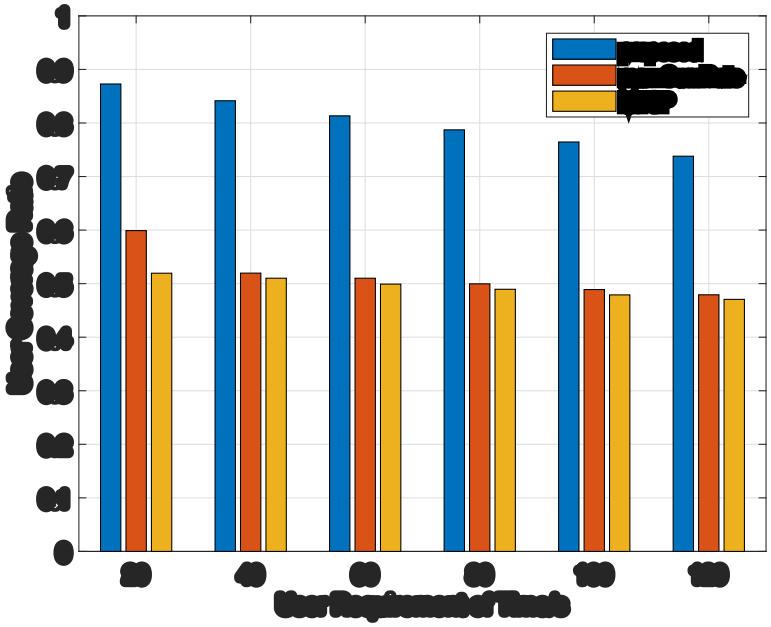

图 3.7　不同时长需求下的用户覆盖率

用户最小速率需求计算出的最小服务数据量需求，作为对比算法的统一标准。此举避免了以最大和速率为目标时，UAV 会在最优（或局部最优）位置悬停不动，最终只服务其覆盖范围内极少数用户的情况。

仿真结果显示，相较于最大化和速率算法和基于 MTSP 的路径规划算法，所提算法在各种情况下都可以达到更高的用户覆盖率。然而，随着用户需求的增加，不论是速率需求、服务时间需求还是用户总数增加时，所有方法可实现的覆盖率都会降低。因此，图3.9给出了不同方法下 UAV 服务时间比率，即 UAV 平

中国知网　https://www.cnki.net

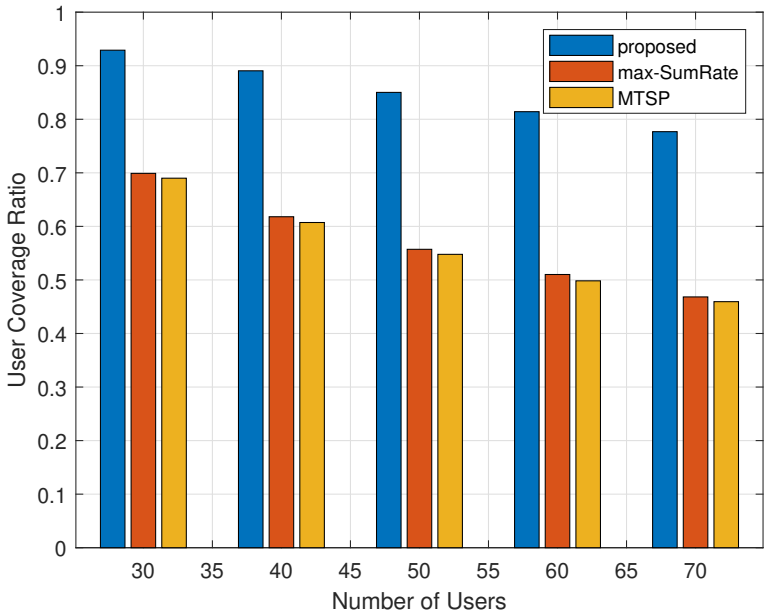

图 3.8　不同用户数下的用户覆盖率

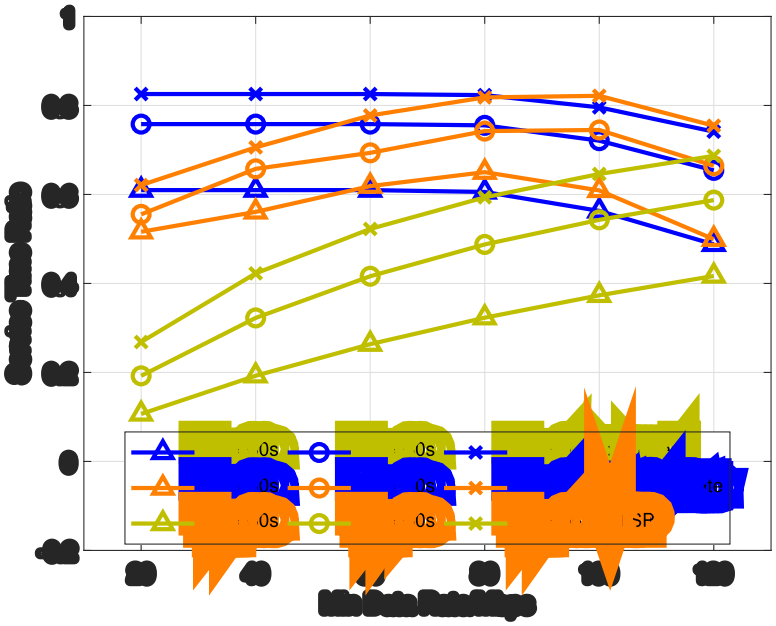

图 3.9　不同速率需求、服务时长需求下的服务时间比率

均服务时长与回到充电站时总工作时长的比值，其中 T_{min} 表示用户所需最少服务时间。服务时间比率越大，系统的通信效率也就越高。

从图3.9可以看出，随着用户速率需求逐渐接近系统的最大可达速率，不同方法所对应的服务时间比率也趋于一致。这是由于在该速率需求水平下，系统已几乎无优化空间，各种方法在路径设计上的差异被显著削弱，从而导致生成的服务路径趋于相似。随着用户速率需求的增加，对比算法的服务时间比率会随之增加，这是因为与需求相对应的用户覆盖率随之降低，从而使 UAV 工作总时

中国知网　https://www.cnki.net

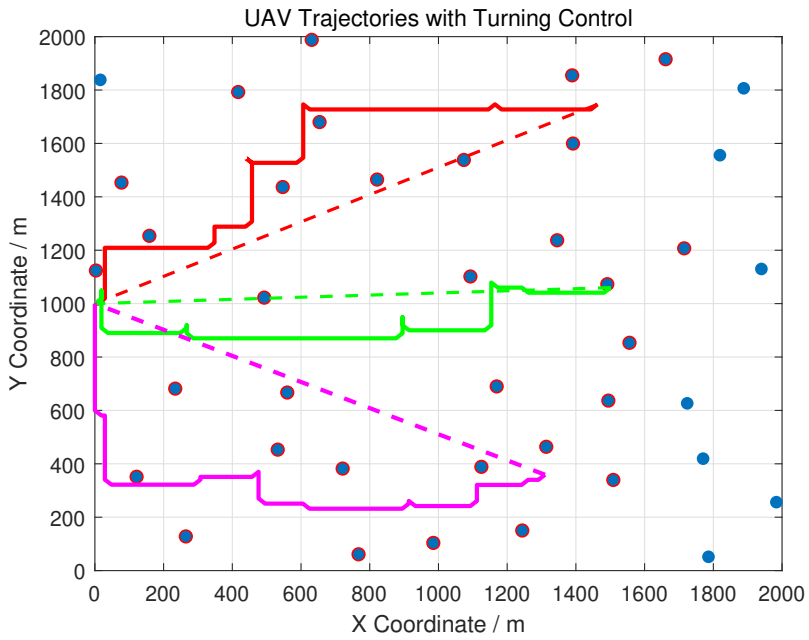

(a) 采用转向控制策略的 UAV 路径图

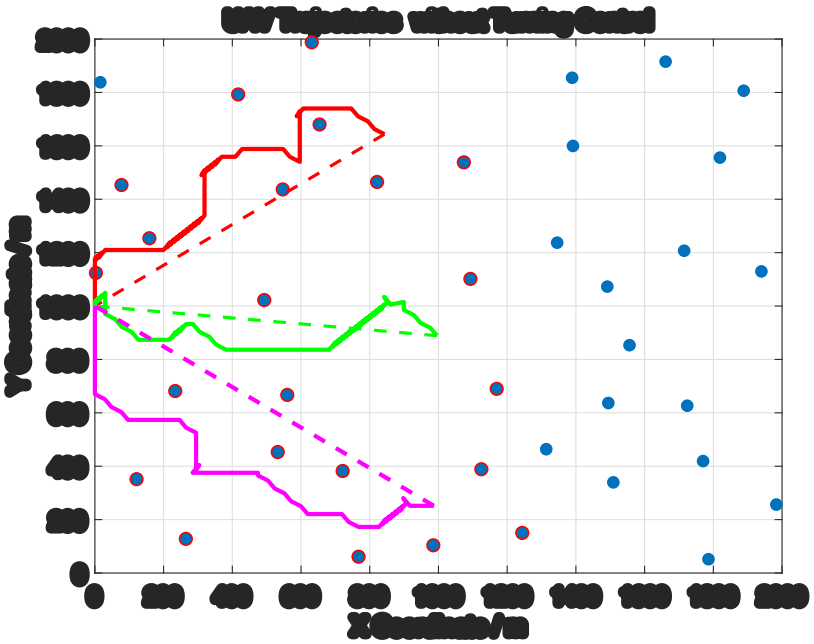

(b) 不进行转向控制的 UAV 路径图

图 3.10　无人机路径单次仿真示意图（4 角度）

长显著减少导致的，在图3.6中相同假设条件下亦有体现。同样地，当用户所需的服务时间更多时，所有方法的服务时间比率都会更高，但会导致系统整体的覆盖率降低，图3.7中的仿真结果可以证明这一点。除此之外，图3.7也能从侧面证明，尽管所提算法在某些情况下的服务时间比率略低于对比算法，但其能够在覆盖率上遥遥领先。

针对基于最大化和速率对比算法的服务时间比率，出现了随着用户速率需求增加而先升后降的现象，其趋势可以从以下两方面进行分析：一方面，服务时

中国知网　https://www.cnki.net

间比率在初期随着用户速率需求的增加而上升，主要归因于前述整体用户覆盖率下降，从而提升了服务时间比率。另一方面，当用户速率需求进一步增高时，服务时间比率开始下降，这是由于高速率用户对链路质量要求更高，UAV 需要飞行更多的距离才能满足用户需求，从而导致更多的能量消耗，加剧了能耗压力，缩短了任务持续时间，最终使服务时间比率出现下降。

综上所述，更高的用户速率需求会降低服务时间比率。更高的用户服务时间需求从表面上看能增加服务时间比率，并使系统有了更高的通信效率，但实际上会大大降低用户覆盖率。而所提算法可以在保证用户覆盖率的同时，还能保持较好的通信效率。

然而，将用户转向功耗纳入考量时，相同路径规划算法下不同的转向策略，也会让系统性能产生显著差异。无人机路径仿真示意图如图3.10与图3.11所示。其中，蓝色圆点为随机分布的 40 个用户，且速率需求均为 100Mbps，所需时间为 60 秒，其外侧的红圈代表被成功服务的用户；不同颜色的三条实线路径分别为三个 UAV 的单次路径仿真，而虚线则表示 UAV 结束服务返回起点时刻的直线距离。

图3.10-(a) 为 4 角度可选集时的路径仿真图，在相同的用户分布等仿真条件下，图3.10-(a) 为采用转向控制策略的路径图，图3.10-(b) 为不进行转向控制时的路径图。可以很明显的看出，采用转向控制策略可以很明显地增加 UAV 在工作周期内的移动距离，在覆盖更多用户的同时，也避免产生了如图3.10-(b) 中因频繁转向决策所导致的大量锯齿状路径。

图3.11为 16 角度可选集时的路径仿真图，由于角度可选集的增加，相邻角度间隔变小，相应的转向损耗也随之降低。因此，相比于图3.10中的 4 角度可选集，在相同假设下的用户覆盖率变得更高，如图3.11-(a) 所示的采用转向控制策略的单次仿真中，覆盖率能够达到 100%，而不进行转向控制的策略则无法满足全覆盖的需求。

在不同转向控制策略下的用户覆盖率与用户需求速率的关系如图3.12所示，其中“ideal”为理想状态下，即不考虑额外的转向功耗时的覆盖率，与图3.6所提算法相同；“free-turning”为不采用转向控制策略，UAV 可以在每次动作决策时进行转向；“ctrl-turning”则是将所提算法加入转向控制后的结果。仿真结果表明，在不进行转向控制时的真实覆盖率，只能达到理想情况下的 80%，而加入转向控制策略后可以达到 95%。这是因为加入转向控制可以使 UAV 在到达相同目标位置时，通过更少的转向来节约更多的能量，从而使 UAV 可以飞行更远的距离，服务更多的用户，而这都是通过在瞬时奖励函数中的加入转向控制因子实现的。除此之外，过多的转向能耗也会影响到约束代价函数的判断，而 UAV 何时停止服务，并于电量耗尽前回到充电站以避免坠机也是由约束代价函数控制的。

中国知网　https://www.cnki.net

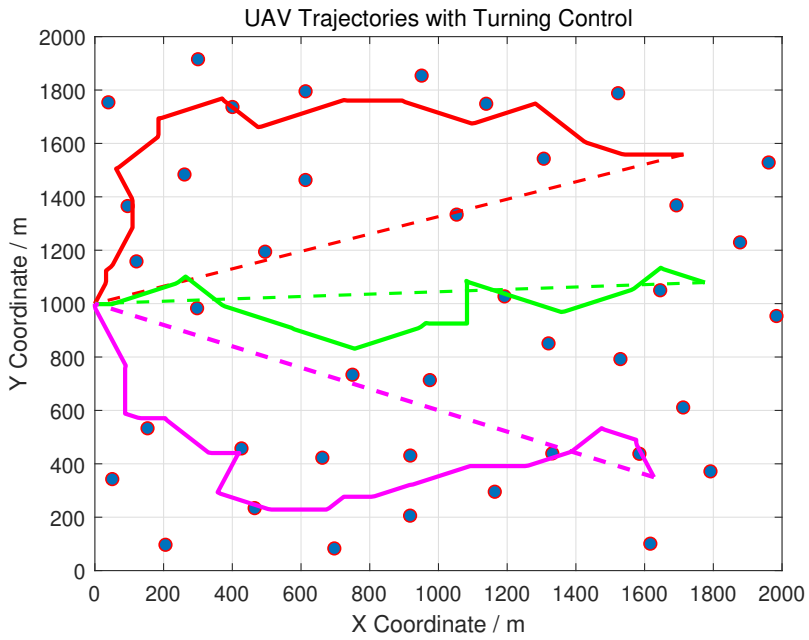

(a) 采用转向控制策略的 UAV 路径图

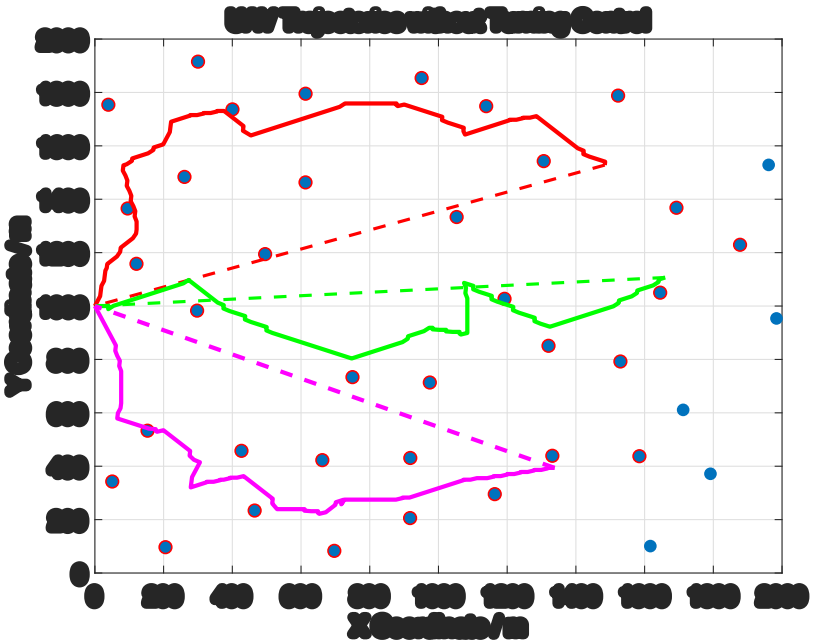

(b) 不进行转向控制的 UAV 路径图

图 3.11　无人机路径单次仿真示意图（16 角度）

仿真证明了瞬时奖励的得分惩罚与约束代价的返回控制策略设计的有效性。

图3.13给出了在用户数为 60，用户速率需求为 100Mbps 的条件下，不同转向控制策略下的用户覆盖率与角度可选集的关系，其中 x 轴表示均匀的 4、8、16 和 32 方向角度可选集。从仿真结果中可以看出，随着角度可选集的增多，用户覆盖率也在增加，这是由于更多角度可选集下的相邻角度转向功耗更小。当角度可选集变多时，加入转向控制的算法与理想情况下用户覆盖率的差距变小。此外，由于角度可选集较多时，不进行转向控制的算法会更频繁地在相邻角度之间

中国知网　https://www.cnki.net

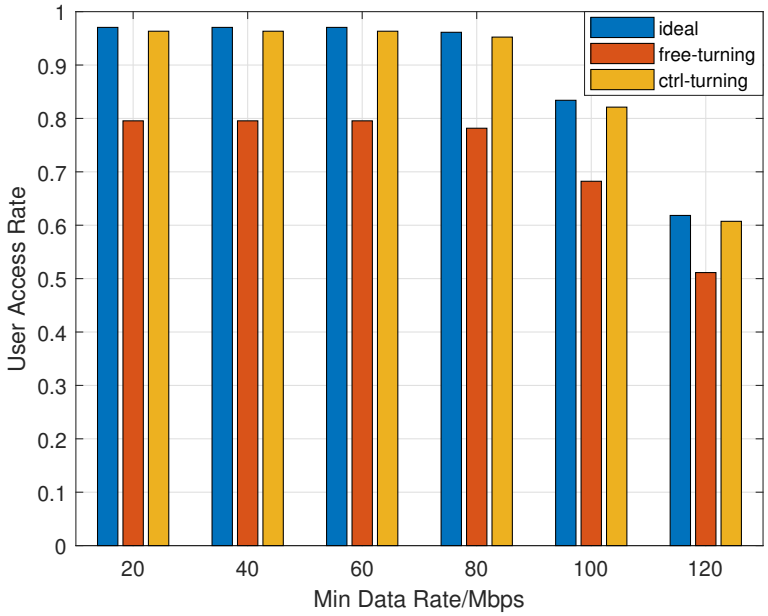

图 3.12　不同转向控制策略下的用户覆盖率与用户需求速率的关系

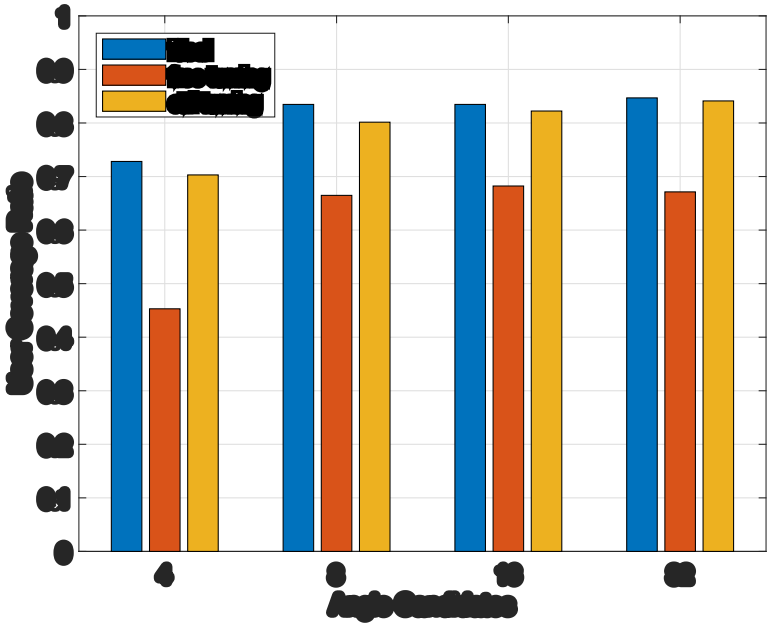
[redacted]
[redacted]
[redacted]

3.7　本章小结

在本章的研究中，针对应急通信场景中的多无人机路径规划问题，旨在最大化覆盖空洞区域内的用户覆盖率。将路径规划问题建模为一个受约束的 MDP 问题，并提出了一种基于多智能体强化学习的算法进行求解。特别地，通过在瞬时奖励和约束代价函数中引入转向控制因子，减少了无人机在决策过程中的频繁转向问题，而这一问题在现有研究中常被忽视。仿真结果表明，所提出的方法能够显著提高用户覆盖率并提升通信效率。同时，转向控制策略的引入有效降低了无人机的能量消耗，使其能够飞行更远的距离并覆盖更多用户。

中国知网　https://www.cnki.net

第 4 章　热点场景中能量受限多 UAV 路径规划与资源分配

4.1　引言

在第 3 章中，我们通过 UAV 路径规划，实现了对紧急通信场景中覆盖空洞区域用户通信需求的有效满足。然而，在通信负载已接近饱和的热点区域，成簇分布的无服务用户将带来更高的通信需求。此时，若同频工作的 UAV 之间产生严重干扰，仅依靠路径规划已难以有效支撑系统性能。因此，本章提出一种联合路径规划与资源分配的优化方案，以满足热点通信场景下的用户服务需求。

针对用户成簇分布的特点，引入非正交多址接入技术，使 UAV 能够同时服务两个用户，从而加快用户需求的满足速度。特别地，考虑到用户分配动作空间维度随用户数量增加而显著扩展，导致训练困难的问题，本文构建扩展加权二分图以表征 UAV 与用户之间的潜在连接关系，并基于改进的最大权重匹配算法实现高效的用户匹配。该方法进一步嵌入至演员-评论家网络架构中，有效降低动作空间的维度，提升训练效率与决策质量。

4.2　场景简述

在热点通信场景中，当前区域基站通信负荷已满载，新加入的用户无法被服务，如图4.1所示。无服务的用户会试图向区域外的基站申请接入，但由于树木、建筑物等遮挡，收到的信号较弱甚至依然无信号。通过 UAV 中继，既可以建立不受遮挡的 LoS 链路，又能够增强信号功率。M 个用户分布在整个区域中，由 N 个 UAV 作为中继为其建立通信链路，UAV 也依然有电池容量的限制。于图4.1中可以观察到，由于用户数的显著增加，势必需要更多的 UAV 来保证覆盖，同频复用的相邻 UAV 间不可避免地产生了干扰，而这极大地影响了通信效率。另外，由于热点区域内用户通常具有成簇分布的特点，簇内用户需求相似，而不同簇间的用户需求各异，即属于不同簇的用户，其基本速率需求、服务时长需求都不同，若都采用统一分配的资源则必然会产生浪费。

为了给热点场景中无服务用户提供无线覆盖，采用多个 UAV 作为中继，利用热点区域外基站的资源建立更多的通信链路。基于用户成簇分布、簇间用户需求各异的特点，利用 NOMA 技术可以使同一时频资源内接入多个用户。由于 UAV 与用户数量较多，全局信息共享代价过大，因此希望每个 UAV 尽可能通过其观测到的部分信息来进行决策。基于此，针对 UAV 的能量受限特性，以满足更多用户覆盖需求为主要目标，同时考虑 UAV 与用户数量较多时的干扰问题，设计基于部分观测信息的 MARL 算法以实现多 UAV 的路径规划和资源分配。此

中国知网　https://www.cnki.net

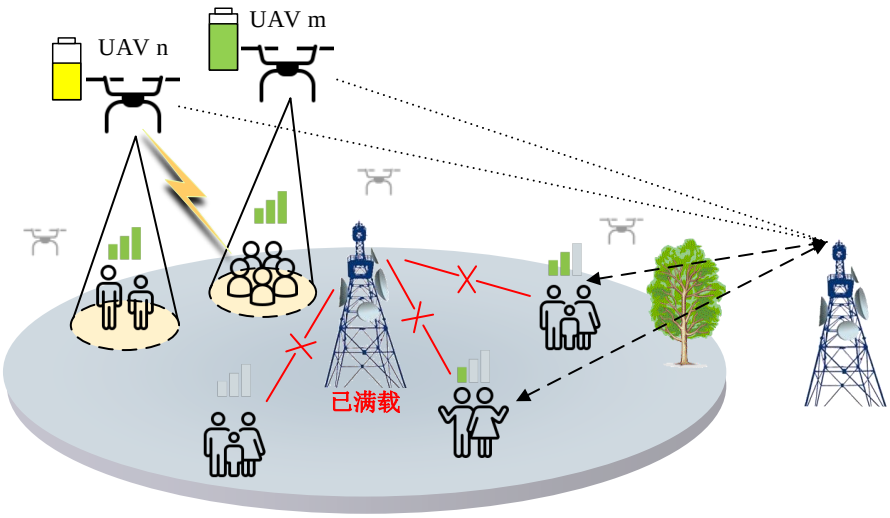

图 4.1　热点通信场景 UAV 工作示意图

外，针对 UAV 与用户数量变多后，状态空间与动作空间维度过大难以训练的问题，需要对动作空间维度降低方法开展进一步研究。

4.3　问题建模

与前述应急通信场景中的覆盖空洞不同，面向热点区域内基站过载造成的覆盖不足、用户难以接入的问题，可以通过 UAV 中继引入热点区域外的资源，以接入更多用户。然而，随着 UAV 数量的增加，工作在同频的 UAV 在下行信道中会产生干扰。基于式(3.5)，可以得到同频干扰下的 UAV n 到用户 m 的传输速率 $r_{n,m}$ 为：

$$r_{n,m} = W\log_2\left(1 + \frac{p_n G_{n,m}}{\sum\limits_{n'\in\mathcal{N}\setminus n} p_{n'} G_{n',m} + N_0 W}\right), \tag{4.1}$$

其中，$\mathcal{N}$ 表示 UAV 的集合，$p_{n'}$ 为与 UAV n 同频的 UAV n' 的信号发射功率，而 $G_{n',m}$ 为 UAV n' 到用户 m 的路径损失系数，根据式(3.1)-(3.4)可知其主要由 UAV 与用户之间的距离决定。

在此基础上，由于用户成簇分布，不同簇间的用户需求速率不同，选择正交频分多址接入（Orthogonal Frequency Division Multiple Access, OFDMA）来同时服务多个用户存在以下不足，一方面是 UAV 的发射机能力有限，不一定可以实现任意颗粒度的频率分配；另一方面传统的 OFDMA 系统在时频资源紧张时，不能很好地避免同频干扰，且无法支持大量用户的同时接入。UAV-NOMA 系统通过功率域复用实现用户间信号可控叠加，从而具备更低的小区间干扰，能够支持更多用户的同时接入[44]。有研究证明了将 NOMA 应用于 UAV 网络，不仅可以达到更高的频谱利用率，还可以增加 UAV 接入的用户数量[45]。因此，只需通过

中国知网　https://www.cnki.net

有限数量的 UAV 便可实现为如演唱会或体育场等热点通信场景中用户提供高质量服务。此外，还可以依靠 UAV 的移动性，通过 UAV 之间的位置协调，充分利用链路质量的不对称性，进一步增加 NOMA 系统的 UAV 网络吞吐量。

基于用户在功率域的强弱关系，利用串行干扰消除（Successive Interference Cancellation, SIC）可以对两个 NOMA 用户同时服务，两用户 NOMA 的下行发送叠加信号为：

$$x = \sqrt{p_1}x_1 + \sqrt{p_2}x_2, \tag{4.2}$$

其中，p_i 为用户 i 的下行发射功率，而对其发送信号有 $E\left[\left|x_i\right|^2\right] = 1$，则用户 i 的接收信号为：

$$y_i = h_i x + w_i, \tag{4.3}$$

其中，h_i 为用户 i 与基站之间的复信道系数，而 w_i 为包含小区间干扰的高斯噪声，其谱密度为 $N_{0,i}$。在两用户叠加时，如果有 $\left|h_1\right|^2 \Big/ N_{0,1} > \left|h_2\right|^2 \Big/ N_{0,2}$，则用户 2 在本地直接进行解码出属于自己的信号 x_2，而用户 1 先正确解出用户 2 的发送信号 x_2，再基于 SIC 将用户 2 的叠加信号消除，实现无干扰解码并得到属于自己的信号 x_1。在带宽为 1Hz 的假设条件下，用户 1 和用户 2 点传输速率 r_1 和 r_2 可以分别被表示为[63]：

$$r_1 = \log_2\left(1 + \frac{p_1\left|h_1\right|^2}{N_{0,1}}\right), \tag{4.4}$$

$$r_2 = \log_2\left(1 + \frac{p_2\left|h_2\right|^2}{p_1\left|h_2\right|^2 + N_{0,2}}\right). \tag{4.5}$$

结合式(4.1)、(4.4)和(4.5)，可以得到当 UAV n 基于 NOMA 技术对已配对用户同时进行服务时，强用户 m 在同频干扰下的传输速率 $r_{n,m}$ 为：

$$r_{n,m} = W\log_2\left(1 + \frac{p_{n,1}G_{n,m}}{\sum\limits_{n'\in\mathcal{N}\setminus n} p_{n'}G_{n',m} + N_0 W}\right), \tag{4.6}$$

而弱用户 m' 的传输速率 $r_{n,m'}$ 为：

$$r_{n,m'} = W\log_2\left(1 + \frac{p_{n,2}G_{n,m'}}{p_{n,1}G_{n,m'} + \sum\limits_{n'\in\mathcal{N}\setminus n} p_{n'}G_{n',m'} + N_0 W}\right), \tag{4.7}$$

其中，$p_n = p_{n,1} + p_{n,2}$ 为 UAV n 的总发射功率，$G_{n,m}$ 与 $G_{n,m'}$ 分别为 UAV n 到用户 m 和 m' 的路径损失系数。已有研究证明，NOMA 不仅能同时接入多个用户，对系统和速率也有一定的提升[64]。

中国知网　https://www.cnki.net

有关 UAV-NOMA 系统中 UAV 路径规划的研究主要集中于 UAV 辅助的 NOMA 基站场景，利用 NOMA 基站和 UAV 联合服务地面用户，其中的典型代表是以最大化和速率[65]、最大化能量效率[66]等为主要目标来设计合理的 UAV 路径规划方案。然而，以上研究中的 NOMA 均为必要条件，只关心系统和速率的提升，而不考虑用户的潜在需求，难以保证用户的公平性。在保证两用户 NOMA 公平性的前提下，有研究提出了以最大化最小用户速率为目标的多 UAV 辅助 NOMA 的优化问题[67]，并成功利用 SCA 进行求解，但此研究中的 UAV 被视为均匀分布的可移动基站，且位置实时已知；而对于 UAV-NOMA 系统设备成簇与资源管理的研究，则只将 UAV 的固定部署位置设为优化变量，并没有对 UAV 的路径进行任何规划设计，这使得 UAV 能服务的用户总数依然有限，更没有考虑 UAV 的能量受限特性。另外，以上研究中的用户全部默认为 NOMA 用户，而非可选择是否使用 NOMA，这在诸如用户簇间信道差异较小、或单一用户资源需求过高等场景下，甚至会使用户的成功接入率低于不采用 NOMA 的场景。每个 UAV 如何基于当前观测状态，灵活地作出当前时隙是否采用 NOMA 的决策，也需要进一步研究。

综上所述，与第三章中的研究目标相同，依然为满足更多的用户服务需求，提高系统的覆盖率。即在总时间 $\boldsymbol{T}$ 内，若能满足用户基本速率 $r_m^{(0)}$ 的服务时隙数大于或等于门限 λ_m，则认为该用户被成功覆盖。因此，基于式(3.15)，对用户 m 依然由 b_m 来描述其基本覆盖需求是否已被满足，有：

$$b_m = I\left(\sum_{t=1}^{T}\sum_{n=1}^{N} I\left(r_{n,m,t} \geqslant r_m^{(0)}\right) x_{n,m,t} \geqslant \lambda_m\right). \tag{4.8}$$

基于 NOMA 之原理，对任一用户而言，是可以直接解码的低速率需求的弱用户，还是先解码出已配对的弱用户信号，再基于 SIC 消除干扰，得到自己所需信号的高速率需求的强用户，是根据其所处的信道环境状态决定的。故对 UAV 而言，需要通过合理的功率分配，来同时满足弱用户和强用户的速率需求，即同时满足 $r_m \geqslant r_m^{(0)}$ 与 $r_{m'} \geqslant r_{m'}^{(0)}$。UAV 与用户的连接状态也与前述研究点中不同，是面向已配对的用户同时建立连接，有 $x_{n,m,t} = 1$ 与 $x_{n,m',t} = 1$。则在 UAV n 覆

中国知网　https://www.cnki.net

盖范围内的用户 m 在时刻 t 的速率为：

$$r_{n,m,t}=\begin{cases} W\log_2\left(1+\dfrac{p_{n,t}G_{n,m,t}}{\sum\limits_{n'\in\mathcal{N}\setminus n}p_{n',t}G_{n',m,t}+N_0W}\right), & \text{only } x_{n,m,t}=1, \\ W\log_2\left(1+\dfrac{p_{n,t}^{(m)}G_{n,m,t}}{\sum\limits_{n'\in\mathcal{N}\setminus n}p_{n',t}G_{n',m,t}+N_0W}\right), & x_{n,m,t}=x_{n,m',t}=1 \text{ and C0}, \\ W\log_2\left(1+\dfrac{p_{n,t}^{(m)}G_{n,m,t}}{p_{n,t}^{(m')}G_{n,m',t}+\sum\limits_{n'\in\mathcal{N}\setminus n}p_{n',t}G_{n',m,t}+N_0W}\right), & x_{n,m,t}=x_{n,m',t}=1 \text{ and } \overline{\text{C0}}, \\ 0, & \text{otherwise}, \end{cases} \tag{4.9}$$

其中，在两用户 NOMA 中，UAV 的总功率 $p_{n,t}=p_{n,t}^{(m)}+p_{n,t}^{(m')}$，条件 C0 为：

$$\text{C0}:\ \frac{G_{n,m,t}}{\sum\limits_{n'\in\mathcal{N}\setminus n}p_{n',t}G_{n',m,t}+N_0W}>\frac{G_{n,m',t}}{\sum\limits_{n'\in\mathcal{N}\setminus n}p_{n',t}G_{n',m',t}+N_0W}, \tag{4.10}$$

用来区分强用户与弱用户，而用户 m 与 m' 分别为当前 UAV 覆盖下具有不同需求的簇中用户。在此基础上，将两用户 NOMA 的功率分配也纳入考量，得到可兼容 NOMA 且目标为最大化用户覆盖率的优化问题P2：

$$\begin{aligned} \text{P2}:\quad & \max_{\boldsymbol{\Theta}}\ \frac{1}{M}\sum_{m=1}^{M}b_m \\ \text{s.t.}\quad & \text{C1}: e_{n,T}\leqslant E_{\max},\forall n\in\mathcal{N} \\ & \text{C2}: \mathbf{p}_{n,0}=\mathbf{p}_{n,T}=\mathbf{p}_0,\forall n\in\mathcal{N} \\ & \text{C3}: \sum_{n=1}^{N}x_{n,m,t}\leqslant 1,\forall m\in\mathcal{M},\forall t\in\mathcal{T} \\ & \text{C4}: \sum_{m=1}^{M}x_{n,m,t}\leqslant 2,\forall n\in\mathcal{N},\forall t\in\mathcal{T} \\ & \text{C5}: V_{\min}\leqslant\frac{1}{\Delta}\left(\mathbf{p}_{n,t}-\mathbf{p}_{n,t-1}\right)\leqslant V_{\max},\forall n\in\mathcal{N},\forall t\in\mathcal{T} \\ & \text{C6}: \left\|\mathbf{p}_{n,t}-\mathbf{p}_{n',t}\right\|_2\geqslant d_0,\forall n'\neq n \text{and} n,n'\in\mathcal{N} \\ & \text{C7}: p_{n,t}^{(m)}\geqslant 0,\forall m\in\mathcal{M},\forall n\in\mathcal{N},\forall t\in\mathcal{T} \\ & \text{C8}: \sum_{m=1}^{M}p_{n,t}^{(m)}x_{n,m,t}\leqslant p_{\max},\forall n\in\mathcal{N},\forall t\in\mathcal{T} \end{aligned} \tag{4.11}$$

其中，$\mathcal{N}$ 为 UAV 集合，$\mathcal{M}$ 为用户集合，$\mathcal{T}$ 为工作时间集合，$p_{\max}$ 为 UAV 的最大发射功率。优化变量集合 $\boldsymbol{\Theta}$ 为：

$$\boldsymbol{\Theta}=\left\{\left[\mathbf{p}_{n,t}\right],\left[\mathbf{x}_{n,t}\right],\left[\mathbf{A}_{n,t}\right]\middle|n\in\mathcal{N},t\in\mathcal{T}\right\}, \tag{4.12}$$

中国知网　https://www.cnki.net

在时刻 t，$\mathbf{p}_{n,t}$ 为 UAV n 的位置，$\mathbf{x}_{n,t} = \left[x_{n,1,t}, \cdots, x_{n,M,t}\right]^T$ 为 UAV n 与所有用户之间的连接状态向量，$\mathbf{A}_{n,t} = \left[p_{n,t}^{(m)}, p_{n,t}^{(m')}\right]^T$ 为下行发射功率，在不采用 NOMA 时有 $p_{n,t}^{(m')} = 0$。

对约束条件而言，C1-C3、C5-C6与式(3.17)中定义相同；而C4扩展为 UAV 可同时连接两个 NOMA 配对用户；C7-C8为对 UAV 的发射功率约束，C7规定了发射功率必须大于等于 0，而C8则要求发射总功率不能超过 p_{max}。基于此，UAV n 在时刻 t 的通信能量损耗变为：

$$e_{n,t}^{\omega} = \Delta \cdot \sum_{m=1}^{M} p_{n,t}^{(m)} x_{n,m,t}, \tag{4.13}$$

其中 Δ 为当前的时隙间隔。

不难看出，相较于前述研究点中的问题，式(4.11)中优化问题 P2 变为了更复杂的非凸问题。随着 UAV 和用户数量的增加，相应的状态空间也变得更大，依赖于全局信息进行训练的复杂度也将大大增加。此外，随着 NOMA 技术的引入，动作空间中又包含了更多的用户连接关系和额外的功率分配需求。因此，考虑采用基于部分观测的多智能体强化学习进行求解，尽量减少需要全局交互的信息；与此同时，UAV 之间也需要部分协作，以尽量避免同频干扰所引起的传输速率降低。

4.4　基于部分观测 MARL 的多 UAV 路径规划与资源分配

针对式(4.11)中优化问题 P2 及其约束条件，为了计算式(4.9)中在同频干扰条件下的下行传输速率，需要先验已知其他 UAV 的位置以及当前发射功率。然而，由于 UAV 的覆盖范围有限，考虑用户集合 $U_{n,t} = \left\{m \,\middle|\, d_{n,m,t} \leqslant D_{th}\right\}$ 为 UAV n 的可观测用户，其中 $d_{n,m,t} = \left\|\mathbf{p}_{n,t} - \mathbf{p}_{m,t}^{\mathrm{UE}}\right\|_2$ 为 UAV 与用户的距离。正因如此，UAV 无法获知全局用户的瞬时状态信息，鉴于通过全局共享信息将造成大量的交互开销，故将原问题建模为分布式部分观测的马尔科夫决策过程（Dec-POMDP）。Dec-POMDP 由八元组 $\langle N, S, A, P, R, \gamma, O, Z\rangle$ 构成，相较于前述研究点的受约束 MDP，额外增加了每个智能体 i 观测状态 O_i, 有联合观测空间 $O = O_1 \times O_2 \times \cdots \times O_N$；$Z$ 为基于联合观测空间的概率分布，即执行联合动作 $\underline{a} = a_1 \times \cdots \times a_N$, $a_i \in A_i$，使全局状态从 $s \in S$ 转移到 $s' \in S$ 时，观测为 O 的概率分布。

4.4.1　状态、动作与奖励设计

基于 Dec-POMDP 的多元组 $\langle N, S, O, A, \gamma, P, Z, R, C\rangle$ 可被设计为：

- N 为 UAV 的数量。

中国知网　https://www.cnki.net

- S 为所有 UAV 的全局状态空间。UAV n 在时隙 t 的状态空间为：$s_{n,t} = \left\{E_{n,t}^{res}, \mathbf{p}_{1,t}, \cdots, \mathbf{p}_{N,t}, \mathbf{p}_{1,t}^{\mathrm{UE}}, \cdots, \mathbf{p}_{M,t}^{\mathrm{UE}}\right\}$，包含全部 UAV 和全部用户的位置，这在 UAV 覆盖范围受限时无法直接获得。
- O 为部分观测状态，对 UAV n 而言，由于其覆盖范围有限，仅可观测到覆盖范围内的部分用户位置 $\mathbf{p}_{m,t}^{\mathrm{UE}}$，为了保证网络输入状态的一致性，以距离最近的 $M_d^{(n)}$ 个用户作为 UAV n 的可观测用户，因此得到 UAV n 在时隙 t 的部分观测状态 $o_{n,t} = \left\{E_{n,t}^{res}, \mathbf{p}_{1,t}, \cdots, \mathbf{p}_{N,t}, \mathbf{p}_{1,t}^{\mathrm{UE}}, \cdots, \mathbf{p}_{M_d,t}^{\mathrm{UE}}\right\}$。
- γ 为折扣系数。
- P 为状态转移矩阵，有 $p\left(s_{i+1} \middle| s_i, a_i\right)$ 表示于当前状态 $s_i \in S$ 执行动作 $a_i \in A$ 时，转移到状态 $s_{i+1} \in S$ 的概率，一般难以直接得到其显式解。
- Z 为基于联合观测空间的概率分布，在 $p\left(s_{i+1} \middle| s_i, a_i\right)$ 的转移概率下，到达新状态 $s_{i+1} \in S$ 时，观测到 o_{i+1} 的概率 $p\left(o_{i+1} \middle| s_{i+1}, a_i\right)$。
- A 为离散的动作空间，对 UAV n 而言，包括运动状态决策与资源分配决策两部分，其中有关运动状态决策的部分与前述研究点相同，为当前的速度 $v_{n,t}$ 与前进方向 $\theta_{n,t}$ 的决策，均从离散的可选集中选取动作，二者共同决定了 UAV n 的行进轨迹；有关资源分配的决策部分，则主要由用户连接状态 $\mathbf{x}_{n,t}$ 和功率分配状态 $\mathbf{A}_{n,t} = \left[p_{n,t}^{(m)}, p_{n,t}^{(m')}\right]$ 组成，由于可以选择连接单用户或同时连接两个 NOMA 用户，故共有 $\left(1 + M_d^{(n)} + M_d^{(n)}\left(M_d^{(n)} - 1\right)\Big/2\right)$ 种可选连接状态，当只服务一个用户时，在功率分配状态中有 $p_{n,t}^{(m')} = 0$。因此将 UAV n 在时隙 t 的动作设计为 $a_{n,t} = \left\{v_{n,t}, \theta_{n,t}, \mathbf{x}_{n,t}, \mathbf{A}_{n,t}\right\}$。此外，当用户功率设定为在有限集内选择时，受 UAV 最大功率 $p_{\max}$ 限制，$p_{n,t}^{(m)}$ 与 $p_{n,t}^{(m')}$ 只能取如图4.2所示的离散方格之一。
- R 为瞬时奖励，包括基于动作决策的奖励，UAV 的碰撞避免，以及对 UAV 频繁转向的控制，基于前述研究点，将瞬时奖励设计为：

$$
\begin{aligned}
R_{n,t}\left(o_{n,t}, \mathbf{a}_t\right) = \mu_1 \sum_{m=1}^{M_d^{(n)}} \left[I\left(r_{n,m,t} \geqslant r_m^{(0)}\right) - b_{m,t}\right] x_{n,m,t} - \mu_2 c_n^{\mathrm{col}} \\
- \mu_3\left(\left|\theta_{n,t} - \theta_{n,t-1}\right| \Big/ \Delta\theta_0\right),
\end{aligned}
\tag{4.14}
$$

其中，$r_{n,m,t}$ 为 UAV n 与用户 m 之间的传输速率，基于部分观测状态 $o_{n,t}$ 中 UAV 与用户的位置关系，可以得到 UAV 与用户间的信道状态，再根据当前联合动作空间 $\mathbf{a}_t$ 中所有 UAV 发射功率，结合 UAV 与用户当前的连接关系，通过式(4.9)计算得到，成功覆盖用户时得到的奖励权重为 μ_1；c_n^{col} 为碰撞惩罚项，其权重由系数 μ_2 控制，碰撞惩罚与两个 UAV 之间的距离有关，有 $c_n^{\mathrm{col}} = \sum_{n' \in \mathcal{N} \setminus n} f\left(d_{n,n'}\right)$，对应到式(4.11)中约束条件 C6 的最小距离 d_0，$f\left(d_{n,n'} \geqslant d_0\right) = 0$ 表示此时没有碰撞惩罚；对于 UAV 的频繁转向控制

中国知网　https://www.cnki.net

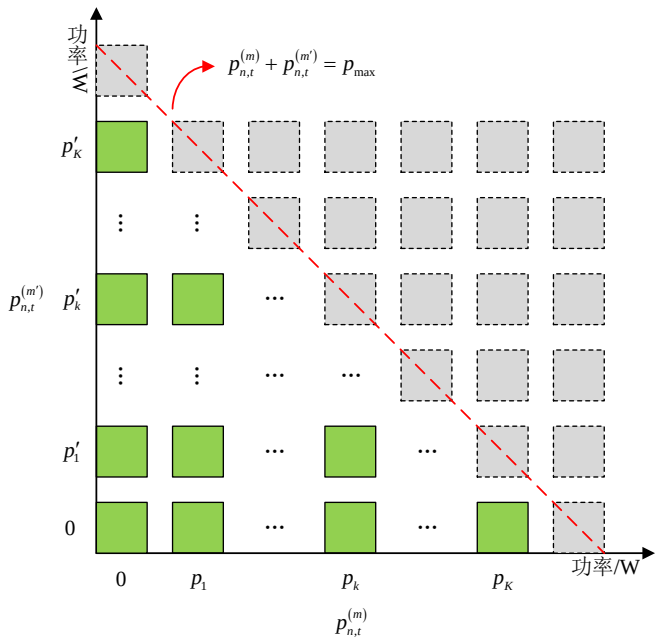

图 4.2　配对用户功率可选集示意图

则仍然用动作决策角度之差计算得分，并用系数 μ_3 控制其权重。

- C 为瞬时约束代价，其定义与式(3.29)相似，有：

$$C_{n,t}\left(o_{n,t},a_{n,t}\right)=\begin{cases}-\left|R_{n,t}\left(o_{n,t},\mathbf{a_t}\right)\right|, & \text{C9},\\ 0, & \text{otherwise},\end{cases} \tag{4.15}$$

其中，约束条件 C9 为：

$$\text{C9}:\ E_{n,t}^{res}\leqslant\rho\hat{E}_{n,t}^{res}\ \text{and}\ \left|\theta_{n,t}-\hat{\theta}\right|>\theta_{th}, \tag{4.16}$$

上述瞬时代价约束的设计可以确保 UAV 安全地返回充电站。

不难看出，相较于前述研究点中的设计，UAV 的状态空间与动作空间都更加庞大，且奖励中的速率计算、碰撞惩罚等也更为复杂。尤其是加入 NOMA 技术之后，UAV 与用户的连接状态也剧烈扩张，若仍从离散可选集中选取，将带来大量的决策分支，而这使网络的收敛难度也大大增加。因此，在保证准确度的前提下，如何对动作空间进行合理降维，也是需要进一步研究的问题。

4.4.2　基于扩展二分图的用户分配

相较于频分多址接入，以 NOMA 接入的两个用户能够满足更广泛条件下的用户需求。特别是受 UAV 能力所限，不能对频谱进行任意颗粒度的分配时，可以基于用户信道状态并对功率域进行分配，来更灵活地满足 NOMA 用户各自的速率需求。然而，引入 NOMA 技术后，UAV 与用户间连接状态的维度大大增加，对应于式(4.11)中优化问题 P2 的约束条件 C4，UAV n 在当前时刻 t 可选择与 0、

中国知网　https://www.cnki.net

1 或 2 个用户连接，这使得潜在的可选连接状态数呈集合增长。因此，对用户连接状态的简化有助于降低动作空间维度。

假设与 UAV n 同时连接的 NOMA 用户组中用户 m 与 m' 的最低速率需求分别是 $r_m^{(0)}$ 和 $r_{m'}^{(0)}$。当总功率 $p_n = p_n^{(m)} + p_n^{(m')}$ 时，定义全部功率分配给用户 m 时的信干噪比 SINR_m 为：

$$\mathrm{SINR}_m = \frac{p_n G_{n,m}}{\sum\limits_{n' \in \mathcal{N} \setminus n} p_{n'} G_{n',m} + N_0 W}, \tag{4.17}$$

相应的，全部功率分配给用户 m' 时的信干噪比 SINR'_m 为：

$$\mathrm{SINR}_{m'} = \frac{p_n G_{n,m'}}{\sum\limits_{n' \in \mathcal{N} \setminus n} p_{n'} G_{n',m'} + N_0 W}, \tag{4.18}$$

基于此，结合式(4.6)与(4.7)，可以计算得到接入时的瞬时速率 r_m 与 r'_m 为：

$$r_m = W \log_2 \left(1 + \alpha \mathrm{SINR}_m\right), \tag{4.19}$$

$$r_{m'} = W \log_2 \left(1 + \frac{(1-\alpha)\,\mathrm{SINR}_{m'}}{1 + \alpha \cdot \mathrm{SINR}_{m'}}\right), \tag{4.20}$$

其中，$0 \leqslant \alpha \leqslant 1$ 为功率分配系数，即 $p_n^{(m)} = \alpha p_n$，$p_n^{(m')} = (1-\alpha)\, p_n$。然而，当两用户的信道强度相似时，不仅很难通过 NOMA 获得额外的信道增益，还会因互相干扰带来不可忽视的性能损失[68]。因此，可以针对式(4.19)与(4.20)，设定相应的门限 δ，当两用户信道条件相近时，有

$$\mathrm{C10}: \frac{1}{\delta} \leqslant \frac{\mathrm{SINR}_m}{\mathrm{SINR}_{m'}} \leqslant \delta,\ \forall m, m' \in \mathcal{M}, \tag{4.21}$$

此时，认为用户 m 与用户 m' 不能组成两用户 NOMA 组，UAV 与用户间的连接关系 $\mathbf{x_{n,t}}$ 变为：

$$\mathbf{x}_{n,t} = \begin{cases} x_{n,m,t} = 1, x_{n,m',t} = 1, & \overline{\mathrm{C10}}, \\ x_{n,m,t} = 1, & \mathrm{C10}, \\ \mathbf{0}_{M \times 1}, & \text{otherwise}, \end{cases} \tag{4.22}$$

即当用户 m、m' 与 UAV 之间满足条件 C10 时，只考虑为单一用户 m 建立连接，故可在可选集之中去除相似信道用户的配对。由于用户成簇分布，簇内用户不仅有相同的速率需求，还有相似的信道强度，簇内无法组成两用户 NOMA 组。因此，当 $M_d^{(n)}$ 个用户分为 K 个簇时，可以从用户连接状态可选集中去掉 $\sum_k M_k \left(M_k - 1\right)/2$ 个备选，其中 M_k 为第 k 个簇内的用户数，这将有效地降低

中国知网　https://www.cnki.net

动作空间的维度。然而，不同 UAV 对应的簇和簇内用户数不尽相同，很难形成一致的降维方案。

此外，针对功率分配可选集的降维，对已配对用户 m 与用户 m'，有如图4.2所示的功率可选集。在两用户 NOMA 时，对弱用户 m' 而言，要将强用户 m 的信号视作干扰，因此需要将弱用户的功率 $p_{n,t}^{(m')}$ 设置得更大以满足其基本速率 $r_{m'}^{(0)}$，基于式(4.20)，需满足：

$$\frac{(1-\alpha)\,\mathrm{SINR}_{m'}}{1+\alpha\cdot\mathrm{SINR}_{m'}} \geqslant 2^{r_{m'}^{(0)}/W}-1, \tag{4.23}$$

其中，$\alpha = p_{n,t}^{(m)} \Big/ \left(p_{n,t}^{(m)} + p_{n,t}^{(m')}\right)$。基于式(4.19)，对强用户也需满足：

$$\alpha\mathrm{SINR}_{m} \geqslant 2^{r_{m}^{(0)}/W}-1, \tag{4.24}$$

当 α 无法同时满足式(4.23)与式(4.24)时，将无法满足两用户的基本速率需求，可以将其排除出 $\mathbf{A}_{n,t} = \left[p_{n,t}^{(m)}, p_{n,t}^{(m')}\right]$ 的可选集，以降低功率可选集的维度。然而，由于受到用户速率需求、UAV 间相互干扰等多种因素影响，不同 UAV 对应的 α 也很难保持一致，这也使得网络很难实现。

综上所述，针对用户连接关系和 NOMA 功率分配，需要寻找一种替代的降维方案。此方案既需要满足算法的目标，又能够保证对所有 UAV 的一致性，使其不影响智能体网络的训练。因此，考虑将 UAV 与用户设备的连接关系决策从原问题中进行分离。UAV 与用户的潜在连接关系可以由加权图表示，如图4.3所示。图中每条边均可满足用户的速率需求，使 UAV 与用户间建立连接。基于式(4.11)中优化问题 P2 的约束条件 C3 与 C4，UAV 可选择与 0、1 或 2 个用户连接，而选择依据则以加权图中的每条边的权重决定。

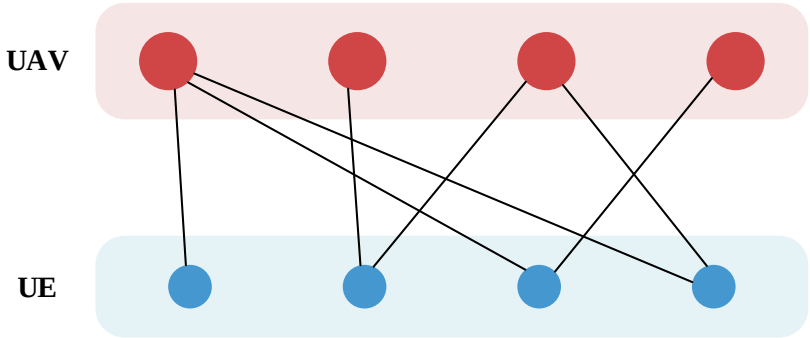

图 4.3　UAV 与用户的潜在连接关系示意图

由于 UAV 可以选择同时连接组成 NOMA 组的两个 UE，故将 UE 节点设计为包括仅连接一个用户与同时连接两个用户的新集合。如图4.4所示，针对 4 用户场景，将所有可能的 NOMA 组进行罗列，可以得到 UAV 与用户新集合之间的连接关系，而这恰好符合二分图的连接关系。

中国知网　https://www.cnki.net

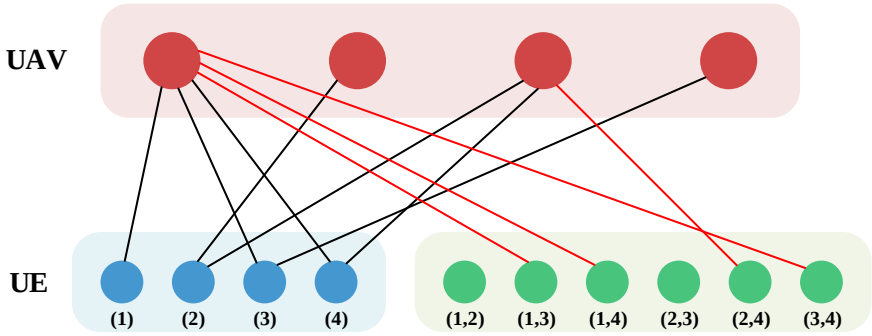

图 4.4　符合二分图的扩展连接关系示意图

二分图最大匹配算法的目标是找出最多条匹配且互不相交的边，对应到UAV与用户的潜在连接关系中，即为帮助每个 UAV 寻找最能满足目标需求的用户。综合式(4.17)-(4.24)的潜在降维需求，对每条边的权重进行定义，只连接单个用户的边的权重定义为：

$$w_{n,m} = \left[\lambda_1\left(\frac{r_{n,m,t}^{(I)}}{r_{\max}}\right) + \lambda_2\left(\frac{\sum_{\tau=1}^{t-1} r_{n,m,\tau}\Delta}{r_m^{(0)} t_m^{(0)}}\right)\right] I\left(r_{n,m,t}^{(I)} \geqslant r_m^{(0)}\right)\left(1 - b_m\right), \tag{4.25}$$

其中 $r_{n,m,t}^{(I)}$ 为所有 UAV 均以最大功率发射信号时，由 UAV n 服务的用户 m 在时刻 t 的可达速率，基于式(4.9)与(4.17)有：

$$r_{n,m,t}^{(I)} = W\log_2\left(1 + \frac{p_{\max} G_{n,m,t}}{\sum\limits_{n' \in N \backslash n} p_{\max} G_{n',m,t} + N_0 W}\right), \tag{4.26}$$

此外，$r_{\max}$ 为 UAV 与用户间的最大速率，即水平距离 $d = 0$ 时的可达速率，Δ 为时隙间隔，$t_m^{(0)}$ 为用户 m 的需求服务时长；$I\left(r_{n,m,t}^{(I)} \geqslant r_m^{(0)}\right)$ 为判断满足速率需求的示性函数，而 $\left(1 - b_m\right)$ 则表示当用户 m 已被满足时则此边不再拥有权重；λ_1 与 λ_2 分别为当前速率和当前用户已完成数据量传输比率的归一化系数，有 $\lambda_1 + \lambda_2 = 1$，将权重 $w_{n,m}$ 的范围限制在 $[0, 1]$ 之间。

同时连接 NOMA 组内两用户的边的权重定义为：

$$\begin{aligned} w_{n,m,m'} = \left(1 - b_m\right)\Bigg[&\frac{2\lambda_1}{r_{\max}}\left(\max_{r_{n,m,t}^{(I)} \geqslant r_m^{(0)}, r_{n,m',t}^{(I)} \geqslant r_{m'}^{(0)}}\left(r_{n,m,t}^{(I)} + r_{n,m',t}^{(I)}\right)\right) \\ &+\lambda_2\left(\frac{\sum_{\tau=1}^{t-1} r_{n,m,\tau}\Delta + \sum_{\tau=1}^{t-1} r_{n,m',\tau}\Delta}{r_m^{(0)} t_m^{(0)} + r_{m'}^{(0)} t_{m'}^{(0)}}\right)\Bigg]\left(1 - b_{m'}\right), \end{aligned} \tag{4.27}$$

其中，中括号内的前一项为满足两用户最小速率需求时的最大和速率，NOMA 连接时的速率 $r_{n,m,t}^{(I)}$ 与 $r_{n,m',t}^{(I)}$ 可结合式(4.9)、(4.19)与(4.20)得到，而决定速率的关键则由功率分配系数 α 决定；后一项为当前 NOMA 用户组内已完成数据量传输的比率，以保证已被服务过的符合条件用户被优先服务。这可以保证不会出现 UAV 随机连接任意用户，使每个用户都获得了部分服务，却没有用户能最终完

中国知网　https://www.cnki.net

成任务的情况。系数 λ_1 与 λ_2 与前式内定义相同。在此定义下，扩展节点权重 $w_{n,m,m'}$ 的值可能会略高于 1，而这也更倾向于满足在单位时间内尽可能接入更多用户的目标。

基于以上权重定义，可以得到 UAV 与用户扩展集合之间的权重矩阵 **W**:

$$\mathbf{W}=\begin{bmatrix} w_{1,1} & \cdots & w_{1,M} & w_{1,1,2} & w_{1,1,3} & \cdots & w_{1,M-2,M} & w_{1,M-1,M} \\ w_{2,1} & \cdots & w_{2,M} & w_{2,1,2} & w_{2,1,3} & \cdots & w_{2,M-2,M} & w_{2,M-1,M} \\ \vdots & \cdots & \vdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ w_{N,1} & \cdots & w_{N,M} & w_{N,1,2} & w_{N,1,3} & \cdots & w_{N,M-2,M} & w_{N,M-1,M} \end{bmatrix}, \quad (4.28)$$

至此，可以利用 Kuhn-Munkres（K-M）算法[69-70]得到加权二分图的最大权重子图，也就是基于部分观测状态集合中的元素，便可得到的当前时刻 UAV 与用户连接关系。K-M 算法的简要流程如下：①以每个 UAV 节点的最高权重标准初始化子图，并通过匈牙利算法[69]挑选当前的最大匹配；②若最大匹配不是最佳匹配，则选择一条有冲突的增广路径，降低对应路径内相互冲突的 UAV 节点的标准，以引入更多满足标准的边来扩充子图，并对新加入边对应的 UE 节点提升权重标准，保证提升量与其相连的 UAV 降低量相同；③挑选满足“相连的两节点顶标和”与“两节点边权重”相等的边，不断重复上述过程直到完美匹配。

基于图4.4中 UAV 与用户的连接关系，假设式(4.28)中加权二分图的权重矩阵 **W** 为：

$$\mathbf{W}=\begin{bmatrix} 6 & 0 & 5 & 2 & 0 & 10 & 7 & 0 & 0 & 4 \\ 0 & 8 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 6 & 0 & 4 & 0 & 0 & 0 & 0 & 5 & 0 \\ 0 & 0 & 4 & 3 & 0 & 0 & 0 & 0 & 0 & 5 \end{bmatrix}, \quad (4.29)$$

其中，前四列对应仅与单用户连接是的权重，后六列为扩展后 NOMA 组的权重。基于式(4.11)中的限制条件 C3，用户不能同时被两个 UAV 服务，因此，形成扩展二分图之后的 NOMA 组节点间不能视作相互独立。当单用户节点被当前二分图路径选中成为匹配路径时，与其相关的所有 NOMA 节点将不可被其他 UAV 匹配。进一步地，当 NOMA 节点被选中成为匹配路径时，与两用户的节点及与其中任一用户相关的 NOMA 节点也将不可被其他 UAV 匹配。据此，需要在现有的二分图最大权重匹配算法流程中，加入一个随匹配循环次数变化的变量 $\mathbf{U}_k$，表征当前已匹配的用户集合。在初始化阶段，将变量设置为空集，即 $\mathbf{U}_0=\varnothing$；在

中国知网　https://www.cnki.net

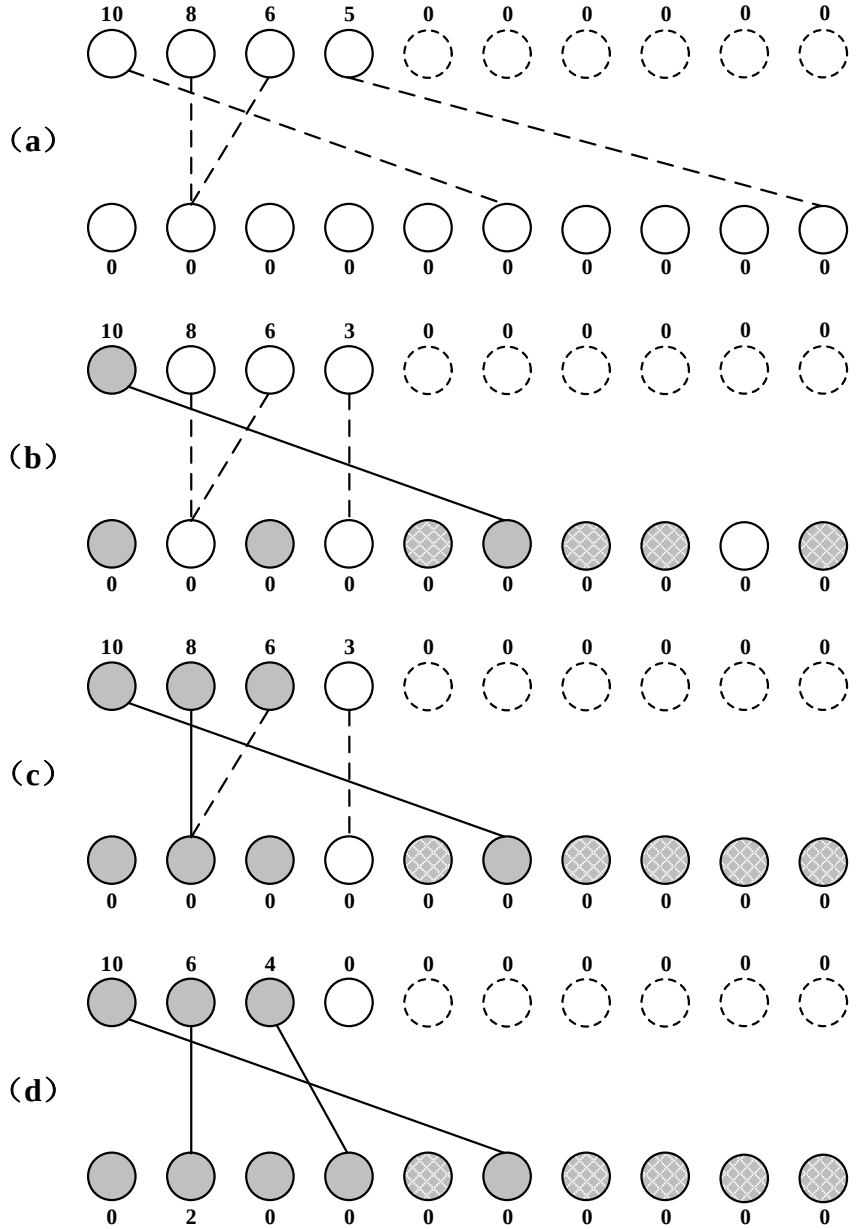

图 4.5　改进的最大权重匹配算法流程示意图

第 k 步时，有 $\mathbf{U}_k = \mathbf{U}_{k-1} \cup \mathbf{u}_k$，其中 $\mathbf{u}_k$ 为在第 k 步新匹配的用户。此外，还有与 $\mathbf{W}$ 维度相同的权重控制矩阵 $\boldsymbol{\Omega}_k$，在初始化阶段时为全 1 矩阵。在第 k 步时，$\boldsymbol{\Omega}_k$ 根据集合 $\mathbf{U}_k$ 中的已匹配用户，将矩阵中 UAV 节点与已匹配用户节点、以及 UAV 节点与含有已匹配用户的 NOMA 扩展节点位置的值全置为 0，并基于此得到第 k 步的新权重矩阵 $\mathbf{W}_k$，有：

$$\mathbf{W}_k = \mathbf{W} \odot \boldsymbol{\Omega}_k, \tag{4.30}$$

其中，$\odot$ 表示哈达玛积，而 $\boldsymbol{\Omega}_k$ 则将与已匹配用户有关的权重值都控制为 0。

基于式(4.29)中的权重值，图4.5通过四个步骤的子图给出了改进的最大权重匹配算法基本流程：

- 子图 (**a**) 为初始化步，上面的节点表示 UAV，下面的节点表示用户及 NOMA

中国知网　https://www.cnki.net

扩展。初始化时，将用虚拟 UAV 将权重矩阵补充成为方阵，但虚拟节点与用户扩展节点间权重值均为 0。每个 UAV 节点顶部的值为其潜在可获得的最大权重，而虚线则表示最大权重的潜在连接关系。此时的已匹配用户集合为 $\mathbf{U}_0 = \varnothing$。

- 子图 (**b**) 为算法第一步，选择最大权重的边，即第 1 个 UAV 节点与第 6 个用户节点。由图4.4可知，第 6 个用户节点表示的是用户 1 和用户 3 形成的 NOMA 组，因此用户 1 和 3 被选中，有新匹配用户集合 $\mathbf{u}_1 = \{1,3\}$，已匹配用户集合则变为 $\mathbf{U}_1 = \mathbf{U}_0 \cup \mathbf{u}_1$。此时，与用户 1 和用户 3 相关的所有 NOMA 节点将不再作为潜在的可选节点，在子图 (**b**) 中用网格填充标识出。通过 $\mathbf{U}_1$ 中的已匹配用户集合得到权重控制矩阵 $\boldsymbol{\Omega}_1$，基于式(4.30)计算得到新权重矩阵 $\mathbf{W}_1$。
- 子图 (**c**) 为算法第二步，由 $\mathbf{W}_1$ 的权重值可知，有两个 UAV 节点的最大权重边均为用户 2，进而产生了冲突。在此情况下，选择更大权重的边作为匹配边，而将无法满足另一条潜在边的差值权重赋予冲突的用户节点，则当前新匹配用户为 $\mathbf{u}_2 = \{2\}$，已连接用户集合为 $\mathbf{U}_2 = \mathbf{U}_1 \cup \mathbf{u}_2$，并基于此得到权重控制矩阵 $\boldsymbol{\Omega}_2$ 和权重矩阵 $\mathbf{W}_2$ 的更新。对于新增的不可选节点，即与用户 2 相关的 NOMA 节点，也由子图 (**c**) 中的网格填充标出。
- 子图 (**d**) 为算法第三步，冲突退避后的 UAV 节点基于 $\mathbf{W}_2$ 选择的最大权重匹配边，得到新匹配用户 $\mathbf{u}_3 = \{4\}$，已连接用户集合 $\mathbf{U}_3 = \mathbf{U}_2 \cup \mathbf{u}_3$，此时所有用户节点均已匹配，则算法成功找到了最大权重匹配策略，将返回当前的匹配关系和匹配权重值。

在前述改进的最大权重匹配算法基本流程实例中，在所有用户找到最大匹配时算法终止，但在实际场景中，用户数量远多于 UAV，因此终止条件通常为所有 UAV 均找到最大权重匹配边。基于此，改进的二分图最大权重匹配 K-M 算法的详细流程如算法4.1所示。

基于改进的最大权重匹配 K-M 算法，对式(4.25)与(4.27)中的权重设计进行初步仿真验证。表4.1给出了用户分簇及各簇内用户的速率需求，基于各簇用户的速率需求差异，有潜在两用户 NOMA 组形成条件。在仿真中，假设 UAV 1 位于簇 A 附近，UAV 2 所在位置满足利用 NOMA 同时服务簇 B 和簇 D 内用户的条件，UAV 3 位于簇 C 附近。表4.2给出了已完成数据量传输比率状态，并用红色标示出了相邻状态间的变化值。

图4.6给出了基于表4.2中瞬时状态的用户选择和可达速率，其中横轴为用户编号，深色柱状图为速率需求，浅色柱状图为当前可达速率，橙色右半轴则表示当前用户已完成传输数据量的比率，从上到下的子图分别对应“状态 0”到“状态 4”。可以观察到，在“状态 0”时所有用户均未被服务，基于改进的最大权

中国知网　https://www.cnki.net

重匹配 K-M 算法，UAV 会选择其可视范围内可达速率最高的用户进行服务。从“状态 0”变化到“状态 1”时，尽管 UAV 1 对簇 A 中的 3 号用户可达速率更高，但由于 2 号用户已被服务过 30%，且可达速率能满足其速率需求，故而 2 号用户权重更高，仿真结果也证明了算法会优先选择 2 号用户。在“状态 1”变化到“状态 2”的过程中，簇 B 和簇 D 中的用户形成 NOMA 组，同时由 UAV 2 进行服务，但由于 4 号用户已被服务，NOMA 组从 $(5,13)$ 变化为 $(4,13)$。从“状态 2”变化到“状态 3”时亦然。“状态 3”到“状态 4”的变化则证明了当用户已被服务 100% 时将不再服务。

综上所述，可以基于扩展的加权二分图，通过当前的部分观测状态来计算边的权重，并基于改进的最大权重匹配 K-M 算法得到当前权重下 UAV 与用户最佳连接状态 $\mathbf{x}_{n,t}$。仿真验证了在满足速率需求的条件下，所提算法会优先服务已被服务过的用户，且当用户需求被满足时便不再对其进行服务。更重要的是，由于此算法输入仅为当前的状态，且不同的瞬时状态可以都可以得到确定的连接关系，因此将其反馈给网络时，不会破坏网络的一致性。

算法 4.1　改进的最大权重匹配 K-M 算法

输入：$N \times \left(M^2+M\right)/2$ 维权重矩阵 $\mathbf{W}$。
输出：$N \times \left(M^2+M\right)/2$ 维匹配矩阵 $\mathbf{M}$。
初始化：将权重矩阵 $\mathbf{W}$ 扩展为 $\left(M^2+M\right)/2 \times \left(M^2+M\right)/2$ 维方阵 $\mathbf{D}$，已匹配用户集合 $\mathbf{U}_0 = \varnothing$，权重控制矩阵 $\boldsymbol{\Omega}_0$ 为与矩阵 $\mathbf{W}$ 的同维度的全 1 矩阵。
初始匹配：在矩阵 $\mathbf{D}$ 中的每一行中找出该行的非零最大权重，计入行权重向量中，并将其所对应的行和列位置标记为“潜在匹配”；
while $k \leqslant K_{max}$ **do**
　搜索“潜在匹配”中最大权重值对应的列；
　将该列对应的用户 $\mathbf{u}_k$ 纳入已匹配用户集合 $\mathbf{U}_k = \mathbf{U}_{k-1} \cup \mathbf{u}_k$；
　if 最大权重值对应的列中存在多个“潜在匹配” **then**
　　将多个“潜在匹配”中最大值对应的行和列标记为“已匹配”；
　　将行权重向量中该行对应的值修改为“潜在匹配”中的第二大权重值；
　　将最大权重与第二大权重的差值计入列权重向量的相应位置；
　　将列权重向量中的最大值加到其他未匹配的列中；
　end
　基于 $\mathbf{U}_k$ 得到对应的权重控制矩阵 $\boldsymbol{\Omega}_k$；
　匹配更新：基于式(4.30)得到新的权重矩阵 $\mathbf{W}_k$ 以及相应的 $\mathbf{D}_k$，并基于 $\mathbf{D}_k$ 得到新的“潜在匹配”；
　$k = k+1$；
end

中国知网　https://www.cnki.net

表 4.1　用户分簇及各簇速率需求

用户分簇	簇 A	簇 B	簇 C	簇 D
用户编号	1,2,3	4,5,6	7,8,9,10,11	12,13,14
簇内用户数/个	3	3	5	3
簇内用户速率需求/Mbps	100	80	120	20
初始数据传输比率/%	0,0,0	0,0,0	0,0,0,0,0	0,0,0

表 4.2　用户已完成传输数据量比率状态

用户分簇	簇 A	簇 B	簇 C	簇 D
用户编号	1,2,3	4,5,6	7,8,9,10,11	12,13,14
状态 0/%	0,0,0	0,0,0	0,0,0,0,0	0,0,0
状态 1/%	0,30,0	0,0,0	0,0,0,0,0	0,0,0
状态 2/%	0,30,0	30,0,0	0,0,0,0,0	0,0,0
状态 3/%	0,30,0	30,0,0	0,0,0,0,0	0,0,50
状态 4/%	0,30,0	30,0,0	0,0,100,0,0	0,0,50

4.4.3　基于 AC 网络的联合路径规划与功率分配

将原优化问题 P2 转化为 Dec-POMDP 问题时，由于每个 UAV 只能观测到部分信息，若每次决策前都进行信息共享，必然会产生大量的信息交互负担，降低系统效率，这就要求 UAV 在决断和执行时要尽可能避免依赖全局信息。另外，对每个 UAV 的奖励与代价的评判也最好相互独立，使 UAV 在作决策时不受其他 UAV 影响，来保证每个 UAV 决策的自主性。故在网络训练阶段可以通过集中式的训练来保证网络的准确度，而执行阶段则交由 UAV 自主决策。基于演员-评论家框架的中心式训练和分布式执行策略可以实现这一目标，如图4.7所示，在网络训练阶段采用中心式结构，各智能体部署演员网络，即策略网络，目标是做出动作决策；而评论家网络则是价值网络，联合观测状态对演员网络的动作进行评价，并反馈到网络的进一步训练中，直到网络收敛；分布式执行则是指在网络训练完成后，各智能体基于实际场景中各自的部分观测状态，由已训练好策略的演员网络进行动作决策。

当使用加权二分图最大匹配算法得到 UAV 与用户的连接状态 $\mathbf{x}_{n,t}$ 后，动作空间的维度会显著降低，只需考虑 UAV 的路径规划和功率分配即可。引入加权二分图的网络架构如图4.8所示，在训练过程中，用户分配的决策从动作空间中被分离；而在执行阶段，亦可通过 UAV 上内置了基于扩展加权二分图的改进的最大权重匹配 K-M 算法，根据当前的观测状态进行用户分配的实时决策。

引入加权二分图后，基于 AC 网络算法的简要流程为：以当前观测状态集合

中国知网　https://www.cnki.net

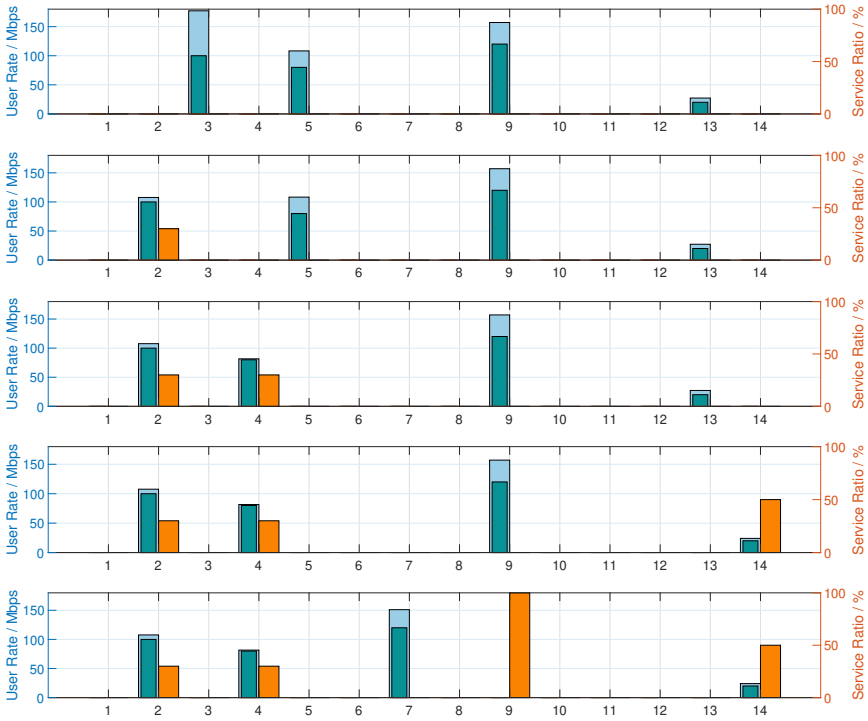

图 4.6　瞬时状态用户选择及可达速率仿真

为输入，基于式(4.28)得到每条边的权重矩阵，并通过改进的最大权重匹配 K-M 算法得到扩展加权二分图的最大匹配，以此确定当前 UAV 与用户的连接状态 $\mathbf{x}_{n,t}$；之后，根据此连接状态与动作决策，来确定下个部分观测状态，并基于此计算瞬时奖励 $R_{n,t}$（包含瞬时代价 $C_{n,t}$）；将当前状态、动作、奖励、代价、下一状态一同存入每个 UAV 的回放经验池，并反馈给 AC 网络以供随时调用。

基于 DDPG 算法[71-72]，对每个 UAV 都需要训练 4 个 DNN 网络，即演员网络的在线策略网络 $\mu_\theta(s)$ 和目标策略网络 $\mu_{\tilde{\theta}}(s)$，以及评论家网络的在线价值网络 $Q_\phi(s,a)$ 和目标价值网络 $Q_{\tilde{\phi}}(s',a')$。

在 DDPG 的基础上，多智能体深度确定性策略梯度（Multi-Agent Deep deterministic policy gradient, MADDPG）算法[54]中每个智能体在对评论家网络进行训练时，都需将当前全部观测状态和全部智能体动作进行拼接，并用拼接后的观测状态和动作向量作为网络的输入，得到一维的 Q 值。基于图4.8的架构，将所有 UAV 的观测拼接成观测向量 $\mathbf{s}=\{\mathbf{o}_1,\cdots,\mathbf{o}_N\}$，所有动作拼接成动作向量 $\mathbf{a}=\{a_1,\cdots,a_N\}$。对回放经验池 D 中存储的回放样本进行采样，并计算出目标价值网络 $Q_{\tilde{\phi}_i}(\mathbf{s}',\mathbf{a}')$，以此来训练 $Q_{\phi_i}(\mathbf{s},\mathbf{a})$，基于式(2.21)，利用回放经验池中的采样，可以得到损失函数：

$$L(\phi_i)=\mathbf{E}_{(\mathbf{s},\mathbf{a},\mathbf{r},\mathbf{s}',\mathbf{d})\sim D}\left[\left(Q_{\phi_i}(\mathbf{s},\mathbf{a})-\left(r_i+\gamma\left(1-d_i\right)Q_{\phi_i}(\mathbf{s}',\mathbf{a}')\right)\right)^2\right],\tag{4.31}$$

中国知网　https://www.cnki.net

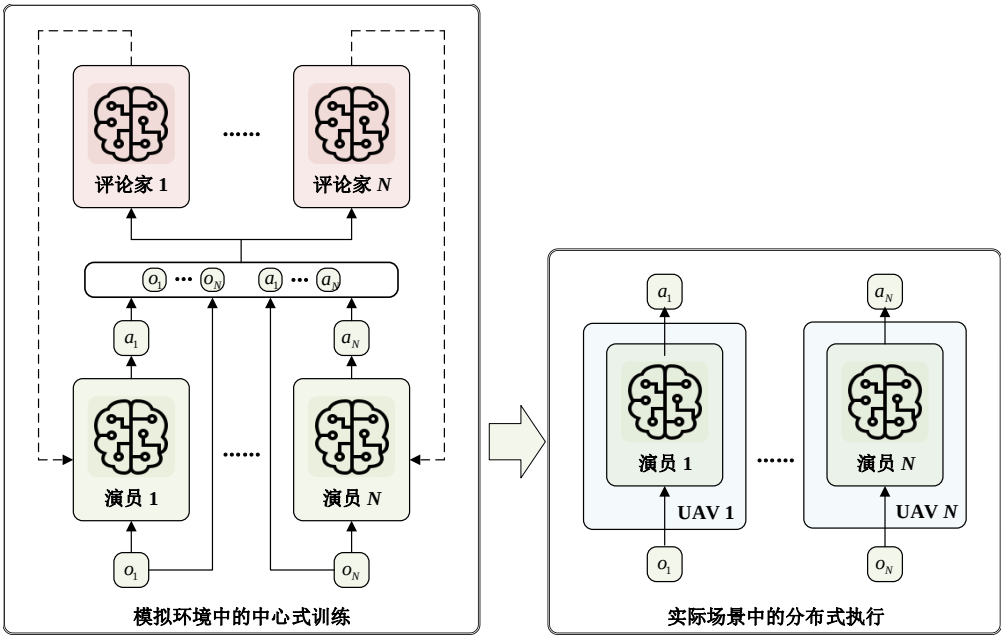

图 4.7　中心式训练-分布式执行的 AC 网络架构

其中，r_i 为当前奖励，$d_i \in \{0,1\}$ 为中止状态标识，当 $d_i = 1$ 时，$\mathbf{s}'$ 为中止状态，即智能体在当前状态没有获得额外的奖励。而后，利用2.2.1节中的梯度下降法求解网络参数 ϕ_i。

对每个 UAV 的演员网络而言，只将其自身的观测向量 $\mathbf{s}_i = \mathbf{o}_i$ 作为网络的输入，有目标函数：

$$J\left(\theta_i\right) = E_{\mathbf{s}_i \sim D}\left[Q_{\phi_i}\left(\mathbf{s}, \mu_{\theta_i}\left(\mathbf{s}_i\right)\right)\right], \tag{4.32}$$

通过最大化目标函数（或最小化目标函数的负值），基于2.2.2中的策略梯度求解网络参数 θ_i。MADDPG 算法的训练流程如算法4.2所示。

进一步地，在最大化长期奖励的预期中，当 UAV 可与用户产生连接时，以悬停状态服务来节省能量，此时只需对 UAV 的功率分配进行决策；而当 UAV 观测范围内无用户可服务时，再考虑其自主决策的飞行路径，此时则关闭通信发射机，也能够降低对其他同频 UAV 的干扰。

4.5　仿真结果与分析

30 个用户簇随机分布在 2000m × 2000m 的范围中，每个簇中有 5-15 个不等数量的用户，由 6 个 UAV 进行服务。UAV 工作于 100m 高的平面上，下行发送信号中心频率 20GHz，带宽为 40MHz，不同用户簇内用户的速率需求各异，将其分为低中高三档，分别对应 20Mbps、60Mbps 与 100Mbps，每个簇的总需求服务时间设为 600 秒。噪声的功率谱密度为-174dBm/Hz，UAV 的发射功率为 20dBm。UAV 的飞行功率与转向功率与前述研究点相同，每个 UAV 的总能量为 100 千焦。对于折扣系数、学习率等神经网络参数的初始设置也与前述研究点类似，并

中国知网　https://www.cnki.net

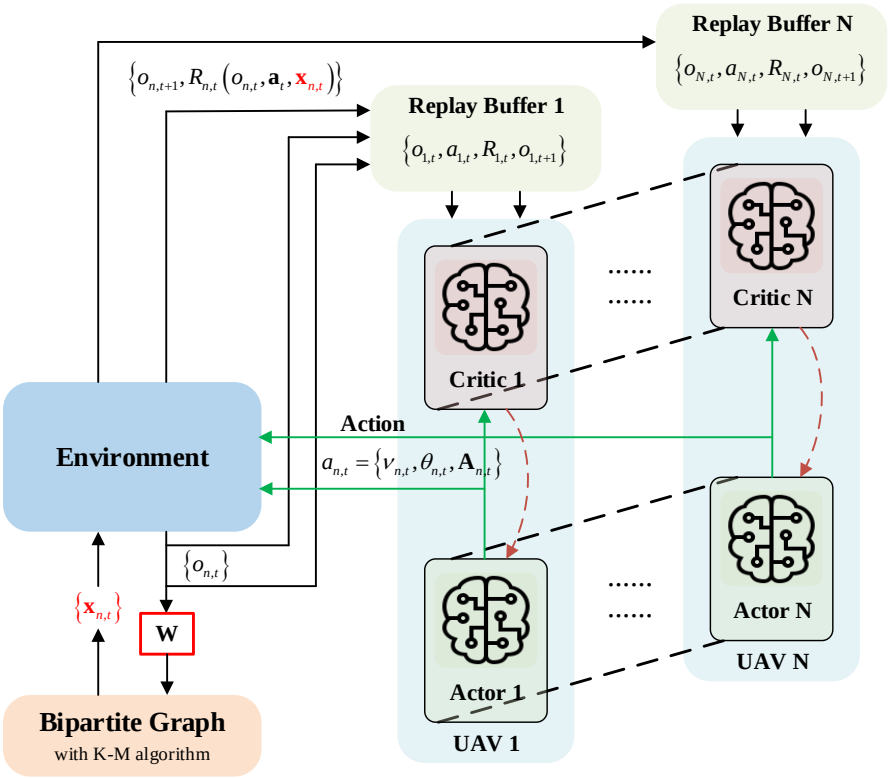

图 4.8　引入加权二分图的网络架构

根据训练中的具体情况进行适当调整。

将动作空间中的速度设置为 0m/s、10m/s 两档，角度设置为均匀分布的 8 个离散角度，UAV 的功率调节设置为可变的 10 档，即可按照最大功率的 10% 为粒度进行 NOMA 用户分配和 UAV 间的功率控制。图4.9给出了不同分簇用户速率需求分布下的用户覆盖率，其中“Low”为低速率用户簇，“Medium”为中速率用户簇，“High”为高速率用户簇，其后百分比表示此速率用户簇占所有簇的比例。对比算法为前述研究点中提出的、单位时间仅服务单用户的算法，以及

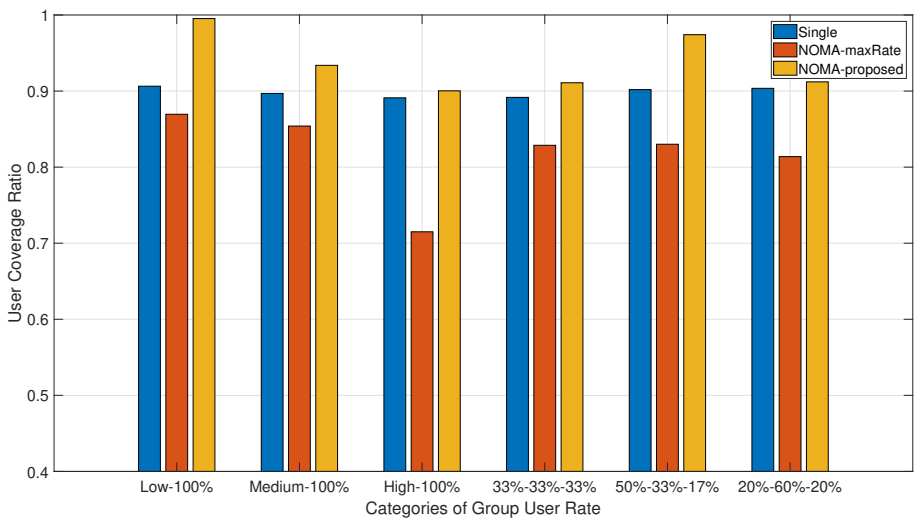

图 4.9　不同分簇用户速率需求分布下的平均用户覆盖率

中国知网　https://www.cnki.net

算法 4.2　MADDPG 算法

初始化：每个 UAV 的演员网络参数 θ_i 与 $\tilde{\theta}_i$，评论家网络参数 ϕ_i 和 $\tilde{\phi}_i$；
for $t = 1$ *to* T_{max} **do**
　for $i \in \mathcal{N}$ **do**
　　以概率 ε 选择随机动作，或以概率 $1-\varepsilon$ 选择最优动作 a_i；
　end
　执行动作 $a = a\left(a_1, \cdots, a_n\right)$，得到包含代价的奖励 r，和下一状态 $\mathbf{s}'$；
　将以上经验 $\left(\mathbf{s}, a, r, \mathbf{s}'\right)$ 存入回放经验池 $\mathcal{D}$；
　状态转移 $\mathbf{s} \leftarrow \mathbf{s}'$；
　for $i = 1$ *to* N **do**
　　从回放经验池中抽取 B 组最小批量抽样 $\left(\mathbf{s}^j, a^j, r^j, \mathbf{s}'^j\right)$；
　　设定目标值：

$$y^j = r_i^j + \gamma\left(1 - d_i^j\right) Q_i^{\mu'}\left(\mathbf{s}'^j, a_1', \cdots, a_N'\right)\Big|_{a_k'=\mu_k'\left(o_k^j\right)},$$

　　通过式(4.31)中损失函数 $L\left(\phi_i\right)$，用梯度下降法来更新评论家网络；
　　通过对式(4.32)中目标函数 $J\left(\theta_i\right)$ 求策略梯度来更新演员网络：

$$\nabla J\left(\theta_i\right) \approx \frac{1}{B}\sum_j \nabla_{\theta_i}\mu_i\left(o_i^j\right)\nabla_{a_i}Q_i^{\mu}\left(\mathbf{s}^j, a_1^j, \cdots, a_i, \cdots, a_N^j\right)\Big|_{a_i=\mu_i\left(o_i^j\right)},$$

　end
　更新每个 UAV 的目标策略网络参数：$\theta_i' \leftarrow \tau\theta_i + (1-\tau)\theta_i'$。
end

在以最大化和速率为目标的算法[28-29]的基础上，进行适应性调整以兼容 NOMA 系统的改进算法。

图4.9的前三列分别为用户簇全部为低、中、高速率时的平均用户覆盖率。可以看到，当用户速率需求越高时，用户的覆盖率越低。尤其在采用 NOMA 技术的算法中，用户速率需求越高，其可形成 NOMA 组的难度就越大，可实现的覆盖率也就越低。在全部为高速率用户时，所提算法已经和仅服务单用户时的算法覆盖率相近，而基于最大和速率 NOMA 的算法则产生了明显下滑。后三列则为分簇用户不同速率需求分布情况下的平均覆盖率。其中，“33%-33%-33%”对应于高中低速率需求簇随机均匀分布的场景；“50%-33%-17%”对应于低速率需求簇更多，占全部簇的一半，而高速率需求簇更少的场景；“20%-60%-20%”则对应于低速率和高速率需求簇都较少，而中等速率需求簇最多的场景。可以很明显的看出，在低速率需求簇及用户分布较多时，引入 NOMA 技术能更有效地提高覆盖率。这是因为速率需求差异越大，越容易形成 NOMA 组，能在同一时间内同时满足两个用户的需求。此外，可以观察到仅服务单用户的算法，即前述研究点所提算法，其用户覆盖率表现在多种场景下均较为稳定，而这也证明了前述研究点算法的合理性和准确性。综上所述，仿真结果表明，不论是与单位时间内仅服务单用户的算法，还是与基于最大和速率 NOMA 的算法相比，所提出的兼容

中国知网　https://www.cnki.net

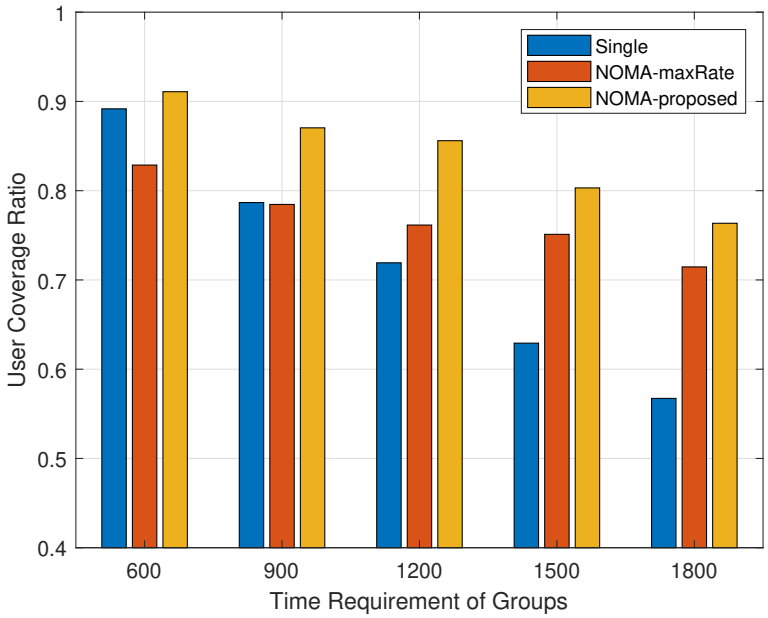

图 4.10　不同分簇用户服务时长需求下的平均用户覆盖率

单用户与 NOMA 的算法都能够有效地提高用户的平均覆盖率。

不同分簇用户服务时长需求下的平均用户覆盖率如图4.10所示，其中用户簇的速率需求均为“33%-33%-33%”，即高中低速率需求簇均匀分布。利用前述研究点中单位时间内仅服务单用户的所提算法得到的覆盖率会随着用户簇服务时长需求增加而显著降低，这也与第三章的仿真结果相符。由于受到簇内用户数和用户速率需求的随机性影响，其在覆盖率上的表现相较于前述研究点中的仿真衰减更为明显。兼容 NOMA 技术的算法虽然在用户簇服务时长需求增加时也会出现覆盖率降低的情况，但可以在满足 NOMA 条件的任一时刻同时给两个用户提供覆盖，而这可以在一定程度上降低覆盖率随服务时长需求增加而衰减的趋势。在此基础上，所提出的兼容单用户与 NOMA 的算法在用户平均覆盖率上依然具有良好地表现，这也进一步证明了扩展二分图权重设计的合理性和有效性。尽管式(4.27)是以 NOMA 用户组的最大可达和速率作为权重的一部分进行设计的，但在满足用户分配的连接关系时，基于式(4.14)获得奖励之决策，只与其是否能满足当前用户需求有关，而非必须达到最大可达和速率的唯一位置。也就是说，扩展二分图权重只决定了 UAV 的用户连接和 NOMA 功率分配的潜在目标，而 UAV 的动作决策依然由所设计的奖励函数及策略网络所决定。

图4.11为不同起止点时的 UAV 路径图，由红色标出的返回点即为 UAV 充电站的位置。其中，图4.11-(a) 给出了起点与终点相同的 UAV 路径图，可以观察到，对于距离较远的用户簇，UAV 在能量受限的情况下很难覆盖到，必须在能量耗尽前返回充电站。图4.11-(b) 则给出了理想情况下，充电站位于区域中心，UAV 从区域边缘随机位置对用户进行覆盖的路径。在此仿真中，尽管用户簇由 30 个

中国知网　https://www.cnki.net

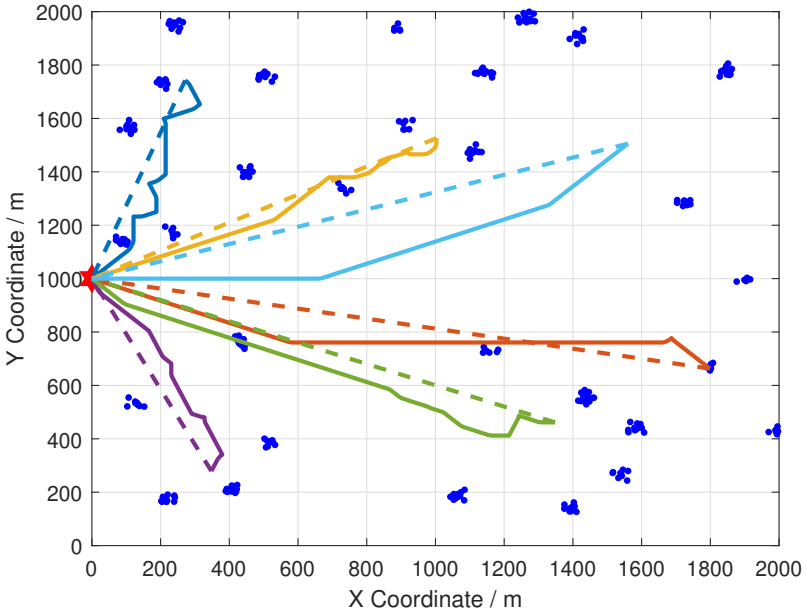

(a) 起止点位于区域边缘同位置的 UAV 路径图

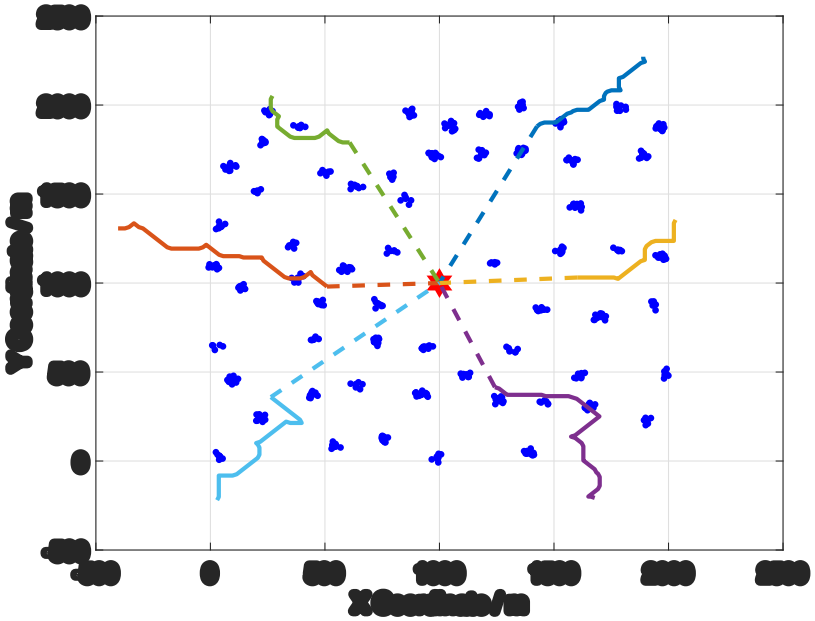

(b) 从区域外出发、返回点位于中心的 UAV 路径图

图 4.11　无人机路径单次仿真示意图（16 角度）

增加为 60 个，但依然可以成功覆盖全部用户，这是因为 UAV 的平均移动距离更短，在同样的能量约束下能够更容易地满足用户覆盖。

不同角度可选集下的平均用户覆盖率如图4.12所示，其中横轴为 4、8、16、32 角度可选集。由于最大和速率 NOMA 对比算法不受角度可选集影响，因此其覆盖率始终在 80% 左右。可以观察到，不论是单位时间内仅服务单用户的算法还是兼容单用户与 NOMA 的所提算法，在角度可选集在 4、8、16 不断增加时，相应的用户覆盖率都会提高，这是由于转向损耗变小造成的。当角度可选集为

中国知网　https://www.cnki.net

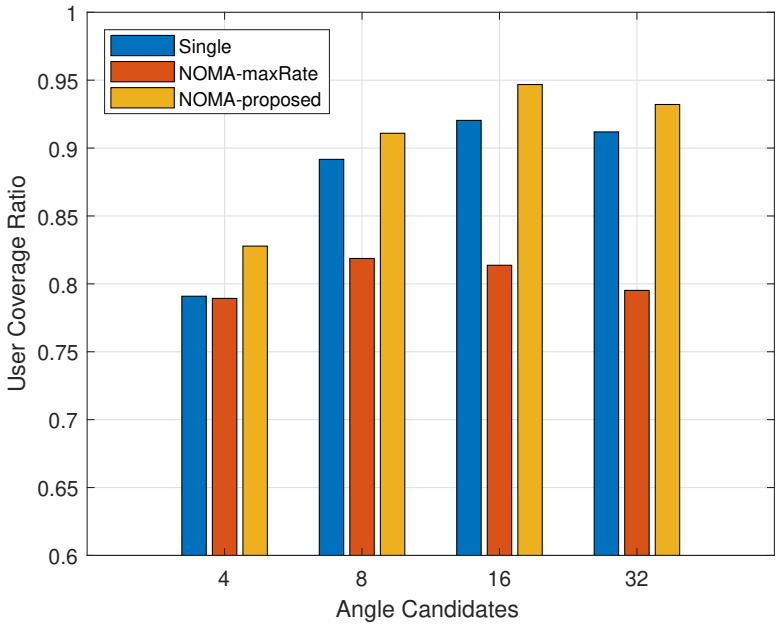

图 4.12　不同角度可选集下的平均用户覆盖率

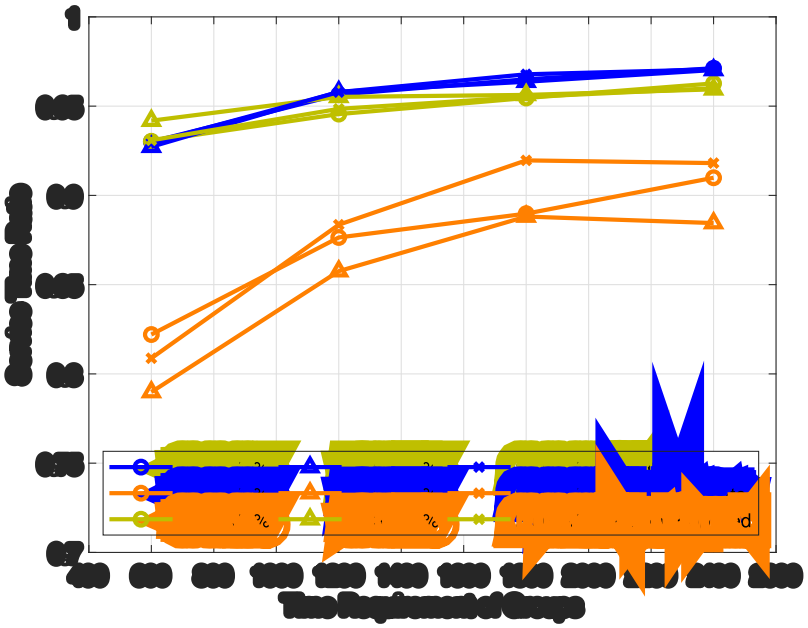

图 4.13　不同用户簇服务时长需求与速率需求下的服务时间比率

32 时，用户覆盖率会略微降低，这是因为过于相近的可选角度可能会使转向更为频繁，这也与第三章中结论相一致。仿真结果表明，所提出的兼容单用户与 NOMA 的算法在不同的角度可选集时，在用户覆盖率上相比于对比算法都有明显的提升。

图4.13给出了不同用户簇服务时长需求、不同速率需求分布下的平均服务时间比率。其中服务时间比率的定义与前述研究相同，即 UAV 为用户提供服务的

中国知网　https://www.cnki.net

总时长与 UAV 回到充电站时的工作总时长之比。可以看到，在用户簇服务时长需求增加时，平均服务时间比率都会增加，但结合图4.10中相同场景假设的仿真可知，是平均覆盖率降低导致的，即高服务时长需求使 UAV 花费了更多时间来满足用户需求，而这导致了 UAV 服务的总用户数变少。由于用户成簇分布，同簇内用户距离相近，利用第三章中所提算法，即单位时间内仅服务单个用户时，相比于随机均匀分布的用户场景，UAV 用于飞行的时间占比会变得更少。因此，其可以达到很高的服务时间比率，且用户服务时长需求越高则越明显。此外，仿真结果表明，尽管所提出的兼容单用户与 NOMA 的算法在服务时间比率上略逊色于仅服务单用户的算法，但图4.10证明了在相同假设条件下，本章所提算法在覆盖率上的优越性。

4.6　本章小结

在本章的研究中，针对热点通信场景中的多无人机路径规划问题，目标依然是最大化覆盖空洞区域内的用户覆盖率。由于 UAV 的观测范围受限，路径规划问题被建模为一个受约束的 Dec-POMDP 问题，并基于演员评论家网络提出了一种兼容单用户与 NOMA 连接的 MARL 算法进行求解。为了解决引入 NOMA 技术后，UAV 的用户分配动作空间维度增加且难以训练的问题，采用扩展加权二分图表征 UAV 与用户的潜在连接关系，基于改进的二分图最大权重匹配 K-M 算法来实现用户匹配，并将其引入演员评论家网络架构中，从而显著降低动作空间维度。仿真结果表明，对于成簇分布的用户，所提出的方法相较于对比算法能够实现更高的用户覆盖率，并且能够保证较高的通信效率。

中国知网　https://www.cnki.net

第 5 章　总结与展望

5.1　本文工作总结

本论文探讨了基于无人机辅助无线通信的两大典型覆盖空洞场景中，目标为提升用户覆盖率的多无人机路径规划和资源分配问题的优化方法。将每章的内容概括总结如下：

在第一章中，首先阐明了特定场景下覆盖空洞带来的通信问题，强调了开展多 UAV 路径规划与资源分配研究的必要性，并指出能量受限条件下 UAV 所面临的关键挑战。围绕相关研究问题，对国内外研究现状进行了系统梳理，分析了在应急通信与热点通信两类典型应用场景中现有 MARL 方法的局限性，进而明确了本研究的目标方向。通过绘制研究内容的组织架构图，对全文的研究内容进行了清晰概述。

在第二章中，系统梳理了本研究所依赖的理论模型与数学工具。深入分析了强化学习的基本概念及深度强化学习的数学建模与推导过程，并对多智能体强化学习的核心概念、工作机制、基本数学模型及其组织架构进行了概括性介绍，为后续章节的算法设计与问题求解提供了坚实的理论支撑与数学基础。

在第三章中，研究了应急通信场景下的多 UAV 路径规划问题，旨在最大化覆盖空洞区域内的用户覆盖率。该问题被建模为受约束的马尔可夫决策过程，在建模过程中充分考虑了 UAV 的能耗特性，并将离散动作空间中常被忽略的转向控制因素纳入模型设计。为高效求解该问题，引入了基于 QMIX 的多智能体强化学习算法。仿真结果表明，该方法在提升用户覆盖率和通信效率方面具有显著优势，转向控制策略的引入也有效提升了 UAV 的能量利用效率，使其能够覆盖更广区域，服务更多用户。

在第四章中，围绕热点通信场景下的多 UAV 路径规划问题展开研究，目标依然是最大化覆盖空洞区域中的用户覆盖率。为提升资源利用效率，引入 NOMA 技术以加速用户覆盖，但同时也对 UAV 的用户分配带来了新的挑战。考虑到 UAV 观测范围的局限性，将该问题建模为一个受约束的 Dec-POMDP，并基于演员-评论家网络设计了一种兼容 NOMA 用户分配机制的多智能体强化学习算法。针对 NOMA 引发的高维动作空间问题，将用户分配模块从决策网络中剥离，结合扩展的加权二分图方法，实现了 UAV 与用户的高效实时匹配。仿真结果表明，针对成簇分布的用户，所提方法在提升用户覆盖率的同时，仍保持了较高的通信效率，展现出良好的性能优势。

综上所述，本文围绕应急通信与热点通信两类典型覆盖空洞场景，分别设计了基于多智能体强化学习的多 UAV 路径规划与资源分配优化方法，有效提升了

中国知网　https://www.cnki.net

能量受限 UAV 在复杂环境下的通信覆盖能力，为实现高效、智能的空中通信系统构建了切实可行的技术方案。

5.2　未来研究展望

在未来的研究中，随着算法技术的不断进步以及硬件性能的显著提升，当前 UAV 在复杂约束下面临的大维度动作空间难以训练的问题将逐渐成为历史。这一进展将推动智能决策体系的发展，尤其是在多层级高维度决策的优化方面，使得 UAV 能够在更复杂的环境中实现更为精准和高效的决策。随着高效算法和更强大的计算能力的引入，UAV 能够更加灵活地处理更加复杂的约束条件，从而进一步提升系统的性能与效能。

进一步地，在现有的 UAV 连续动作决策优化方案的研究中，可以加入更加贴近实际场景需求的约束条件，特别是在如灾后应急通信，敏感区域（如战场等）覆盖，以及未来的太赫兹系统中。这些约束将帮助 UAV 在执行任务时，不仅能进行连续的动作决策，还能够兼顾实际应用中的需求，从而进一步提升任务完成的可靠性，为研究落地提供可能。

此外，随着 UAV 技术和通信技术的不断进步，利用 UAV 作为移动基站对目标用户群进行自主跟踪，进而实现 6G 网络中“在任何位置乃至太空都有无线通信覆盖”的愿景，尤其是在灾害应急通信和偏远地区网络覆盖方面，也是未来可行的研究方向之一。

总的来说，在未来的研究中，将不仅限于 UAV 的路径规划和资源分配优化，还将着重于如何提升 UAV 在不同环境下的适应能力，以应对多层级高维度的复杂任务。这要求进一步提高 UAV 的自主决策能力和智能化水平，以更好地应对未来多变的环境和复杂的应用场景。

中国知网　https://www.cnki.net

参考文献

[1] MAHESHWARI A, CHAND N. A survey on wireless sensor networks coverage problems[C]// Proceedings of 2nd International Conference on Communication, Computing and Networking, ICCCN 2018, Chandigarh, INDIA, March 29-30, 2018. Springer.

[2] WANG Q, LI W, YU Z, et al. An overview of emergency communication networks[J]. Remote Sensing, 2023, 15(6): 1595.

[3] 3rd Generation Partnership Project. TS 38.211: Technical specification group radio access network; NR; physical channels and modulation(release 16): 38.211[S/OL]. 3GPP, 2020. https://www.3gpp.org/ftp/Specs/archive/38_series/38.211/.

[4] BANAFAA M, SHAYEA I, DIN J, et al. 6G mobile communication technology: Requirements, targets, applications, challenges, advantages, and opportunities[J]. Alexandria Engineering Journal, 2023, 64: 245-274.

[5] BOR-YALINIZ I, YANIKOMEROGLU H. The new frontier in RAN heterogeneity: Multi-tier drone-cells[J]. IEEE Communications Magazine, 2016, 54(11): 48-55.

[6] FAN Y, SU T, CHEN Z. Emergency communication network coverage method based on UAV self-organizing wireless communication technology[C]//2023 IEEE 6th International Conference on Pattern Recognition and Artificial Intelligence (PRAI), Haikou, China, August 18-20, 2023. IEEE.

[7] GOMEZ-DELAHIZ J, FAKHREDDINE A, MURILLO J, et al. Joint optimization of throughput and energy consumption in microservices-based UAV networks[C]//IEEE INFOCOM 2024 - IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS), Vancouver, BC, Canada, May 20, 2024. IEEE.

[8] ZAKI-HINDI A, AMORIM R, KOVACS I Z, et al. Uplink coexistence for high throughput UAVs in cellular networks[C]//2022 IEEE Global Communications Conference (GLOBECOM), Rio de Janeiro, Brazil, December 04-08, 2022. IEEE.

[9] OKERE E E, BALYAN V. Sixth generation enabling technologies and machine learning intersection: A performance optimization perspective[J]. Future Internet, 2025, 17(2): 50.

[10] PUSPITASARI A A, AN T T, ALSHARIF M H, et al. Emerging technologies for 6G communication networks: Machine learning approaches[J]. Sensors, 2023, 23(18): 7709.

[11] CICEK C T, GULTEKIN H, TAVLI B, et al. UAV base station location optimization for next generation wireless networks: Overview and future research directions[C]//2019 1st International Conference on Unmanned Vehicle Systems-Oman (UVS), Sultan Qaboos Univ, Muscat, Oman, February 5-7, 2019.

中国知网 https://www.cnki.net

[12] ZHAO N, LIU Z, CHENG Y. Multi-agent deep reinforcement learning for trajectory design and power allocation in multi-UAV networks[J]. IEEE Access, 2020, 8: 139670-139679.

[13] GUPTA L, JAIN R, VASZKUN G. Survey of important issues in UAV communication networks[J]. IEEE communications surveys & tutorials, 2015, 18(2): 1123-1152.

[14] ALZENAD M, EL-KEYI A, LAGUM F, et al. 3-D placement of an unmanned aerial vehicle base station (UAV-BS) for energy-efficient maximal coverage[J]. IEEE Wireless Communications Letters, 2017, 6(4): 434-437.

[15] WU Q Q, ZENG Y, ZHANG R. Joint trajectory and communication design for multi-UAV enabled wireless networks[J]. IEEE Transactions on Wireless Communications, 2018, 17(3): 2109-2121.

[16] ZENG S, ZHANG H, SONG L. Trajectory optimization and resource allocation for multi-user OFDMA UAV relay networks[C]//2019 IEEE Global Communications Conference (GLOBECOM), Waikoloa, HI, USA, December 9-13, 2019. IEEE.

[17] ZENG S H, ZHANG H L, DI B Y, et al. Trajectory optimization and resource allocation for OFDMA UAV relay networks[J]. IEEE Transactions on Wireless Communications, 2021, 20 (10): 6634-6647.

[18] QIN X T, SONG Z Y, HAO Y Y, et al. Joint resource allocation and trajectory optimization for multi-UAV-assisted multi-access mobile edge computing[J]. IEEE Wireless Communications Letters, 2021, 10(7): 1400-1404.

[19] LI Y B, ZHANG H J, LONG K P, et al. Joint resource allocation and trajectory optimization with QoS in UAV-based NOMA wireless networks[J]. IEEE Transactions on Wireless Communications, 2021, 20(10): 6343-6355.

[20] ARULKUMARAN K, DEISENROTH M P, BRUNDAGE M, et al. Deep reinforcement learning[J]. IEEE Signal Processing Magazine, 2017, 34(6): 26-38.

[21] FERIANI A, HOSSAIN E. Single and multi-agent deep reinforcement learning for AI-enabled wireless networks: A tutorial[J]. IEEE Communications Surveys and Tutorials, 2021, 23(2): 1226-1252.

[22] ZENG Y, ZHANG R, LIM T J. Wireless communications with unmanned aerial vehicles: Opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.

[23] WANG Q, ZHANG W Q, LIU Y W, et al. Multi-UAV dynamic wireless networking with deep reinforcement learning[J]. IEEE Communications Letters, 2019, 23(12): 2243-2246.

[24] 杜威, 丁世飞. 多智能体强化学习综述[J]. 计算机科学, 2019, 46(08): 1-8.

[25] 孙彧, 曹雷, 陈希亮, 等. 多智能体深度强化学习研究综述[J]. 计算机工程与应用, 2020, 56(05): 13-24.

[26] OROOJLOOY A, HAJINEZHAD D. A review of cooperative multi-agent deep reinforcement

中国知网 https://www.cnki.net

learning[J]. Applied Intelligence, 2023, 53(11): 13677-13722.

[27] CHEN Y J, LIAO K M, KU M L, et al. Multi-agent reinforcement learning based 3d trajectory design in aerial-terrestrial wireless caching networks[J]. IEEE Transactions on Vehicular Technology, 2021, 70(8): 8201-8215.

[28] CHEN W, CHANG D K, CHEN Y J. Trajectory control in self-sustainable UAV-aided mmWave networks: A constrained multi-agent reinforcement learning approach[C]//2022 IEEE International Conference on Communications Workshops, Seoul, South Korea, May 16-20, 2022. IEEE.

[29] ZENG Y, ZHANG R. Energy-efficient UAV communication with trajectory optimization[J]. IEEE Transaction on Wireless Communications, 2017, 16(6): 3747-3760.

[30] SALEHI S, HASSAN J, BOKANI A, et al. A QoS-aware, energy-efficient trajectory optimization for UAV base stations using Q-learning[C]//2020 19TH ACM/IEEE International Conference on Information Processing in Sensor Networks (IPSN 2020), Sydney, Australia, April 21-24, 2020. IEEE.

[31] CHEN B, LIU D, HANZO L. Decentralized trajectory and power control based on multi-agent deep reinforcement learning in UAV networks[C]//ICC 2022-IEEE International Conference on Communications, Seoul, South Korea, May 16-20,2022. IEEE.

[32] ZHANG L, HE C, PENG Y, et al. Multi-UAV data collection and path planning method for large-scale terminal access[J]. Sensors, 2023, 23(20): 8601.

[33] 王斯略. 基于协作 UAV 的节能路径规划[D]. 西安电子科技大学, 2020.

[34] WANG L, WANG K, PAN C, et al. Deep reinforcement learning based dynamic trajectory control for UAV-assisted mobile edge computing[J]. IEEE Transactions on Mobile Computing, 2021, 21(10): 3536-3550.

[35] WANG Y, GAO Z, ZHANG J, et al. Trajectory design for UAV-based internet of things data collection: A deep reinforcement learning approach[J]. IEEE Internet of Things Journal, 2021, 9(5): 3899-3912.

[36] ZENG Y, XU X. Path design for cellular-connected UAV with reinforcement learning[C]//2019 IEEE Global Communications Conference (GLOBECOM), Waikoloa, HI, USA, December 9-13, 2019. IEEE.

[37] WANG S, QI N, JIANG H, et al. Trajectory planning for UAV-assisted data collection in IoT network: A double deep Q network approach[J]. Electronics, 2024, 13(8): 1592.

[38] ZHAN C, ZENG Y. Aerial-ground cost tradeoff for multi-UAV-enabled data collection in wireless sensor networks[J]. IEEE Transactions on Communications, 2020, 68(3): 1937-1950.

[39] SHEN C, CHANG T H, GONG J, et al. Multi-UAV interference coordination via joint trajectory and power control[J]. IEEE Transactions on Signal Processing, 2020, 68: 843-858.

中国知网 https://www.cnki.net

[40] LI J, ZHAI X B, QIAN H Y, et al. Joint trajectory design and power allocation in NOMA-based UAV networks[J]. IEEE Transactions on Vehicular Technology, 2024, 73(2): 2345-2357.

[41] CHEN G, ZHAI X B, LI C. Joint optimization of trajectory and user association via reinforcement learning for UAV-aided data collection in wireless networks[J]. IEEE Transactions on Wireless Communications, 2022, 22(5): 3128-3143.

[42] FU C W, KU M L, CHEN Y J, et al. UAV trajectory, user association, and power control for multi-UAV-enabled energy-harvesting communications: Offline design and online reinforcement learning[J]. IEEE Internet of Things Journal, 2024, 11(6): 9781-9800.

[43] SHIRVANIMOGHADDAM M, DOHLER M, JOHNSON S J. Massive non-orthogonal multiple access for cellular IoT: Potentials and limitations[J]. IEEE Communications Magazine, 2017, 55(9): 55-61.

[44] NEELAM M, SUNDRU A. Comparative analysis of UAV-OMA and UAV-NOMA techniques for 6G networks[C]//2024 OPJU International Technology Conference (OTCON) on Smart Computing for Innovation and Advancement in Industry 4.0, Raigarh, India, June 5-7, 2024. IEEE.

[45] 邵晓强. 非正交多址系统中的设备成簇和资源管理[D]. 西安电子科技大学, 2020.

[46] QIN P, FU Y, ZHANG J, et al. DRL-based resource allocation and trajectory planning for NOMA-enabled multi-UAV collaborative caching 6G network[J]. IEEE Transactions on Vehicular Technology, 2024, 73(6): 8750-8764.

[47] LU Y, LUO Z, GAO Z, et al. Throughput maximization in multi-UAV NOMA networks based on deep reinforcement learning[C]//2023 2nd International Conference on Computing, Communication, Perception and Quantum Technology (CCPQT), Xiamen, China, August 4-7, 2023. IEEE.

[48] MONTAGUE P. Reinforcement learning: An introduction, by Sutton, R.S. and Barto, A.G. [J]. Trends in cognitive sciences, 1999, 3(9): 360.

[49] SUTTON R S, SZEPESVÁRI C, MAEI H R. A convergent O(n) algorithm for off-policy temporal-difference learning with linear function approximation[J]. Advances in neural information processing systems, 2008, 21(21): 1609-1616.

[50] SUTTON R S, MAEI H R, PRECUP D, et al. Fast gradient-descent methods for temporal-difference learning with linear function approximation[C]//Proceedings of the 26th Annual International Conference on Machine Learning, Montreal, Quebec, Canada, June 14-18, 2009. ACM.

[51] GRONDMAN I, BUSONIU L, LOPES G A, et al. A survey of actor-critic reinforcement learning: Standard and natural policy gradients[J]. IEEE Transactions on Systems, Man, and Cybernetics, part C (applications and reviews), 2012, 42(6): 1291-1307.

中国知网 https://www.cnki.net

[52] ZHANG K, YANG Z, BAŞAR T. Multi-agent reinforcement learning: A selective overview of theories and algorithms[J]. Handbook of Reinforcement Learning and Control, 2021: 321-384.

[53] NGUYEN T T, NGUYEN N D, NAHAVANDI S. Deep reinforcement learning for multiagent systems: A review of challenges, solutions, and applications[J]. IEEE Transactions on Cybernetics, 2020, 50(9): 3826-3839.

[54] LOWE R, WU Y, TAMAR A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]//Advances in Neural Information Processing Systems 30 (NIPS 2017), Long Beach, CA, USA, December 4-9, 2017. NIPS.

[55] MOZAFFARI M, SAAD W, BENNIS M, et al. Drone small cells in the clouds: Design, deployment and performance analysis[C]//2015 IEEE Global Communications Conference (GLOBECOM), San Diego, CA, USA, December 6-10, 2015. IEEE.

[56] FILIPPONE A. Flight performance of fixed and rotary wing aircraft[M]. Elsevier, 2006.

[57] GUNDLACH J. Designing unmanned aircraft systems[M]. American Institute of Aeronautics & Astronautics Reston, VA, USA, 2014.

[58] YAO J J, ANSARI N. Online task allocation and flying control in fog-aided internet of drones [J]. IEEE Transactions on Vehicular Technology, 2020, 69(5): 5562-5569.

[59] HOSEINI S A, HASSAN J, BOKANI A, et al. Trajectory optimization of flying energy sources using Q-learning to recharge hotspot UAVs[C]//IEEE INFOCOm 2020-IEEE conference on computer communications workshops (INFOCOm WKSHPS), Electr Network, July 6-9, 2020. IEEE.

[60] CHRISTIANSEN D. Announcing amazing micro-mouse maze contest[J]. IEEE Spectrum, 1977, 14(5): 27-27.

[61] All Japan micromouse 2017[EB/OL]. 2017. https://micromouseonline.com/2017/11/26/japan-micromouse-2017/.

[62] RASHID T, SAMVELYAN M, DE WITT C S, et al. Monotonic value function factorisation for deep multi-agent reinforcement learning[J]. Journal of Machine Learning Research, 2020, 21(178): 1-51.

[63] SAITO Y, KISHIYAMA Y, BENJEBBOUR A, et al. Non-orthogonal multiple access (NOMA) for cellular future radio access[C]//2013 IEEE 77th Vehicular Technology Conference (VTC Spring), June 2-5 , Dresden, Germany, 2013. IEEE.

[64] DING Z G, YANG Z, FAN P Z, et al. On the performance of non-orthogonal multiple access in 5G systems with randomly deployed users[J]. IEEE Signal Processing Letters, 2014, 21 (12): 1501-1505.

[65] ZHAO N, PANG X W, LI Z, et al. Joint trajectory and precoding optimization for UAV-assisted NOMA networks[J]. IEEE Transactions on Communications, 2019, 67(5): 3723-3735.

中国知网 https://www.cnki.net

[66] PANG X, TANG J, ZHAO N, et al. Energy-efficient design for mmWave-enabled NOMA-UAV networks[J]. Science China Information Sciences, 2021, 64: 1-14.

[67] LIN Y, FENG W, WANG J, et al. User fairness optimization for multi-UAV-aided NOMA networks: A location-aware perspective[C]//2021 IEEE Global Communications Conference (GLOBECOM), Madrid, Spain, December 07-11, 2021. IEEE.

[68] TSE D, VISWANATH P. Fundamentals of wireless communication[M]. Cambridge university press, 2005.

[69] KUHN H W. The hungarian method for the assignment problem[J]. Naval research logistics quarterly, 1955, 2(1-2): 83-97.

[70] MUNKRES J. Algorithms for the assignment and transportation problems[J]. Journal of the society for industrial and applied mathematics, 1957, 5(1): 32-38.

[71] SILVER D, LEVER G, HEESS N, et al. Deterministic policy gradient algorithms[C]// Proceedings of the 31st International Conference on Machine Learning, Bejing, China, June 22-24,2014. PMLR.

[72] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.

中国知网 https://www.cnki.net