doi: 10.3969/j.issn.1007-7375.240136

基于深度多智能体强化学习的机床混流装配线调度优化

姜兴宇，陈嘉淇，王立权，徐伟宏

（沈阳工业大学 机械工程学院，辽宁 沈阳 110023）

摘要: 为保证机床混流装配车间生产的机床准时交付，提出一种基于改进的深度多智能体强化学习的机床混流装配线调度优化方法，以解决最小延迟生产调度优化模型求解质量低、训练速度缓慢问题，构建以最小延迟时间目标的混流装配线调度优化模型，应用去中心化分散执行的双重深度 Q 网络 (double deep Q network，DDQN) 的智能体来学习生产信息与调度目标的关系。该框架采用集中训练与分散执行的策略，并使用参数共享技术，能处理多智能体强化学习中的非稳态问题。在此基础上，采用递归神经网络来管理可变长度的状态和行动表示，使智能体具有处理任意规模问题的能力。同时引入全局/局部奖励函数，以解决训练过程中的奖励稀疏问题。通过消融实验，确定了最优的参数组合。数值实验结果表明，与标准测试方案相比，本算法在目标达成度方面，平均总延迟工件数较改善前提升了 24.1%～32.3%，训练速度提高了 8.3%。

关键词: 机床混流装配线；深度多智能体强化学习；递归神经网络；全局/局部奖励函数

中图分类号: TP391; F406.2　　**文献标志码:** A　　**文章编号:** 1007-7375(2025)04-0015-09

Scheduling Optimization for Mixed-flow Assembly Lines of Machine Tools Based on Deep Multi-agent Reinforcement Learning

JIANG Xingyu, CHEN Jiaqi, WANG Liquan, XU Weihong

(School of Mechanical Engineering, Shenyang University of Technology, Shenyang 110023, China)

Abstract: In order to ensure the on-time delivery of machine tools in mixed-flow assembly shops, a scheduling optimization method based on improved deep multi-agent reinforcement learning is proposed, aiming to to address the low solution quality and slow training speed in minimizing production delays. A scheduling optimization model for mixed-flow assembly lines is constructed with the objective of minimizing delay time, where double deep Q network (DDQN) agents with decentralized execution are applied to learn the relationship between production information and scheduling objectives. The framework adopts the strategies of centralized training and decentralized execution, utilizing parameter sharing to deal with the non-stationary problem in multi-agent reinforcement learning. On this basis, a recurrent neural network is used to manage variable-length state and action representations, enabling agents to handle problems of arbitrary scale. A global/local reward function is also introduced to solve the reward sparsity problem in the training process. The optimal parameter combinations are identified through ablation experiments. Numerical experimental results show that, compared with the standard benchmarks, the proposed algorithm improves the average total delay of workpieces by 24.1% to 32.3% compared to before the improvement, and the training speed increased by 8.3% in terms of the achievement of the objective.

Key words: machine tool mixed-flow assembly line; deep multi-agent reinforcement learning; recurrent neural network; global/local reward function

机床装配是机床制造的最后环节，直接决定机床的质量与性能。机床产品类型多，结构与装配工艺复杂，制造周期长，在装配过程中存在各种不确定因素。尤其是面临多种系列机床的大批订单或复

收稿日期： 2024-03-31

基金项目： 辽宁省“揭榜挂帅”科技计划资助项目 (2022JH1/10800061)；辽宁省教育厅高校基础科研重点攻关资助项目 (LJKZZ20220023)；沈阳市科学技术计划资助项目 (23-503-6-01)

作者简介： 姜兴宇 (1980－)，男，辽宁省人，教授，主要研究方向为智能制造技术及人机交互优化。
Email: xy_jiang9211@sut.edu.cn

中国知网 https://www.cnki.net

杂装配任务时，装配工人必须迅速准确地获取待装配机床的装配序列信息，以减少延迟并提高交付率，避免因流程堵塞或装配设备故障导致的生产中断。因此，如何针对最小工件延迟问题制定合理的装配调度方案，对于缩短复杂机床产品的制造周期，提高机床生产的准时交付能力具有重要的现实意义。

在混合流装配线的排序和准时交付问题上，现有研究主要集中在启发式规则和算法优化上[1-2]。例如，李燚等[3]通过改进蚁群算法解决汽车混流装配调度模型问题，该算法在信息素全局更新以及概率转移规则过程中使用特定启发式函数，并更改迭代过程中最优解的评价方法。李思瀚等[4]通过结合缓冲时间插入策略和抽样仿真技术，采用非支配排序遗传算法 (nondominated sorting genetic algorithm II，NSGA-II)，实现了质量鲁棒性和解的鲁棒性的双重优化目标，有效缩短了交付周期并减少了等待浪费。Cano-Belmán 等[5]提出一种基于散射搜索的超启发式方法，用于解决混合模型装配线的排序问题，该方法在低级别使用优先级规则通过构造程序。Belkharroubi 等[6]使用混合反应式贪婪随机自适应搜索程序 (hybrid reactive greedy randomized adaptive search procedure, HRGRASP) 解决混合模型装配线平衡问题类型。尽管智能算法能够利用其全局搜索能力找到更优的解决方案，但其计算时间的需求往往过大，不适合多系列大批量情境下的机床生产。启发式规则虽然可以在较短时间内提供合理的调度方案，但对于不同的调度问题，单一规则的适应性通常较差，并且随着作业规模的增加，计算时间也会大幅度上升。

随着人工智能技术发展，越来越多的学者开始关注基于深度强化学习的智能优化调度的研究。例如，郭具涛等[7]提出一种基于复合规则和强化学习的混流装配线调度方法，该方法利用近端策略优化 (proximal policy optimization, PPO) 算法和强化学习过程，对复合规则权值参数进行调控优化，生成平衡与排序方案。张中伟等[8]利用深度强化学习技术，针对柔性作业车间的节能调度问题，开发了一种智能调度算法，有效减少了能耗和提升了生产效率。Deng 等[9]提出一种具有强化学习 (reinforcement learning, RL) 功能的三维分布估计算法 (estimation of distribution algorithm, EDA)，以在最大限度提高模糊分布式混合流车间交货准确性的同时，最小化工期和总能耗。Li 等[10]开发了一种基于双深 Q 网络的协同演化 (double deep Q-network-based co-evolution, D2QCE)，以求解最小化总加权延迟和总能耗分布式异构混合流程车间调度问题 (distributed heterogeneous hybrid flow shop scheduling problem with multiple priorities of jobs, DHHFSP-MPJ)。Zhang 等[11]提出一种基于 Q-learning 的超启发式进化算法 (Q-learning-based hyper-heuristic evolutionary algorithm, QLHHEA) 来求解分布式装配阻塞流水车间调度问题 (distributed assembly blocking flowshop scheduling problem, DABFSP)，其目标是最小化最大完工时间。强化学习算法通过持续学习环境中的奖励回报函数，能够根据调度问题的实时状态作出合理决策。然而，随着调度问题的变化，需要对模型进行重新训练，这会影响到问题求解的实时性，难以快速应对外部变化的环境。

综上，现有研究在解决调度问题上，智能算法能够利用其全局搜索能力找到更优的解决方案，强化学习算法通过持续学习环境中的奖励回报函数，能够根据调度问题的实时状态作出合理动作，能够提高求解的实时性，但仍未达到预期效果。主要存在如下问题。

1) 智能算法在处理不同调度问题时，若只依赖单一规则，通常难以适应复杂多变的情况，且随着作业规模的扩大，所需的计算时间也会成倍增长。这就要求在算法设计过程中必须考虑算法的扩展性。

2) 传统强化学习面临调度问题的规模变化时，算法复杂度会提高，影响调度实时性。多智能体强化学习还面临环境变化导致训练非稳态问题。此外，传统强化学习的奖励方式会在训练过程中产生奖励稀疏性，从而影响算法的收敛速度。

基于此，本文提出一种基于深度多智能体强化学习的机床混流装配线调度优化方法，构建以最小延迟时间为目标的混流装配线调度优化模型，应用集中训练和机床分散执行方案以及参数共享技术[12]，构建多智能体训练框架，引入可变长度的状态和行动表示，并运用基于递归神经网络的 Q 网络进行训练，确保该算法能够处理不同的任务。为解决训练过程中的奖励稀疏问题，加入了全局/局部奖励函数 (global/local reward function, GLRF)，以加快多智

中国知网 https://www.cnki.net

能体的训练速度，最终通过对优化前后的混流装配线历史生产数据进行训练与试验，验证优化方案的可行性与实用性，形成装配调度系统最小延迟时间生产目标的调度方案。

1　机床混流装配线调度优化模型

1.1　问题描述

机床混流装配线有 n 台待装配机床，它们将在生产线上经过 M 个装配阶段。每个阶段有一个或多个多能工可供选择，至少有一个阶段包含多个具有相同装配任务的工人。每台机床都将依次通过 M 个阶段进行装配。在任何阶段，可选择一名工人对当前阶段的机床进行装配。在任何阶段，机床都可以在该阶段的任一工作台上进行装配。在任何给定时刻，一台机床只能在一个工作台上进行装配，每个工作台也只能装配一台机床。假设装配过程中的损耗时间可以忽略不计，一旦开始装配就不能中断。所有工作台上的装配人员都在持续工作，任意相邻两个阶段之间都有无限的缓冲区。本文目标是确定所有机床的装配顺序和各个工序中选择的装配工作台，使得总的作业延迟时间最小化。

本文以车铣复合车削中心机床产品的混流装配流水线为研究对象，每种机床都是由几种不同的零件装配而成。每个装配阶段都有一定数量的并行机台和装配工人，每台机床都要经过相同的装配流水线。装配时，所有的零件都可以在零时刻到达，一台待装配机床任意时刻只能在一个阶段装配。根据以上生产特点，本文对机床产品混流装配线装配生产问题提出以下假设。

1) 每个工作台一次只能装配一台机床；

2) 准备时间包含在装配时间之中；

3) 机床在工作台上装配时，不允许中断；

4) 工序不能预订；

5) 一个装配任务不能同时在不同工作台上进行装配；

6) 所有工作台可以连续装配。

1.2　数学模型

本文使用数学符号的含义如表 1 所示。

搭建机床混流装配线最小总延迟时间问题的数学模型。式 (1) 为目标函数，表示最小化延迟时间的目标函数。式 (2) 为决策变量，表示机床 i 在第 j 阶段是否选择被分到第 k 名工人装配。

表 1　模型参数说明

Table 1　Description of model parameters

参数符号	符号说明
n	待装配机床台数
J_i	第 i 台待装配机床
M_i	第 i 台机床的装配阶段数
P_{ij}	第 i 台机床的第 j 个装配阶段
W	工人的数量
U_k	第 k 名工人的利用率
S_{ij}	第 i 台机床在第 j 阶段的开始时间
C_{ij}	第 i 台机床在第 j 阶段的结束时间
λ_{ijk}	第 i 台机床在第 j 阶段的第 k 名工人
t_{ijk}	第 i 台机床在第 j 阶段工人 k 的装配时间
t_k^{j+1}	工人任务序列中下一个作业的操作时间
D_i	第 i 台机床的交货截止时间
L_{ij}	机床 i 在第 j 阶段的松弛时间
T_{ij}	机床 i 在第 j 阶段交货截止期剩余时间
A_{ij}	机床 i 在第 j 操作阶段完成后剩余的需要装配的时间
R	仿真时的实时时间
E_t	期待的操作的加工时间
E_{interval}	期待作业到达的间隔时间
Y_i	第 i 台机床的延迟时间

$$f=\min\sum_{i=1}^{n}Y_i,\ \ i\in(1,2,\cdots,n)。\tag{1}$$

$$\lambda_{ijk}=\begin{cases}1,\ \text{机床}i\text{第}j\text{阶段选择第}k\text{名工人装配；}\\0,\ \text{其他。}\end{cases}\tag{2}$$

s.t.

$$C_{ij}=S_{ij}+T_{ij}\lambda_{ijk}U_k；\tag{3}$$

$$U_k=\frac{E_t}{E_{\text{interval}}}\times 100\%；\tag{4}$$

$$\sum_{k=1}^{n}\lambda_{ijk}=1,\ \ i\in(1,2,\cdots,m)；\tag{5}$$

$$\lambda_{ijk}=1,\ \ C_{i-1j}<S_{ij},\ \ i\in(1,2,\cdots,m)；\tag{6}$$

$$\lambda_{ijk}=1,\ \ C_{ij-1}<S_{ij},\ \ i\in(1,2,\cdots,n)；\tag{7}$$

$$Y_i=\max\,(C_{im}-D_i,\ 0),\ \ i\in(1,2,\cdots,m)；\tag{8}$$

$$L_{ij}=T_i-A_{ij}；\tag{9}$$

$$T_{ij}=D_i-R；\tag{10}$$

中国知网　https://www.cnki.net

$$A_{ij}=\sum_{j=j+1}^{O_i} t_{ij},\ i\in(1,2,\cdots,n)。\tag{11}$$

式 (3) 表示机床的每个装配阶段的过程是连续的，一旦被分配到工位上开始装配后不可中断。式 (4) 表示每个工位实际利用率。式 (5) 表示每台机床在同一装配阶段只能选择该阶段其中一个工位进行装配。式 (6) 表示工位约束，每个工位同一时刻只可装配一台机床，即该工位下一个需要装配机床的开始时间不得小于同一工位上一个装配机床完成的时间。式 (7) 表示机床开始装配的时间不能早于其在上一阶段结束时间。式 (8) 表示机床 J_i 的延迟时间。式 (9) 表示机床 J_i 在第 j 装配阶段的松弛时间。式 (10) 表示机床 J_i 在第 j 装配阶段离截止时间的剩余时长。式 (11) 表示机床 J_i 在 j 装配阶段离所有加工完成的剩余时间。

2 基于深度多智能体强化学习求解

针对上述目标函数与约束方程，将深度多智能体强化学习应用于机床混流装配线的生产调度问题。本文采取一个集中训练、分散执行的方法，所有智能体共享神经网络参数，使得调度任务保持一致性。算法框架如图 1 所示。首先，将调度问题转换为一个序列决策问题，这涉及到定义状态、动作、奖励以及探索和利用的策略。接着，使用基于深度多智能体强化学习 (deep multi-agent reinforcement learning, Deep MARL) 的算法，根据装配车间的历史生产数据来训练调度策略。最终，将策略应用于实际的装配任务，优化机床装配过程的调度。

在混流装配线中，每个工位都可以被视为一个马尔可夫决策过程 (Markov decision process, MDP)，每个工人代表一个状态，而在每个状态下可采取的动作则对应不同的工件装配顺序。以下是将调度问题建模为 MDP 的步骤。

2.1 状态空间

本文引入一种可变长度状态和行动表示法，这样深度强化学习 (deep reinforcement learning, DRL) 智能体就能在每个决策时间点计算出每项工作的综合优先级[13]。状态矩阵中的工作特征和工人特征如表 2 所示。

其中，$\boldsymbol{o}_k(t)=(t_{ijk}, D_j, L_{ij}, t_k^{j+1}, E_k)$ 表示每个工人当前观测到的状态，则混流装配车间的状态为所有智能体的观察状态集合 $\boldsymbol{o}(t)=(\boldsymbol{o}_1(t), \cdots, \boldsymbol{o}_k(t))$。加入此方法的优势在于状态矩阵的长度是可变的，当机床 J_i 被选中并分配给当前闲置工人 W_i 时，在时间点 t 相应的行会同时从状态矩阵 $\boldsymbol{o}_t$ 中删除，并在下一个决策点 t+1 时转移到状态矩阵 $\boldsymbol{o}_{t+1}$ 中。

2.2 动作空间

为提高每个工人的装配效率，本文按照复合规则库来计算每个作业的优先度，每个规则的权重根据当前状态来确定，使用 4 种常见的启发式规则 [SPT,LWKR,MS,WINQ]来计算每个工人的优先度，这些规则侧重于作业的不同方面，以确保候选作业至少拥有一项独特特征，使其比其他作业更紧急或更适合。具体启发式规则含义如下。

1) SPT (shortest processing time)：优先选择处理时间最短的任务。

2) LWKR (least work remaining)：优先选择剩余工作量最少的任务。

3) MS (minimal slack)：选择最紧急的作业。

4) WINQ (work in queue)：选择下一个操作工人工作量最少的作业。

动作空间的大小等于现在可执行工序数目的大小。运用智能体向前传播矩阵计算出一个大小为 q 元素的矩阵，每个元素对应着可执行工序数的优先级，然后通过 SoftMax 函数转化为选择工人的概率。

动作的执行采用贪婪策略，在训练阶段，从动作空间中以 $1-\varepsilon$ 的概率执行动作 a_i 选择具有最高优先度的工人，以 ε 的概率随机选择一个工人。在执行阶段，从经验回放库中选择值最高的动作。

2.3 奖励函数

传统车间调度问题中，奖励函数的设计通常是在所有作业的操作都已排定，并且作业的延迟时间确定后，才给予最终的奖励。这种设计忽略了作业排序过程中每个动作的优劣，导致训练过程中出现奖励稀疏性问题，从而延长了智能体的训练时间。为解决这个问题，需要补充局部反馈来加速训练过程，本文加入全局/局部奖励函数 (GLRF) 用于平衡奖励。$F_1(t)$ 代表全局奖励函数；γ_1 是一个大的折扣因子，$\gamma_1\in[0.999,1]$；$F_2(t)$ 是局部奖励；γ_2 是一个较小的折扣因子，$\gamma_2\in[0,0.001]$；τ 为时间的步长。

中国知网 https://www.cnki.net

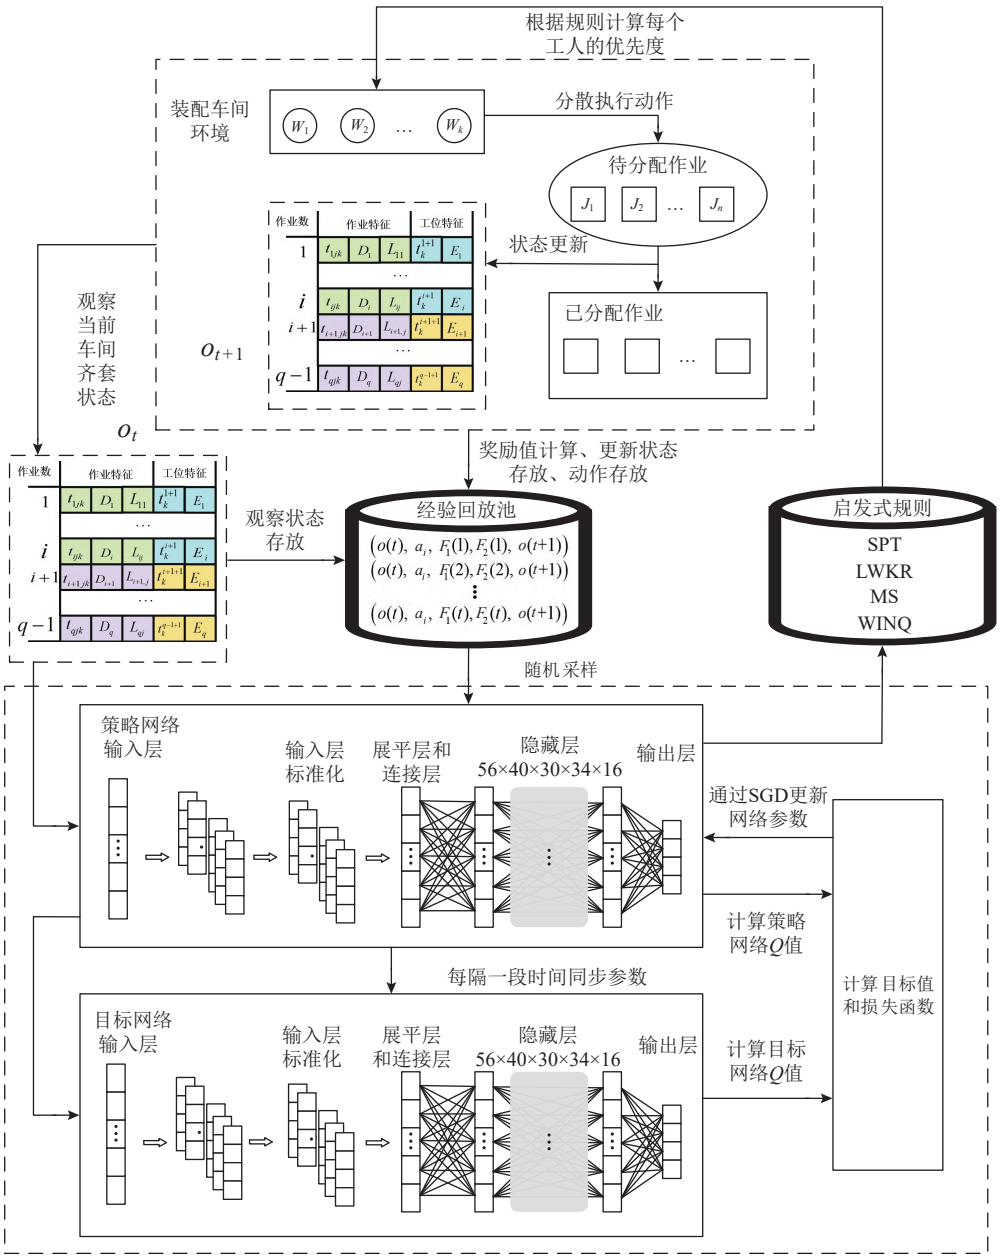

图 1　算法框架

Figure 1　Algorithm framework

表 2　状态矩阵中的工作特征和工位特征

Table 2　Job features and station features in the state matrix

特征	状态矩阵中的状态特征
作业特征	加工时间 t_{ijk}
	截至日期 D_i
	松弛时间 L_{ij}
工人特征	工人任务序列中下一个作业的操作时间 t_k^{j+1}
	工人的利用率 E_k

$$F(t)=\sum_{\tau=0}^{+\infty}\gamma_1^{\tau}F_1(t+\tau)+\sum_{\tau=0}^{+\infty}\gamma_2^{\tau}F_2(t+\tau)。\tag{12}$$

根据 1.2 节中的目标函数，全局奖励函数 $F_1(t)$ 将全局奖励的总和设置为总延迟时间的相反数。

$$F_1(t)=\begin{cases}-(\max\{C_{i,j},0\}),\ \text{作业 } i \text{ 在 } t \text{ 时刻完工；}\\ 0,\ \text{其他。}\end{cases}\tag{13}$$

局部奖励函数 $F_2(t)$ 如式 (14) 所示。机床 J_i 总延迟时间 $Y_i(t)$ 为两个相邻决策点的差，定义为短期奖励。

$$F_2(t)=\begin{cases}1,\ Y_i(t)<Y_i(t-1);\\ -1,\ \text{其他。}\end{cases}\tag{14}$$

中国知网　https://www.cnki.net

$$Y_i(t) = \max(C_{im} - D_i, 0),\ i \in (1, 2, \cdots, m)。 \tag{15}$$

2.4 算法伪代码

改进后的 Deep MARL 的伪代码如下所示。

Deep MARL 算法

输入 初始化智能体数量和相关信息
输出 智能体的动作序列
1 初始化策略网络和评估网络
2 **For** episode = 1: N **do**
3 初始化车间智能体数量
4 初始作业到达每个工人所在工位
5 **While** $t < T$ **do**
6 初始化一个随机过程,以探索动作
7 **for** agent$_k$ **in** agents **do**
8 获取智能体观测到状态 $\boldsymbol{o}(t)$
9 计算动作概率 $p(a|\boldsymbol{o}(t), \theta_i)$
10 根据贪婪策略选择动作 a_i
11 执行动作 a_i，观察新状态 $\boldsymbol{o}(t+1)$
12 根据式 (14) 计算局部奖励 $F_2(t)$
13 将不完整经验 ($\boldsymbol{o}(t)$, a_i, $F_2(t)$, $\boldsymbol{o}(t+1)$) 放入公共经验回放池 B
14 **end for**
15 **If** 机床 J_i 已经被装配完 **then**
16 根据式 (13) 计算出全局奖励 $F_1(t)$
17 将 $F_1(t)$ 放入到不完整经验 ($\boldsymbol{o}(t)$, a_i, $F_1(t)$, $F_2(t)$, $\boldsymbol{o}(t+1)$) 并存储到经验回放池 B
18 **Else:**
19 重复 7 ~ 14 行伪代码
20 **End if**
21 If 全部机床已经被装配完 then
22 **exitloop**
23 **Else:**
24 重复 7 ~ 20 行伪代码
25 **End if**
26 **End while**
27 **End for**

3 实例验证

以 A 公司车铣复合车削中心装配车间为例，其中共有 4 种不同的机床型号，如图 2 所示。型号分别为 G-220MC、G-220MY、G-250MY 和 G-250MYL。G-220MC 与 G-220MY 相比，后者多一条轴使得刀塔可以上下移动，而 G-220MC 则不能上下移动；G-250MY 与 G-250MYL 相比，后者的 Z 轴行程比前者大。这 4 种不同型号的机床，在装配工艺流程中被依次分解为 14 个工序，如表 3 所示。

图 2 4 款不同系列的机床

Figure 2 Four different series of machine tools

混流装配过程中的每个最小生产循环中共有 60 台机床和 20 名装配工人。其中，钳工 16 名，电工 4 名。为保证流水线各工序生产平衡，在每个工位有 2 ~ 5 个不等速的装配钳工与电工。车间的装配方式为固定床身，采用线边物料方式进行装配，装配组长派不同的员工到工位旁进行装配。对表 3 中 4 款不同型号的车铣复合车削中心装配进行调度。机床的混流装配车间如图 3 所示。

本文所提出的方法在 Python3.9 进行编程，计算环境为 11th Gen Intel (R) Core (TM) i7-1165G7 @ 2.80 GHz 1.69 GHz CPU，16.0 GB RAM，Windows11 系统。

实验中，多层感知机 (multilayer perceptron, MLP) 参数设置如表 4 所示。本次算例验证采用消融实验，改进后的算法与以下 4 种方案进行比较。

1) 方案 1 为双重深度 Q 网络 (double deep Q-Network, DDQN)[14]：主要针对 DQN 算法[15]的 Q 值过估计问题，改变目标值的计算方法。

2) 方案 2 为深度多智能体强化学习 (deep multi-agent reinforcement learning, Deep MARL)[16]：Deep MARL 通过在大规模系统中处理多智能体的协作，适应动态变化以及提高系统鲁棒性。

3) 方案 3 基于方案 2 引入递归神经网络的 Q 网络：可变长度状态和行动表示法，使 DRL 智能体就能在每个决策时间点计算出每项工作的综合优先级。

4) 方案 4 基于方案 3 引入 GLRF：主要针对奖励稀疏性的问题加入局部奖励，加速训练过程。

图 4 显示了各算法在平均奖励的收敛性能。可以明显看出 4 种方案在前 2 000 轮剧烈波动，随着训练次数增加，方案 4 不断调整评估和目标网络参

中国知网 https://www.cnki.net

表 3　车铣复合车削中心装配流程及不同系列的装配时间

Table 3　Assembly process and assembly time of different series for turn-mill machining centers

工序序号	工作内容	工时/min				工位数量
		G-220MC	G-220MY	G-250MY	G-250MYL	
1	滑板与床鞍的装配	150	120	170	200	4
2	床头箱与床身的装配	180	150	200	250	5
3	滑板横向移动与主轴轴线垂直度的调整	120	100	130	160	4
4	尾座与床身的装配	120	100	130	160	3
5	床鞍与床身的装配	150	120	170	200	2
6	*Z* 向传动的装配	360	290	400	490	3
7	*X* 向传动的装配	240	190	270	320	2
8	润滑系统的装配	120	100	130	160	2
9	编码器、电动刀架、主电机的安装	180	150	200	240	3
10	*X*、*Z* 向行程开光的安装	120	100	130	160	2
11	床鞍附件的安装	90	70	100	120	3
12	电箱、机床防护及机床拉门的装配	360	290	400	490	4
13	机床电气的装配	760	610	840	1 030	4
14	冷却系统的装配	60	50	70	80	2

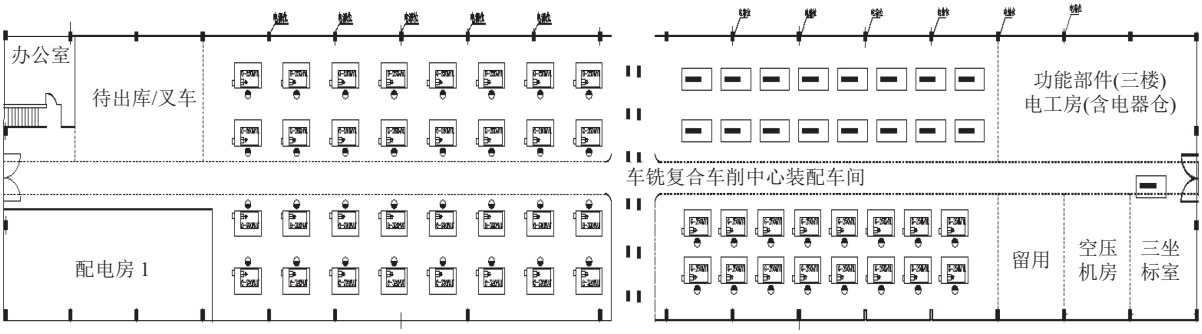

图 3　车铣复合车削中心装配 CAD 布局图

Figure 3　CAD layout for assembly of turn-mill machining centers

表 4　MLP 的训练参数和超参数

Table 4　Training parameters and hyperparameters of MLP

参数	值
折扣因子 γ	0.95
探索率 ε	0.3
最小批次大小	48
经验回放池大小	512
激活函数	ReLU
损失函数	Huber loss
优化器	SGD，动量 = 0.8
学习率	4×10^{-3}
隐含层	56×40×30×24×16

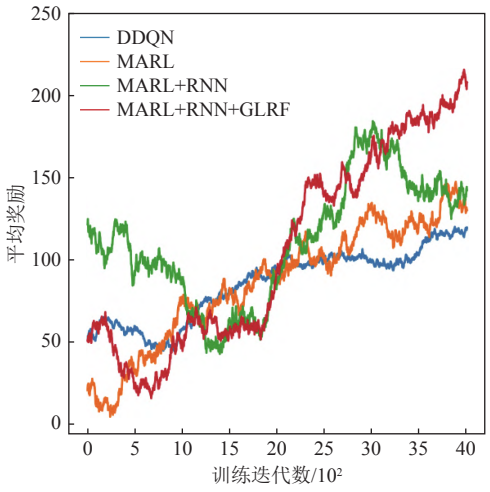

图 4　平均奖励的收敛性能

Figure 4　Convergence performance of average reward

中国知网　https://www.cnki.net

数，计算局部与全局奖励，提高 MARL 训练速度，逐渐得到近似最优策略。因此，从 2 000 轮开始，平均奖励明显提高，其中方案 4 的奖励上升最明显，最终值稳定在 220 附近，优于前 3 种方案 13.5% ~ 15.1%。

图 5 比较了各算法的平均总延迟。可以明显看出，方案 4 在方案 2 的基础上引入 GLRF 和 RNN 后，训练的收敛速度会比方案 1、方案 2 和方案 3 收敛的速度快 200 ~ 400 轮。原因是该算法采用集中训练和分散执行以及解决奖励稀疏性问题后，不同工位的平均利用率最大化。这验证了所提出算法的有效性。此外，从第 1 000 轮开始，方案 4 就可以获得相对较低的总延迟时间，同时，平均总延迟工件数优于前 3 种方案 24.1% ~ 32.3%。

本文还对比在不同任务规模下的 4 种方案收敛速度。从图 6 看出，随着 4 种系列机床的任务数量从 60 增加到 70 再增加到 80，方案 4 在收敛速度和最终损失值上都优于前 3 种方案。改良的算法比未改良的算法的最终损失值要低 22.3% ~ 33.3%。这表明基于递归神经网络的 Q 网络进行训练能够适应不同任务数量的调度任务，缩短了反复训练的时间，同时加入的 GLRF 能解决因奖励稀疏而带来的训练收敛时长过长的问题。智能体的训练速度提升，使得车间在实时调度上会有更好的响应速度。

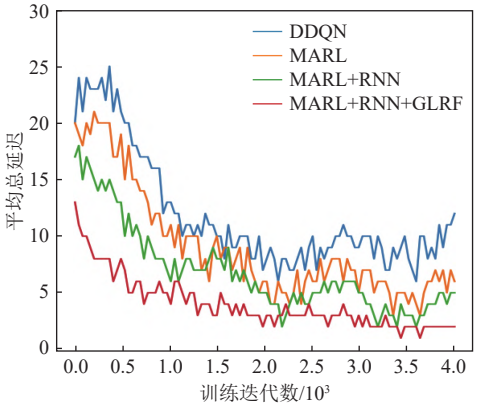

图 5 平均总延迟

Figure 5 Average total tardiness

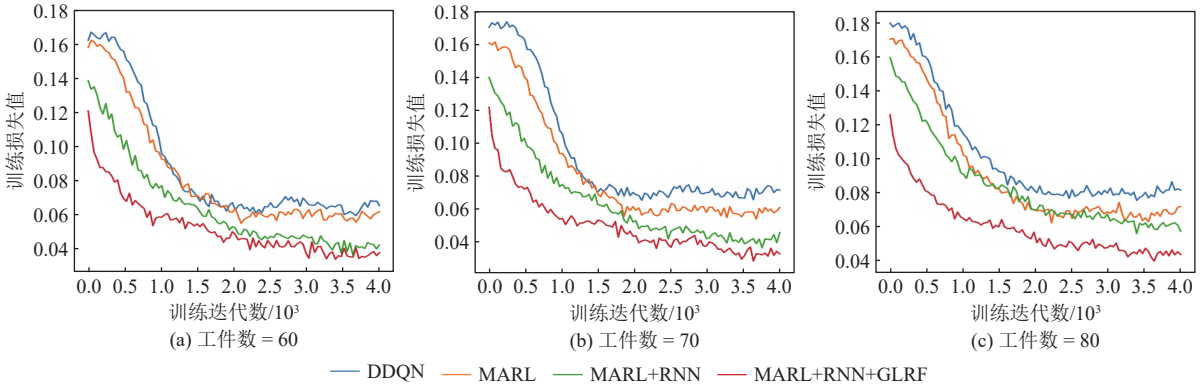

图 6 训练损失

Figure 6 Training loss

利用本案例提出的算法，对一个月平均产量为 60 台机床，每个系列各 15 台的混流装配车间进行调度的甘特图如图 7 所示，4 种系列各 15 台机床的最大完工时间为 23 178 min，总的延迟作业时间 (total tardiness, TT) 约为 4 工时（240 min）。

4 结论

为保证机床混流装配车间生产的机床准时交付，针对最小延迟生产调度优化模型求解质量、训练速度缓慢问题，本文提出一种基于改进的深度多智能体强化学习的机床混流装配线调度优化方法。由于强化学习本身基于马尔科夫决策过程，相较于车床装配调度过程中所采用的启发式算法或元启发式算法，该方法具有更高精确性和实时性。此外基于递归神经网络的 Q 网络进行训练，确保该算法能处理不同的任务。在此基础上加入了局部/全局奖励，有效解决了奖励稀疏性的问题。通过消融实验表明，针对车铣复合车削中心装配过程，所改良的算法在调度目标的达成度方面，平均总延迟工件数比改进前提高了 24.1% ~ 32.3%，训练时间减少了 8.3%。结果表明，改进后的深度多智能体算法在解决机床调度问题上具有更有效的实时响应，确保了机床装配过程的高效性与连续性。

中国知网 https://www.cnki.net

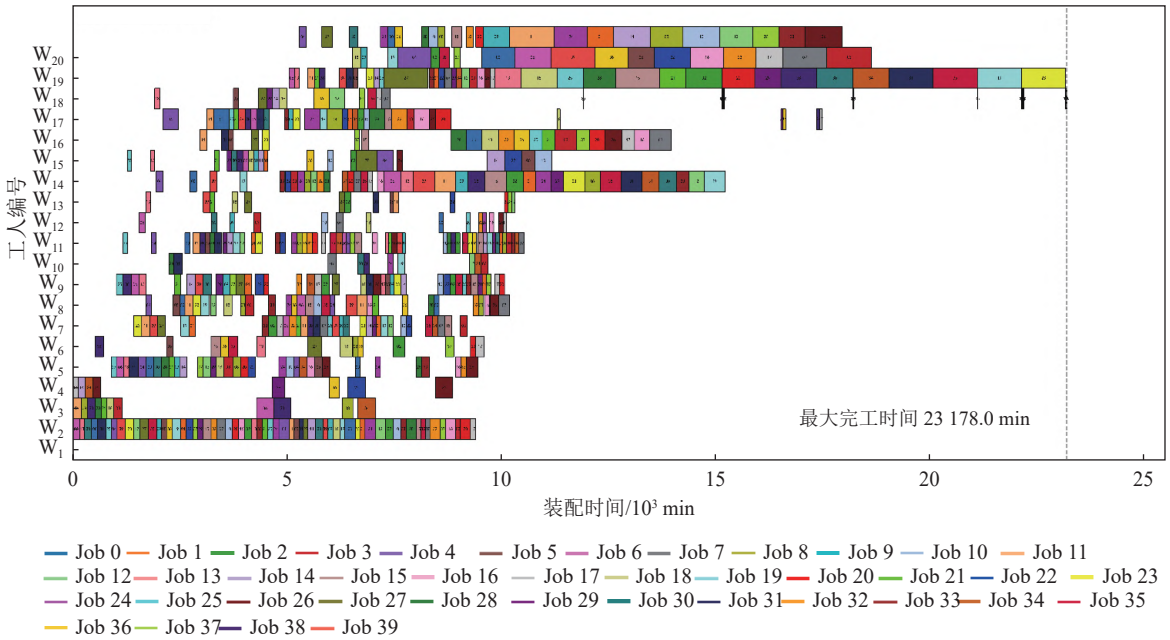

图 7　总作业数为 60 台机床的装配调度方案

Figure 7　Assembly scheduling program for a total operation of 60 machines

参考文献：

[1] 李颖俐, 李新宇, 高亮. 混合流水车间调度问题研究综述[J]. 中国机械工程, 2020, 31(23): 2798-2813.
LI Yingli , LI Xinyu , GAO Liang. Review on hybrid flow shop scheduling problems[J]. China Mechanical Engineerin, 2020, 31(23): 2798-2813.

[2] DE GIORGIO A, MAFFEI A, ONORI M, et al. Towards online reinforced learning of assembly sequence planning with interactive guidance systems for Industry 4.0 adaptive manufacturing[J]. Journal of Manufacturing Systems, 2021, 60: 22-34.

[3] 李燚, 唐倩, 刘联超, 等. 基于改进蚁群算法的汽车混流装配调度模型求解[J]. 中国机械工程, 2021, 32(9): 1126-1133.
LI Yi, TANG Qian, LIU Lianchao, et al. An improved ACO algorithm for automobile mixed-flow assembly scheduling problems[J]. China Mechanical Engineering, 2021, 32(9): 1126-1133.

[4] 李思瀚, 莫超雄, 刘建军, 等. 物料齐套时间不确定的多地总装作业前摄性调度[J]. 工业工程, 2021, 24(3): 104-114.
LI Sihan, MO Chaoxiong, LIU Jianjun, et al. Proactive scheduling of multi-location final-assembly operations with uncertain material kitting time[J]. Industrial Engineering Journal, 2021, 24(3): 104-114.

[5] CANO-BELMÁN J, RÍOS-MERCADO R Z, BAUTISTA J. A scatter search based hyper-heuristic for sequencing a mixed-model assembly line[J]. Journal of Heuristics, 2010, 16: 749-70.

[6] BELKHARROUBI L, YAHYAOUI K. Solving the mixed-model assembly line balancing problem type-I using a hybrid reactive GRASP[J]. Production & Manufacturing Research, 2022, 10(1): 108-31.

[7] 郭具涛, 吕佑龙, 戴铮, 等. 基于复合规则和强化学习的混流装配线调度方法[J]. 中国机械工程, 2023, 34(21): 2600-2606.
GUO Jutao, LYU Youlong, DAI Zheng, et al. Compound rules and reinforcement learning based1 scheduling method for mixed model assembly lines[J]. China Mechanical Engineering, 2023, 34(21): 2600-2606.

[8] 张中伟, 李艺, 高增恩, 等. 基于深度强化学习的柔性作业车间节能调度研究[J]. 工业工程, 2024, 27(1): 78-85.
ZHANG Zhongwei, LI Yi, GAO Zengen, et al. Energy-efficient flexible job-shop scheduling based on deep reinforcement learning[J]. Industrial Engineering Journal, 2024, 27(1): 78-85.

[9] DENG L, DI Y, WANG L. A reinforcement-learning-based 3-D estimation of distribution algorithm for fuzzy distributed hybrid flow-shop scheduling considering on-time-delivery[J]. IEEE Transactions on Cybernetics, 2023, 54(2): 1024-1036.

[10] LI R, GONG W, WANG L, et al. Double DQN-based coevolution for green distributed heterogeneous hybrid flowshop scheduling with multiple priorities of jobs[J]. IEEE Transactions on Automation Science and Engineering, 2023, 21(4): 6550-6562.

[11] ZHANG Z, QIAN B, HU R, et al. Q-learning-based hyper-heuristic evolutionary algorithm for the distributed assembly blocking flowshop scheduling problem[J]. Applied Soft Computing, 2023, 146: 110695.

[12] LIU R, PIPLANI R, TORO C. A deep multi-agent reinforcement learning approach to solve dynamic job shop scheduling problem[J]. Computers & Operations Research, 2023, 159: 106294.

[13] LI F, LANG S, HONG B, et al. A two-stage RNN-based deep reinforcement learning approach for solving the parallel machine scheduling problem with due dates and family setups[J]. Journal of Intelligent Manufacturing, 2023, 35: 1107-1140.

[14] LADOSZ P, WENG L, KIM M, et al. Exploration in deep reinforcement learning: a survey[J]. Information Fusion, 2022, 85: 1-22.

[15] CHRAIBI A, BEN A, TOUHAFI A, et al. A novel dynamic multi-objective task scheduling optimization based on dueling DQN and PER[J]. The Journal of Supercomputing, 2023, 79(18): 21368-21423.

[16] BAHRPEYMA F, REICHELT D. A review of the applications of multi-agent reinforcement learning in smart factories[J/OL]. Frontiers in Robotics and AI, 2022, 9(2022-11-01). https://doi.org/10.3389/frobt.2022.1027340.

(责任编辑: 刘敏仪)

中国知网 https://www.cnki.net