蘭州理工大學

硕士论文

兰州理工大学图书馆

中国知网 https://www.cnki.net

学校代号 10731　　学　号 212085500088

分 类 号 TP242.2　　密　级 公开

LANZHOU UNIVERSITY OF TECHNOLOGY

专业学位硕士学位论文

家庭服务机器人语义地图构建与寻物研究

学位申请人姓名　何　镇

培 养 单 位　机电工程学院

导师姓名及职称　张淑珍 副教授

张　岩 高级工程师

学 科 专 业　机械工程

研 究 方 向　移动机器人

论文提交日期　2024 年 3 月 20 日

中国知网 https://www.cnki.net

学校代号：10731

学　　号：212085500088

密　　级：公开

兰州理工大学专业学位硕士学位论文

家庭服务机器人语义地图构建与寻物研究

学位申请人姓名：　何　镇

导师姓名及职称：　张淑珍　副教授

　　张　岩　高级工程师

培　养　单　位：　机电工程学院

专　业　名　称：　机械工程

论文提交日期：　2024 年 3 月 20 日

论文答辩日期：　2024 年 5 月 18 日

答辩委员会主席：　魏　泰　高级工程师

中国知网　https://www.cnki.net

Semantic Map Construction and Object Search for Domestic Service Robots

By

HE Zhen

B.E. (Guangxi University of Science and Technology) 2018

A thesis submitted in partial satisfaction of the

Requirements for the degree of

Master of Engineering

in

Mechanical Engineering

in the

School of Mechanical and Electrical Engineering

Lanzhou University of Technology

Supervisor

Associate Professor Zhang Shuzhen

Senior Engineer Zhang Yan

March, 2024

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 课题背景及研究意义.....1
1.2 国内外研究现状.....2
1.2.1 家庭服务机器人国内外研究现状.....2
1.2.2 目标检测国内外研究现状.....2
1.2.3 语义地图国内外研究现状.....5
1.2.4 图神经网络国内外研究现状.....7
1.3 本文内容和章节安排.....9
第二章 机器人地图构建与导航方法.....11
2.1 引言.....11
2.2 机器人地图构建方法.....11
2.2.1 传统粒子滤波 SLAM 算法.....11
2.2.2 Gmapping 算法.....13
2.2.3 机器人建立环境地图分类.....15
2.3 基于栅格地图的路径规划方法.....18
2.3.1 Dijkstra 算法.....18
2.3.2 A*算法.....19
2.4 本章小结.....20
第三章 室内语义地图的构建.....22
3.1 引言.....22
3.2 建立栅格地图.....22
3.3 未知室内环境语义地图构建.....23
3.3.1 家庭室内环境场景识别.....23
3.3.2 室内物体数据集的制作.....24
3.3.3 室内物体坐标与栅格地图坐标的转换.....25
3.4 避免室内门口场景语义标注错误策略.....26
3.4.1 室内物体场景置信度设置.....27
3.4.2 引力斥力函数.....28
3.4.3 语义标注阈值设置.....29
3.5 本章小结.....30
第四章 室内物体与机器人位姿关系图谱的建立.....31
4.1 引言.....31
4.2 图结构的定义及室内物体搜索方法.....31
4.2.1 图结构的定义.....31

中国知网 https://www.cnki.net

4.2.2 室内动态物体搜索方法.....32
4.3 图神经网络.....33
4.3.1 策略网络的搭建.....34
4.3.2 用词向量增强图结构.....34
4.3.3 构建训练模型.....35
4.4 建立室内物体与移动机器人位姿关系图谱.....36
4.4.1 训练图神经网络.....36
4.4.2 室内物体与机器人位姿关系图谱.....37
4.5 本章小结.....39
第五章 实验验证.....40
5.1 引言.....40
5.2 实验平台搭建.....40
5.2.1 实验硬件平台.....40
5.2.2 实验软件平台设置.....40
5.3 家庭室内环境语义地图.....41
5.3.1 室内物体数据集训练 YOLOv5s.....41
5.3.2 建立室内语义地图.....41
5.4 室内环境寻物实验.....44
5.5 本章小结.....46
总结与展望.....47
全文总结.....47
研究展望.....48
参考文献.....49

中国知网 https://www.cnki.net

摘 要

针对目前家庭服务机器人功能单一，交互性较差，难以满足人们对于家庭服务机器人高智能化的要求。本课题主要对服务机器人快速准确寻找位置坐标未知室内物体的方法进行研究。根据家庭室内环境中物体之间的摆放位置具有一定的内在联系，构建家庭室内语义地图和室内物体与移动机器人位姿关系图谱，搭建实验平台对本文提出的方法进行验证。具体研究内容如下：

(1)基于可调场景语义标注范围的家庭室内语义地图构建

语义地图可提供场景类别信息和室内物体坐标及种类信息，针对传统方法建立的语义地图在室内门口易出现语义标注错误现象，本文提出一种基于场景置信度的具有阈值可变范围的语义标注方法，该方法根据 YOLOv5s 识别物体，然后通过深度相机和坐标转换，得到物体大小赋予相应的场景置信度，基于该场景置信度，设置一定阈值使得语义标注范围限制在移动机器人当前所在区域，在场景切换时语义标注范围不会立即改变；基于人工势场虚拟力“引力斥力”原理，实现语义标注范围的扩大或缩小；结合具有阈值和可变语义标注范围，避免在门口场景出现语义标注错误。通过实验，对本文提出的建立室内语义地图方法在建图效率和精确度两方面进行验证。

(2)室内物体与移动机器人位姿关系图谱的构建

将语义地图上的固定物体作为地标物体节点，移动机器人观测到地标节点的位姿作为移动机器人位姿节点，组成图结构。用概率模型通过对应关系在地标物体附近随机生成动态物体，作为动态物体节点。通过策略梯度法以移动机器人用更少的步长找到动态物体为奖励，以训练图神经网络输出动态物体节点与图结构之间的概率关系作为边；用图聚类算法显式输出节点与边的关系，构建出室内物体与机器人位姿之间的关系图谱。结合语义地图和关系图谱移动机器人可以快速准确的在位置坐标未知的限制下找到动态物体。通过实验，在真实家庭室内环境对本文结合语义地图和关系图谱方法，在寻找动态物体时所用路程及时间两方面进行验证。

(3)实验验证

搭建实验平台，移动机器人在真实家庭室内环境，分别用传统方法和本文提出的建立室内语义地图的方法，在建立语义地图时间和精确度两方面进行对比；结合语义地图和室内物体与移动机器人位姿关系图谱，进行室内位置坐标未知的动态物体寻找实验，并与传统方法寻找位置坐标已知的动态物体，对寻找物体时移动机器人所用路程和时间两方面进行对比，来验证本文方法的高效性。

关键词：室内环境；可调场景语义标注范围；室内物体关系；图神经网络；寻物导航

中国知网 https://www.cnki.net

Abstract

In response to the current limitations of home service robots, which exhibit single functionality and poor interactivity, falling short of users' expectations for highly intelligent household assistance, this study primarily focuses on enabling such robots to accurately and rapidly locate indoor objects with unknown position coordinates. Recognizing that the placement of objects within a home environment exhibits inherent spatial relationships, the project aims to construct a semantic map of the indoor space and a graph depicting the relationship between indoor objects and the mobile robot's pose. An experimental platform will be established to validate the proposed methodologies. The specific research content is outlined as follows:

(1) Construction of a Home Indoor Semantic Map Based on Adjustable Scene Semantic Annotation Range

Semantic maps provide information on scene categories, indoor object coordinates, and types. Addressing the issue of semantic annotation errors commonly occurring near indoor doorways in traditional semantic map construction methods, this study proposes a threshold-varying, scene-confidence-based semantic annotation approach. This method utilizes YOLOv5s for object recognition, followed by depth camera data and coordinate transformation to assign scene confidence based on object size. A threshold is set to restrict the semantic annotation range to the mobile robot's current area, ensuring it does not immediately change during scene transitions. Inspired by the "attractive-repulsive" principle of artificial potential fields, the semantic annotation range can be dynamically expanded or contracted. By combining both the adjustable threshold and variable annotation range, this method aims to prevent annotation errors at doorway scenarios. Experimental validation is conducted to assess the efficiency and accuracy of the proposed indoor semantic map construction method.

(2) Construction of a Graphical Representation of Indoor Object-robot Pose Relationships

In this process, fixed objects on the semantic map are designated as landmark object nodes, while the poses of the mobile robot as observed relative to these landmarks become robot pose nodes, together forming a graph structure. A probabilistic model is employed to generate dynamic objects in proximity to the landmark objects, which are then represented as dynamic object nodes. Policy gradient methods are used to train a graph neural network (GNN), with the reward being the ability of the robot to locate dynamic objects using fewer steps. The GNN is trained to output the probability relationships between dynamic object nodes and the overall

中国知网 https://www.cnki.net

graph structure as edges. Finally, a graph clustering algorithm explicitly outputs a graphical representation of the relationships between indoor object nodes and mobile robot pose nodes. By integrating the semantic map and this relationship graph, the mobile robot can efficiently and accurately locate dynamic objects even when their precise coordinates are unknown. Experiments are conducted in a real-world home environment to validate the proposed method that combines semantic mapping and the object-robot pose relationship graph, specifically assessing the traversal distance and time required for finding dynamic objects.

(3) Experimental Validation

An experimental platform is established with a mobile robot operating within a genuine residential indoor setting. Two distinct approaches are compared: the commonly-employed traditional method and the proposed technique for constructing an indoor semantic map presented in this work. The comparison focuses on both the time taken to build the semantic map and its achieved accuracy. Subsequently, incorporating the semantic map and the indoor object-robot pose relationship graph, experiments are conducted to locate dynamic objects within the environment where their exact coordinates are unknown. These results are contrasted against those obtained using traditional methods for finding dynamically positioned objects whose coordinates are known. The comparison assesses the traversal distance and time expended by the mobile robot during object search, thereby validating the efficiency of the proposed methodology.

Keyword: Indoor Environment; Adjustable Scene Semantic Labeling Scope; Indoor Object Relationships; Graph Neural Networks; Object Search Navigation

中国知网 https://www.cnki.net

插图索引

图 1.1 图神经网络的应用 8
图 1.2 主要内容结构流程图 10
图 2.1 Gmapping 算法建图流程 13
图 2.2 地图种类 16
图 2.3 占据栅格地图示意图 17
图 2.4 Dijkstra 算法流程 19
图 3.1 构建语义地图整体框架 22
图 3.2 Places205-VGG16 网络模型 23
图 3.3 栅格单元属于某个场景语义的概率示意 24
图 3.4 相机、移动机器人坐标与栅格地图坐标的关系 25
图 3.5 语义场景标注错误示例 26
图 3.6 变化的场景语义标注范围 27
图 3.7 语义标注阈值与建图时间和精准度的关系 29
图 4.1 室内地标物体与移动机器人位姿组成的图结构 32
图 4.2 动态物体寻找过程 33
图 4.3 向移动机器人位姿节点添加词向量 35
图 4.4 成功率与步长曲线 37
图 4.5 节点之间力的关系 38
图 4.6 室内物体与移动机器人位姿关系图谱 39
图 5.1 实验平台 41
图 5.2 室内物体数据集 PR 曲线图 41
图 5.3 语义地图建图实验场景和移动机器人 42
图 5.4 家庭室内环境语义地图 43
图 5.5 三种导航算法寻找目标物体最短路线轨迹 45

中国知网 https://www.cnki.net

附表索引

表 2.1 常见激光 SALM 算法优缺点 15
表 3.1 制作的室内物体数据集种类 25
表 4.1 室内地标物体与动态物体对应关系 33
表 4.2 家庭室内地标物体 36
表 5.1 室内语义建图实验数据 42
表 5.2 室内寻物实验数据 45

中国知网 https://www.cnki.net

第一章 绪论

1.1 课题背景及研究意义

随着机器人技术的不断发展，其应用领域已不再仅仅局限于工业制造、军事科技和医疗保健等重度垂直或高精尖行业，而是逐步渗透至服务业，如清洁、教育陪伴、智能家居等领域，并在部分家庭生活中取代人力劳动。家庭服务机器人的广泛应用已成为不可逆转的社会发展趋势[1]。近几年，各国政府纷纷出台了多项政策以促进机器人行业的加速发展。例如，日本政府于 2019 年公布了《人工智能战略 2019》；美国在 2021 年推出了《人工智能/机器学习战略计划》；德国在 2019 年发布了《国家工业战略 2030》；韩国于 2020 年启动了《2020 智能机器人行动计划》。同时，我国也在 2021 年由工信部联合 15 个相关部门共同发布《“十四五”机器人产业发展规划》[2]。以上举措充分表明，世界各国政府都在积极推动智能机器人产业的全面发展与应用。

在家庭生活中，家务劳动对个体生活质量具有直接影响，过度繁重的家务负担会导致人们的身心疲惫，无法得到充分的休憩，长期以往，健康状况自然会受到影响，甚至增加患上慢性疾病的风险。特别是当前我国社会老龄化趋势愈发明显，对于以老年人为主的家庭中，家务劳动的繁劳程度直接关乎生活幸福感。现阶段市面上的常见家庭服务机器人主要包括清洁机器人和智能家居机器人，但它们普遍存在功能单一、智能化程度偏低、人机交互不足等问题。

随着人们对于家庭服务智能化需求的提升，急需智能程度更高的家庭服务机器人走入家庭。智能家庭服务机器人应具有类似人类直观理解室内周围环境的能力，如很直观的知道室内那个房间是客厅、厨房，以及客厅有沙发、电视等家具。智能家庭服务机器对室内周围环境的理解，可使服务机器人执行更为复杂的任务，比如室内寻物、取物等。

本课题针对家庭室内服务机器人理解室内环境以及寻找位置坐标未知的动态物体进行研究，通过建立室内语义地图使移动机器人理解周围环境，然后通过训练图神经网络，输出室内物体与机器人位姿之间的概率关系，通过图聚类算法将这种概率关系建立成室内物体与机器人位姿关系图谱。结合语义地图和室内物体与机器人位姿关系图谱，使移动机器人快速准确的寻找位置坐标未知的动态物体，为后续家庭服务机器人取物提供理论基础。

中国知网 https://www.cnki.net

1.2 国内外研究现状

1.2.1 家庭服务机器人国内外研究现状

日本索尼公司在1999年率先推出了全球首款家庭服务机器人—宠物机器人“Aibo”[3]。至2002年，美国I Robot公司推出了名为Roombam的家用清洁机器人，凭借其实惠的价格和实用功能，深受消费者喜爱。与此同时，WowWee公司研发的一款安保机器人具备与环境互动及通过网络远程操控的能力，显著提升了家庭服务机器人的技术水平。2004年，韩国SK公司发布了一款名为Mastitech的安保机器人，这款机器人能够探测火灾、煤气泄漏等紧急状况，并将相关信息实时发送至主人手机，还能依据主人指令执行现场应急操作[4]。

我国在服务机器人领域的研发与日本、美国等国家相比起步较晚。清华大学研发七自由度移动式护理机器人，以高位截瘫人员作为护理对象，目标是在无人看护的情况下替患者完成取药、送水、翻书等工作。浙江某公司研发的陪伴机器人阿铁，具备36种仿人交互表情来满足老年用户需求，具备看护、娱乐互动及简单的在线咨询等服务功能[5]。近年来,在国家863计划的支持下，我国在服务机器人研究和产品研发方面已开展了大量工作，并取得了一定的成绩，如哈尔滨工业大学研制的导游机器人、迎宾机器人、清扫机器人等；华南理工大学研制的机器人护理床；中国科学院自动化研究所研制的智能轮椅等。但是我国服务机器人市场从2005年前后才开始初具规模。目前，我国的家用服务机器人主要有吸尘器机器人、教育、娱乐、保安机器人、智能轮椅机器人、智能穿戴机器人、智能玩具机器人。市场上销售的保洁机器人有北京利而浦电器有限责任公司的福玛特保洁机器人、浙江海星电子科技有限公司的HAC-2智能吸尘器、深圳银星智能电器有限公司的kv8家用清洁机器人、台湾某公司的QQ-2保洁机器人、上海罗宝公司的罗宝智能吸尘器机器人等[6]。

在家庭中移动机器人为了更智能的完成服务，如在位置坐标未知的情况下寻找主人需要的物体。服务机器人首先需理解室内周围环境，语义地图可提供移动机器人所处环境的场景信息和物体信息，使移动机器人能够类似人类理解周围环境和物体，因此移动机器人依赖语义地图可根据语义信息执行符合人类行为习惯的动作指令，从而更高效更智能的执行任务。建立室内语义地图首先需要依赖视觉信息分类室内场景及识别室内物体，目前物体识别算法主要有基于候选区域和基于回归模型的深度学习目标检测方法。

1.2.2 目标检测国内外研究现状

目标检测任务的核心在于精准定位图像中各目标的位置及其类别，而在室内场景下，这一任务面临多方面的挑战：(1)光照变化：室内光照条件易受户外气候及内部光源影响，引起图像整体亮度变化及局部对比度波动，这会对目标检测产生显著干扰。克服多种光照环境下稳定检测特定目标，历来是目标检测技术领域亟待攻克的关键难题。(2)部分遮

中国知网 https://www.cnki.net

挡问题：在现实场景中，目标物在二维图像或视频中常因立体空间重叠而出现部分遮挡现象。在遮挡导致目标信息不完整的情况下，仍能准确检测出目标的位置与类别，这是当前研究中的一个重要难点。(3)目标特征稀疏：某些目标可能具有较少的色彩、纹理等显着特征，所提供的可识别信息极其有限，这使得这类目标的检测变得尤为困难。针对这些问题，科研人员已投入大量精力进行深入研究，并在目标检测技术上取得了一系列进展[7]。

在传统的目标检测算法中，研究工作的核心聚焦于特征的设计，国外和国内的研究者们开发了一系列有效的图像特征，诸如 SIFT[8]、HOG[9]、LBP[10]等图像特征。尽管这些人为设计的特征在特定的应用情境下展现出了良好的性能，但它们普遍存在局限性，即不具备广泛的适用性。此外，人工特征在表达目标细节与高层次语义信息方面的能力相对有限，难以充分描述所有复杂场景中的目标。与此相反，基于深度学习的目标检测技术[11]摒弃了手动设计特征的做法，转而通过深度神经网络逐层抽取图像的低阶、中阶直至高阶特征。这种方法依赖于大规模数据集的训练，使网络具备自我学习和提炼特征的能力，从而驱动目标检测过程。借助合理的网络架构设计，能够有效地提取图像的高级语义特征，对目标进行更为精确的描述，极大地提高了检测结果的准确度。深度学习在计算机视觉领域的突破性进展引人瞩目，一系列创新的网络架构不断涌现，逐步确立了其在计算机视觉研究领域的主导地位[12]。

基于深度学习的目标检测技术基本上可以归纳为两大体系：一类是以候选区域为核心的方法，早期的深度学习检测技术大多属于此类；另一类则是依赖于回归模型的检测策略，这类方法在速度上往往表现出优势。

(1)基于候选区域的深度学习目标检测算法

自 2013 年起，基于候选区域的深度学习目标检测方法开始崭露头角，通过采用卷积神经网络(Convolutional Neural Network, CNN)作为特征提取手段，取得了显著的进步，目标检测性能得到持续提升。其中，P. Sermanet 等人[13]提出的 Overfeat 算法标志着深度学习在目标检测领域的初步应用。Overfeat 结合滑动窗口和预定义区域的方式，从不同尺度提取候选框，随后运用 CNN 对每个候选区域进行分类以判断其类别和置信度。由于 Overfeat 采用多尺度和多位置的候选框聚合分类置信度，因此提高了检测的准确性。尽管 Overfeat 在速度和精度上相对较低，但它作为早期深度学习目标检测的成功实践，对后续研究产生了重大影响。在此基础上，Girshick[14]进一步发展了 R-CNN 目标检测算法，相较于 Overfeat，其检测精度显著提升，在 ILSVRC 2013 数据集上的平均精度(mean Average Precision，mAP)从 24.3%跃升至 31.4%。何恺明等[15]紧随其后提出了 SPP-Net 网络结构，旨在解决 R-CNN 在处理候选区域时由于裁剪和调整尺寸带来的误差问题。SPP-Net 通过在卷积特征层上引入空间金字塔池化层，替代了对原始图像进行裁剪和缩放的操作，从而实现对不同尺寸图像提取固定维度特征，有效减少了重复计算，提高了检测

中国知网 https://www.cnki.net

速度。

R-CNN 检测框架利用 Selective Search 方法来生成候选框，随后采用支持向量机(SVM)对这些候选框进行类别分类，并运用线性回归技术对候选框的位置和尺寸进行精调，值得注意的是，针对每个不同的类别，R-CNN 都会独立训练一个边界框回归器。尽管 R-CNN 在检测性能上实现了显著提升，但该算法存在一些明显的局限性：首先，候选框的生成依赖于 Selective Search 算法，且每个框都需要通过 CNN 逐一进行特征提取，这导致了大量的计算资源消耗；其次，尽管 SVM 模型在许多场景中表现出色，但在面对大量训练数据时，其线性模型的特性可能并非是最佳解决方案；此外，R-CNN 并非完全意义上的端到端系统，其各个处理步骤需独立运行并储存中间结果，加上所需的额外数据存储，这对存储空间需求较高。尽管 R-CNN 在速度上有所欠缺，但它的出现无疑为深度学习在目标检测领域的应用拓展了新的思路与可能性。

基于候选区域的深度学习目标检测技术经历了不断的优化和发展过程。最初的重大突破在于将特征抽取方式转变为利用卷积神经网络(CNN)提取，进一步，随着 Region Proposal Network(RPN)的引入，候选框的生成效率得以显著提升，从而加快了整体检测速度。在此基础上，一系列创新工作如 R-FCN[16]、ResNet[17]、LocNet[18]、HyperNet[19]以及 ION[20]等相继提出，它们共同促进了基于候选区域的目标检测方法在精准度和运算速度两方面的持续进步。然而，这一类方法在执行特征提取、类别判断以及位置偏移校正等核心步骤时，通常采取序列化的方式，这种串行处理结构极大地限制了检测系统的实时性。相比之下，基于回归模型的深度学习目标检测技术较好地克服了这一问题，旨在实现更快捷、高效的目标检测流程。

(2)基于回归模型的深度学习目标检测方法

不同于基于候选区域的深度学习目标检测方法，基于回归模型的深度学习目标检测方法，不需要通过候选框的提取，而是利用回归思想，直接在图片的多个位置上回归出目标的位置和可能的类别。

J. Redmon[21]首次提出 YOLO(You Only Look Once)算法以来，该算法，通过整合目标识别与定位至单一环节，实现了检测速度的显著提升，常规版本可达每秒 45 帧，而轻量级快速版更是达到了每秒 155 帧的速度水平。YOLO 的基本原理是在 448×448 像素的图像上划分成 N×N 的网格，并由包含目标中心的网格负责对该目标的检测，每个网格单元预测一组边界框、相关置信度以及各类别的概率分数。YOLO 简化了检测流程，明显提升了检测效率。尽管 YOLO 在精度上存在一定的下降，但其提出的整体检测新思路对于推动深度学习目标检测技术发展起到了积极推动作用。与此同时，诸如 G-CNN[22]等类似方法同样关注检测速度，采用回归模型，通过从大量候选框逐步迭代收敛至少量初始化网格，以求精确得出最终的边界框。Wei Liu 等人[23]所研发的 SSD(Single Shot MultiBox Detector)则是结合了 YOLO 模型的快速特性与 Faster R-CNN 中的锚点机制，

中国知网 https://www.cnki.net

通过应用两个卷积层进行全图多尺度特征回归，不仅保留了 YOLO 的高速优势，还有效改善了 YOLO 在目标定位上的不准确性，在 PASCAL VOC 数据集上取得了高达 72.1%的检测精度，与 Faster R-CNN 相当。后续，Redmon 推出了 YOLO9000[24]，针对原始 YOLO 存在的局限进行了改进，提升了检测效果；随后的 YOLOv2 相较于 YOLOv1 在识别种类、精度、速度及定位准确性等方面均取得重大改进。考虑到 YOLO 算法的良好性能能够适应 SLAM(Simultaneous Localization and Mapping)系统的要求，Bavle 等人[25]设计了一种结合室内环境语义信息的粒子滤波定位方法，将语义信息融入先验地图中辅助无人机精确定位，但该方法在运算速度上显得较慢。YOLOv3[26]则引入了残差网络架构和多尺度检测理念构建了更深层次的网络结构，从而提升了平均精度(Mean Average Precision ,mAP)，被广泛应用于语义视觉 SLAM[27]中的目标检测任务。至于 YOLOv4[28]，作者 Alexey 等人将其主干网络的残差模块替换成 CSP(Stage Partial Networks)，构建了 CSPDarknet 网络结构，同时采纳新的数据增强策略和修改损失函数，在速度和精度上超越了其他单阶段检测模型。不过，YOLOv4 在小目标检测、抗光照变化能力以及移动端部署便捷性等方面仍有待改进。紧随其后，Glenn Jocher 在 YOLOv4 发布两个月后开源了 YOLOv5[29]。YOLOv5 的最大特色在于基于 PyTorch 框架实现，受益于 PyTorch 丰富的生态支持，YOLOv5 在模型训练和部署上更为简便，尤其适合移动端部署，且模型参数较少。在本文所涉及的室内物体检测应用中，选择使用了 YOLOv5s 模型，作为 YOLOv5 系列中最为紧凑的一款，YOLOv5s 在计算资源有限的设备上表现卓越。

在目标检测中，为了训练和评估目标检测模型，数据集起着至关重要的作用。由于 COCO 数据集中只包含十种室内物体，导致很多室内物体遗漏，本文制作室内物体数据集训练 YOLOv5s 识别室内物体。利用 YOLOv5s 对室内物体进行识别，通过深度相机以及坐标转换计算物体在二维栅格地图的坐标，进行物体语义标注；利用场景识别模型 Places205-VGG16 神经网络进行场景识别，建立室内二维语义地图。

1.2.3 语义地图国内外研究现状

在移动机器人执行任务的过程中，首要步骤是构建一幅环境地图，地图的精确度直接决定了机器人执行任务的效率与准确性。传统 SLAM 技术构建的地图主要反映环境的几何布局与连接结构，包括但不限于特征地图、拓扑地图和栅格地图。特征地图着重刻画简单几何元素，如点、线、面等；拓扑地图则是以节点形式表示障碍或关键地点，节点间以连线表达可达性关系；栅格地图则通过不同分辨率的网格单元标识出障碍、自由空间和未知区域，分别以黑、白、灰三色区别。尽管这些地图形式足以描绘环境的基础几何特征，但它们未能有效捕获和表达环境的语义信息，这限制了移动机器人快速、精确地执行任务的能力[30]。

语义地图的引入弥补了这一不足，它包含了物体的具体类别信息，增强了机器人对环境的理解力，从而能够支持更高层次的定位导航和更智能的人机交互功能。鉴于此，

中国知网 https://www.cnki.net

越来越多的科研人员开始致力于语义地图的研究，以期提升移动机器人在复杂环境中的表现和智能化水平。

Yu Xiang 和 Dieter Fox 等[31]运用 DA-RNN 网络架构构建语义地图，该方法将网络输出的语义信息整合至三维重建过程中，尤其是与 KinectFusion[32]这一早期实时 RGB-D 为基础的 SLAM 技术相结合，从而在三维地图中注入丰富的语义内容。继 KinectFusion 之后，ElasticFusion [32]进一步提升了三维重建效果。Mccormac 等[33]研究者在此基础上，借助 ElasticFusion 技术和卷积神经网络(CNN)，研发出了名为 SemanticFusion 的密集型三维语义映射技术。邹斌等[33]研究人员则基于 ORB-SLAM2 系统建立了稠密点云地图，并通过点云分割技术将其划分为具有明显类别的区域，同时运用 YOLOv3 算法提取并融入语义信息，最终实现了稠密点云语义地图的构建。胡美玉等[35]采用了 ORB-SLAM 来确定相机姿态，并对 DeepLab 算法进行了改良以实现对场景中物体的语义分割，进而将在三维空间中的语义信息映射到地图中，完成了三维语义地图的构建工作。另外，Li 等人[36]借助 LSD-SLAM 算法估计并构建了半稠密环境地图，并运用 DeepLab-V2 进行语义分割处理，还引入条件随机场(CRF)进行正则化优化以提高分割质量，他们采用贝叶斯估计方法进行数据关联，以此方式建立了一种语义地图。相较于较为稀疏的语义地图，这种方法构建的地图含有更多信息量；而相比稠密的语义地图方案，该方法的独特之处在于仅依赖单目摄像头即可完成建图。

上述提到的构建语义地图的 SLAM 方法均依托于视觉 SLAM 技术，然而，由于视觉传感器易于受到环境因素干扰而导致累积误差，故此类方法构建的地图鲁棒性有限。相比之下，激光雷达因其高精度和较小的环境影响特性，被众多学者用于构建语义地图研究，尤其是结合视觉系统的语义信息。早先，Liu Z 和 Von Wichert G[37]采用 2D 激光雷达和 Gmapping 算法构建二维栅格地图，并运用贝叶斯推理方法来生成语义地图。后续研究中，Li ZhiXiu 等人[38]提出了一种轻量化卷积神经网络模型，用于目标检测以获取环境物体的语义信息，同时结合激光 SLAM 算法来确定机器人位置并构造二维栅格地图，最后利用贝叶斯估计更新物体的占据概率，将物体信息与环境信息深度融合，形成了二维栅格形式的语义地图。Chen X 等人[39]提出了 SuMa++算法，该算法利用 RangeNet++网络对激光雷达数据进行语义分割以排除动态物体，并在 SuMa[40]的基础上构建了高精度的语义地图。Sünderhauf N 等人[41]则将 RGB-D 数据转换为激光数据格式，并使用 Gmapping 算法构建二维栅格地图，同时采用 AlexNet 卷积神经网络及其 Places205 分类模型对识别目标进行概率估计，通过贝叶斯估计用不同颜色更新栅格地图，最终构建出二维语义栅格地图。王鹏[42]提出了一种复合型语义地图构建方法，首先利用 RGB-D 信息模拟激光数据，构建基础的二维语义栅格地图，接着运用拓扑节点识别算法构建拓扑地图。在此之上，再通过 RGB-D SLAM 技术获取三维点云地图，并通过映射关系将其叠加到栅格地图上，从而构建了一个多层次、综合性的语义地图。

中国知网 https://www.cnki.net

建立语义地图有基于激光和相机两种方法，纯相机视觉方法建立语义地图的方法一般计算量较大，对于硬件要求高，而纯激光方法建立的语义地图其包含的场景或物体语义信息不够丰富。本文结合激光与视觉方法，用 Gmapping 算法利用激光建立室内环境二维栅格地图，然后用视觉的方法分类室内场景和物体，将场景和物体的语义信息用占据栅格算法[41]在二维栅格上标注，建立室内语义地图。

室内语义地图包含场景与固定物体的语义信息，但是不包含经常移动的动态物体(如手机、钥匙、杯子等)信息，为了在位置坐标未知情况下服务机器人能够快速准确找到动态物体，需要建立动态物体与固定物体以及机器人位姿之间的关系，本文训练图神经网络表达出室内物体与机器人位姿之间的概率关系，结合该概率关系和语义地图，完成移动机器人寻找位置坐标未知的动态物体任务。

1.2.4 图神经网络国内外研究现状

图模型是一种专为处理非欧式空间数据而诞生的技术手段。近年来，研究者们吸取了卷积神经网络、循环神经网络以及深度自动编码器的灵感，将适用于非欧空间数据的图模型概念融入深度学习框架，催生了图神经网络(Graph Neural Networks, GNN)的诞生。图神经网络的理论基石是不动点理论原理，具体而言，假设有一个图模型，其每个节点均带有初始特征状态，图神经网络的学习任务就是在邻近节点信息交互的基础上，通过迭代计算得到所有节点的隐含状态。根据巴拿赫不动点定理，只要确保所采用的前馈神经网络构建的全局更新函数表现为压缩映射，则经过反复的迭代运算，节点状态将收敛至某一稳定状态。

图神经网络通过节点间的特征信息传递，配合可微分的聚合和更新函数，实现了节点特征的递归强化。Scarselli 等人[43],率先将递归神经网络的概念延伸到了图形结构数据的处理。Z. Wu 等[44]研究者进一步提出利用门控递归单元提升图神经网络的表现力。Gilmer 等人[45]则通过信息传递神经网络拓宽了图神经网络的应用范畴。近年来，学界对如何更好地将深度学习方法与图模型相结合展开了深入探究。Kipf 等人[46]提出了图卷积网络以应对半监督分类任务；Wang 等人[47]将图卷积网络应用于视频识别任务中对象关系的捕捉；Chen 等人[48]则将图卷积网络运用于场景解析中不同区域间关系的推断。鉴于多数模型在充足的数据支持下能够取得相近的性能，零样本和少样本学习在图像分类领域的价值日益凸显，不少研究开始探讨如何利用图神经网络整合结构信息以服务于图像分类。例如，Wang 等人[49]设计了一种知识图谱，以其作为附加信息指导零样本分类，每个节点代表一个类别，并将节点对应的词嵌入作为输入供分类器预测不同类别归属。针对卷积网络在深度部分可能出现的过平滑问题，Kampffmeyer 等人[50]提出采用覆盖更大邻域的单层图卷积模块，该模块涵盖了图中的相邻节点以及多跳节点。实验结果显示，这种方法能够有效地与现存的零样本分类器协同工作，解决了图卷积神经网络在传播过程中可能出现的过平滑效应。

中国知网 https://www.cnki.net

图神经网络在场景理解任务中的应用旨在解决卷积神经网络在处理复杂特征间信息交流与关系推理时遇到的挑战。在实际应用场合，面对多模态、多尺度和多阶段特征融合的复杂性，图神经网络展现出更强的适应性和稳定性。近年来，研究者们提出了一种基于门控机制的信息整合与状态更新策略，允许在固定的迭代次数内高效实现理想的特征交互与整合。研究表明，此类模型能够有效处理复杂数据，尤其在关系推理和信息交互层面展现出独特优势。正因为如此，图神经网络在社交网络分析、知识图谱挖掘、推荐系统构建以及生命科学研究等诸多领域得到了广泛应用与认可[51]。

图神经网络在移动机器人中的一些应用：

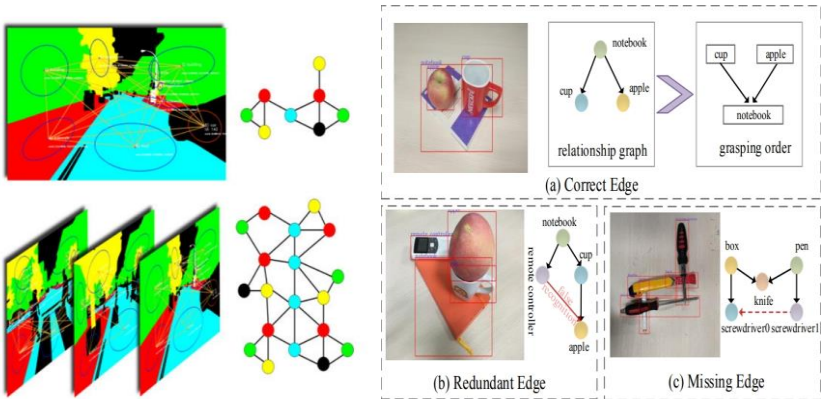

(a)建立语义地图之间的拓扑关系[52]　(b)图神经网络推理语义地图之间的拓扑关系[53]

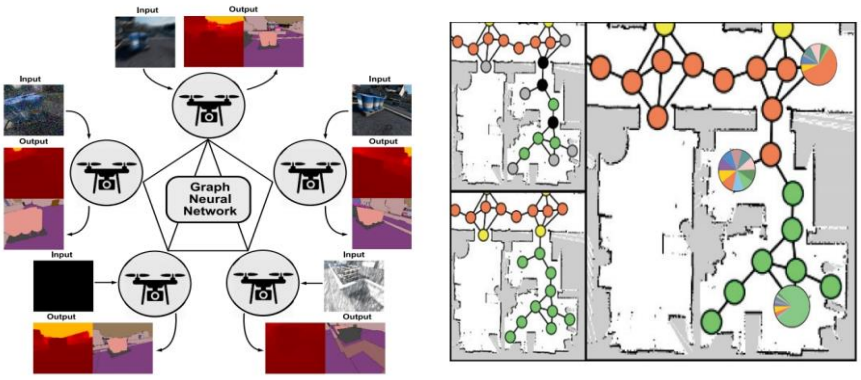

(c)多移动机器人协作之间的拓扑关系[54] (d)图神经网络建立节点与边缘的拓扑关系[55]

图 1.1 图神经网络的应用

综上所述，随着人们对于家庭服务智能化需求的提升，急需智能程度更高的服务机器人走入家庭，现有的服务机器人功能单一，不能理解所处的周围环境。本文以服务机器人理解室内周围环境，在目标物体位置坐标未知的情况下快速准确寻物为研究目的。通过场景识别模型 Places205-VGG16 以及 YOLOv5s 目标检测对室内场景分类、识别物体进行语义标注，建立室内语义地图；将语义地图中的固定物体节点以及移动机器人可以观测到固定物体的位姿节点，组成图结构。通过随机概率模型在固定物体附近按照对应关系随机生成动态物体，通过策略梯度法以寻找到动态物体最少步长为奖励，训练图

中国知网 https://www.cnki.net

神经网络，输出动态物体与图结构之间的概率关系；用图聚类算法将固定物体、动态物体以及移动机器人位姿作为节点，将节点间的概率关系作为边，建立室内物体与移动机器人位姿关系图谱；服务机器人结合语义地图和该关系图谱，完成位置坐标未知的动态物体寻物任务。

1.3 本文内容和章节安排

本文各章节的主要内容安排如下：

第一章：综述课题研究的背景及意义，指出家庭服务机器人亟需更加智能化。本文面向家庭服务机器人智能化，主要在移动机器人寻找位置坐标未知的动态物体方面研究。综述建立语义地图所需要的目标检测模块国内外研究现状、语义地图国内外研究现状，以及构建室内物体与移动机器人位姿关系图谱所用的图神经网络国内外研究现状。

第二章：对移动机器人地图构建与导航技术进行阐述，分析传统粒子滤波建图算法原理以及其优缺点，Gmapping 算法在传统粒子滤波算法的基础上进行改进，使得 Gmapping 算法广泛应用于室内环境建图。对常见的搜索路径规划方法 Dijkstra 算法和 A*算法原理和其优缺点进行简要概述。并说明本文在建立室内语义地图时利用 Gmapping 算法建立室内栅格地图为基础;在移动机器人寻找地标物体时用 A*算法导航。

第三章：针对已有语义地图建图时间慢、部署设备要求高、实时性差、在家庭室内门口容易出现语义标注错误等问题，对家庭室内环境场景识别模型 Places205-VGG16 进行先验概率优化，制作室内物体数据集训练 YOLOv5s 目标检测模型。在此基础上，提出融合阈值与可变语义标注范围的策略，避免室内房间门口场景语义标注错误。

第四章：利用家庭室内环境物体摆放位置具有一定的内在联系，用梯度策略以找到动态物体步长最少为奖励训练图神经网络，将语义地图中的固定物体节点、移动机器人位姿节点、动态物体节点，三个节点之间的概率关系表达出来。用图聚类算法将节点用概率关系作为边连接起来，建立室内物体与移动机器人位姿之间关系图谱。

第五章：在真实家庭室内环境，搭建实验平台。对本文提出建立室内语义地图方法与常见传统建图方法在建图效率和建图精准度两方面对比。结合语义地图和室内物体与移动机器人位姿关系图谱进行位置坐标未知的动态物体寻物导航任务，并与传统路径规划算法在寻找位置坐标已知物体所用路程长度和时间两方面进行对比。

本文主要内容之间结构流程如图 1.2 所示。

中国知网 https://www.cnki.net

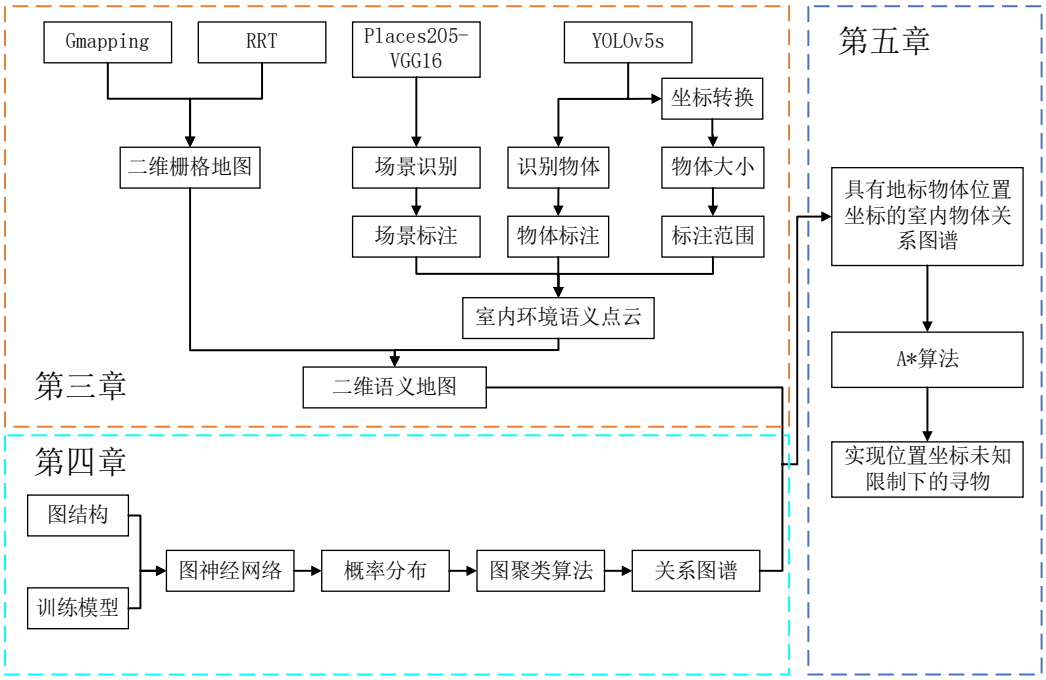

图 1.2 主要内容结构流程图

中国知网 https://www.cnki.net

第二章 机器人地图构建与导航方法

2.1 引言

移动机器人的自主探索需要基于建立的环境地图，现有移动机器人基于激光 SLAM 建图算法主要有 Gmapping 算法[56]、Hector 算法[57]、Cartographr 算法等[58]，其中 Gmapping 算法是基于改进优化 Rao-lackwellized 粒子滤波方法，并结合移动机器人里程计信息来实现位姿估计，解决了粒子耗散问题并减低了计算量，适用于室内中小场景。因此本文采用 Gmapping 算法建立室内二维栅格地图作为建立语义地图的基础。

移动机器人室内导航常用的搜索算法有 Dijkstra 算法[59]和 A*算法[60]，本文使用室内物体与机器人位姿关系图谱方法进行导航寻找动态物体，关系图谱是一种拓扑地图，不具有位置坐标信息，所以本文在寻找动态物体是首先用 A*算法导航到与动态物体关系最大的地标物体附近，然后在地标物体附近利用 YOLOv5s 检测寻找动态物体。

2.2 机器人地图构建方法

机器人建图方法主要分为基于激光雷达和基于相机视觉的方法。激光 SLAM 因其构建地图精度高、稳定性好、不存在累计误差等优点广泛应用于室内环境建图，其缺点是不适用于室外开放环境。视觉 SLAM 随着近年计算机视觉快速发展，其具有结构简单、成本较低、可提取环境中的语义信息以及在室内室外都可以应用等优点受到广泛研究，缺点是精度较差，容易受光照等因素影响。本文建立家庭室内环境地图所用的 Gmapping 算法是通过传统粒子滤波 SLAM 算法改进而来。

2.2.1 传统粒子滤波 SLAM 算法

传统的粒子滤波 SLAM 方法主要依靠对移动机器人运动状态及环境感知信息的处理，通过粒子集合来模拟和推测机器人位姿与地图构建。在这一过程中，粒子代表机器人位姿和构建地图的假设，其权重则代表对应假设的可信度。经过若干轮采样迭代，选取那些权重较大的粒子来更新机器人位姿估计和地图构建，最终实现定位和建图的目的。

最常见的粒子滤波算法 RBFP[61](Rao-Blackwellized Particle Filter，粒子滤波器)将定位与建图分开处理，给定激光观测数据(激光雷达扫描数据/scan)为 $z_{1:t}=z_1,z_2,...,z_t$，里程计数据(里程计测量数据/odom)为 $u_{1:t}=u_1,u_2,...,u_{t-1}$，则移动机器人位姿序列集合与地图特征信息的后验概率为：

$$p\left(x_{1:t},m\middle|z_{1:t},u_{1:t\text{-}1}\right) \tag{2.1}$$

中国知网 https://www.cnki.net

其中，$x_{1:t}$ 为移动机器人位姿序列；m 为环境地图的特征信息。为了加快计算速度，在采样过程中减少了状态空间维数，并利用外部传感器信息和里程计信息，来估计地图 m 和移动机器人轨迹 $x_{1:t}=x_1,x_2,...,x_t$ 的联合后验的概率：

$$p(x_{1:t},m|z_{1:t},u_{1:t-1})=p(m|x_{1:t},z_{1:t-1})p(x_{1:t}|z_{1:t},u_{1:t-1}) \tag{2.2}$$

其中，$p(x_{1:t},m|z_{1:t},u_{1:t})$ 表示估计移动机器人轨迹；$p(m|z_{1:t},z_{1:t-1})$ 表示在已知移动机器人轨迹和激光雷达观测数据的情况下，计算地图特征信息的后验概率。整体过程为以下四个步骤：

(1)采样：移动机器人里程计运动模型作为粒子滤波的建议分布 π，新的粒子 $x_t^{(i)}$ 由上一时刻 x 粒子点集 $x_t^{(i-1)}$ 在建议分布 π 中采样得到，更新后的粒子点集 $x_t^{(i)}$ 可表示为 $x_t^{(i)}P\left(x_i\left|x_t^{(i-1)},u_{t-1}\right.\right)$。

(2)重要性权重：重要性权重是用来描述建议分布与目标分布之间差异性指标，基于贝叶斯定理得出。在移动机器人运动过程中，可能的轨迹可以用粒子点 $x_t^{(i)}$ 表示，则运动轨迹对应的权重为：

$$w_t^{(i)}=\frac{p\left(x_{1:t}^{(i)}\left|z_{1:t},u_{1:t-1}\right.\right)}{\pi\left(x_{1:t}^{(i)}\left|z_{1:t},u_{1:t-1}\right.\right)} \tag{2.3}$$

(3)重采样：重采样就是将新生的粒子根据重要性权重代替，粒子总量不变，权重小的粒子被删除，将有限数量的粒子近似连续分布。

(4)地图估计：在粒子 $x_t^{(i)}$ 与移动机器人运动轨迹对应的基础上，基于样本的移动机器人轨迹 $x_{i:k},z_{1:k}$ 进行运算得出粒子地图估计 $P\left(m_i\left|x_{i:k}^i,z_{1:k}\right.\right)$。通过整合所有移动机器人轨迹的地图得出实际地图 m，重要性权重的实现需要新的观测评估移动机器人粒子轨迹权重，当重新计算轨迹对应的权重时，随时间增加以及移动机器人轨迹增长，计算量将越来越大，通过 RBPF 算法，利用贝叶斯网络条件独立性，进一步简化权重计算，得到新的递归计算形式：

$$\begin{aligned}
w_t^{(i)}&=\frac{p\left(x_{1:t}^{(i)}\left|z_{1:t},u_{1:t-1}\right.\right)}{\pi\left(x_{1:t}^{(i)}\left|z_{1:t},u_{1:t-1}\right.\right)}\\
&=\frac{p\left(z_t\left|x_{1:t-1}^{(i)},z_{1:t-1}\right.\right)p\left(x_{1:t}^{(i)}\left|z_{1:t-1},u_{1:t-1}\right.\right)}{\pi\left(x_t^{(i)}\left|x_{1:t-1}^{(i)},z_{1:t},u_{1:t-1}\right.\right)\pi\left(x_{1:t-1}^{(i)}\left|z_{1:t-1},u_{1:t-2}\right.\right)}\\
&=\frac{p\left(z_t\left|x_{1:t}^{(i)},z_{1:t-1}\right.\right)p\left(x_t^{(i)}\left|x_{1:t-1}^{(i)},u_{t-1}\right.\right)p\left(x_{1:t-1}^{(i)}\left|z_{1:t-1},u_{1:t-2}\right.\right)\eta}{\pi\left(x_t^{(i)}\left|x_{1:t-1}^{(i)},z_{1:t},u_{1:t-1}\right.\right)\pi\left(x_{1:t-1}^{(i)}\left|z_{1:t-1},u_{1:t-2}\right.\right)}\\
&\propto\frac{p\left(z_t\left|m_{t-1}^{(i)},x_t^{(i)}\right.\right)p\left(x_t^{(i)}\left|x_{t-1}^{(i)},u_{t-1}\right.\right)}{\pi\left(x_t^{(i)}\left|x_{1:t-1}^{(i)},z_{1:t},u_{1:t-1}\right.\right)}\bullet w_{t-1}^{(i)}
\end{aligned} \tag{2.4}$$

中国知网 https://www.cnki.net

其中，n 是根据贝叶斯规则得出的归一化因子，建议分布越接近目标分布 $\eta = 1/p\left(z_k \middle| z_{1:k-1}, u_{1:k}\right)$，效果越好。

传统粒子滤波 SLAM 在一定程度能够满足定位与建图的需求，但其精度和鲁棒性任存在局限性[62]，因此本文采用在传统粒子滤波基础上改进的 Gmapping 算法进行室内环境建立二维栅格地图作为语义地图的基础。

2.2.2 Gmapping 算法

针对 RBPF-SLAM 在多次重采样过程中出现的粒子耗散和多样性减少的问题，Gmapping 算法引入统计学方法优化了重采样机制[63]，以少量粒子实现更高精度的地图构建。Gmapping 算法的一个显著特点是，在构建小型场景和低特征环境的地图时，能够实现较高精度的同时保持较低的计算负载。

然而，Gmapping 算法存在局限性，主要体现在缺乏回环检测功能，这可能导致地图构建过程中出现位置偏差。此外，该算法依赖于移动机器人提供的里程计信息，当面对大范围地图时，所需粒子数量急剧增加，进而大幅增加了计算需求，因此不适合大规模场景的建图任务[64]。Gmapping 算法的基本运作逻辑是将激光雷达采集的数据转化为一系列的激光扫描线，并将这些扫描线与预先设定的地图栅格进行匹配，从而确定移动机器人的位置姿态。在匹配过程中，算法采用最小二乘法计算出最优化的机器人位姿估计值，并依据此估计值更新地图内容。随着机器人不断移动和探索，算法会持续迭代地图更新，直至完成整幅地图的构建，具体建图流程如图 2.1 所示。

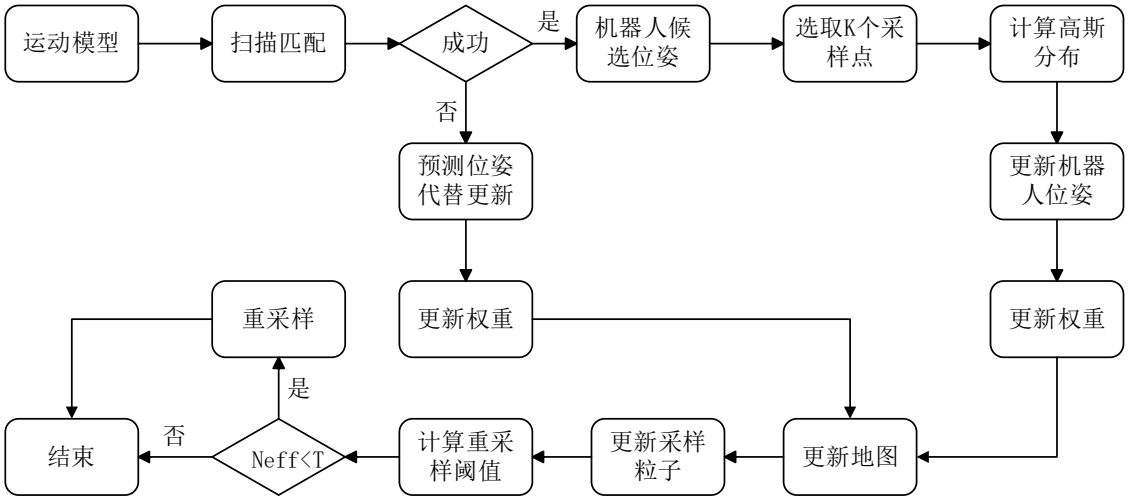

图 2.1 Gmapping 算法建图流程

Gmapping 算法对 RBPF-SLAM 算法中建议分布和重采样两部分具体改进如下：

(1) Gmapping 算法对 RBPF-SLAM 算法中建议分布改进为，用极大似然估计采样代替建议分布采样，用运动模型 $P\left(x_t \middle| x_{t-1}, u_t\right)$ 代替式(2.4)中的 $\pi\left(x_t^{(i)} \middle| x_{1:t-1}^{(i)}, z_{1:t}, u_{1:t-1}\right)$ 得到式(2.5)，而且将最新观测值 z_k 整合到建议分布中，通过将 z_k 整合到建议分布中，对有意义的区域用观测似然函数代替 $P\left(x_k \middle| x_{k-1}^i, u_k\right)$，为了与 RBPF-SLAM 理论部分进行区别，在

中国知网 https://www.cnki.net

以下推导中将t更换为k。

$$w_k^i \propto w_{k-1}^i \frac{p\left(z_k \middle| m_{k-1}^i, x_k^i\right) p\left(x_k^i \middle| x_{k-1}^i, u_k\right)}{p\left(x_k^i \middle| x_{k-1}^i, u_k\right)} = w_{k-1}^i p\left(z_k \middle| m_{k-1}^i, x_k^i\right) \tag{2.5}$$

$$p\left(x_k^i \middle| x_{k-1}^i, u_k\right) \to p\left(x_k \middle| m_{k-1}^i, x_{k-1}^i, z_k, u_k\right) \tag{2.6}$$

使用式（2.6）建议分布，优化权重计算：

$$\begin{aligned} w_k^i &= w_{k-1}^i \frac{\eta p\left(z_k \middle| m_{k-1}^i, x_k^i\right) p\left(x_k^i \middle| x_{k-1}^i, u_k\right)}{p\left(x_k^i \middle|, m_{k-1}^i, x_{k-1}^i, z_k, u_k\right)} \\ &\propto w_{k-1}^i p\left(z_k \middle| m_{k-1}^i, x_k^i\right) p\left(x_k^i \middle| x_{k-1}^i, u_k\right) \frac{p\left(z_k \middle| m_{k-1}^i, x_{k-1}^i, u_k\right)}{p\left(z_k \middle| m_{k-1}^i, x_k\right) p\left(x_k \middle| x_{k-1}^i, u_k\right)} \\ &\propto w_{k-1}^i p\left(z_k \middle| m_{k-1}^i, x_{k-1}^i, u_k\right) \end{aligned} \tag{2.7}$$

目标分布只有一个最大值，采用x_j覆盖在目标分布最大值的区域中，从而忽略低概率区域，节省计算。

近似区间L^i具有特定确定区域，L^i区间为：

$$L^i = \left\{ x \middle| p\left(z_k \middle| m_{k-1}^i, x\right) > \varepsilon \right\} \tag{2.8}$$

Gmapping 算法通过激光传感器模型对当前激光与地图的匹配度进行量化与优化，确定观测似然函数的有效区域，从而提高建图的精度和效率。在观测似然函数有效区间内采样，提高采样的精度和效率，并根据目标分布评估采样点，以得到更准确的移动机器人位置和地图信息。在间隔L^i之间通过采样K个x_j确定各自的均值μ_i和方差P_i。

$$\begin{aligned} \mu_i &= \frac{1}{\eta^i} \sum_{j=1}^{K} x_j p\left(z_k \middle| m_{k-1}^i, x_j\right) p\left(x_j \middle| x_{k-1}^i, u_k\right) \\ P_k^i &= \frac{1}{\eta^i} \sum_{j=1}^{K} p\left(z_k \middle| m_{k-1}^i, x_j\right) p\left(x_j \middle| x_{k-1}^i, u_k\right) \left(x_j - \mu_k^i\right) \left(x_j - \mu_k^i\right)^T \\ \eta^i &= \sum_{j=1}^{K} p\left(z_k \middle| m_{k-1}^i, x_j\right) p\left(x_j \middle| x_{k-1}^i, u_k\right) \end{aligned} \tag{2.9}$$

基于以上参数估计，可得到最优建议分布的封闭解的近似表达，使用极大似然估计法找到局部极值x_t，然后在x_t附近取k个位姿，对其进行位姿匹配。假设移动机器人位姿服从高斯分布，计算它们的均值和方差，并使用多元正态分布计算移动机器人位姿的后验概率。多元正态分布公式可以根据均值和协方差计算得出。这使得 Gmapping 具有非常高效率的粒子采样方法，使用此建议分布，权重可以计算为：

中国知网 https://www.cnki.net

$$
\begin{aligned}
w_k^i &= w_{k-1}^i p\left(z_k \middle| m_{k-1}^i, x_{k-1}^i, u_k\right) \\
&= w_{k-1}^i \int p\left(z_k \middle| m_{k-1}^i, x'\right) p\left(x' \middle| x_{k-1}^i, u_k\right) dx' \\
&\simeq w_{k-1}^i \sum_{j=1}^{K} p\left(z_k \middle| m_{k-1}^i, x_j\right) p\left(x_j \middle| x_{k-1}^i, u_k\right) \\
&= w_{k-1}^i \eta^i
\end{aligned}
\tag{2.10}
$$

(2)Gmapping 算法对重采样进行改进时，为了使较好的粒子在重采样过程中不被噪音影响而丢失，改进的重采样策略的有效性通过式(2.11)衡量，其中ϖ是粒子归一化权重，当建议分布与目标分布之间相近度高时，各粒子的权重也都近似，反之则各粒子的权重相差较大。根据粒子自身权重的离散程度，决定是否需要进行重采样。即用阈值判断参数N_{eff}的有效性，当N_{eff}小于目标阈值时进行重采样。

$$
N_{eff} = \frac{1}{\sum_{\mathrm{i}=1}^{N} \left(\varpi^{\mathrm{i}}\right)^2}
\tag{2.11}
$$

综上，Gmapping 算法通过对 RBPF 粒子滤波中的提议分布和重采样机制进行改进，有效地解决了粒子数量减少和粒子耗散的问题。具体来说，该算法利用最新一帧激光雷达数据观测，将粒子的有效分布限定在高似然函数所对应的区域，随后在这个区域内实施定向的粒子采样，由此限制了采样的广度，使得即使使用较少的粒子也能较好地覆盖移动机器人位姿的概率分布。此外，Gmapping 还巧妙地将高似然函数所对应区域从基于里程计的观测模型转移至基于激光雷达的观测模型，从而提升了定位和建图的精确度。

常见的利用激光雷达建图的算法还有 Hector 算法和 Cartographter 算法，由于本文中没有使用这两种建图算法，其建图原理不再详细描述，表 2.1 列出常见建图算法的优缺点。

表 2.1 常见激光 SALM 算法优缺点

激光 SLAM 算法	算法优点	算法缺点
Gmapping	解决了粒子衰减问题；在室内中小型场景效果较好；易于部署	缺少闭环检测使得精度较低
Cartographter	具有闭环检测，在室内大型场景效果较好；实时性好	计算量大
Hector	不需要里程计和 IMU	对激光雷达要求精度高；缺少闭环检测

2.2.3 机器人建立环境地图分类

移动机器人根据激光雷达获取家庭室内环境信息，并对周围环境进行理解，最终建立室内环境地图，以此描述物体准确位置以及表达所处环境信息。地图可根据其内容和

中国知网 https://www.cnki.net

形式分为多种类型，比较典型的有尺度地图[65]、拓扑地图[66]和语义地图[67]，如图 2.2 所示。本文在建立室内环境二维栅格的基础上用场景分类网络，以及目标检测网络将室内场景以及物体信息占据在栅格地图的单元上，建立室内语义地图。

(1)栅格地图：栅格地图是用一个个栅格组成的网格表示地图，每个栅格储存不同的的数值，表达不同的含义。栅格地图凭借其离散化环境表示、易构建与更新、计算效率、精确定位能力、多传感器融合、路径规划友好以及软件工具成熟的诸多优势，在移动机器人建图中得到了广泛应用。尽管存在诸如空间分辨率选择导致的空间浪费、大范围地图可能导致的数据量过大等问题，但通过合理的设计与优化，栅格地图仍然是目前移动机器人领域建图与导航的标准方法之一。

(2)拓扑地图：拓扑地图是一种简洁化的地图表示形式，主要用于揭示环境结构中各点间的连通关系，尤其适用于描述室内环境的空间布局。本文通过构建室内物体节点与移动机器人位姿节点间的关系图谱也是一种拓扑地图。与详细的比例尺地图相比，拓扑地图倾向于忽略具体的空间几何细节，仅强调点与点之间的连通性。在移动过程中，机器人只需依据拓扑地图掌握当前位置所处的连通边信息。拓扑地图结构简明，利于快速进行路径规划和提升导航效率，但也因其抽象化的特点，导致机器人在地图上的定位不够精确。

(3)语义地图：语义地图是在普通尺度地图的基础上进行深化和扩展，增添了场景及物体属性标签，包含了诸如名称、类别、尺寸等关于地图中物体的具体信息。该类地图的一大优势在于能够使机器人更好地理解和诠释周边环境，使机器人理解模式更趋近于人类思维，从而有利于实现机器人与人类用户更流畅自然的互动，并完成更为复杂的任务。然而，由于语义地图承载的信息丰富度较高，相应地对机器人的数据处理能力和计算性能提出了更高的要求。当前，语义地图已在自动驾驶、智能家居服务等多个领域得到了广泛应用。

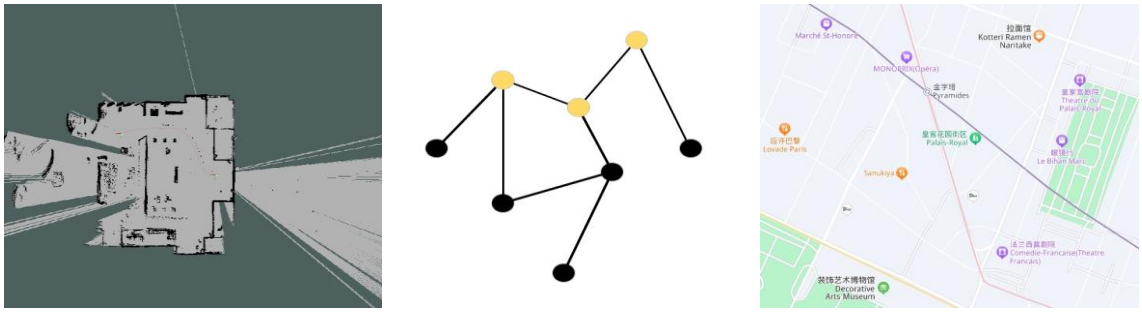

(a)栅格地图　　(b)拓扑地图　　(c)语义地图

图 2.2 地图种类

本文基于二维栅格地图建立室内语义地图，利用场景分类网络以及目标检测算法，分类室内场景和提取室内物体语义信息语义信息，将室内场景和物体的语义信息用占用栅格算法，占据栅格单元建立室内语义地图。

中国知网 https://www.cnki.net

栅格地图通过赋予栅格单元数值表示占有情况，用0~1的概率值描述栅格被占用的概率，对于某个栅格单元通过引入空闲（Free）状态与 Occupied（被占用）状态概率的比值作为描述栅格单元的占用率，比值占用率为 Odd(s)，当接受到激光雷达观测值 $z(0\sim1)$)后,更新栅格单元占用率 Odd(s)，根据条件概率得出观测值 z 产生后栅格单元占用率 Odd(s)，表示为式(2.12)，占据栅格地图如图 2.3 所示。

$$Odd(s|z)=\frac{p(s=1|z)}{p(s=0|z)} \tag{2.12}$$

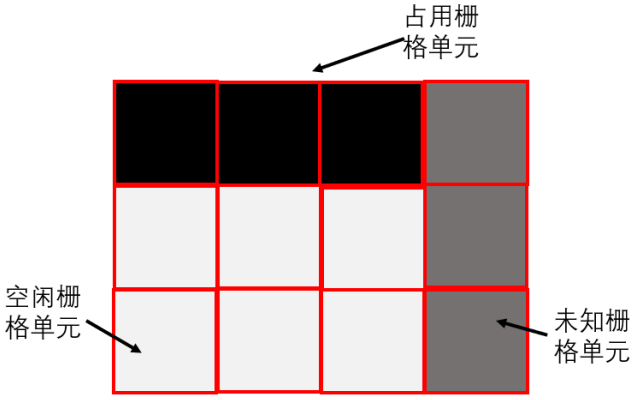

图 2.3 占据栅格地图示意图

根据贝叶斯概率公式得：

$$\begin{aligned} p(s=1|z)&=\frac{p(z|s=1)\,p(s=1)}{p(z)} \\ p(s=0|z)&=\frac{p(z|s=0)\,p(s=0)}{p(z)} \end{aligned} \tag{2.13}$$

将式(2.13)代入(2.12)后，两边取对数可得：

$$\log Odd(s|z)=\log\frac{p(z|s=1)}{p(z=0)}+\log Odd(s) \tag{2.14}$$

此时栅格状态表达式(2.14)中，激光雷达测量值的部分只在等式右边的第一项，即这一项为测量值模型。在使用激光雷达建图时，栅格单元只有占据和空闲两种状态，用 $\log Odd(s)$ 来表示栅格单元 s 的状态为 S，可推导出：

中国知网 https://www.cnki.net

$$
\begin{aligned}
lofree &= \log \frac{p\left(z=0|s=1\right)}{p\left(z=0|s=0\right)} \\
looccupied &= \log \frac{p\left(z=1|s=1\right)}{p\left(z=1|s=0\right)} \\
S^{'} &= S + \log \frac{p\left(z|s=1\right)}{p\left(z=0\right)}
\end{aligned}
\tag{2.15}
$$

在激光雷达未测量之前栅格单元初始状态 S_{init} 为未知状态，其空闲和占用概率都为 0.5。

$$
S_{init} = \log Odd\left(s\right) = \log \frac{p\left(s=1\right)}{p\left(s=0\right)} = \log \frac{0.5}{0.5} = 0 \tag{2.16}
$$

此时，栅格单元状态的更新可通过加法进行概率计算，经过激光雷达多次扫描，环境中每个栅格单元被赋值。

$$
\begin{aligned}
S^{+} &= S^{-} + lofree \\
S^{+} &= S^{-} + looccupied
\end{aligned}
\tag{2.17}
$$

其中，S^{+} 和 S^{-} 分别表示激光雷达测量值之后和之前栅格单元 s 的状态，S^{+} 越大则栅格单元被占据的概率就越大。

2.3 基于栅格地图的路径规划方法

移动机器人导航任务分为全局路径规划和局部路径规划，其中全局路径规划是一个单序列规则问题，目的是在移动机器人工作空间中找到一条符合算法规则的道路，目前常见的全局路径规划可分为基于图搜索和基于采样方法两类，其中基于图搜索算法的代表是深度优先搜索 (depth first search, DFS)与广度优先搜索(breath first search, BFS)，基于采样算法的代表是快速拓展随机树 (rapidly-exploring random trees, RRT)及其系列变种算法。这两种算法虽在形式上略有不同, 但其思想都在于从起始状态开始对当前工作空间进行不断的探索, 直至终点状态被发现后再对探索过程进行回溯以生成路径，这类算法随着搜索空间增大消耗时间急剧增加。

目前移动机器人在室内环境常见的全局路径规划搜索算法为 Dijkstra 算法和 A*算法。本文在寻找室内位置坐标未知的动态物体时，首先移动机器人查询关系图谱得到与动态物体关系最大的地标物体，然后依赖语义地图得到该地标物体的位置坐标，最后利用 A*算法导航移动到地标物体附近寻找动态物体。

2.3.1 Dijkstra 算法

Dijkstra 算法是一种广度搜索的算法，适用于有向或无向带权图，其算法思想基于贪心策略，每次选择当前最短距离的节点作为下一步的处理对象，在求解过程中使用了

中国知网 https://www.cnki.net

一个数组记录已经确定最短路径的节点到起点的距离，以及一个集合 S 记录已经确定了最短路径的节点，最终求解出起点到所有节点的最短路径。

Dijkstra 算法的基本步骤如图 2.4 所示。最主要的两个步骤是求出从原点出发到各顶点的最短路径和遍历下一循环最短路径，如下式(2.18)所示：

$$\begin{cases} d_j = \min\left[d_j, d_k + l_{kj}\right] \\ d_i = \min\left[d_j\right] \end{cases} \tag{2.18}$$

其中，l_{kj} 是从任意已知最短原点路径的顶点k到各顶点j的直接连接距离；d_j 为原点到各个顶点的最短路径；d_k 为已知最短原点路径顶点 k 的最短原点路径；d_i 为指定最短路径，下一循环选择顶点的最短原点路径。

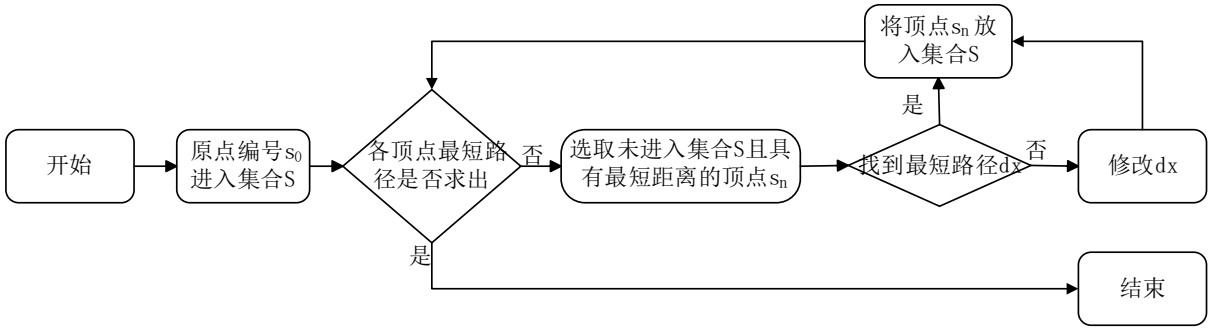

图 2.4 Dijkstra 算法流程

Dijkstra 算法具有较强的鲁棒性，适用范围广，且在搜索任务中可以得到完整移动机器人移动路径。其优点有(1)准确性：Dijkstra 算法能够保证在给定的图中，如果存在一条路径，那么找到的解将是最短的路径。(2)普适性：适用于各种类型的图，包括有向图和无向图，只要图的边权重非负。(3)实现简单：相比于其他更复杂的最短路径算法，Dijkstra 算法相对容易实现。(4)广泛应用：在网络路由、地图导航、社交网络等领域有着广泛的应用。

其缺点有(1)非负权重限制：Dijkstra 算法不能用于包含负权重边的图。这是因为算法基于贪心策略，一旦最短路径被选中，就不会再被更新，负权重可能会导致算法早期做出的选择不是全局最优的。(2)时间复杂度：Dijkstra 算法的耗费时间与环境尺度有关，对于大规模地图搜索计算成本极高，而且效率偏低。(3)动态图问题：Dijkstra 算法不适合动态变化的图。在图的结构或权重发生变化时，可能需要重新运行整个算法来更新最短路径。

2.3.2 A*算法

结合 Dijkstra 算法和最佳优先搜索算法 (BFS)的优点，增加启发式搜索，衍生了 A*算法[68]。该算法不需要遍历图中的所有节点，提高了节点搜索速度，其思想是以当前节点 n 为中心，向周围扩展待选节点 $node = [n_1, n_2, n_3, ...]$。A* 算法在栅格地图搜索时，将

中国知网 https://www.cnki.net

当前中心节点 n 所在方格周围 8 个方格作为下一步待选节点，选中节点不能在阻碍区域范围内。通过评价函数计算待选节点的代价值，选择代价值最小的节点作为下一步节点 n+1。A* 算法的评价函数为：

$$f(n)=g(n)+h(n) \tag{2.19}$$

其中，$f(n)$表示待搜索点的路径评价函数，用来选取最优路线；$g(n)$表示从起点到当前点的最短路径；$h(n)$表示当前点到目标点的最短路径，是启发函数。移动机器人的执行搜索任务时，出发点为 A*算法的起始点，每次移动时用式（2.19）在栅格地图上选择扩展点，所有选择的点组成移动机器人行走的路径轨迹。当$h(n)$取值为 0 时，A*算法相当于 Dijkstra 算法，当$g(n)$取值为 0 时，A*算法相当于 BFS 算法。

在 A*算法的路径搜索进程中，首先利用 openList 存储有待评估的节点，而 closeList 则记录已经评估过的节点。算法通过代价函数$g(n)$来计算从起始节点 s 至当前候选节点 n 的实际行驶成本，同时采用启发式函数$h(n)$估算从候选节点 n 至目标节点 e 的预计行驶成本。依据公式(2.19)，算法会选择 openList 中具有最小综合代价（实际成本与预估成本之和）的节点作为下一个要考察的对象，持续这一迭代过程直到找到目标节点为止。因此，可以说 A*算法是在估价函数中加入特定约束条件后形成的一种高效启发式搜索方法，这样的搜索策略有助于规避无效的搜索路径，从而大幅度提升搜索效率。

A*算法的优点有(1)效率和速度：A*算法通过启发式函数来评估剩下的路径代价，有效减少了搜索空间。这种估算让 A*算法比其他纯粹的广度优先或深度优先搜索算法更快找到最短路径。(2)灵活性：A*算法的启发式函数是可定制的，这意味着可以根据问题的具体需求调整它，以提高搜索效率。(3)准确性和完整性：只要启发式函数不超过估计实际成本，A*算法保证找到最短路径。这一点是通过对所有可能的路径进行考虑和评估来实现的。(4)适用性广泛：A*算法可以应用于许多类型的搜索问题，包括但不限于路线规划、游戏中的 NPC 移动、图形编辑器中的对象寻径等。

其缺点有(1)空间复杂度：A*算法在运行过程中需要存储所有探索过的节点以及还未探索的节点。在大规模搜索问题中，这可能会消耗大量的内存。(2)对启发式函数的依赖：A*算法的效率和效果很大程度上依赖于启发式函数的选择。一个不合适的启发式函数可能导致搜索效率低下，甚至找不到解。(3)计算成本：尽管 A*算法比许多其他算法更快，但在处理非常大的数据集或复杂环境时，其计算成本仍然可能非常高。(4)路径优化限制：在某些情况下，A*算法找到的最短路径可能不是“最优”的路径，特别是当路径的“优化”不仅仅基于长度或成本时。

2.4 本章小结

本章主要对目前移动机器人常见的室内建图算法和路径规划导航算法原理进行阐述。对基于激光雷达建图的传统粒子滤波算法以及改进传统粒子滤波算法的 Gmapping

中国知网 https://www.cnki.net

算法建图原理进行说明，并对基于栅格地图的路径规划算法 Dijkstra 算法和 A*算法原理进行说明并总结了优缺点，为下文建立室内语义地图以及室内移动机器人寻物导航提供了理论支持。

中国知网 https://www.cnki.net

第三章 室内语义地图的构建

3.1 引言

移动机器准确理解环境信息是移动机器人智能化的关键环节，由于语义地图可提供场景信息和物体信息，能够使移动机器人对其所处的区域和物体进行理解，因此移动机器人可根据语义信息执行符合人类行为习惯的动作指令，从中提取隐含的运动方式及语义指令，从而更高效更智能的执行任务。

本章针对已有语义地图建图时间慢、部署设备要求高、实时性差、在家庭室内门口容易出现语义标注错误等问题，对家庭室内环境场景识别模型 Places205-VGG16 进行先验概率优化，制作室内物体数据集训练 YOLOv5s 目标检测模型，提高目标检测精度。在此基础上，提出融合阈值与可变语义标注范围的策略，避免室内房间门口场景语义标注错误。

3.2 建立栅格地图

在未知室内环境下，移动机器人首先利用激光雷达和里程计获取的室内信息，基于 RRT[69](Rapidly-exploring Random Trees)快速拓展随机树融合 Gmapping 建图算法，自主建立未知环境室内二维栅格地图，在此基础上，构建室内语义地图，建立室内语义地图整体框架如图 3.1 所示。

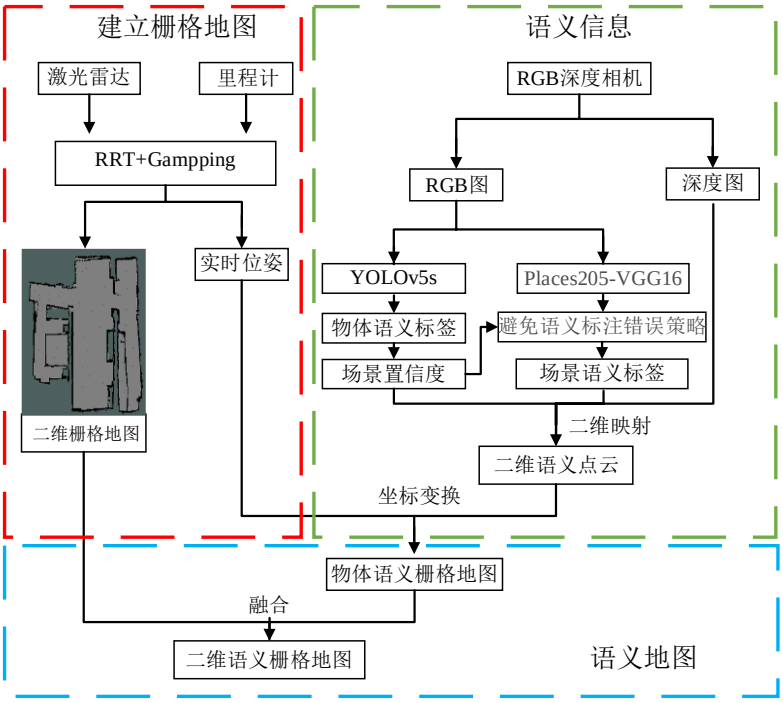

图 3.1 构建语义地图整体框架

中国知网 https://www.cnki.net

首先移动机器人利用相机获得的 RGB 图，基于先验概率优化场景识别模型 Places205-VGG16 神经网络[70]进行场景识别；然后，利用制作的室内物体数据集训练 YOLOv5s 模型对室内物体进行识别，通过深度相机和坐标转换计算物体在二维栅格地图的坐标，进行物体语义标注；并得出物体实际尺寸，赋予物体场景置信度；基于物体场景置信度提出室内环境避免门口场景语义标注错误策略；最后，家庭室内环境二维栅格地图与场景语义标签和物体语义标签进行融合，建立室内二维语义地图。

3.3 未知室内环境语义地图构建

3.3.1 家庭室内环境场景识别

在常用基准数据集中，场景识别模型 Places205-VGG16 的神经网络性能稳定，该模型涵盖了 205 个场景类，每一个场景类别中包含 5000 多张图片，利用 250 万多张图片的数据集，可对场景识别任务进行大量训练，网络模型如图 3.2 所示。

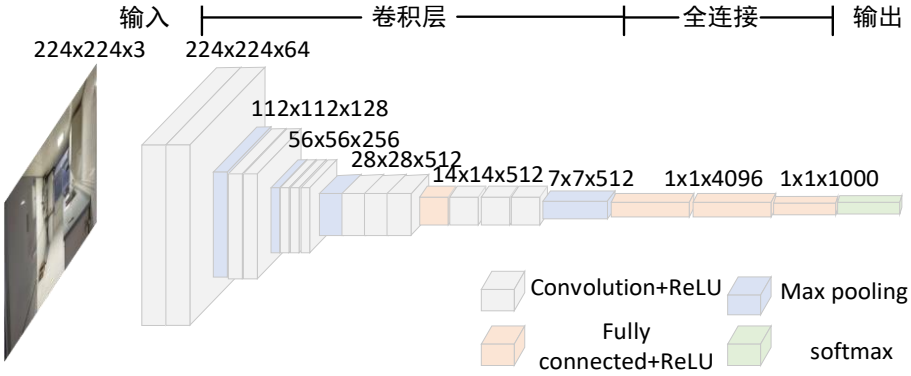

图 3.2 Places205-VGG16 网络模型

将室内语义场景分类问题转化为概率估计问题，设相机当前场景中给定的第 t 幅图像为 I_t，则 Places205-VGG16 网络 softmax 输出层的输出在第 t 个场景类别 x_t 上的离散概率分布为 $p(x_t \mid I_t)$。将场景类别的标签集合定义为：

$$\hat{x} = \left(x_0, x_1, x_2 \cdots x_t \cdots x_n\right) \qquad n = 205 \tag{3.1}$$

相对于所有场景类别标签，通过 Places205-VGG16 网络模型估计得到图像数据流的场景离散分布为 $p(\hat{x}_t \mid I_{\{0\sim t\}})$，其中 $I_{\{0\sim t\}}$ 为相机从 0 到 t 时刻获取的图像序列，则似然函数可表示为：

$$\mathcal{L}\left(I_t \middle| \hat{x}\right) = \left(p\left(x_0 \middle| I_t\right), p\left(x_1 \middle| I_t\right) \cdots p\left(x_{n-1} \middle| I_t\right), p\left(x_n \middle| I_t\right)\right) \tag{3.2}$$

其中，$p(x_n \mid I_t)$ 为第 t 幅图像对于场景中第 n 类场景的离散概率分布；$x_0, x_1, x_2 \cdots x_n$ 之间相互独立。

上述场景识别算法只是对每张场景图像单独处理，通过相机获取相邻两帧图片在时间上的连续性。针对所有场景类别标签，将场景分类问题解释为贝叶斯估计问题，估计所有可能场景中标签的概率分布。假设上述估计问题满足一阶马尔科夫特性，理论上将

中国知网 https://www.cnki.net

得到更为一致的场景分类识别效果。贝叶斯滤波公式为：

$$p\left(\hat{x}_t \middle| I_t\right) = \mathcal{L}\left(I_t \middle| \hat{x}_t\right) \cdot p\left(\hat{x}_{t-1} \middle| I_{t-1}\right) \tag{3.3}$$

将场景分类看作贝叶斯估计问题，可将其他先验信息加入进行计算。由于 Places205-VGG16 网络模型的数据集包含很多家庭室内环境不需要的场景，因此加入先验概率 $p(\hat{x})$ 可以进一步提升场景识别效率，减小计算量，加入先验概率的贝叶斯滤波公式为：

$$p\left(\hat{x}_t \middle| I_t\right) = p(\hat{x})\mathcal{L}\left(I_t \middle| \hat{x}_t\right) \cdot p\left(\hat{x}_{t-1} \middle| I_{t-1}\right) \tag{3.4}$$

有了当前图像场景概率后，将场景类别的语义信息映射到 Gmapping 建立的室内二维栅格地图，应用栅格占用算法[41]将场景类别的语义信息与室内二维栅格地图相融合，每一个场景类别的语义信息代表一个地图层，如图 3.3 所示。

设栅格单元为 m，则 m 被场景类别语义 x_n 占据的概率为 $p_m\left(x_n \middle| I_{\{0-t\}}\right)$：

$$p_m\left(\hat{x}_n \middle| I_{\{0\sim t\}}\right) = \left(\left(1+\frac{1-p_m\left(\hat{x}_n \middle| I_t\right)}{p\left(\hat{x}_n \middle| I_t\right)}\right)\left(\frac{1-p_m\left(\hat{x}_n \middle| I_{\{0:t-1\}}\right)}{p\left(\hat{x}_n \middle| I_{\{0:t-1\}}\right)}\left(\frac{p(\hat{x}_n)}{1-p(\hat{x}_n)}\right)\right)^{-1}\right) \tag{3.5}$$

根据式(3.5)，栅格单元 m 被场景语义占据的更新取决于相机当前图像 I_t。

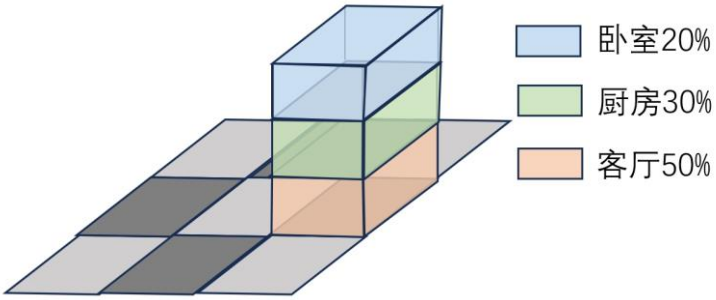

图 3.3 栅格单元属于某个场景语义的概率示意

3.3.2 室内物体数据集的制作

移动机器人需具有自适应感知环境中物体的能力，在进行目标检测时，需获取图像中物体类别以及物体在图像中的位置坐标，本研究应用 YOLOv5s 算法进行物体检测。

YOLOv5s 官方 COCO 数据集所能识别的 80 种类别未包括一些常见的家庭室内物体，如立式空调、枕头等。为了更好识别家庭室内环境，本文制作了室内环境物体数据集，具体种类如表 3.1。通过旋转、裁剪等数据增强方式对数据集进行扩充。最终训练集包含 19 种类别共计 3500 多张图片，测试集包含 1500 多张图片。

中国知网 https://www.cnki.net

表 3.1 制作的室内物体数据集种类

室内场景	客厅		厨房	卧室	
室内物体	键盘	茶几	垃圾桶	笔记本电脑	柜子
	立式空调	桌子	苹果	键盘	床
	柜子	沙发	柜子	台灯	鼠标
	电视	鼠标	杯子	杯子	手机
	杯子	椅子	冰箱	枕头	
	手机	笔记本电脑		书籍	

使用 LabelImg 工具对每张图像中的室内物体进行标注。识别对象被一个矩形边界框包围，并给出类别和名称。将标注后的矩形边界框坐标信息和识别对象的类别信息保存在生成的 XML 文件中。然后，根据 XML 文件生成“train”、“trainval”、“test”、“val”四个文本文件。

3.3.3 室内物体坐标与栅格地图坐标的转换

利用 YOLOv5s 识别室内物体，得到物体在栅格地图上的位置。将相机坐标系下识别的物体坐标，转换到栅格地图坐标中。设物体在相机坐标系下位姿为 $\boldsymbol{T}_o^c$，相机在移动机器人坐标系下位姿为 $\boldsymbol{T}_c^r$，移动机器人在栅格地图坐标系下位姿为 $\boldsymbol{T}_r^m$，物体在栅格地图坐标系下位姿为 $\boldsymbol{T}_o^m$，如图 3.4 所示。

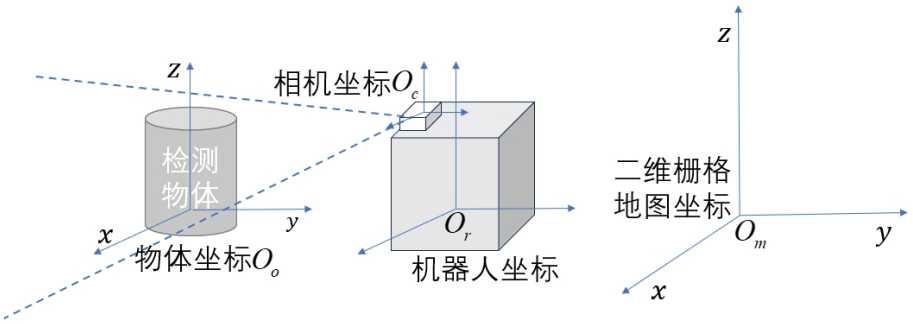

图 3.4 相机、移动机器人坐标与栅格地图坐标的关系

提取 YOLOv5s 算法计算出的物体检测框坐标 $X_{\min}, X_{\max}, Y_{\min}, Y_{\max}$ 的像素，计算室内物体在移动移动机器人构建的栅格地图坐标系下坐标，计算公式为：

$$\begin{bmatrix} x_g \\ y_g \end{bmatrix} = \operatorname{int}\left\{ \frac{1}{\mathrm{Re}} \left[\begin{bmatrix} \boldsymbol{R}_{mr} & \boldsymbol{T}_{mr} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \boldsymbol{R}_{cr} & \boldsymbol{T}_{cr} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} \right] \right\} \tag{3.6}$$

其中，(x_g, y_g) 为物体在栅格地图坐标系下的坐标；int 为取整函数；Re 为二维栅格地图的分辨率；$\boldsymbol{R}_{mr}, \boldsymbol{T}_{mr}$、分别为移动机器人坐标系相对世界坐标系的旋转和平移矩阵，平移量和旋转量由激光 SLAM 获取。

中国知网 https://www.cnki.net

$$\boldsymbol{R}_{mr}=\begin{bmatrix}\cos\varphi & -\sin\varphi & 0\\ \sin\varphi & \cos\varphi & 0\\ 0 & 0 & 1\end{bmatrix},\boldsymbol{T}_{mr}=\begin{bmatrix}t_{mx}\\ t_{my}\\ 0\end{bmatrix} \tag{3.7}$$

其中，t_{mx},t_{my},φ，表示激光 SLAM 输出的移动机器人位姿；$\boldsymbol{R}_{cr},\boldsymbol{T}_{cr}$ 为移动机器人坐标系相对相机坐标系的旋转和平移矩阵：

$$\boldsymbol{R}_{cr}=\begin{bmatrix}0 & 0 & 1\\ 0 & -1 & 0\\ 1 & 0 & 0\end{bmatrix},\boldsymbol{T}_{cr}=\begin{bmatrix}t_x\\ t_y\\ t_z\end{bmatrix} \tag{3.8}$$

其中，t_x,t_y,t_z，为移动机器人坐标系的原点相对相机坐标系的位置，通过测量相机在移动机器人上的安装尺寸来获得。在本文中，$t_x=209.5mm$，$t_y=18mm$，$t_z=205mm$。物体在相机坐标系下的坐标 X_c，Y_c，Z_c 由像素点所对应的点云深度计算公式得出[71]。

3.4 避免室内门口场景语义标注错误策略

移动机器人在对当前房间进行实时语义场景标注过程中，如移动机器人在客厅，二维栅格地图被客厅语义场景所占据，当移动机器人移动到卧室门口未进入卧室，可以检测到卧室的物体时，则原来被客厅场景占据的栅格地图会被卧室语义场景覆盖，造成客厅语义地图场景标注错误。这种语义标注错误在推拉门或较大的门口更容易出现，如图 3.5 所示，图中 α 为语义场景标注错误的三角形区域角度。

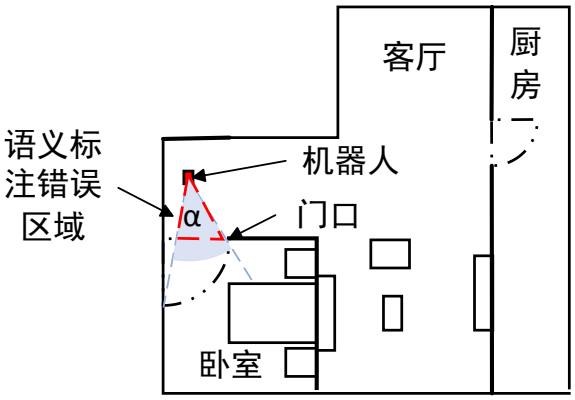

图 3.5 语义场景标注错误示例

传统方法在室内语义建图时为避免上文描述的语义场景标注错误，通常关闭房门或是用物体遮挡门口，建立完一个房间再建立另一个房间的地图。为实现移动机器人完全自主的建立语义地图，本研究提出一种避免室内房间门口场景语义标注错误的策略。基于人工势场法虚拟力[72]“引力和斥力”， 给同一场景物体“引力”，不同场景物体“斥力”，“引力”和“斥力”使语义标注范围变大或变小,即采用可变语义标注范围。当移动机器人在某一场景随着检测到属于这一场景的物体越多，移动机器人在该场景的语义标注范围就越大；当识别到不属于这个场景的物体则在该位置语义标注的范围变小。如图

中国知网 https://www.cnki.net

3.6 所示，当移动机器人在卧室门口，检测到不属于客厅的物体时，在卧室方向的语义标注范围变小，语义标注半径由 D 变为 d。

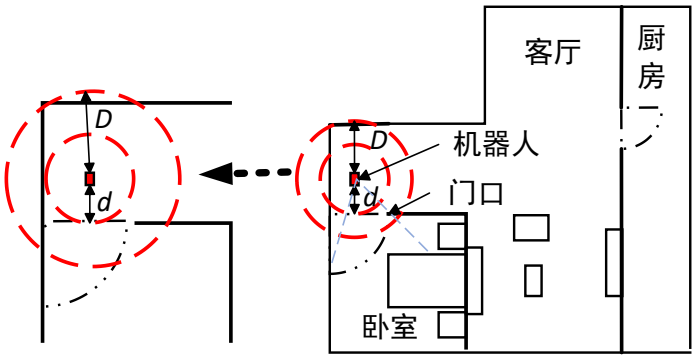

图 3.6 变化的场景语义标注范围

采用可变范围语义标注，移动机器人在门口切换场景时将检测到两个不同场景，则物体语义标注范围减小，语义标注错误区域也会变小，但仍然出现小范围场景语义标注错误。基于此，本文设定一个场景语义标注阈值，移动机器人识别同一场景室内物体累计超过该阈值时，则切换场景语义标注，以避免在门口识别到少量非移动机器人所在区域物体，错误的进行当前门口位置场景语义标注。因此融合阈值和可变语义标注范围的方法，在门口场景切换区域，移动机器人不会立即改变场景的语义标注，而是需要检测到更多同一场景的室内物体后，再进行新场景的语义标注。可变语义标注范围使得移动机器人在门口语义标注范围变小，移动机器人语义标注场景限定在当前区域，避免在门口出现场景语义标注错误的情况。

3.4.1 室内物体场景置信度设置

家庭室内家具的摆放具有很大随机性和不确定性，为了更准确识别场景，将室内家具分为两类，一类是较大的基本不移动物体，如：冰箱、床、书桌等，另一类是较小可能经常移动的物体，如：椅子、杯子、笔记本电脑等。移动机器人在较大的家具旁边，更加确信自己当前所处的场景，如移动机器人在床边，会更加确信当前所处的位置是卧室，因此设置较大的家具更大场景置信度。

利用 YOLOv5s 识别室内物体，输出包含室内物体检测框坐标信息，结合深度相机测量室内物体与相机之间的距离信息，通过 3.3.3 小节坐标转换可以求出室内物体的实际尺寸。

为了减小计算量，对 YOLOv5s 识别到的每一个物体，只计算检测框较长的一条边。设置室内物体的长或宽其中一边大于 $1.5m$ 则为较大家具，赋予场景置信度 $C=0.3$；对于长和宽都小于 $1.5m$ 的家具为小家具，赋予场景置信度 $C=0.1$，移动机器人在当前场景识别到属于该场景的物体，则场景置信度为 C_{at}，识别到不属于该场景的物体，则场景置信度为 C_{rep}。

中国知网 https://www.cnki.net

3.4.2 引力斥力函数

建立室内物体的“引力斥力”函数，利用“引力斥力”公式来计算语义标注范围，引力函数[72]为：

$$F_{at}=\begin{cases}\frac{1}{2}\eta r^2 & 0\leqslant r\leqslant r_0\\ 0 & r>r_0\end{cases} \tag{3.9}$$

其中，r 为移动机器人语义标注范围；η 为引力系数常量；r_0 为移动机器人相机工作范围。

斥力函数为：

$$F_{rep}=\begin{cases}-\frac{1}{2}k\left(\frac{1}{r}-\frac{1}{r_0}\right)^2 & 0\leqslant r\leqslant r_0\\ 0 & r>r_0\end{cases} \tag{3.10}$$

其中，k 为斥力系数常量。

移动机器人在当前场景进行识别，属于该场景的物体具有“引力”，不属于该场景的物体具有“斥力”，即本文中物体场景置信度的含义就是室内物体对移动机器人的“引力”或“斥力”即：

$$F=C \tag{3.11}$$

则由公式(3.9)-(3.11)得出语义标注受到“引力”或“斥力”影响的标注范围 r_{at} 和 r_{rep} 分别为：

$$r_{at}=\begin{cases}\sqrt{\frac{2C_{at}}{\eta}} & 0.6\leqslant d_1\leqslant 4\\ 0 & d_1<0.6\text{或}d_1>4\end{cases} \tag{3.12}$$

$$r_{rep}=\begin{cases}-\frac{r_0{}^2k}{2C_{rep}r_0{}^2+k+2\sqrt{C_{rep}k}r_0} & 0.6\leqslant d_2\leqslant 4\\ 0 & d_2<0.6\text{或}d_2>4\end{cases} \tag{3.13}$$

其中，d_1 为移动机器人与当前场景物体距离；d_2 为移动机器人与另一场景物体距离，由相机工作范围可得(3.13)式中 $r_0=0.6\,\mathrm{m}$。

当机器人在门口语义标注范围没有穿过门口，即语义标注没有发生错误时，语义标注范围可通过测量得出，即 r 已知，则可由式(3.12)、(3.13)得出 η,k 。

设移动机器人检测到属于该场景的物体有 q 个，检测到不属于该场景的物体为 p 个，则受到室内物体“引力”或“斥力”共同影响下语义标注范围为：

$$r=\sum\nolimits_{i=1}^{q}r_{at}+\sum\nolimits_{i=1}^{p}r_{rep} \tag{3.14}$$

其中，$\sum r_{at}$ 和 $\sum r_{rep}$ 分别为移动机器人在当前位置受到的“引力”或“斥力”影响

中国知网 https://www.cnki.net

下语义标注范围的距离。

语义标注范围的变化使得移动机器人在门口语义标注错误区域变小，但不能完全避免错误区域。此时设置一定阈值，使移动机器人在门口检测到不属于当前场景的物体时不会立即切换语义标注场景，结合具有阈值和变范围的语义标注避免移动机器人在门口语义标注错误。

3.4.3 语义标注阈值设置

通过实验得出本研究中场景语义标注阈值与建图时间和精确度之间的关系如图 3.7 所示，其中场景语义标注阈值为同一场景室内物体场景置信度的累计求和，对不同场景置信度之和取最大值。如：移动机器人在门口同时检测客厅中一个大物体和两个小物体，卧室中一个大物体一个小物体，则客厅反馈给移动机器人的阈值为 0.3+0.1+0.1=0.5，卧室反馈给移动机器人的阈值为 0.3+0.1=0.4，取其中最大值 0.5。

精确度(PA)按照标注正确像素占总像素的比例计算，得到：

$$PA=\frac{\sum_{i=0}^{u}P_{ii}}{\sum_{i=0}^{u}\sum_{j=0}^{u}P_{ij}} \tag{3.15}$$

其中，u 表示像素的总数量；P_{ii} 表示真正的标注数量；P_{ij} 表示本属于 i 类但被预测为 j 类的像素数量，实验结果如图 3.7 所示。

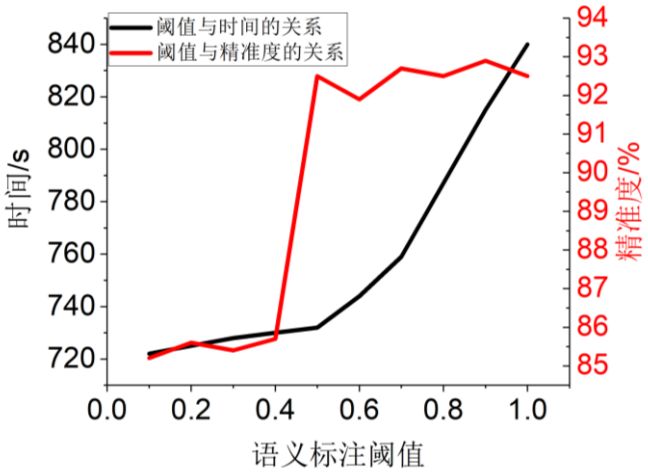

图 3.7 语义标注阈值与建图时间和精准度的关系

从图 3.7 可看出语义标注阈值在 0.6 以上时，建图时间迅速增加，这是由于移动机器人在同一场景识别室内物体越多越耗费时间；在语义标注阈值较低时精确度较低，这是因为移动机器人在门口识别到不属于移动机器人所在场景的物体时，在语义标注阈值较低时会发生场景语义标注错误；在语义标注阈值为 0.5 时精确度大幅增长，然后在一定范围波动，这是因为此时移动机器人没有发生语义标注错误，即使语义标注阈值增大也不会影响场景语义标注的精确度。根据以上实验结果，在本文家庭实验环境中选取语

中国知网 https://www.cnki.net

义标注阈值为 0.5。

3.5 本章小结

针对在家庭室内门口容易出现语义标注错误的问题，提出了利用 YOLOv5s 和深度相机，通过坐标转换得到室内物体大小，赋予物体 场景置信度，移动机器人语义标注时在不同场景切换时，由场景置信度累加的阈值决定，经过实验得出不同阈值对建图效率和时间的影响，本文选择阈值为 0.5。

基于人工势场法虚拟力“引力和斥力”， 给与移动机器人同一场景物体“引力”，不同场景物体“斥力”，使语义标注范围变大或变小，移动机器人语义标注范围由阈值和“引力斥力”共同决定，使得移动机器人在门口语义标注时不会立即改变当前标注场景且语义标注范围减小，从而避免在门口移动机器人语义标注穿过门口出现语义标注错误。

中国知网 https://www.cnki.net

第四章 室内物体与机器人位姿关系图谱的建立

4.1 引言

移动机器人通过语义地图上的语义信息理解地图上的区域场景和物体的信息及坐标，但是语义地图不能表达物体之间的关联信息，也不包含经常移动的物体，如手机、钥匙等。移动机器人仅依靠语义地图不能寻找这些位置坐标未知的动态物体，而人类对室内物体之间的位置联系具有直观的理解，如手机可能在客厅的沙发或茶几附近，钥匙可能在门口的玄关附近。

我们生活的家庭环境中物体之间的摆放位置具有一定的关联性，本章利用图神经网络，将室内物体与机器人位姿之间的关联表示为概率分布。为了减少计算、方便后续使用，将固定物体、动态物体以及机器人位姿组成节点，将固定物体与动态物体之间的概率关系，以及物体与移动机器人位姿之间的概率关系组成边，用图网络聚类算法显式输出节点和边，建立关系图谱。移动机器人在寻找位置坐标未知的动态物体时，首先通过关系图谱查询与寻找的动态物体关系最大的地标物体，然后通过语义地图得到固定物体坐标，A*算法导航到固定物体节点附近，在固定物体附近寻找动态物体，完成寻找位置坐标未知的动态物体任务。

4.2 图结构的定义及室内物体搜索方法

4.2.1 图结构的定义

将室内所有物体分为固定的地标物体$\mathcal{L}=\{\ell_1,\ell_2,\ell_3,...,\ell_n\}$，如：冰箱、桌子和动态物体$c=\{c_1,c_2,c_3,...,c_n\}$，如：手机、钥匙等。定义学习策略为$\pi\left(\mathcal{G},c_{target}\right)$，$\pi$由一个图卷积层和三个全连接层组成，其中$\mathcal{G}=\left(\mathcal{X}\cup\mathcal{L},\varepsilon\right)$，包含移动机器人位姿信息$\mathcal{X}$，地标物体$\mathcal{L}$的大小以及种类信息，将移动机器人位姿和地标物体称为节点，ε表示移动机器人位姿和地标物体之间关系的边，即节点之间的边，移动机器人位姿节点之间的边表示移动机器人可以从一个位姿节点导航到另一个位姿节点。地标物体节点与移动机器人位姿节点之间的边，表示移动机器人在该位姿可以观测到地标物体。这样定义的$\mathcal{G}$称为图结构，如图 4.1 所示。动态物体c是包含在 YOLOv5s 训练数据集中，但是具体位置不确定。学习策略$\pi\left(\mathcal{G},c_{target}\right)$需要经过训练来表达出动态物体$c$与$\mathcal{G}$之间隐藏的概率关系。

中国知网 https://www.cnki.net

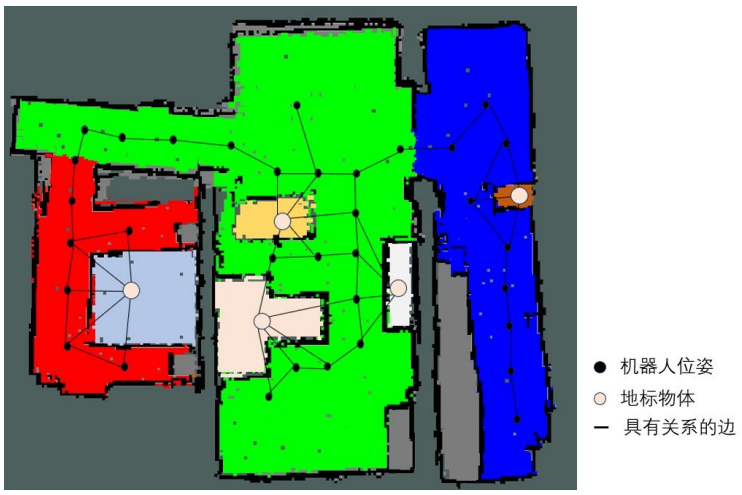

图 4.1 室内地标物体与移动机器人位姿组成的图结构

移动机器人的任务是用尽可能短的路程找到目标物体，给移动机器人输入寻找的目标物体，当目标物体是地标物体 $\mathcal{L}$ 时，移动机器人可由语义地图得出地标物体的位置坐标，然后利用 A*算法导航到地标物体所在的区域，找到目标物体。

当目标物体是位置坐标未知的动态物体 c 时，移动机器人首先利用室内物体与机器人位姿关系图谱，找到与目标物体概率关系最大的机器人位姿节点，然后导航到该节点寻找动态物体。

但是，在关系图谱中地标物体节点、动态物体节点、移动机器人位姿节点，其中的动态物体节点是由一个随机概率模型按照与地标物体的对应关系随机生成，其位置坐标由地标物体决定。其中的移动机器人位姿节点是能够观测到地标物体或者动态物体的位姿，其坐标最终也是由地标物体决定。所以在整个室内物体与移动机器人位姿关系图谱中，地标物体的位置坐标决定动态物体节点和移动机器人位姿节点，地标物体位置坐标变化时，动态物体节点和移动机器人位姿节点随之变化。所以为了关系图谱寻找动态物体方法，具有广泛适用性。本文在寻找动态物体时，让机器人首先查询关系图谱中与动态物体关系最大的地标物体，然后依赖语义地图提供的位置坐标，使用 A*算法导航到地标物体，在地标物体附近寻找动态物体。

这种先寻找地标物体，然后在地标物体附近寻找动态物体方法的优点是，当家庭室内环境中地标物体位置发生变化时，只需重新建立室内语义地图，即得到当前地标物体的位置坐标就能够完成寻找位置坐标未知的动态物体，其适用场景具有普适性。

4.2.2 室内动态物体搜索方法

移动机器人寻找动态物体的策略是首先查询关系图谱中与动态物体关系最大的地标物体，然后从初始位置出发，通过语义地图得到地标物体的坐标，利用 A*算法到达与动态物体关系最大的地标物体所在的坐标，在到达地标物体附近后左右旋转，通过 YOLOv5s 目标检测寻找动态物体[73]。

在动态物体具体搜索中，如果第一次移动机器人在地标物体附近寻找不到动态物体，

中国知网 https://www.cnki.net

则移动机器人移动到与动态物体关系次密切的地标物体附近，重复此步骤继续寻找，直到找到动态物体或者遍历所有与动态物体关系大于 0 的地标物体。本文中的室内物体关系是一种人为限定的概率关系，如手机有概率出现在茶几或床头柜附近，不会出现在冰箱附近。地标物体与动态物体的对应关系由表 4.1 给出。如果还未找到动态物体，则任务失败。如图 4.2 给出的移动机器人寻找动态物体的流程图。

表 4.1 室内地标物体与动态物体对应关系

室内地标物体	动态物体
客厅（茶几）卧室（床）	手机、遥控器、眼镜
卧室（床）客厅（沙发）	枕头
厨房（冰箱、桌子）	苹果
厨房（桌子、抽屉）	小刀
客厅（玄关、茶几）	钥匙
客厅（茶几）厨房（桌子）	杯子

由于本文中使用的 RGB 深度相机工作范围为 0.6~4m，移动机器人在地标物体附近可能已经检测到需要寻找的动态物体，但移动机器人与寻找的动态物体还有一定距离，还需要进一步靠近动态物体。本文中这一步骤首先通过 YOLOv5s 目标检测将含有动态物体的关键帧，使用深度相机直接得出当前移动机器人与动态物体得距离，当距离大于 0.6m 时，移动机器人向动态物体靠近，直至移动机器人与动态物体的距离小于 0.6m，此值由相机工作范围决定。

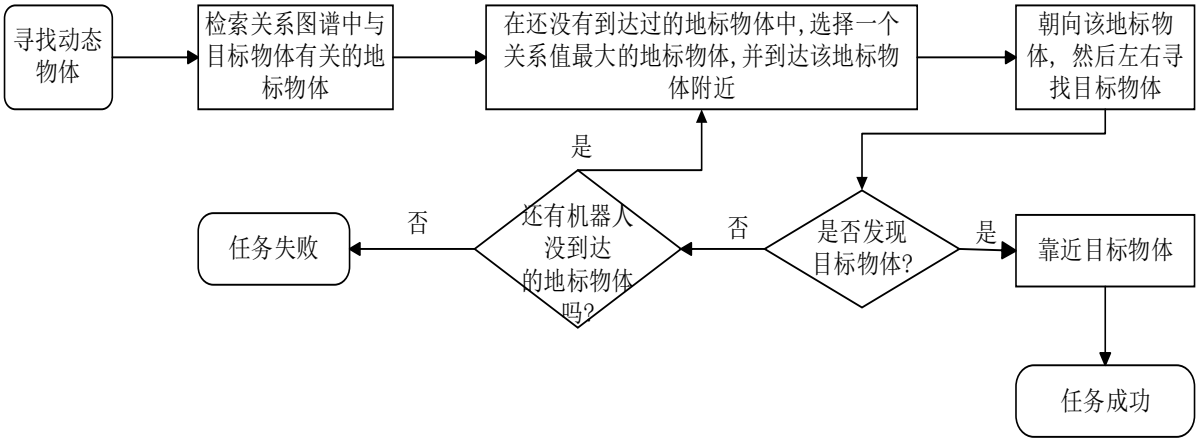

图 4.2 动态物体寻找过程

4.3 图神经网络

学习策略 $\pi\left(\mathcal{G}, c_{target}\right)$ 需要经过训练来表达出动态物体 c 与图结构 $\mathcal{G}$ 之间隐藏的概率关系，但是图结构无法像文本或者图片直接输入到卷积神经网络中处理。因为在图结构中，节点在图中没有固定的排序或者参考点来确定位置，另外图结构通常是动态变化

中国知网 https://www.cnki.net

的，在加入新的节点整个图都会改变。所以本文中学习策略$\pi\left(\mathcal{G},c_{target}\right)$为图神经网络。

4.3.1 策略网络的搭建

图神经网络$\pi\left(\mathcal{G},c_{target}\right)$，由一个图卷积层和三个全连接层组成，每个全连接层之间有非线性激活函数 ReLu。

使用由 Kipf & Welling 提出的图卷积算子[74]：

$$\boldsymbol{Z}=\sigma\left(\boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{A}\boldsymbol{D}^{-\frac{1}{2}}\boldsymbol{Y}\Theta\right) \tag{4.1}$$

其中，$\boldsymbol{Y}\in\mathbb{R}^{N\times 300}$表示添加的所有地标物体节点矩阵$y_i$具有 300 个维数；$\Theta\in\mathbb{R}^{300\times 64}$表示图卷积层的权值矩阵；$\sigma$表示 ReLu 激活函数；$\boldsymbol{A}=\boldsymbol{A}+\boldsymbol{I}$表示插入自循环的邻接矩阵$\boldsymbol{A}$；$\boldsymbol{D}_{\mathrm{ii}}=\sum_{\mathrm{j}}\boldsymbol{A}_{\mathrm{ij}}$表示对角度矩阵。对于图结构$\mathcal{G}$中的每个地标物体节点，该图卷积算子累加地标物体节点的所有直接邻接，将地标物体节点矩阵y_i的 300 个维数压缩为更为紧凑的 64 维数，图卷积算子通常会遍历节点的所有直接邻接节点，并将邻接节点的特征信息聚合到中心节点上。在每次卷积层迭代中，节点特征经过一个权重矩阵的变换后，再与其邻居节点的特征进行混合。通过学习权重矩阵，图卷积网络可以自动学习到哪些特征应当被保留和聚合，哪些特征可以被压缩和简化。

在实际操作中，为了将 300 维特征压缩至 64 维，会经过多层图卷积运算，并在每一层中通过非线性激活函数 ReLu 来引入非线性复杂性，以保持模型的表达能力。最后，通过学习到的权重矩阵将节点的高维特征映射到一个低维的空间中，从而实现维度压缩，同时也保留了节点间的结构信息和语义关系。

全连接层$f\left(z_i,z_{target}\right)$，其中$z_i$为经过压缩的地标物体节点矩阵$y_i$，维数为 64。其中目标对象$z_{target}=\sigma\left(y_{target},\Theta\right)$将目标$y_{target}$的词向量与图卷积层的权值矩阵$\Theta$相乘，维数为 64。采用三个全连接层$f_1,f_2,f_3$计算图结构中每个移动机器人位姿节点的概率分布，最终输出概率分布p_i。

图神经网络$\pi\left(\mathcal{G},c_{target}\right)$的最终输出概率分布$p_i$，作为图结构中移动机器人位姿节点的概率分布的对数，通过从该分布中抽样，获得动态物体节点与移动机器人位姿节点的概率关系，但是该概率关系没有位置坐标信息，在图结构$\mathcal{G}$种，只有地标物体是固定的，其位置坐标可由语义地图获得。利用该概率关系组成的室内物体关系图谱，移动机器人在寻找经常移动的动态物体时，不是进行全地图遍历，而是在与该动态物体关系最大的地标物体周围搜寻，从而完成位置坐标未知限制下的寻物任务。

4.3.2 用词向量增强图结构$\mathcal{G}$

图嵌入旨在通过保留图的网络拓扑结构和节点内容信息，将图中顶点表示为低维向量，以便使用简单的机器学习算法进行处理，FastText 模型[75]是 2016 年由 FaceBook AI Research 提出的一个词向量训练与文本分类算法，每一个词语都用 300 维的向量表达，

中国知网 https://www.cnki.net

这也是词嵌入技术的一个优势，即它的向量维度是固定的。利用神经概率语言模型训练词的分布式表示，将词映射到一个低维、稠密的实数向量空间中的技术。通过计算词向量之间的距离，可表示词与词之间的语义相似度，例如：在寻找过程中目标对象是未知的如手机，但在语义上与已知对象，如遥控器相似，并且它倾向于出现在相似的地方，手机和遥控器都会出现在客厅茶几上或卧室床上，则有很高的机会成功导航并找到它。

通过向每个移动机器人位姿节点添加地标物体语义向量 y_i 增强图结构 $\mathcal{G}$，使得图结构更加丰富，训练结果更加鲁棒。如图 4.3 所示。由于移动机器人位姿不具有语义信息，初始化移动机器人位姿节点的语义表示为 $0=[0,0,...,0]^T$。在添加地标物体语义向量 y_i 后，图卷积层将语义信息从地标物体的节点经过更新和压缩传递到移动机器人位姿节点，此时移动机器人位姿节点具有语义信息 z_i，然后全连接层 f 从移动机器人位姿节点语义信息 z_i，以及目标对象 z_{target} 之间与地标物体之间的对应关系中，获得移动机器人位姿节点的概率分布 p_i。

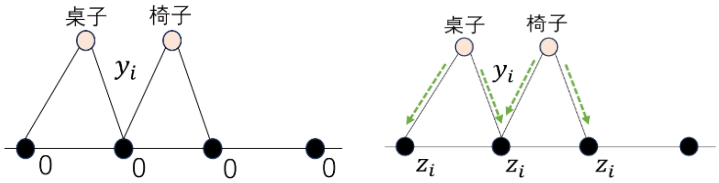

（a）初始化移动机器人位姿节点　　（b）语义信息传递给移动机器人位姿节点

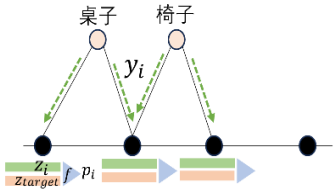

（c）位姿节点信息与目标对象之间的概率关系 p_i

图 4.3 向移动机器人位姿节点添加词向量

4.3.3 构建训练模型

首先构建如表 4.2 包含的 7 个地标物体节点、移动机器人位姿节点和边组成图结构，只有地标物体节点的地图定义为 c_{map}，其中的移动机器人位姿节点被随机分配在客厅、厨房以及卧室三个房间，每个移动机器人位姿节点之间设置至少 $0.5m$ 间隔。然后用词向量填充地标物体节点，对于填充的地标物体节点，至少有一个随机的移动机器人位姿节点与之连接，即移动机器人在该位姿下可以观测到地标物体。

动态物体没有直接出现在图结构中，由概率 $p\left(c_{target}\middle|c_{map}\right)$ 在地标物体附近生成，与地标物体之间的距离小于 $0.2m$，概率值从 0.1 到 0.9 之间随机分布。但是动态物体只能出现在与其有关系的特定地标物体附近，比如 $p\left(\text{手机}\middle|\text{茶几}\right)=0.7$，表示手机在茶几附近出现的概率为 0.7，$p\left(\text{手机}\middle|\text{冰箱}\right)$ 则不成立，表示手机不会出现在冰箱附近。本文中动态物体与地标物体的对应关系如表 4.1 所示。

中国知网 https://www.cnki.net

4.4 建立室内物体与移动机器人位姿关系图谱

4.4.1 训练图神经网络

通过基于策略的方法 REINFORCE[76]训练图神经网络$\pi\left(\mathcal{G},c_{target}\right)$，它是策略梯度方法中最早提出的，也是最简单、最基本的方法。强化学习中的奖励函数是学习过程的核心组成部分，它定义了一个信号，用来评价策略网络(agent)采取特定行动(action)在特定状态(state)下的好坏。这个信号反映了每个行动对于达成任务目标的贡献程度。通过这些信号，策略网络学习如何调整其行为，以最大化累积奖励。

本文中以找到动态物体最少步长为奖励，强化学习奖励函数公式为：

$$V_s=\sum_{k=0}^{goal} r_{t+k}\cdot\gamma^k \tag{4.2}$$

其中，V_s表示图神经网络$\pi\left(\mathcal{G},c_{target}\right)$在寻找动态物体时累计的奖励值；$\gamma^k$表示第$k$步的奖励衰减，$\gamma\in[0,1]$，本文中取$\gamma=0.85$；$r_{t+k}$表示策略网络$\pi\left(\mathcal{G},c_{target}\right)$对当前时刻$t$预测第$k$个机器人位姿节点的奖励。每一步的奖励值可表示为:

$$r_{t+k}=l(e_{t+k},e_{t+k+1})\cdot p(e_{t+k})p\left(e_{t+k+1}\right) \tag{4.3}$$

其中，$l(e_{t+k},e_{t+k+1})$表示机器人位姿节点e_{t+k}与机器人位姿节点e_{t+k+1}之间的距离；$p(e_{t+k})$和$p\left(e_{t+k+1}\right)$表示机器人位姿节点e_{t+k}和e_{t+k+1}能够找到动态物体的概率。

使用 Adam 作为优化器，学习率为 0.01，以寻找动态物体步长最少为奖励，为了获得奖励，模型必须在 40 步内找到目标，否则认为任务失败。模型训练总轮次 epoch 设定为 300，用成功率和成功找到目标的步长，两个指标评价模型训练的性能，移动机器人从一个位姿节点移动到下一个位姿节点为一个步长。

将家庭室内环境中的 7 种地标物体整理如下表 4.2：

表 4.2 家庭室内地标物体

地标物体	所在区域	数量
床	卧室	1
柜子	卧室	1
电视	客厅	1
沙发	客厅	2
茶几	客厅	1
柜子	客厅	2
冰箱	厨房	1

用词向量将桌子、洗衣机、电脑和椅子填充成为室内物体，然后在固定的地标物体附近随机生成与之有关系的动态物体，组成家庭室内环境，包含 11 个地标物体，随机概率生成手机、杯子和苹果 3 个动态物体。

首先对策略网络$\pi\left(\mathcal{G},c_{target}\right)$进行预训练，从家庭室内环境随机抽取二十组数据，每组数据包含三个动态物体，找出那些移动机器人位姿可以检测到该动态物体。预训练会

中国知网 https://www.cnki.net

将策略网络$\pi\left(\mathcal{G},c_{target}\right)$中的权重初始化为对动态物体和移动机器人位姿节点有关的值，减少模型的训练时间。经过 300 轮训练后其成功找到目标物体和找到目标物体的步长增长曲线如图 4.4 所示，成功率达到 0.92，步长最少为 7。

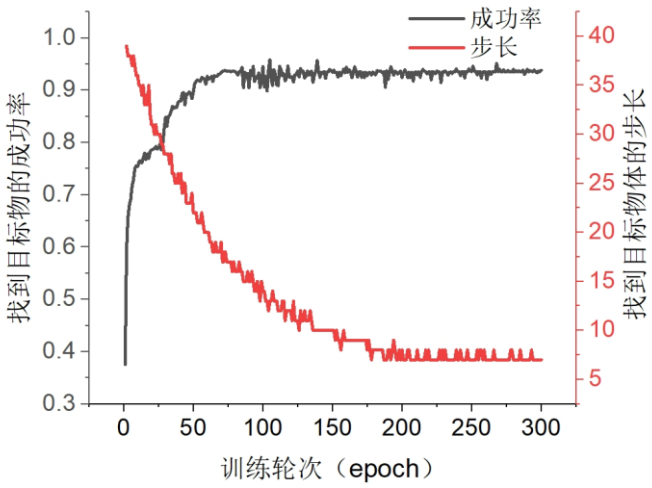

图 4.4 成功率与步长曲线

经过多轮的强化学习训练，室内地标物体节点、地标物体附近概率生成的动态物体节点以及能够观测到地标物体和动态物体的移动机器人位姿节点，这三种节点之间的概率关系趋于稳定，用图网络聚类算法将这种关系用关系图谱显式表达出来。

4.4.2 室内物体与机器人位姿关系图谱

假设关系图谱中有两个节点u,v，节点u,v之间的连接权重为τ，则节点之间的距离为：

$$d\left(u,v\right)\begin{cases} 1/\tau \quad (\tau \geqslant 0.1) \\ remove \quad edge\left(u,v\right) \quad \tau < 0.1 \end{cases} \tag{4.4}$$

当节点u,v之间的连接权重大于等于 0.1 时，节点之间的距离为权重τ的倒数；当节点之间的权重小于 0.1 时，节点之间没有边连接。

节点之间边的距离由直接连接的吸引力F_i、共同邻居的内聚吸引力F_c以及非共同邻居节点斥力F_{nc}，共同决定。其中直接连接的吸引力F_i就是两个节点之间有直接相连的边，当权重增加时，节点之间的相互吸引力使得两节点距离越来越近，如图 4.5(a)所示；共同邻居的内聚吸引力F_c是假设节点u和节点v都与另一个节点w相连，则节点w会对节点u,v造成吸引力，将节点u,v距离拉近，如图 4.5(b) 所示；非共同邻居节点斥力F_{nc}指与节点u,v相连的边会把节点u,v拉向自己，使得节点u,v相互远离，表现出斥力，如图 4.5(c) 所示。

中国知网 https://www.cnki.net

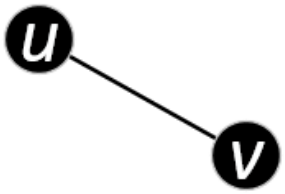

(a) 节点 u、v 存在吸引力 F_i

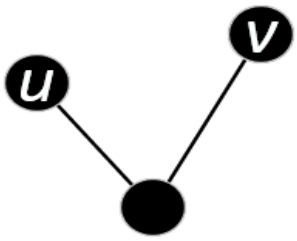

(b) 节点 u、v 存在内聚吸引力 F_c

(c) 节点 u、v 存在非共同邻居节点斥力 F_{nc}

图 4.5 节点之间力的关系

直接连接的吸引力 F_i 为：

$$F_i = -\frac{f\left(d\left(u,v,\right)\right)}{edge\left(u\right)} + \frac{f\left(d\left(u,v,\right)\right)}{edge\left(v\right)} \tag{4.5}$$

其中，$f\left(\bullet\right)=\sin\left(\bullet\right)$ 表示直接连接引力的连接函数；$edge\left(\bullet\right)$ 表示当前节点包含边的数量。

共同邻居的内聚吸引力 F_c 为：

$$F_c = -\sum_{x\in CN}\left(\frac{1}{edge\left(u\right)}\cdot f\left(1-d\left(x,u\right)\right)\cdot\left(1-d\left(x,u\right)\right)+\frac{1}{edge\left(v\right)}\cdot f\left(1-d\left(x,v\right)\right)\cdot\left(1-d\left(x,v\right)\right)\right) \tag{4.6}$$

其中，$CN=\left(\Gamma\left(u\right)-u\right)\cap\left(\Gamma\left(v\right)-v\right)$，$\Gamma\left(\bullet\right)$ 表示当前节点所有节点的集合，但是这个集合包含节点本身，所以去除当前节点本身得到当前节点的所以邻居节点，然后将两个节点所以邻居节点求交集，得到两个节点的共同邻居节点 CN 。

非共同邻居节点斥力 F_{nc} 为：

$$F_{nc} = -\sum_{x\in NN(u)}\left(\frac{1}{edge\left(u\right)}\cdot f\left(1-d\left(x,u\right)\right)\right)-\sum_{x\in NN(v)}\left(\frac{1}{edge\left(v\right)}\cdot f\left(1-d\left(x,v\right)\right)\right) \tag{4.7}$$

其中，对于节点 u，其与节点 v 的非共同邻居 $NN\left(u\right)=\Gamma\left(u\right)-\Gamma\left(u\right)\cap\Gamma\left(v\right)$，对于节点 v，其与节点 u 的非共同邻居 $NN\left(v\right)=\Gamma\left(v\right)-\Gamma\left(v\right)\cap\Gamma\left(u\right)$。

由式(4.4)可得在第 t 次训练时，节点 u,v 之间边的距离和权重。则在 t+1 次训练时，节点 u,v 之间连接的边可表示为：

$$d_{t+1}\left(u,v\right)=d_t\left(u,v\right)+\Delta t^2\cdot\left(F_i,F_c,F_{nc}\right) \tag{4.8}$$

中国知网 https://www.cnki.net

其中，Δt 表示采样的步长，因为本文建立室内物体与移动机器人位姿之间的关系图谱，主要是让机器人知道动态物体可能出现在什么位置，具体的地标物体位置坐标由语义地图提供，所以本文 $\Delta t = 1$。

将地标物体节点、动态物体节点、移动机器人位姿节点作为关系图谱的节点，将图神经网络模型最终输出的移动机器人位姿节点概率分布 p_i，作为节点之间的连接权重即节点之间的边。用图网络聚类算法显式输出各个节点之间的关系，建立关系图谱，如图 4.6 所示。

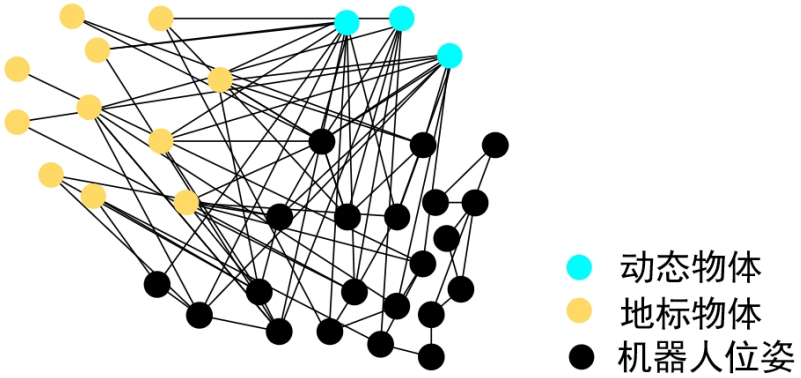

图 4.6 室内物体与移动机器人位姿关系图谱

图 4.6 所示的室内物体与移动机器人位姿关系图谱，其节点之间的边包含地标物体与动态物体之间的概率关系，以及移动机器人在那些位姿可以观测到地标物体，利用该关系图谱移动机器人在寻找坐标未知的动态物体时，首先移动机器人通过该关系图谱查询到与寻找的动态物体关系最大的地标物体，然后通过语义地图和 A*算法，可以直接到达地标物体附近寻找动态物体，实现在位置坐标未知的限制下快速找到动态物体。

4.5 本章小结

本章以地标物体、动态物体以及移动机器人位姿为节点，以训练图神经网络 $\pi\left(\mathcal{G}, c_{target}\right)$ 输出移动机器人能够观测到室内物体的概率为边，经过训练后，在建立的训练模型中，机器人成功找到动态物体的成功率为 92%，最少步长达到 7 步。

用图网络聚类算法将节点和边的概率关系显式输出，建立室内物体与移动机器人位姿关系图谱，在寻找位置坐标未知的动态物体时，通过关系图谱查询与动态物体关系最大的地标物体，移动机器人结合语义地图和 A*算法移动到地标物体附近寻找动态物体，完成位置坐标未知情况下的寻物任务。

中国知网 https://www.cnki.net

第五章 实验验证

5.1 引言

为验证本文采用结合家庭室内环境语义地图和室内物体与移动机器人位置关系图谱，寻找位置坐标未知的动态物体方法的性能。在真实家庭环境布署移动机器人为下位机，笔记本电脑为上位机，建立室内环境语义地图，对建立语义地图的精确率和时间两方面与常见的传统方法进行对比。然后利用训练后的图神经网络，输出室内物体节点与机器人位姿节点的概率关系，通过图聚类算法建立室内物体与移动机器人位置关系图谱，结合语义地图和室内物体与移动机器人位置关系图谱，在家庭室内环境进行位置坐标未知的动态物体寻物任务，并与 A*算法和 Dijkstra 算法在已知动态物体位置坐标的前提下，对三种方法寻找动态物体所用路程和时间进行对比。

5.2 实验平台搭建

5.2.1 实验硬件平台

（1）移动机器人：移动机器人为四轮差速转向，尺寸为：419*327*190*mm*。

（2）视觉传感器：采用奥比中光 Astro pro 深度相机作为视觉传感器，该款相机最高分辨率为 1280*720，帧率为 30fps，水平方向可视角度为 60°，垂直方向视角为 46.7°，工作范围 0.6~4*m*，相机通过 usb 接口与移动机器人连接。

（3）激光雷达：为了实现建图与导航功能，本文移动机器人搭载镭神 N10 激光雷达，通过 usb 与移动机器人连接。

（4）上位机：使用笔记本电脑作为上位机，CPU 型号 i5-13500HX， GPU 型号 NVIDIA GeForce GTX4060 8GB，支持 cuda 计算，能够加速图形处理与识别速度，笔记本与移动机器人通过 WIFI 进行通讯。

5.2.2 实验软件平台设置

实验采用 Ubuntu20.04 作为操作系统，Ubuntu 为开源的操作系统，支持多种开发语义与开发环境，能够较好的支持机器人的编程开发。实验采用机器人操作系统(ROS)作为通讯机制，ROS 是一个开源的机器人通讯与控制平台，能够将机器人的传感器信息与机器人的控制命令进行通信，实验程序以 Python 与 C++作为主要开发语言，Python 版本为 3.7.2，PyTorch 版本为 1.6.0。

中国知网 https://www.cnki.net

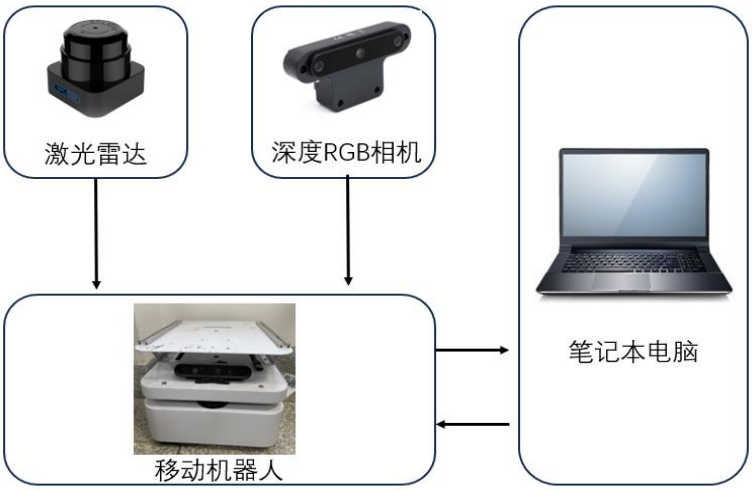

图 5.1 实验平台

5.3 家庭室内环境语义地图

5.3.1 室内物体数据集训练 YOLOv5s

训练参数设置参照文献[29]，图片分辨率为 640*640*3，batch size 为 32，模型训练总轮次 epoch 设定为 300，选择 SGD 优化器进行优化，初始学习率设置为 0.01，模型权重衰减量为 0.005，动量设置为 0.937，用于防止过拟合，Mosaic 参数设置为 1.0。在设置交并比 IOU 阈值为 0.5 时，训练的精确率召回率 PR 曲线如图 5.2 所示。

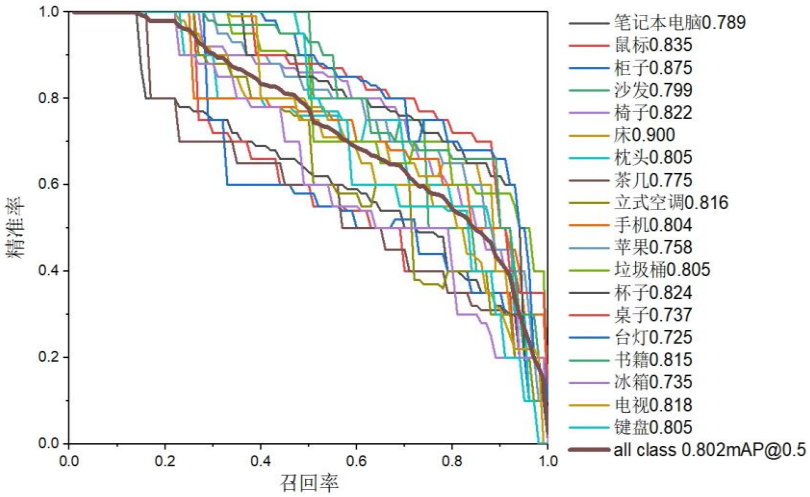

图 5.2 室内物体数据集 PR 曲线图

从图 5.2 可以看出，训练的 19 种室内物体，平均精度 mAP 为 0.802，根据文献[29]，精度满足实验需要。

5.3.2 建立室内语义地图

实验场地为家庭环境一室一厅一厨房共约 $70m^2$，如图 5.3 所示。

中国知网 https://www.cnki.net

(a)厨房　(b)客厅　(c)卧室　(d)移动机器人

图 5.3 语义地图建图实验场景和移动机器人

采用下列五种方法建立语义地图，从建立家庭室内语义地图的时间以及精确度两方面进行对比分析。(1)基于 Bolei Zhou 等人[70]提出的场景识别模型 Places205-VGG16 神经网络，融合家庭二维栅格地图建立家庭室内二维语义栅格地图为对照基准；(2) 场景识别模型 Places205-VGG16 神经网络结合 Glenn Jocher 开源发布的 YOLOv5s[28]，融合家庭二维栅格地图建立具有室内物体语义信息的二维语义栅格地图。验证在加入 YOLOv5s 后室内语义地图建图效率和精确度方面的变化；(3)先验概率优化后的 Places205-VGG16 模型结合室内物体数据集训练的 YOLOv5s 算法，验证先验概率优化后在建图效率方面的提升；(4) Places205-VGG16 模型结合 YOLOv5s 算法，融合本文提出的避免门口语义标注错误策略，主要验证传统建图方法在加入本文提出的策略后建图精确度方面的提升；(5) 先验概率优化的 Places205-VGG16 模型结合室内物体数据集训练的 YOLOv5s 算法，融合本研究提出的避免门口语义标注错误策略，主要验证本文所用方法在建图时间和精确度两个方面的提升。对五种方法分别进行 5 次实验取平均值，实验数据保留一位小数。实验结果如表 5.1 所示。

表 5.1 室内语义建图实验数据

算法	实验参数	实验次数					平均时间/*s*	平均精确度/%	相对提升/%
		1	2	3	4	5			
Places205-VGG16	时间/*s*	684	688	675	669	672	677.6	/	0
	精确度/%	88.5	87.2	86.2	86.9	87.7	/	87.3	0
Places205-VGG16+YOLOv5s	时间/*s*	735	754	725	733	748	739	/	-9.1
	精确度/%	87.2	88.4	87.6	89.1	88.8	/	88.22	0.9
优化Places205-VGG16+室内物体数据集训练YOLOv5s	时间/*s*	424	453	437	442	433	437.8	/	35.4
	精确度/%	90.4	89.5	88.7	87.7	91.5	/	89.56	2.3

中国知网 https://www.cnki.net

续表 5.1 室内语义建图实验数据

算法	实验参数	试验次数					平均时间/s	平均精确度/%	相对提升/%
		1	2	3	4	5			
Places205-VGG16+ YOLOv5s+避免门口语义标注错误策略	时间/s	912	917	923	937	924	922.6	/	-36.2
	精确度/%	95.2	95.7	96.5	95.5	92.3	/	95.04	7.7
优化Places205-VGG16+室内物体数据集训练YOLOv5s+避免门口语义标注错误策略	时间/s	601	612	597	594	610	602.8	/	11
	精确度/%	96.5	95.1	95.3	93.4	95.3	/	95.12	7.8

从表 5.1 实验数据可以得出，相比于 Places205-VGG16 神经网络建立室内语义地图，采用 Places205-VGG16 神经网络结合 YOLOv5s 算法建图的平均效率降低了 9.1%，平均精度提升 0.9%，这是由于增加了 YOLOv5s 算法目标检测模块使得计算量增大，同时检测室内物体对于场景分类有一定辅助作用；采用融合先验概率优化 Places205-VGG16 神经网络和室内物体数据集训练的 YOLOv5s 算法，建图平均效率提升 35.4%，平均精确度提升 2.3%，是由于场景识别模型 Places205-VGG16 神经网络经过先验概率优化后减少了巨大的计算量；采用 Places205-VGG16 神经网络结合 YOLOv5s 算法建图结合避免门口语义标注错误策略的方案后，建图平均时间增加了 36.2%，主要是由于增加了 YOLOv5s 算法和避免门口语义标注错误策略使得计算量增大，而且变化的语义标注范围普遍比传统语义标注范围设置的标注范围小，使得建图效率变低，但是建图的平均精确度提升了 7.7%，主要体现在门口区域的建图，如图 5.4 所示；采用先验概率优化 Places205-VGG16 神经网络和室内物体数据集训练的 YOLOv5s，再融合本文提出的避免门口语义标注错误策略，建图平均效率与平均精确度分别提升了 11.0%和 7.8%，表明与传统语义建图方法相比，本文提出的方法在家庭室内环境下具有一定的优越性。

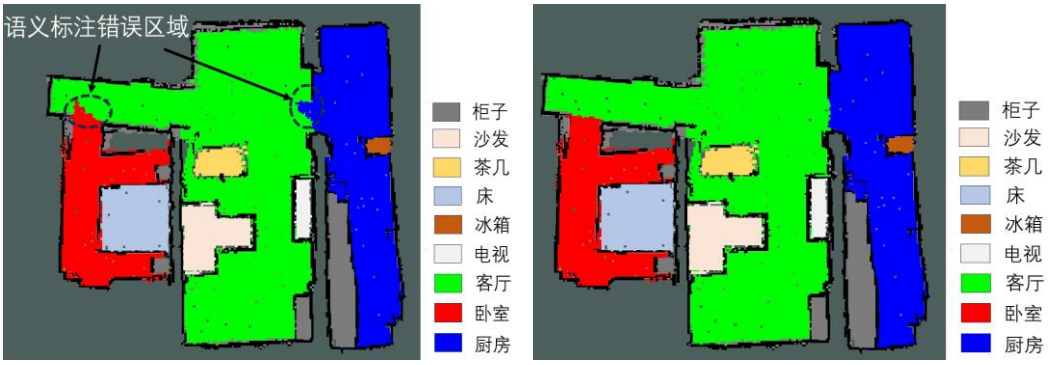

(a)未用避免门口语义标注错误策略　　(b)应用避免门口语义标注错误策略

图 5.4 家庭室内环境语义地图

本文利用先验概率优化 Places205-VGG16 神经网络，融合室内物体制作数据集训练

中国知网 https://www.cnki.net

YOLOv5s 目标检测，对室内环境进行场景识别和物体检测，并针对家庭室内场景门口场景语义标注错误，提出一种避免策略，通过实验得出以下结论：

(1)利用先验概率优化场景识别 Places205-VGG16 融合制作的室内物体数据集训练 YOLOv5s 目标检测，在家庭室内建立语义地图的平均效率提升了 35.4%，平均精确度提升 2.3%。

(2)提出家庭室内避免门口场景语义标注错误的策略，通过计算物体边缘大小赋予室内物体场景置信度，采用场景置信度影响语义标注阈值和语义标注范围的方法。采用先验概率优化场景识别模型 Places205-VGG16 神经网络和室内物体数据集训练 YOLOv5s 目标检测模型，融合避免门口场景语义标注错误的策略，使得语义地图建图平均效率和平均精确度分别提升 11.0%和 7.8%。

(3)提出语义标注范围变化策略，为家庭室内这类复杂环境建立语义地图提供了场景语义标注方法的新思路，通过实验验证了变化语义标注范围策略具有较好的适用性。

5.4 室内环境寻物实验

在如图 5.3 的室内环境，利用图 5.4 所示室内语义地图，在室内地标物体附近根据表 4.1 对应关系随机概率生成 3 个动态物体，利用图 4.6 建立的室内物体与移动机器人位姿关系图谱进行室内位置坐标未知动态物体寻找实验。

为了验证室内物体与移动机器人位姿关系图谱在室内寻找位置坐标未知动态物体的智能性，用传统的 A*导航算法和 Dijkstra 导航算法作为对照标准，主要验证本文所用方法在寻找位置坐标未知动态物体所用路程和耗费时间两个方面的性能。

首先在家庭室内环境图 5.3 所示真实环境，如表 4.2 所示原有 7 种地标物体，基础上利用词向量添加桌子、洗衣机、电脑和椅子，4 种地标物体。然后按照表 4.1 地标物体与动态物体之间的对应关系，随机在地标物体附近概率生成手机、苹果和杯子。

在使用 A*导航算法和 Dijkstra 导航算法时，将手机、苹果和杯子按照随机生成的位置放在地标物体附近。需特别注意的是实验中，在使用室内物体与移动机器人位姿关系图谱寻找动态物体时，其动态物体所在位置坐标是未知的。而在使用传统 A*导航算法和 Dijkstra 导航算法寻找动态物体时，动态物体位置坐标是已知的，是按照随机生成的手机、苹果和杯子位置后，人为标注出其在语义地图中的位置坐标，然后采用 A*导航算法和 Dijkstra 导航算法寻找动态物体。

为了保证实验的客观性，避免噪音干扰，每种寻物方法做 5 次实验，实验数据保留一位小数后取平均值，实验结果如表 5.2 所示，图 5.5 记录了每种寻物方法在寻找目标物体时所用路径最短的一次轨迹路线。

中国知网 https://www.cnki.net

表 5.2 室内寻物实验数据

导航算法	目标物体	实验参数	实验次数 1	2	3	4	5	平均路径长度	平均时间	相较于 A*提升/%	相较于 Dijkstra 提升/%
A*导航算法	手机	路径/*m*	8.3	8.5	8.7	8.5	9.1	8.6	/	/	/
		时间/*s*	165	178	179	176	188	/	177.2	/	/
	苹果	路径/*m*	4.4	4.7	4.2	4.2	4.5	4.4	/	/	/
		时间/*s*	90	85	88	86	88	/	87.4	/	/
	杯子	路径/*m*	5.5	5.6	5.5	5.4	5.4	5.5	/	/	/
		时间/*s*	96	95	98	97	99	/	97	/	/
Dijkstra 导航算法	手机	路径/*m*	9.2	9.5	9.4	9.5	9.7	9.5	/	/	/
		时间/*s*	185	183	185	186	183	/	184.4	/	/
	苹果	路径/*m*	4.9	4.7	5.1	5.2	4.8	4.9	/	/	/
		时间/*s*	92	90	99	102	97	/	96	/	/
	杯子	路径/*m*	5.7	5.7	5.5	6.0	5.8	5.7	/	/	/
		时间/*s*	99	101	98	105	97	/	100	/	/
关系图谱导航	手机	路径/*m*	12.1	12.2	12.0	12.3	12.2	12.2	/	-41.8	-28.4
		时间/*s*	202	212	211	212	210	/	209.4	-18.2	-13.6
	苹果	路径/*m*	4.4	4.7	4.6	4.5	4.3	4.5	/	-2.3	8.2
		时间/*s*	89	90	88	89	87	/	88.6	-1.4	7.7
	杯子	路径/*m*	5.5	5.7	5.6	5.4	5.3	5.5	/	0	3.5
		时间/*s*	95	98	97	97	99	/	97.2	-0.2	2.8

在 A*导航算法中，移动机器人寻找苹果时用的路程最短为 4.2*m*，其路径轨迹如 5.5(a)所示，在 Dijkstra 导航算法中，移动机器人寻找苹果时用的路程最短为 4.7*m*，其路径轨迹如 5.5(b)所示，在室内物体与移动机器人位置关系图谱导航寻物中，移动机器人寻找苹果时用的路程最短为 4.3*m*，其路径轨迹如 5.5(c)所示。

(a)A*导航算法路线轨迹　(b) Dijkstra 导航算法路线轨迹　(c)室内物体关系图谱导航路线轨迹

图 5.5 三种导航算法寻找目标物体最短路线轨迹

中国知网 https://www.cnki.net

在本次室内环境动态物体寻找实验中，使用室内物体与移动机器人位姿关系图谱方法寻找动态物体时动态物体的坐标位置未知，所以移动移动机器人在寻找手机时，依靠关系图谱得出手机与客厅的茶几的关系最大，总是先导航移动到客厅茶几附近寻找手机，在没有寻找到时，才移动到与手机关系次之的卧室的床附近寻找手机，使得在寻找手机实验中，室内物体与移动机器人位姿关系图谱方法导航的成绩相比于 A*算法在路程和时间两方面分别落后 41.8%和 18.2，相比于 Dijkstra 算法在路程和时间两方面分别落后 28.4%和 13.6%。

但是在寻找苹果实验中，依靠室内物体与移动机器人位姿关系图谱方法相较于 A*算法在所用路程和时间两方面分别落后 2.3%和 1.4%，相比于 Dijkstra 算法在所用路程和时间两方面分别提升 8.2%和 7.7%。在寻找杯子实验中，依靠室内物体与移动机器人位姿关系图谱方法相较于 A*算法在所用路程和时间两方面分别落后 0%和 0.2%，相比于 Dijkstra 算法在所用路程和时间两方面分别提升 3.5%和 2.8%。

由实验结果表明，本文提出的室内物体与移动机器人位姿关系图谱方法在寻找室内位置坐标未知的动态物体时，与传统导航算法 A*算法和 Dijkstra 算法在已知寻找目标位置坐标的前提下，两者相比，本文所采用的方法在所用路程和时间两方面与 A*算法相差不大，比 Dijkstra 算法表现较好。也说明本文所采用的室内寻找动态物体方法在位置坐标未知的情况下，与已知目标位置坐标的 A*算法性能相近，表明本文采用的寻找动态物体方法在家庭室内环境具有一定的实际应用价值。

5.5 本章小结

搭建实验所用的硬件平台、软件平台，结合室内物体自制数据集训练 YOLOv5s；先验概率优化 Places205-VGG16；避免室内门口语义标注错误策略，并和已有的 Places205-VGG16 神经网络建立室内语义地图在建图效率和精准度进行对比，实验结果表明，本文提出的建立室内语义地图方法，建图平均效率与平均精确度分别提升了 11.0%和 7.8%，说明本文提出的方法在家庭室内环境建立语义地图具有优越性。

结合语义地图和室内物体与移动机器人位姿关系图谱，进行移动机器人室内位置坐标未知的动态物体寻物实验，通过与 A*算法和 Dijkstra 算法在寻找位置坐标已知的动态物体实验中，所用路程和时间两方面进行对比。实验结果表明，在寻找苹果实验中；采用关系图谱方法相较于 A*算法所用路程落后 2.3%，所用时间落后 1.4%，相比于 Dijkstra 算法在所用路程提升 8.2%，所用时间提升 7.7%。在寻找杯子实验中；关系图谱方法相较于 A*算法在所用路程一样，所用时间落后 0.2%，相比于 Dijkstra 算法在所用路程提升 3.5%，所用时间提升 2.8%。说明本文采用关系图谱寻找未知目标物体位置坐标的方法，能够达到已知目标物体位置坐标前提下 A*算法的性能。

中国知网 https://www.cnki.net

总结与展望

全文总结

本文针对提高家庭服务移动机器人智能性，从室内语义地图构建和室内物体与移动机器人位姿关系图谱的建立两方面进行研究，结合室内语义地图和关系图谱，实现移动机器人在室内寻找位置坐标未知的动态物体时准确高效。最后在真实家庭环境下进行实验，验证本文所提出的方法，并与常见的传统方法进行对比。本文总结如下：

(1)采用先验概率优化 Places205-VGG16，结合室内物体数据集训练 YOLOv5s 对室内环境进行场景分类和物体检测，提出一种基于场景置信度的具有阈值和可变语义标注范围的方法，结合这几种方法建立语义地图，并与传统建图方法进行对比，得出：YOLOv5s 目标检测模块会使得计算量增大，同时检测室内物体对于场景分类有一定辅助作用；先验概率优化 Places205-VGG16 会减少巨大的计算量，对于提升建图效率提升较大；本文提出的避免门口语义标注错误策略使得建图精度得到提升，但也会增加一定的计算量降低建图效率；提出语义标注范围变化策略，为家庭室内这类复杂环境建立语义地图提供场景语义标注方法的新思路。

(2) 将固定物体节点、移动机器人位姿节点以及动态物体节点，用概率关系作为边，建立关系图谱。结合语义地图和关系图谱寻找位置坐标未知的动态物体，并与 A*算法和 Dijkstra 算法寻找位置坐标已知的动态物体，在所用路程和时间两方面进行对比，得出：关系图谱寻物方法寻找动态物体时按照关系图谱中关系大小依次在地标物体附近寻找，如果动态物体不在与它关系最大的地标物体附近，该方法在寻找目标物体时所用路程和时间不具有太大优势，其独特的优点是有较大成功率找到位置坐标未知的目标物体；关系图谱寻物方法在寻找动态物体时，首先利用语义地图和 A*算法移动到地标物体附近，由于 A*算法优秀的导航性能，使得关系图谱寻物方法有较强的实用性。

(3)搭建实验平台，在真实室内环境，建立家庭室内环境语义地图，并与传统算法建立室内语义地图在建图时间和精准度进行对比。实验结果表明，本文所提出的建图方法相比于 Places205-VGG16 神经网络建图方法，在建图平均效率与平均精确度分别提升了 11.0%和 7.8%，说明本文提出的建图方法在家庭室内环境具有一定的优越性。

结合语义地图和室内物体与移动机器人位姿关系图谱，进行移动机器人室内位置坐标未知的动态物体寻物实验，通过与 A*算法和 Dijkstra 算法在寻找位置坐标已知的动态物体实验中，所用路程和时间两方面进行对比。实验结果表明，在寻找苹果和杯子实验中，采用关系图谱方法相较于 A*算法所用路程和时间基本一样，相比于 Dijkstra 算法在所用路程和时间有所减少。说明本文采用关系图谱寻找未知目标物体位置坐标的方法，

中国知网 https://www.cnki.net

能够达到寻找已知目标物体位置坐标前提下 A*算法的性能。

研究展望

本文对家庭服务移动机器人寻找室内位置坐标未知动态物体进行研究，主要对家庭室内环境建立语义地图和建立室内物体与移动机器人位姿关系图谱，两个方面进行研究，在真实家庭环境实验对本文提出的方法与常见传统方法进行对比，实验结果表明本文提出的方法相比常见的传统方法有一定的优势，但研究的过程中任存在一些缺陷，有待进一步完善和改进。具体如下：

(1)本文提出的避免语义地图标注错误策略，语义标注范围大小的变化需要在真实环境实验得到影响语义标注范围的引力及斥力系数 p、q，当实验环境变化要重新计算引力及斥力系数 p、q，其不具有自适性。

(2)本文训练图神经网络得到室内物体与移动机器人位姿概率关系时，动态物体根据表 4.1 的对应关系随机概率生成，其具有一定的人为限制。为建立更符合真实家庭生活环境室内位置坐标未知的动态物体寻物研究，还需加入更大的随机模型，模拟真实家庭生活环境中动态物体的位置分布。

(3)本文实验验证时的真实家庭室内环境，只有客厅、厨房和卧室，而且室内物体摆放简单，使得整体实验环境较为简单，本文提出的建立室内语义地图以及建立室内物体关系图谱在更为复杂的环境中，其性能还需进一步验证。

中国知网 https://www.cnki.net

参考文献

[1] 毛志贤, 朱晓龙, 韦建军, 等. 家庭服务机器人现状与展望[J]. 机电工程技术, 2021, (02):8-14.

[2] 工业和信息化部. 中国机器人产业发展报告2019[R]. 北京: 2019.

[3] 梁荣健, 张涛, 王学谦. 家用服务机器人综述[J]. 智慧健康, 2016, 2(02):1-9.

[4] 宋章军. 服务机器人的研究现状与发展趋势[J]. 集成技术, 2012, 1(03):1-9.

[5] 王秋惠, 张一凡, 刘力蒙. 身龄服务机器人人机界面设计研究进展[J]. 机械设计，2018, 35(09):105-113.

[6] 徐方, 张希伟, 杜振军. 我国家庭服务机器人产业发展现状调研报告[J]. 机器人技术与应用, 2009, (02):14-19.

[7] 刘奇. 激光视觉融合的室内二维语义地图构建及其重定位研究[D]. 武汉科技大学, 2022.

[8] Lowe D G. Method and apparatus for identifying scale invariant features in an image and use of same for locating an object in an image[P]. US:6711293 B1, January 2017.

[9] Dalal N, Triggs B. Histograms of Oriented Gradients for Human Detection[C]// IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, Tokyo, Japan, 2005:886-893.

[10]Aeri R, Mohammad S, Silfia R, et al. Corn Leaf Disease Classification Using Local Binary Patterns (LBP) Feature Extraction[J]. Journal of Physics: Conference Series, 2022, 2406(1).

[11]蒋林, 刘奇, 雷斌, 等. 激光与视觉融合识别并构建语义地图改善定位性能[J].中国激光, 2022, 49(18):140-154.

[12]Viola P, Jones M. Rapid object detection using a boosted cascade of simple features[C]// IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2001:511.

[13]P. Sermanet, D. Eigen, X. Zhang, et al. OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks[J]. Eprint Arxiv, 2014.

[14]R. B. Girshick, J. Donahue, T. Darrell, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]// IEEE Conference on Computer Vision and Pattern Recognition. Portland, OR, USA, 2013:580-587.

[15]K. He, X. Zhang, S. Ren, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 37(9):1904-1916.

中国知网 https://www.cnki.net

[16]Y. Li, K. He, J. Sun. R-fcn: Object detection via region-based fully convolutional networks[C]// Advances in Neural Information Processing Systems. 2016:379-387.

[17]K. He, X. Zhang, S. Ren, et al. Deep residual learning for image recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016:770-778.

[18]S. Gidaris, N. Komodakis. Locnet:Improving localization accuracy for object detection[C]// IEEE Conference on Computer Vis ion and Pattern Recognition, Las Vegas, NV, USA, 2016:789-798.

[19]T. Kong, A. Yao, Y. Chen, et al. HyperNet: towards accurate region proposal generation and joint object detection[C]// IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 2016:845-853.

[20]S. Bell, C. L. Zitnick, K. Bala, et al. Inside-outside net: Detecting objects in context with skip pooling and recurrent neural networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016:2874-2883.

[21]J. Redmon, S. Divvala, R. B. Girshick, et al. You only look once: Unified, real-time object detection[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016:779-788.

[22]M. Najibi, M. Rastegari, L. S.Davis. G-cnn: an iterative gridbased object detector[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016:2369-2377.

[23]W. Liu, D. Anguelov, D. Erhan, et al. SSD: Single shot multibox detector[C]// European Conference on Computer Vision. Springer International Publishing, 2016:21-37.

[24]Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[C]// IEEE Conference on Computer Vision & Pattern Recognition. IEEE, 2017:6517-6525.

[25]H. Bavle, S. Manthe, P. DeLaPuente, et al. Stereo visual odometry and semantics based localization of aerial robots in indoor environments[C]// in 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2018:1018–1023.

[26]A. Farhadi, J. Redmon. Yolov3: An incremental improvement[J]. in Computer Vision and Pattern Recognition. Springer Berlin/Heidelberg, Germany, 2018:1804–2767.

[27]M. Shan, Q. Feng, N. Atanasov. Orcvio: Object residual con-strained visual-inertial odometry[C]// in 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020:5104–5111.

[28]Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020, arXiv.2004.10934.

中国知网 https://www.cnki.net

[29]Bochkovskiy A, Wang C Y, Liao H Y M. Ultralytics YOLOv5s 2020[OL]. https://github.com/ultralytics/YOLOv5s. January 2023.

[30]Xiang Y, Schmidt T, Narayanan V, et al. PoseCNN: A Convolutional Neural Network for 6D Object Pose Estimation in Cluttered Scenes[C]// Proceedings of Robotics: Science and Systems, 2017:719-730.

[31]R. A. Newcombe. KinectFusion: Real-time dense surface mapping and tracking[J]. 2011 10th IEEE International Symposium on Mixed and Augmented Reality, Basel, Switzerland, 2011:127-136.

[32]Whelan T, Salas-Moreno F R, Glocker B, et al. ElasticFusion: Real-time dense SLAM and light source estimation[J]. The International Journal of Robotics Research, 2016, 35(14):1697-1716.

[33]McCormac J, Handa A, Davison J A, et al. SemanticFusion: Dense 3D Semantic Mapping with Convolutional Neural Networks[C]// 2017 IEEE International Conference on Robotics and Automation (ICRA)May 2017:4628–4635.

[34]邹斌, 谭亮, 侯献军. 基于激光雷达的道路可行区域检测[J]. 武汉理工大学学报(交通科学与工程版), 2017, 41(02):203-207.

[35]胡美玉. 基于深度卷积神经网络的室内环境语义地图构建[D]. 东北大学, 2019.

[36]Li D., Shi X., Long Q, et al. DXSLAM: A robust and efficient visual SLAM system with deep features[C]// In Proceedings of the 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Las Vegas, NV, USA, January 2020:4958–4965.

[37]Dong Chen, Ziyuan Liu, Georg Wichert. Uncertainty-Aware Arm-Base Coordinated Grasping Strategies for Mobile Manipulation[J]. Intelligent Robotics System, October 2015:205–223.

[38]Xiuzhi L, Wen W, Jiahao C, et al. DR-SLAM: drift rejection SLAM with Manhattan regularity for indoor environments[J]. Advanced Robotics, 2022, 36(20):1049-1059.

[39]X. Chen, A. Milioto, E. Palazzolo, et al. SuMa++: Efficient LiDAR-based Semantic SLAM[C]// 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Macau, China, 2019:4530-4537.

[40]Behley, Jens, Stachniss, et al. Efficient Surfel-Based SLAM using 3D Laser Range Data in Urban Environments[J]. Robotics: Science and Systems XIV, 2018:58-67.

[41]Sünderhauf N, Pham T T, Latif Y, et al. Meaningful maps with object-oriented semantic mapping[C]// In: IEEE/RSJ International Conference on Intelligent Robots and Systems, 2017:5079-5085.

[42]王鹏. 语义地图及其关键技术研究[D]. 中国科学院大学(中国科学院深圳先进技术

中国知网 https://www.cnki.net

研究院), 2020.

[43]F. Scarselli, M. Gori, A. C. Tsoi, et al. The Graph Neural Network Model[J]. IEEE Transactions on Neural Networks, 2009:61-80.

[44]Wu Z, Pan S, Chen F, et al. A Comprehensive Survey on Graph Neural Networks[J]. IEEE transactions on neural networks and learning systems, 2021, (1):32.

[45]J. Gilmer, S. S. Schoenholz, P. F. Riley, et al. Neural message passing for quantum chemistry[C]// Proceedings of the 34th International Conference on Machine Learning - Volume 70August 2017:1263–1272.

[46]T. N. Kipf, M. Welling. Semi-supervised classification with graph convolutional networks[C]// International Conference on Learning Representations (ICLR), 2017:476-483.

[47]X. Wang, A. Gupta. Videos as space-time region graphs[C]// European Conference on Computer Vision (ECCV), 2018:7886-7893.

[48]Y. Chen, M. Rohrbach, Z. Yan, et al. Graph-based global reasoning networks[C]// IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2019:433-442.

[49]X. Wang, Y. Ye, A. Gupta. Zero-shot recognition via semantic embeddings and knowledge graphs[J]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:6857-6866.

[50]M. Kampffmeyer, Y. Chen, X. Liang, et al. Rethinking knowledge graph propagation for zero-shot learning[J]. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019:11479-11488.

[51]罗骜. 基于图神经网络的场景理解算法研究[D]. 电子科技大学, 2020.

[52]Abel Gawel , Carlo Del Don, Roland Siegwart，et al. X-View: Graph-Based Semantic Multi-View Localization[C]// IEEE ROBOTICS AND AUTOMATION LETTERS, VOL. 3, NO. 3, JULY 2018:1687-1693.

[53]Kaiyu Zheng, Andrzej Pronobis, Rajesh P. N. Rao, et al. Learning Graph-Structured Sum-Product Networks for Probabilistic Semantic Maps[C]// Proceedings of the AAAI Conference on Artificial Intelligence, 32 Volume, 2018:4547-4555.

[54]Yang Zhou, Graduate Student. Multi-Robot Collaborative Perception With Graph Neural Networks[C]// IEEE ROBOTICS AND AUTOMATION LETTERS, VOL. 7, NO. 2, APRIL 2022:2289-2296.

[55]Mengyuan Ding, Yaxin Liu1. Visual Manipulation Relationship Detection based on Gated Graph Neural Network for Robotic Grasping[C]// 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2022:1401-1410.

中国知网 https://www.cnki.net

[56]Jianwei Z, Jinyu L, Jiaxin Z. Research on Two-Round Self-Balancing Robot SLAM Based on the Gmapping Algorithm[J]. Sensors, 2023, 23(5):2489-2489.

[57]Kevin T, Laura R, Miguel B, et al. 2D SLAM Algorithms Characterization, Calibration, and Comparison Considering Pose Error, Map Accuracy as Well as CPU and Memory Usage[J]. Sensors, 2022, 22(18):6903-6903.

[58]Jianwei Z, Jinyu L, Jiaxin Z. Research on Two-Round Self-Balancing Robot SLAM Based on the Gmapping Algorithm[J]. Sensors, 2023, 23(5):2489-2489.

[59]Casas L D M P, Kraus L, SedeñoNoda A, et al. Targeted multiobjective Dijkstra algorithm[J]. Networks, 2023, 82(3):277-298.

[60]Jintao Y, Zhenhua G, Mingze J, et al. Robot path planning based on improved A* algorithm[J]. Journal of Physics, 2023, 2637(1):617-626.

[61]H. Wang, J. Ni, Y. Qi, et al. Optimal Design of Laser SLAM Algorithm Based on RBPF improved resampling technology[C]// 2020 IEEE International Conference on Mechatronics and Automation (ICMA), Beijing, China, 2020:1245-1250.

[62]张振海, 周伟, 何光, 等. 一种基于粒子滤波的双目视觉惯导 SLAM 技术[J]. 遥测遥控, 2023, 44(02):18-26.

[63]马啸龙. 面向送餐的移动机器人的 SLAM 与路径规划方法研究及应用[D]. 兰州大学, 2023.

[64]李少伟, 钟勇, 杨华山, 等. SLAM 算法建图对比研究[J]. 内燃机与配件, 2024, (03):36-38.

[65]瞿新豪, 丁云飞, 谢亚琴. 基于栅格地图改进的智能路径选择算法[J]. 电子测量技术, 2022, 45(05):86-93.

[66]祁贤雨, 王巍, 王琳, 等. 基于物体语义栅格地图的语义拓扑地图构建方法[J]. 吉林大学学报(工学版), 2023, 53(02):569-575.

[67]郭旭达, 宋勇磊. 一种基于 RGB-D 相机的语义地图构建方法[J]. 计算机与数字工程, 2023, 51(10):2438-2443.

[68]赵学健, 叶昊, 贾伟, 等. AGV 路径规划及避障算法研究综述[J]. 小型微型计算机系统, 2024, 45(03):529-541.

[69]姜涛, 周兴阁, 陈宇. 基于 RRT~(*)算法和 DWA 算法的分层结构路径规划策略[J]. 计算机测量与控制, 2024:1-9.

[70]B. Zhou, A. Lapedriza, J. Xiao, et al. Learning deep features for scene recognition using places database[J]. in Proceedings of the Advances in neural informationprocessing systems, 2014:487-495.

[71]Zou Y, Chen X. Hand–eye calibration of arc welding robot and laser vision sensor through

中国知网 https://www.cnki.net

semidefinite programming[J]. Industrial Robot: the international journal of robotics research and application, 2018, 45(5):597-610.

[72]刘冰雁, 叶雄兵, 王新波, 等. 基于改进人工势场的无人地面车辆路径规避算法[J]. 中国惯性技术学报, 2020, 28(6):769-777.

[73]周方波, 赵怀林, 刘华平. 基于场景图谱的室内移动机器人目标搜索[J]. 智能系统学报, 2022, 17(05):1032-1038.

[74]Kipf N T, Welling M. Semi-Supervised Classification with Graph Convolutional Networks[J]. Neural Process Letters, 2022:2645–2656.

[75]Bojanowski. P., Grave E., Joulin A. et al. Enriching Word Vectors with Subword Information[J]. Transactions of the Association for Computational Linguistics, 2017, 5:135-146.

[76]刘建伟, 高峰, 罗雄麟. 基于值函数和策略梯度的深度强化学习综述[J]. 计算机学报, 2019, 42(06):1406-1438.

中国知网 https://www.cnki.net