燕山大學
YANSHAN UNIVERSITY

硕 士 学 位 论 文

MASTER'S DISSERTATION

论文题目　面向家庭服务机器人的端到端室内服务指令解析方法研究

作者姓名　孙永派

学科专业　计算机科学与技术

指导教师　娄凤伟 教授

2022 年 5 月

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

中图分类号：TP391.4 学校代码：10216
UDC：004 密级：公开

工学硕士学位论文

面向家庭服务机器人的端到端室内服务指令解析方法研究

硕 士 研 究 生：孙永派
导 师：娄凤伟教授
申 请 学 位：工学硕士
学 科 专 业：计算机科学与技术
所 在 单 位：信息科学与工程学院
答 辩 日 期：2022 年 5 月
授予学位单位：燕山大学

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

A Dissertation in Computer Science and Technology

RESEARCH ON END-TO-END INDOOR SERVICE INSTRUCTION PARSING METHOD FOR HOME SERVICE ROBOT

by Sun Yongpai

Supervisor: Professor Lou Fengwei

Yanshan University

May,2022

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

摘 要

自然语言指令解析是使人和机器人之间的交互变得更自然、流畅的重要环节。在人-机器人交互过程中，使机器人了解指令的意图和指令中关键单词的含义是自然语言指令解析的基础工作，但往往自然语言指令数据难以收集，导致模型存在泛化能力差的问题。另外，自然语言指令导航是人-机器人交互所必须具备的能力，也是完成取物任务的前提，但由于自然语言的任意性，不同人对于相同任务的指令描述会存在不同，这可能会导致指令和导航行为动作在映射过程中出现对齐不一致的问题。目前，针对泛化能力差的问题，常用意图-插槽联合建模方法、数据增强等方法，这些方法并没有充分考虑到不同意图的指令之间存在的共享知识和私有知识；针对映射不一致的问题，常用非端到端的统计模型方法，这种方法并没有考虑误差的累积和机器人所处环境对映射过程的影响。因此，构建新的端到端神经网络模型来提高模型的泛化性能和指令映射过程中的对齐能力是提高人-机器人交互体验的关键。

首先，针对机器人存在泛化能力差的问题，提出了一种语义特征提取和融合算法。该算法首先利用多个编码器结构提取不同意图指令的共享特征和私有特征，然后将提取到的特征使用门机制进行动态地融合。整个过程充分考虑了不同意图的指令之间的相关关系，并对其进行显式地建模，使指令中的语义特征能够被充分利用。

其次，提出了基于图注意力网络的意图-插槽联合优化方法，用于对两个任务之间的相关性关系进行建模。该方法通过显式建模的方式对两个任务的关系进行量化，以提高端到端模型的特征充分性。与已有的端到端意图-插槽联合模型相比，该方法不仅考虑了意图信息对插槽信息的指导作用，还考虑了指令中不同插槽之间的约束和相互关系，进一步提高了模型对意图和插槽显式建模的性能，同时也提高了模型的可解释性。

最后，针对自然语言指令映射不一致的问题，提出了基于神经网络搭建的端到端地图-指令双向注意力交互模型。该模型在指令映射过程中将地图信息作为知识库来辅助映射，并通过双向注意力交互将指令特征和地图特征进行融合，从而使模型在行为动作序列生成过程中减少误差，缓解因指令描述不同导致的映射不一致的问题。

关键词：深度学习；人-机器人交互；端到端；指令解析；自然语言指令导航

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Abstract

Natural language instruction analysis is an important step to make the interaction between humans and robots more freely and smoothly. In the interaction process between humans and robots, making the robot understand the intention of the instruction and the meaning of the keywords in the instruction is the basic work of natural language instruction parsing, but it is often difficult to collect natural language instruction data, which leads to the problem of the poor generalization ability of the model. In addition, natural language instruction navigation is a necessary ability for Human-Robot Interaction, and it is also the prerequisite for completing the task of fetching objects. However, due to the arbitrariness of natural language, different people have different instruction descriptions for the same task, which may cause instructions and the alignment of navigation actions during the mapping process is inconsistent. At present, for the problem of poor generalization ability, common intent-slot joint modeling methods and data enhancement methods are commonly used. These methods do not fully consider the shared knowledge and private knowledge existing between instructions of different intentions; For the problem of inconsistent mapping, a non-end-to-end statistical model is often used. This method does not consider the accumulation of errors and the impact of the robot's environment on the mapping process. Therefore, improving the generalization performance of the model and the alignment ability in the instruction mapping process is the key to improving the human-robot interaction experience.

Firstly, to address the problem of the poor generalization ability of robots, semantic feature extraction and fusion algorithm is proposed. The algorithm first uses multiple encoder structures to extract the shared and private features of different intent instructions and then uses the gate mechanism to dynamically fuse the extracted features. The whole process fully considers the correlation between instructions with different intentions, and explicitly models them, so that the semantic features in the instructions can be fully utilized.

Secondly, a joint intent-slot optimization method based on graph attention network is proposed to model the correlation between two tasks. This method quantifies the relationship between the two tasks by explicitly modeling to improve the feature adequacy

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

of the end-to-end model. Compared with the existing end-to-end intent-slot joint model, this method not only considers the guiding role of the intent information on the slot information but also considers the constraints and mutual relations between different slots in the instruction, which further improves the model pairing. The performance of explicit modeling of intents and slots also improves the interpretability of the model.

Finally, aiming at the inconsistency of natural language instruction mapping, an end-to-end map-instruction bidirectional attention interaction model based on neural network is proposed. The model uses map information as a knowledge base to assist the mapping in the instruction mapping process, and combines instruction features and map features through two-way attention interaction so that the model can reduce errors in the process of generating action sequences and alleviate the problem of inconsistent mapping during the process of generating action sequences.

Keywords: deep learning; human-robot interaction; end-to-end; instruction parsing; natural language instruction navigation

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

目 录

摘 要 I
Abstract II
第 1 章 绪 论 1
1.1 课题背景及研究意义 1
1.2 国内外研究现状及存在的问题 2
1.2.1 SLU 研究现状 2
1.2.2 机器人室内导航研究现状 3
1.2.3 目前存在的问题 4
1.3 论文主要研究内容 5
1.4 论文组织结构 6
第 2 章 指令解析方法及相关技术研究 7
2.1 指令特征提取 7
2.2 意图检测与槽填充 9
2.2.1 意图检测常用方法 10
2.2.2 槽填充常用方法 11
2.2.3 意图-插槽联合建模方法 12
2.3 动作序列提取常用方法 14
2.4 本章小结 16
第 3 章 指令意图和插槽信息解析方法研究 17
3.1 多编码器特征融合模型概述 17
3.2 指令特征提取及表示方法 18
3.2.1 指令特征提取 19
3.2.2 指令特征融合算法 21
3.3 指令意图信息解析 23
3.4 意图-插槽联合优化方法 24
3.4.1 图注意力网络 25
3.4.2 意图-插槽联合交互方法 26
3.5 本章小结 27
第 4 章 行为动作序列解析方法研究 28
4.1 地图-指令双向注意力交互模型 28
4.1.1 模型概述 28
4.1.2 模型算法流程 30

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

4.2 数据表示方法 31
4.2.1 地图数据的表示 32
4.2.2 自然语言指令的表示 35
4.3 地图-指令双向交互算法 36
4.4 行为动作序列提取 39
4.5 本章小结 40
第 5 章 实验验证及分析 41
5.1 联合意图检测和槽填充特征融合模型实验及分析 41
5.1.1 实验数据集 41
5.1.2 评价指标 42
5.1.3 实验设计 42
5.1.4 实验结果及分析 44
5.2 地图-指令双向注意力交互模型实验及分析 46
5.2.1 实验数据集 46
5.2.2 评价指标 47
5.2.3 实验设计 47
5.2.4 实验结果及分析 48
5.3 本章小结 50
结 论 51
参考文献 53
攻读硕士学位期间承担的科研任务与主要成果 58
致谢 59

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第 1 章 绪 论

1.1 课题背景及研究意义

近十几年来，随着计算机技术、人工智能、深度学习等技术的快速发展以及人们生活水平的不断提高，家庭服务机器人被越来越多的人所接纳，协助人们完成繁重的家务，为人们提供生活上的帮助等[1,2]。这些技术的出现和发展促使家庭服务机器人能够更好地完成工作，在家庭服务机器人的智能性和自主性不断完善的同时也为它们的使用带来了保障，促使家庭服务机器人融入人们的生活。另外, 根据第七次全国人口普查显示，我国现如今已有 2.64 亿的老龄化人口；肢体残疾群体已逾 2400 万，位居各类残疾首位。人口的老龄化和残障人士的数量巨大，需要服务机器人帮助他们更好地生活，且数量需求高，对减轻我国社会经济发展负担的意义十分重大[3,4]。

随着社会需求和行业发展，我国越来越多的家庭追求居家设备的智能化，对于家庭服务机器人的需求日渐增多，这就对于人-机器人交互(Human-Robot Interaction, HRI)能力的要求越来越严格。HRI 涉及人行为识别(Human Behavior Recognition, HBR)[5]、自然语言处理(Natural Language Processing, NLP)[6]、机器学习(Machine Learning, ML)[7]等诸多领域，其发展目标是使机器人能够简单、自然地与人沟通，完全理解人类的语言和行为，并给予恰当的反馈。随着人工智能时代的到来，非端到端的流水线式建模方法弊端愈发明显，已不再满足现阶段人们的需求，因此，使用深度学习方法搭建端到端的神经网络模型赋予了 HRI 新的生机和活力。在未来，端到端网络模型的搭建可以使家庭服务机器人更准确地理解用户的需求，并自主满足人们的需求反馈，显著提升用户的使用体验。这样的美好愿景离不开 HRI 相关学科领域的研究和发展。人与机器人之间的交互通常包括通过语音交互和通过视觉交互两种形式，对于老年人和肢体残疾人群体来说，通过语音实现交互的形式更加方便和快捷。因此，如何使机器人更好地理解人发出的指令并执行显得尤为重要，也使自然语言处理领域的研究受到了越来越多科研人员的重视和关注。

在人与机器人之间的交互过程中，如何使机器人对人发出的自然语言指令进行充分的解析和准确执行是 HRI 发展的必然要求。口语语言理解(Spoken Language Understanding, SLU)是进行指令解析的第一步，也是十分重要的步骤。SLU 的主要目

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

的是对自然语言指令的意图和插槽实体进行识别[8]，形成语义框架，捕捉指令的语义信息，以便后续能够做出适当的、精准的响应。因此，为了使机器人充分理解人的指令，对 SLU 的研究是必要的。考虑到自然语言指令的意图具有不确定性和广泛性，难免会由于某些意图的训练数据不足而导致模型泛化能力变差，但数据稀缺是无法避免的，为每个意图收集丰富的数据也是不现实的，因此，如何将样本充足的意图领域中的知识迁移到样本稀少的意图领域中是当前研究的重点。另外，HRI 必须具备适合于导航的环境特征和推理方法，但不同人对于相同任务的指令描述存在差异，这就使得机器人在进行指令解析的过程中需要充分考虑所处环境信息、非端到端方法的误差传播等因素，并将指令解析为动作序列。因此，如何将家庭环境信息进行抽象表示以及环境信息如何与自然语言指令进行结合也是当前研究的重点。

针对模型泛化能力较差的问题，可以通过增强指令意图对槽填充任务的指导作用从而对数据的语义特征进行充分提取，并进一步考虑不同意图数据之间的关联性和独立性来提升模型的泛化性能。针对指令描述方式不同导致映射不一致的问题，可以将家庭环境信息表示为三元组的形式与指令进行融合，从而在一定程度上解决由于指令描述不同导致的动作片段与指令片段之间映射不一致的问题。

综上所述，本论文主要对家庭环境下指令解析存在的问题进行了研究，并使用端到端的神经网络模型进行建模，减小模型误差，使模型更符合实际应用场景和人们的生活习惯，也为该领域的落地部署奠定了科研基础，具有极强的科研价值。

1.2 国内外研究现状及存在的问题

家庭服务机器人伴随着人工智能的发展不断智能化，功能日新月异，如今已被人们所喜爱和接受，并已经应用到教育、医疗、家政等各个领域。在家庭环境下，自然语言指令解析是家庭服务机器人走向智能化的必由之路，促使研究人员不断推动着模型从流水线形式向端到端形式发展，并向着使家庭服务机器人更加智能化的方向不断推进。

1.2.1 SLU 研究现状

口语语言理解是自然语言指令解析的基础研究，一直受到国内外学者的高度关注。意图检测任务和槽填充任务是口语语言理解的两个主要任务，在机器人领域具有极高的地位和重要性，这两个任务的研究能够促使机器人理解指令的意图和操作实

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

体，对后续工作具有先导作用。自 2011 年 Gokhan Tur 提出意图检测和槽填充的概念以来，各种非端到端的方法层出不穷[9]。在 SLU 任务研究的初期阶段，通常为意图检测和槽填充建立独立模型。对于意图检测任务，目前已经提出了诸如支持向量机(Support Vector Machine, SVM)[10]和循环神经网络(Recurrent Neural Network, RNN)[11]等分类方法来解决该问题；对于槽填充任务，相关的常用方法包括条件随机场(Conditional Random Field, CRF)[12]和长短期记忆网络(Long Short-Term Memory, LSTM)[13]。但随着深度学习的不断发展，人们发现由于两个任务的独立建模导致模型受到误差传播的影响较大，且忽略了两个任务之间的相关性，因此研究重点逐渐转变为使用深度学习方法端到端地对两个任务进行联合训练上。

刘冰、Ian Lane 等人发现基于注意力的编码器-解码器神经网络模型在机器翻译和语音识别领域具有优秀的性能表现，受此启发，他们首次将注意力机制应用到两个任务的联合模型中[14]685-686。郭志文等人考虑到意图和插槽之间存在的强相关性关系，提出了 Slot-Gated 机制，该机制首次在联合模型中对意图和插槽之间的关系进行显式建模，该模型对意图和插槽之间的相关性关系进行量化，明确了两个任务之间的相关性程度[15]753-755。鄂海红等人考虑到意图和插槽之间存在相互关联关系，两个任务之间可以相互加强，在此前发表前的联合模型中，并没有对建立意图和插槽之间的双向关联关系的研究，为了弥补这一空白，提出了能够建立意图和插槽之间双向关联关系的 SF-ID 网络[16]5467-5469。覃立波等人为解决多意图检测和槽填充任务下传统模型仅简单合并多意图信息来指导指令中所有单词的弊端，提出了能够更好地用于联合多意图检测和槽填充的带有单词级动态图交互机制的 AGIF 网络[17]。Bamba Kane 等人用 CNN 网络、Bi-LSTM 网络和条件随机场搭建了 CoBiC 模型，该模型隐式地对意图和插槽相关性进行提取，且可以灵活地作为两个任务的独立模型或联合模型[18]。

口语语言理解的相关研究在诸多科研人员的努力下不断向前推进，取得了优秀的成果，成为了一个重要的研究方向，同时也将在未来的研究中继续深入发展。

1.2.2 机器人室内导航研究现状

对家庭服务机器人来说，执行各类指令时，在各个目标位置之间进行导航是十分常见的，这就要求机器人需要能够根据人的指令准确地完成到目标地点的导航。机器人指令导航旨在将自然语言导航指令映射为相对应的高级导航动作序列。根据服务机器人是否使用视觉信息，可将指令导航分为两大类。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

(1) 基于视觉的指令导航

基于视觉的指令导航方法使机器人能够依据视觉信息并跟随自然语言指令进行导航，主要从强化学习、数据增强和指令对齐角度进行优化。该方法需要同时理解自然语言指令与视觉系统中观察到的实时视觉信息，将二者进行多模态特征融合后做出相应判断并执行对应动作，最终达到目标位置。Angel Chang 等人使用 Matterport 摄像机在九十多个真实家庭环境中采集了 10800 个全景视角图片，并依此构建了一个庞大的仿真环境，首次将真实世界的特征迁移到了仿真环境中[19]。2018 年，Anderson 等人在 Matterport3D 数据集的基础上创建了 R2R 数据集，该数据集将家庭环境场景离散化，在在每个场景设置了机器人可停留的位置，并根据房间的连通性将这些位置进行连接，从而将真实环境转化为图结构，并在这样的环境下随机采样路径进行人工标注[20]。王鑫等人提出了一种 RPA 模型，该方法结合了强化学习中 model-free 与 model-based 两种学习方法进行协同决策，提高了导航的准确率[21]。谭浩等人受到神经网络中的 dropout 层的启发，通过对环境中物体进行随机遮挡来生成新环境的方式实现数据增强，接下来在新环境中进行采样获得新路径，并利用 Fried 提出的 Speaker-Follower 模型生成新指令的标签[22,23]。

(2) 基于语义环境的指令导航

基于语义环境的指令导航相比于基于视觉的指令导航不易受到环境中的噪声干扰，表现能力更强[24]。David 利用统计机器翻译的方法自动发现指令与动作之间的关系和规则，将指令映射到由语法定义的形式语言[25]。Pararth Shah 提出了基于强化学习的 FollowNet 网络来提高机器人执行新指令的能力和在新环境中的泛化能力，他们将房间和地标映射到二维网格点组，使服务机器人导航时能够考虑全局环境信息[26]。Ashwini Pokle 等人首次将端到端的神经网络模型应用于机器人导航，并将地图表示为行为导航图(Behavioral Navigation Graph)，使得地图环境中的语义结构特征得到充分表达，为机器人导航提供了紧凑的路线表示[27]2657-2660。

1.2.3 目前存在的问题

在国内外学者的努力下，对家庭服务机器人自然语言指令的解析已取得了一定成果，但目前仍然存在一些问题尚未解决。

(1) 到目前为止，通过端到端的深度学习方法对意图检测和槽填充联合模型的研究已相对成熟，但尚不够充分。现有模型仅简单地将数据集中的数据输入网络中，导

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

致语义特征的提取不够充分，当数据集中某个意图数据稀缺时，模型无法为该意图提取足够特征，导致模型泛化能力较差。

(2) 在意图检测和槽填充的端到端联合模型中，两个任务的性能优化仍然存在提升空间。意图检测任务和槽填充任务之间存在强相关性，通常槽填充任务需要意图特征进行指导，现有研究对两个任务之间的相关性建模仍不够充分。需要提出性能更加优秀、更符合实际的服务机器人口语语言理解模型联合构建方法。

(3) 现有的家庭服务机器人导航方法主要通过流水线方法进行建模，这种方法会使每一个步骤的误差不断叠加从而影响模型的性能。另外，这种建模方式虽然可以将自然语言指令映射为动作序列，但是对于同一任务的不同描述与动作序列之间的映射鲁棒性较差，并且地图信息的输入表示与指令之间的融合方法尚不完善。

1.3 论文主要研究内容

本文考虑到现有研究存在的问题，使用自然语言处理、图神经网络、注意力机制等端到端建模方法来减少误差的传播，以提高家庭服务机器人的自然语言指令解析能力、提升智能化程度为目标，对自然语言指令的意图和插槽信息的提取、机器人室内导航指令的映射问题进行了如下研究。

(1) 语义特征提取和融合方法的研究

为了提高模型的泛化性能，本文提出了基于多编码器的指令特征提取方法和新的指令特征融合算法，并基于此提出了基于多编码器的联合意图检测和槽填充特征融合模型，研究了由公共编码器和与私有编码器共同进行特征提取的方法，提高了模型语义信息提取能力。另外，研究了一种门机制并实现了将编码器的输出特征进行融合，从而能够表达更丰富的语义特征，使之鲁棒性得到增强。

(2) 联合模型优化方法的研究

为了更好地利用意图检测和槽填充任务之间的相关性，本课题研究了通过图注意力网络将意图和插槽信息进行联合的方法，将预测得到的意图分类结果作为图注意力层中的节点，计算句子中每个单词特征与邻居节点之间的相关性，从而使意图信息能够指导每个单词插槽标签的预测。通过这种方式，槽填充任务能够充分考虑意图检测的结果并考虑每个单词与意图之间的相关程度，以此来提高槽填充的精度。

(3) 地图信息与指令融合方法研究

在已有的序列到序列模型基础上，研究了将地图中的位置地标和动作表示为拓

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

扑结构的行为导航图，并研究了一种通过注意力机制将地图信息与自然语言指令进行融合的方法，使模型在进行动作序列生成过程中将地图信息作为知识库，从而充分考虑地图环境信息，并缓解因描述不同导致的映射不一致的问题。

1.4 论文组织结构

本文主要研究了家庭服务机器人自然语言指令解析中的存在的几个关键问题，并对其进行了深入研究分析。文章共分为 5 个章节，从第 2 章开始为本文主要内容。

第 2 章对常用指令文本特征提取方法、意图检测和槽填充任务联合交互方法、动作序列提取方法和课题研究中使用到的相关技术进行了介绍，并对其适用性进行了分析。

第 3 章对本文提出的多编码器特征提取和特征融合方法、意图-插槽联合优化方法进行了介绍和分析。对应用端到端的深度学习建模方法构建的基于多编码器的联合意图检测和槽填充特征融合模型进行了详细介绍，并对整个自然语言指令语义特征的提取过程进行了详细的介绍和说明。

第 4 章对本文提出的地图表示改进方法、地图信息与指令信息的融合方法进行了介绍。使用三元组表示地图中的位置和地标信息，并将位置之间的动作添加进图中，构成能够紧凑表示导航路线的拓扑图结构，并提出使用双向注意力机制将地图信息与自然语言指令信息进行融合。并对依此构建的端到端网络模型进行了详细介绍和分析。

第 5 章通过实验及其对比实验对本文提出的模型和相关算法进行了验证，说明了算法和模型的可行性，根据实验结果和结论进行了深入分析。

最后，对本文研究成果的不足之处进行了总结，并指明下一阶段的研究方向。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第 2 章 指令解析方法及相关技术研究

为了使人与机器人的交互更加自然、高效，机器人系统必须能够更好地理解自然语言指令信息并提取其中的重要语义特征。为了解决人机交互过程中指令信息提取不充分和机器人遵循自然语言指令进行导航时的映射不一致的问题，本章将自然语言指令解析作为主要的研究内容，对文本特征的提取方法、意图检测和槽填充常用方法、动作序列提取常用方法进行了介绍。

2.1 指令特征提取

现阶段，语音识别技术的发展和研究已相当完善和成熟，基本满足了产业需求，并解决了很多实际问题，因此本文以指令文本阶段的解析作为重点进行研究。文本特征的提取是所有处理文本信息工作的首要任务之一，它将文本信息转化为特征形式，使文本能够被计算机直接进行处理，接着通过设计模型进一步提取文本中的关键信息。目前人们通常使用向量表示文本，但当词汇量过大时，会使得向量变得高维且稀疏，给后续的工作带来低下的效率和庞大的算力开销，而且会对算法的精确性产生负面效果。因此，必须降低向量空间维度，使得文本在低维特征空间下仍能保留原始指令文本含义和所蕴含的上下文信息。下面介绍几种常用的文本特征提取方法：

(1) 词频-逆文档频率

词频-逆文档频率(TF-IDF)是由 Salton 提出的一种基于统计的特征提取方法，常用于文本数据的清洗、数据挖掘等领域，可以过滤掉停用词、常用词等无法表示文本的单词，提取出文本中的关键词信息[28]。单词在文本序列中出现的次数越多，其重要性会随之增加。反之，若单词在语料库中的词频越高，则表示该单词越常见，其重要程度也会随之下降。TF-IDF 的计算方式为词频和逆文档频率的乘积，计算方法如公式(2-1)所示。

$$tfidf_{\mathrm{i,j}}=tf_{\mathrm{i,j}}\times idf_{\mathrm{i}} \tag{2-1}$$

公式(2-1)中i为文本中的某个单词，d_{j}为文本，其中$tf_{\mathrm{i,j}}$为单词i在文档d_{j}中出现的频率。$tf_{\mathrm{i,j}}$计算公式如公式(2-2)所示。

$$tf_{\mathrm{i,j}}=\frac{n_{\mathrm{i,j}}}{\sum_{\mathrm{k}} n_{\mathrm{k,j}}} \tag{2-2}$$

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

公式(2-2)中$n_{i,j}$为单词i在文本d_j中出现的次数，$\sum_k n_{k,j}$为文本d中的每个单词在该文本中出现次数的和。

idf_i表示逆文档频率，是评价一个单词表示文本程度的重要指标，其计算方式如公式(2-3)所示。

$$idf_i = lg\frac{|D|}{1+|\{j:i\in d_j\}|} \tag{2-3}$$

公式(2-3)中$|D|$为数据集中的文本数量，为了防止单词不存在于数据集中，分母为包含单词i的文本数量加 1。

(2) N-Gram 算法

N-Gram 是一种常用的语言模型。它可以被看作是一个窗口，窗口大小为 N，从第一个单词开始依次对整个文本序列进行滑动操作，形成包含 N 个单词的文本序列片段。每一个文本序列片段称为 gram，对所有 gram 的出现次数进行统计和过滤，形成能够表示整个文本的特征向量空间，每一种 gram 表示一个特征维度。

该模型基于马尔科夫假设构建，具体为假设第i个词的出现除与其前面 n-1 个词相关外与其它词均无关。在 N-Gram 语言模型中，若 N 过大，则会导致参数空间过大，向量过于稀疏，而 N 过小则会导致模型忽略单词之间的相关性，因此 N-Gram 模型中的窗口大小常取 2 或 3。

(3) Word2Vec 方法

由于传统的方法会随着语料库中单词数量的增多而变得稀疏，导致输入的数据维度过高，参数规模过大，这意味着需要更多的训练数据，同时也带来了高额的训练时间和训练成本。随着深度学习的发展，解决大规模文本的表示问题变得可行，由于神经网络具备自主学习网络参数的能力，可以节省人工筛选特征等繁琐工作，减小特征维度，这种天然的对文本特征的提取能力极大地提高了后续分类、标注等工作的准确率[29]。Word2Vec 是一种生成词嵌入的方法，它应用了分布式表示，将单词表示为低维的连续且稠密的实数向量。Word2Vec 使用大型文本数据集进行训练，通过学习得到一个通常为几百维度的向量空间，数据集中的每个单词都被映射到该向量空间中，使得单词能够通过其在向量空间中的位置来表达所包含的语义信息和上下文信息。

Word2Vec 方法包含两个模型：CBOW 模型和 Skip-gram 模型[30,31]。二者均为 2 层的前馈神经网络结构。其中前者在训练策略是通过上下文单词预测当前单词，而后

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

者通过当前单词预测其上下文单词。两个模型的架构如图 2-1 所示。

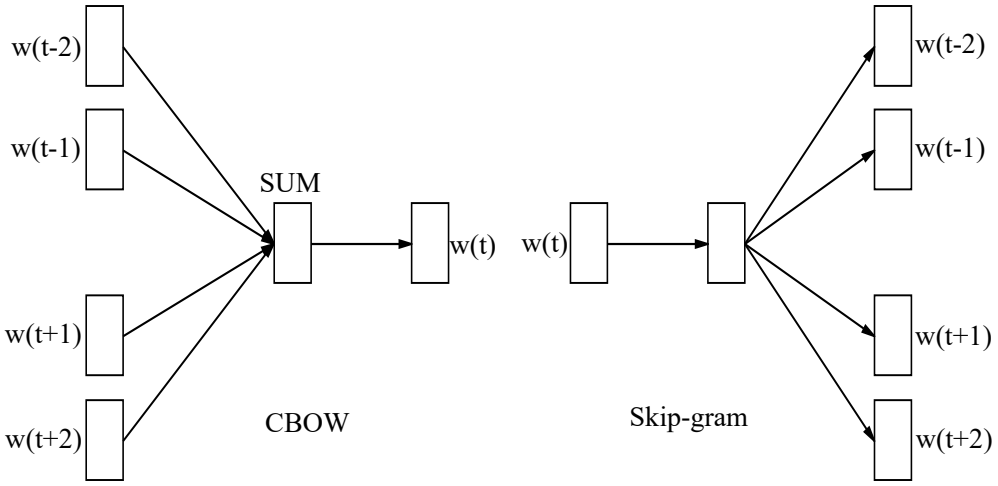

图 2-1 CBOW 模型和 Skip-gram 模型架构

对于 CBOW 模型，首先，其输入为当前单词t的上下文单词，每个单词均使用独热编码来表示，图中窗口大小为 4，即输入当前词的前 2 个单词和后 2 个单词。接着，将输入向量与隐藏层权重矩阵进行点积后执行向量加法操作，并求平均得到隐藏层输出。最后，将隐藏层输出向量与输出层权重矩阵进行点积，计算得到最终的词向量表示，根据误差通过梯度下降法更新模型。

Skip-gram 模型的输入和输出与 CBOW 模型相反，其模型权重矩阵通过训练当前词预测上下文单词的能力来获得，并通过梯度下降来更新。

两个模型经过训练后，通过每个单词的独热编码与词嵌入矩阵进行点积来对词向量矩阵进行查询，词向量矩阵为隐层的参数矩阵。因此，Word2Vec 方法不仅使文本的特征能够以更低维的向量来表示，同时也融入了丰富的上下文语义信息。

2.2 意图检测与槽填充

意图检测和槽填充是口语语言理解的主要任务，作为自然语言指令解析过程中的第一步，二者的性能表现在很大程度上影响着后续工作的顺利进行，其重要性不言而喻。

意图检测的目的是使服务机器人理解说话人的意图，槽填充的目的是从指令中提取语义成分。因此，意图检测可以看作是短文本分类问题，常用支持向量机和循环神经网络等分类模型来解决；槽填充可以看作是严格对齐的序列标注任务，为了获取语义信息，需要将输入序列x映射为插槽标签序列y^S，具体表示如公式(2-4)所示。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$x=(x_1,x_2,...,x_T)\rightarrow y^S=(y_1^S,y_2^S,...,y_T^S) \tag{2-4}$$

公式(2-4)中x为输入序列，y^S为插槽标签序列，T为自然语言指令的长度。

通常使用常用的机器学习方法可以用来分别解决这两个任务，随着研究的深入，人们发现这两个任务之间往往存在着紧密的联系，意图信息可以帮助预测正确的插槽信息进行消歧，正是这种特殊的关系，目前最常使用深度学习方法为这两个任务进行联合建模。

下面对意图检测常用方法、槽填充常用方法及意图-插槽联合建模方法进行详细介绍。

2.2.1 意图检测常用方法

(1) SVM 分类

SVM 算法是一种短文本分类中较为优秀可靠的算法，是应用领域十分广泛的机器学习算法之一。SVM 基于统计学习，是典型的结构风险最小化算法，并依此学习得到分类决策函数。SVM 算法能够在最小化样本误差的同时对结构风险进行最小化，因此算法具备较强的泛化性能，同时，SVM 的特性使得其只需要一定数量的训练数据就可以得到较高的准确率，且样本不均衡对 SVM 造成的影响较小。

对于指令文本的分类问题，首先需要将文本向量化，可以通过 TF-IDF、Word2Vec 等方法完成，接着将其作为 SVM 的输入，经过训练学习得到分类决策函数。对于指令文本的二分类问题，SVM 算法公式如公式(2-5)所示。

$$\begin{cases} \min\limits_{\alpha} \frac{1}{2}\sum\limits_{i=1}^{N}\sum\limits_{j=1}^{N}\alpha_i\alpha_j y_i y_j K(x_i,x_j) - \sum\limits_{i=1}^{N}\alpha_i \\ \qquad s.t. \quad \sum\limits_{i=1}^{N}\alpha_i y_i = 0 \end{cases} \tag{2-5}$$

公式(2-5)中α为拉格朗日系数，x和y分别为样本数据和标签，$K(x_i,x_j)$为核函数。

通常来说，样本并不是严格线性可分的，在实际应用时常使用高斯核函数将数据映射到更高维的向量空间中使之能够线性可分。高斯核函数及计算得到的分类决策函数如公式(2-6)和公式(2-7)所示。

$$K(x,z)=exp(-\frac{\|x-z\|^2}{2\sigma^2}) \tag{2-6}$$

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$f(x)=sign(\sum_{i=1}^{N}\alpha_i^* y_i exp(-\frac{\|x-z\|^2}{2\sigma^2})+b^*) \tag{2-7}$$

(2) 循环神经网络分类

在传统的基于统计的文本分类方法中，一般使用 TF-IDF 等特征向量作为输入，但是这样的特征表示并没有考虑到文本信息中的单词顺序，一般的神经网络通常只能将定长的向量作为输入，很难处理文本信息这样的不定长数据，并且难以捕捉到文本数据中的长距离的依赖。

循环神经网络(RNN)能够很好地处理有序的、不定长的文本数据，并且能够对自然语言指令序列中单词之间的依赖关系进行建模，因此效果明显优于一般的神经网络。RNN 网络在每个时间步处理一个输入，在文本分类问题中，通常使用最后一个时间步的隐藏层状态作为分类器的输入来进行分类，具体算法如式(2-8)和式(2-9)所示。

$$h_t=f(Uh_{t-1}+Wx_t+b) \tag{2-8}$$

$$\hat{y}=softmax(W_0h_t+b_0) \tag{2-9}$$

公式(2-8)为 RNN 网络的状态更新公式，公式(2-9)为使用 RNN 网络最后一个时刻输出的分类公式。

2.2.2 槽填充常用方法

CRF 是一种无向图模型，它对条件概率进行建模，该算法打破了隐式马尔科夫模型(HMM)的观测独立假设，解决了最大熵马尔科夫模型(MEMM)由于局部归一化导致的标注偏差问题，因此该模型常被用于自然语言处理领域中的 NER 任务以及计算机视觉领域中的语义分割的任务中[32]。CRF 目前通常应用在序列标注任务中，它可以自定义特征函数，将其概率度函数表达为参数形式或向量形式，对观测序列之间的依赖关系进行建模。

考虑到指令文本单词之间存在前后相关性，并且插槽标签之间具有线性关系，节点特征函数只与当前节点有关，局部特征函数与上一节点有关，因此常使用线性链条件随机场(linear-CRF)为槽填充任务进行建模[33]。linear-CRF 可以在训练数据时自动学习得到指令文本标注的约束性规则，并且依靠约束性规则来保证最终预测结果的有效性和合理性。linear-CRF 模型架构如图 2-2 所示，其数学公式表示如公式(2-10)和公式(2-11)所示。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

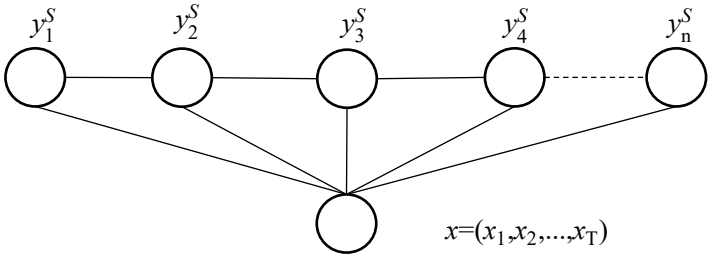

图 2-2 线性链条件随机场

$$P(y|x)=\frac{1}{Z(x)}exp(\sum_{i,k}\lambda_k t_k(y_{i-1},y_i,x,i)+\sum_{i,l}\mu_l s_l(y_i,x,i)) \tag{2-10}$$

$$\hat{y}=argmax P(y|x) \tag{2-11}$$

公式(2-10)中t_k和s_l为特征函数，λ_k和μ_l为权重系数，由于 linear-CRF 为无向图模型，因此$Z(x)$为规范化因子，其数学描述如公式(2-12)所示。

$$Z(x)=\sum_{y}\exp(\sum_{i,k}\lambda_k t_k(y_{i-1},y_i,x,i)+\sum_{i,l}\mu_l s_l(y_i,x,i)) \tag{2-12}$$

2.2.3 意图-插槽联合建模方法

意图检测和槽填充虽然是两个不同的任务，但意图检测和槽填充任务之间存在紧密的联系和相关性，因此目前的主要研究工作都放在了联合模型上。例如句子“Will it storm in kinder Russia” 的意图为“GetWeather”，由于单词在不同的意图下所表达的含义可能不同，因此意图的准确识别有助于模型识别句子中“GetWeather”的相关插槽，而不会识别为“PlayMusic”的相关插槽。同理，对插槽标签的准确识别在一定程度上能够帮助模型预测意图，进行消歧。目前的意图-插槽联合建模工作可以分为以下三种方法[34]。

(1) 隐式联合模型

隐式联合模型的建模方法仅使用共享编码器捕获意图检测和槽填充任务之间的相关性特征，不采用显示交互方式。如张晓东提出的使用共享 RNN 网络来学习意图和插槽之间相关性关系的 Joint ID and SF 模型[35]和刘冰等人提出的带有注意力机制的联合模型。隐式联合建模的方法直接将两个任务之间的相关性特征进行整合，这种建模方法在 SLU 研究初期被广泛使用，其利用了神经网络自主学习模型参数的特点，将这种相关性关系的学习完全交给网络来学习，但这也导致了其可解释性和性能较差。隐式联合建模方法模型架构如图 2-3 所示。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

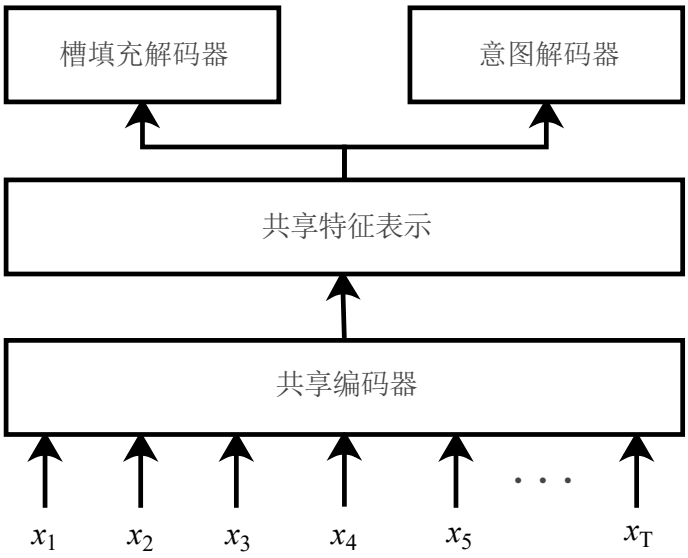

图 2-3 隐式联合建模图

(2) 显式联合模型

随着 SLU 领域研究的深入，人们开始尝试使用显式联合建模的方式来提取两个任务之间相关性特征。显式联合建模方法与隐式联合建模方法不同，其首先使用共享编码器提取相关性特征，接着通过显式的交互模块进一步对两个任务之间的相关性关系进行人工干预，使特征可以得到更好的表达。相比之下，显式联合建模方法能够更加明确两个任务之间的知识转移过程，具有更强的可解释性，其交互模块的形式针对具体任务进行具体研究，增强了模型的性能。显式联合建模方法模型架构如图 2-4 所示。

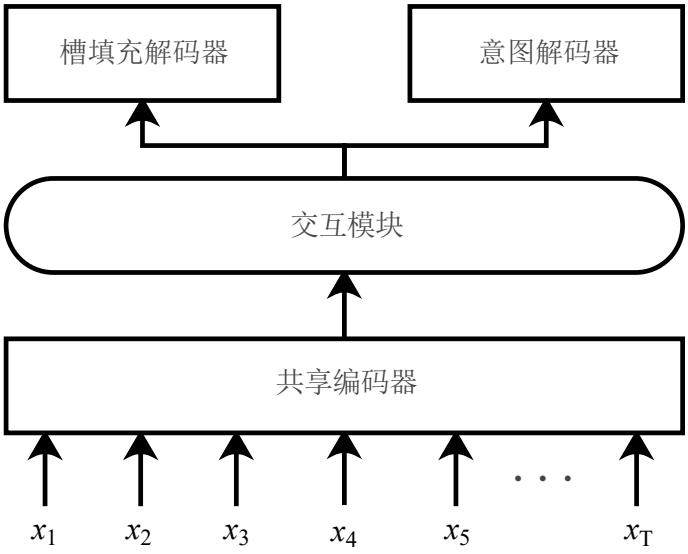

图 2-4 显式联合建模图

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

(3) 预训练范式联合模型

与其它 NLP 任务相同，经过大型语料库训练的预训练模型蕴含丰富的语义特征，因此使用预训练模型能够获得更优秀的性能。自 BERT 提出后，将 BERT 应用在 SLU 任务上的研究使得其性能取得了显著的提升，在这类模型中，BERT 被用做编码器来提取语义特征[36,37]，且通常这种建模方式不需要进行显式交互。预训练范式建模方法模型架构如图 2-5 所示。

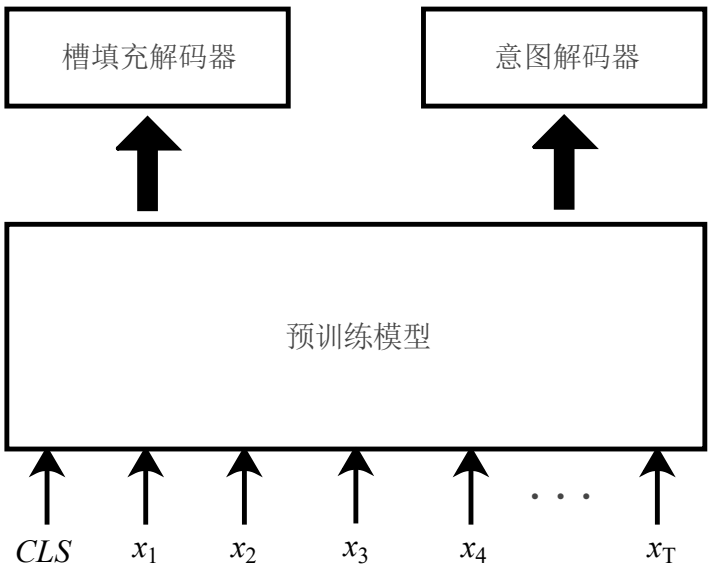

图 2-5 预训练范式联合建模图

2.3 动作序列提取常用方法

家庭服务机器人的导航功能是提高 HRI 完整性所不可或缺的功能之一。由于自然语言指令具有复杂性和不确定性的特点，即使对于相同的指令，不同人的描述依然可能会不同。因此，在机器人导航初期的研究工作中，人们通常手动地提取指令与路径之间的准确映射关系是否具备适合于导航的环境特征和推理方法。在以往的工作中，人们使用手动解析指令的方法将自然语言指令中与导航相关的文本片段解析为导航语义单元，接着通过算法将这些语义单元映射为机器人可执行的动作序列[38]。这样的非端到端的建模方式不仅耗费大量的时间，浪费资源，而且会不可避免地将误差不断传播，对于机器人的智能化是非常不利的。

近年来，随着人工智能的蓬勃发展，使得用深度学习方法端到端地实现自然语言指令到导航动作序列的映射成为可能。目前使用最广泛的是序列到序列(Sequence-to-Sequence, Seq2Seq)模型。Seq2Seq 模型是一种神经网络机器翻译模型，这种模型相比

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

于传统方法能够自主学习输入序列和输出序列之间的映射和对齐关系，大大降低了成本。Seq2Seq 模型的基本结构如图 2-6 所示。

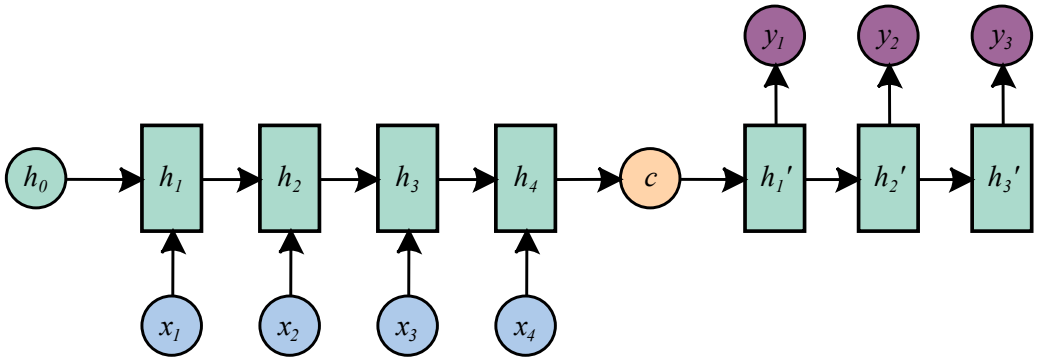

图 2-6 Seq2Seq 模型结构

Seq2Seq 模型分为编码器部分和解码器部分，在实际应用中常使用 LSTM 网络作为编码器和解码器。Seq2Seq 模型的概率表达形式如公式(2-13)所示。

$$\begin{aligned} p(y|x)&=p(y_1,\ldots,y_{T'}|x_1,\ldots,x_T) \\ &=\prod_{t=1}^{T'} p(y_t|c,y_1,\ldots y_{t-1}) \end{aligned} \tag{2-13}$$

公式(2-13)中c为编码器 LSTM 网络最后一个隐藏状态输出，x为自然语言指令输入$x=(x_1,x_2,\ldots,x_T)$，y为行为动作序列输出$y=(y_1,y_2,\ldots,y_{T'})$。

首先，Seq2Seq 编码器将输入的自然语言指令$x=(x_1,x_2,\ldots,x_T)$编码为上下文向量c，具体过程如公式(2-14)所示。

$$c=encoder(h_0,x) \tag{2-14}$$

公式(2-14)中h_0为编码器 LSTM 网络的初始隐藏状态，具体计算过程如公式(2-15)所示。

$$\begin{aligned} h_t&=\mathrm{LSTM}(h_{t-1},x_t) \\ c&=h_T \end{aligned} \tag{2-15}$$

公式(2-15)中h_T即为编码器网络的最后一个时间步的隐藏状态，通常包含了整个文本的上下文语义信息，它将作为解码器网络的输入。

解码器将上下文向量c作为输入，逐一生成目标行为动作产生行为动作序列$y=(y_1,y_2,\ldots,y_{T'})$，具体表示如公式(2-16)所示。

$$y=decoder(c,w_{SOS}) \tag{2-16}$$

公式(2-16)中w_{SOS}为表示序列起始位置的特殊标记。第一个单词的具体生成过程

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

如公式(2-17)和公式(2-18)所示。

$$h_0^{'}=\mathrm{LSTM}(c,w_{\mathrm{SOS}}) \tag{2-17}$$

$$y_1=argmax(softmax(g(h_0^{'}))) \tag{2-18}$$

公式(2-17)中$h_0^{'}$为编码器输出和起始标记输入到 LSTM 中得到的隐藏状态输出；公式(2-18)中$g(\cdot)$为线性变换函数。后续时间步的单词生成过程与公式(2-17)类似，即使用上一个时刻的输出和解码器隐藏状态来计算得到当前时刻的输出。

2.4 本章小结

本章结合课题的研究内容对所涉及的基本概念及常用方法进行了介绍，包括自然语言指令特征提取方法、意图检测和槽填充任务的联合建模方法以及家庭服务机器人动作序列的提取方法，同时也对这些端到端的建模方式在家庭环境场景下的适用性进行了分析，为后续本文家庭服务机器人自然语言指令解析方法的研究奠定了基础。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第 3 章 指令意图和插槽信息解析方法研究

在家庭服务机器人的实际使用时，虽然其在家庭场景下指令的服务意图有限，但仍然会遇到人们发出的指令不存在于机器人理解范围内的情况。在这种情况下，最优的解决方法是为这些指令收集足够多的数据进行网络训练，使机器人能够理解这些指令的意图。但是在实际场景中，由于传统的流水线方法具有较大误差，且这类指令往往难以收集足够数量的数据，造成了模型在这些稀缺意图的指令上效果较差，机器人无法对指令做出正确的动作和反应，严重影响人和机器人之间的交互体验。

为解决上述问题，本章应用端到端的深度学习神经网络建模方法，提出了基于多编码器的联合意图检测和槽填充特征融合模型，对模型所提出的多编码器特征提取方法和显式交互方法进行了详细的介绍，并对本文提出的多编码器特征融合模型算法的有效性进行了分析。

3.1 多编码器特征融合模型概述

虽然由于某些意图的自然语言指令数据稀缺导致模型在这类指令上的效果较差，从而使得模型泛化能力较差，但这些稀缺意图的指令与已知意图的指令之间仍然存在一定的相关性。现有的算法模型都建立在大型数据集的基础之上，但这些数据仅包含有限数量的意图领域，难以扩展到带标签数据有限的新意图领域。鉴于此，本文提出了基于多编码器的联合意图检测和槽填充特征融合模型，如图 3-1 所示。

算法模型使用双向 LSTM 网络(Bidirectional LSTM)[39]作为多编码器的基本结构，这些编码器为每个意图的指令进行编码，动态地为输入数据分配权重并提取特征，并使用公共编码器来提取所有意图之间的共享特征。当给定一个新的意图数据时，即使其数据极少，该模型也可以有效地提取相应意图领域的知识，使模型获得优秀的泛化性能。算法模型的流程如下。

(1) 将训练集输入算法模型；

(2) 通过多编码器结构获得指令的私有特征和共享特征；

(3) 将私有特征和共享特征通过特征融合算法进行融合生成融合特征；

(4) 使用融合特征进行意图分类任务；

(5) 通过意图-插槽交互层进行槽填充任务的解析；

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

(6) 比对验证集结果，对模型进行调参，得到最终的联合模型。

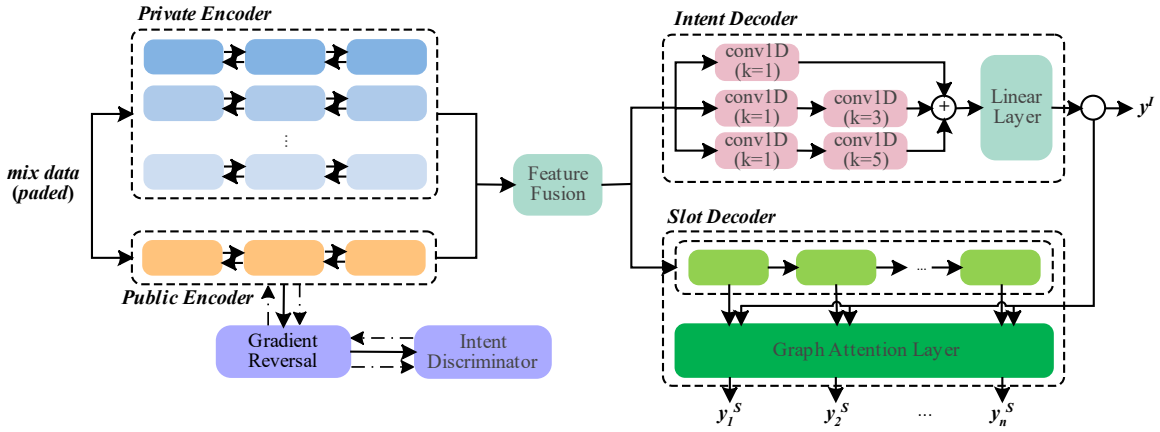

图 3-1 联合意图检测和槽填充特征融合模型

3.2 指令特征提取及表示方法

现有的相关研究仅简单地将不同意图的数据输入到网络中，不能很好地提取到它们之间的共享知识与私有知识，特别是在某些意图数据量很少甚至未知的情况下。而在端到端的深度学习网络模型中，数据的特征表示是决定模型性能的关键，为了能够充分表达和利用数据稀缺意图领域的指令和已知意图的指令之间的关系，本文提出了意图融合编码器，该编码器通过多个编码器并联提取特征的方式来对不同意图的相关关系进行显式建模，接着通过特征融合算法对指令特征进行融合，使其能够针对不同的输入而具有动态的特征表达能力。意图融合编码器结构如图 3-2 所示。

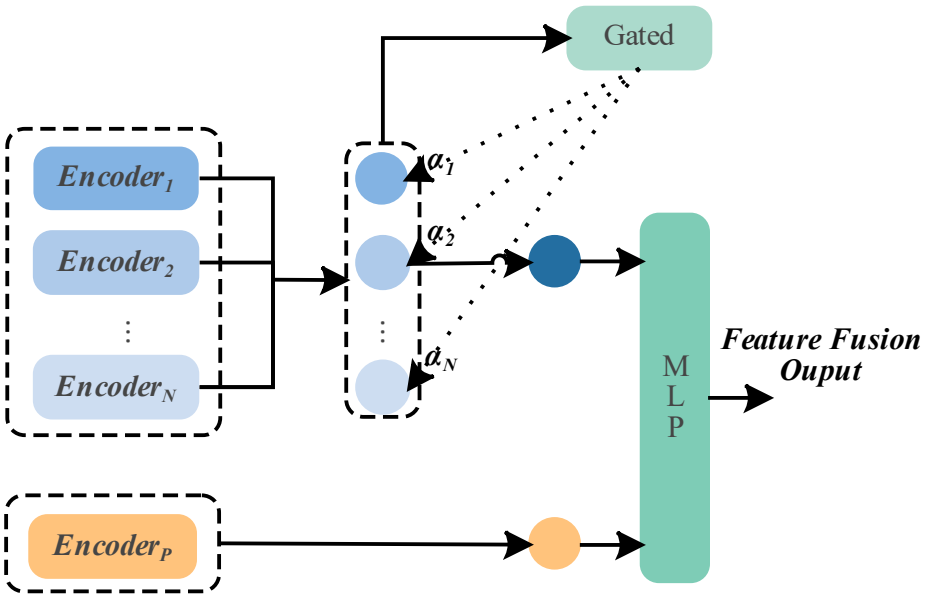

图 3-2 意图融合编码器

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

这种建模方式可以明确特征的作用和特征之间的相互关系，加强特征的可干预性和可解释性，使得特征能够得到更充分的表达。意图融合编码器通过特征提取部分生成私有特征和共享特征，再由特征融合部分将私有特征和共享特征进行融合作为意图融合编码器的最终输出。

3.2.1 指令特征提取

在意图融合编码器中，特征提取部分使用双向 LSTM 网络对指令特征进行提取，由一个公共编码器和与已知意图指令类别数量相同的私有编码器组成。意图融合编码器的数据输入方法不同于以往的建模方法，因此，模型参数在不同意图的指令之间共享，包括用于获取意图共享特征的公共编码器和获取意图私有特征所对应的私有编码器。

(1) 数据输入方法

模型对于指令特征的提取形式决定了数据的输入方法，在以往的建模方法中，对指令特征的提取有如下三种形式。

单一模型模式：如图 3-3 a)所示，该方法是指令特征提取方法中的基本形式，其仅使用单一编码器对输入的指令进行建模，输入数据为混合意图指令数据。这种建模方式仅对输入数据中不同意图领域之间的关系进行隐式建模，但无法明确且有效地提取特定意图的知识信息。

多编码器多模型模式：如图 3-3 b)所示，该方法在建模方式上是单编码器单模型模式的并行化，使用多个模型对指令文本分别进行建模。其数据输入形式不同于单编码器单模型模式，其中的每个模型分别输入不同意图的指令数据，使得模型可以分别提取不同意图数据的独有特征，但该模式无法提取不同意图之间的共享特征，忽略了不同意图指令之间的关系。

多编码器单模型模式：如图 3-3 c)所示，该方法使用公共编码器提取不同意图领域之间的共享特征，并通过多个编码器分别提取不同意图的私有特征，其中。公共编码器的数据输入为混合意图数据，提取私有特征的每个编码器分别输入各意图领域的数据。在这种情况下，若某个意图领域的数据变得稀少，模型将不再具备提取其私有特征的能力。另外，这种方法也未考虑到某些意图领域之间的存在的相关性。

为了使编码器能够同时考虑意图之间的共享知识和某些领域之间的细粒度相关性，本文对多编码器单模型模式的指令特征进行提取进行了改进，提出了意图融合编

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

码器，意图融合编码器使用特征融合算法对各个意图的私有特征进行动态融合，因此，公共编码器和私有编码器的输入均为完整的混合意图数据，这使得模型可以显式地捕获意图领域之间的相关性。

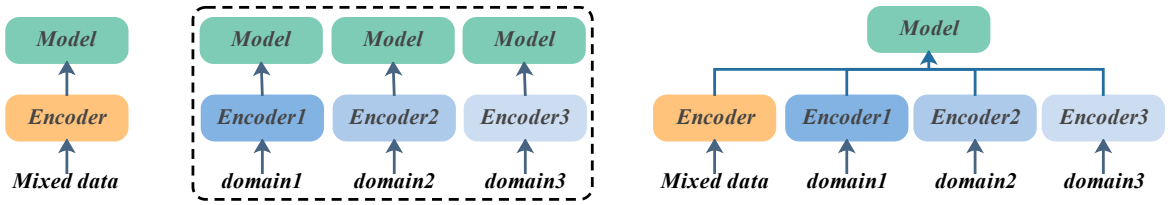

a)单一模型　　b)多编码器多模型　　c)多编码器单模型

图 3-3 指令特征提取形式

(2) 共享特征的提取

共享特征使用公共编码器进行提取，为了提取指令文本中更长距离的依赖关系，缓解梯度消失，并同时考虑整个指令文本的信息，公共编码器采用双向 LSTM 结构搭建。另外，为了提取不同意图领域之间的共享特征，通过公共编码器后连接梯度反转层和分类器的方式混淆不同意图的知识，从而达到提取共享知识的目的。

在本文中，混合意图数据(即原始数据集中所有指令)单词序列$x=(x_1,x_2,\ldots,x_T)$首先作为词嵌入层的输入并对其进行编码，词嵌入层的输出为指令的词嵌入表示形式，如公式(3-1)所示。

$$E=\text{Embedding}(x) \tag{3-1}$$

公式(3-1)中$E=(e_1,e_2,\ldots,e_T)\in R^{T\times d}$，指令中每个单词均表示为维度为$d$的向量，T为当前批次数据的最大指令序列长度。

接下来，指令的词嵌入表示E作为公共编码器的输入，得到指令的共享特征向量表示，为了鼓励模型学习意图之间的共享特征，模型在公共编码器上应用了对抗学习方法，在公共编码器后引入了梯度反转层(Gradient Reversal Layer, GRL)及线性分类器帮助模型训练，GRL 经常被用于提取不变特征和领域适应特征[40]。

在网络训练过程中，通常通过反向传播将损失值(预测值和真实值之间差距)逐层向后传递，每层网络通过接收到的损失值来计算梯度值，并通过优化器更新网络中的参数。基于此，GRL 通过将传播到该层中的损失值与一个负数-λ相乘，使得 GRL 前后的网络向着相反的方向进行参数更新，从而实现对抗学习的效果。

在本文中，GRL 位于公共编码器和线性分类器之间，线性分类器在对意图分类的同时会使得公共编码器对指令特征进行混淆，最终达到动态平衡。指令共享特征的

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

提取如公式(3-2)和公式(3-3)所示。

$$h_{\mathrm{enc,t}}^{\mathrm{pub}}=\mathrm{BiLSTM}_{\mathrm{enc}}^{\mathrm{pub}}(e_{\mathrm{t}}) \tag{3-2}$$

$$H_{\mathrm{enc}}^{\mathrm{pub}}=(h_{\mathrm{enc,1}}^{\mathrm{pub}},\ldots,h_{\mathrm{enc,T}}^{\mathrm{pub}}) \tag{3-3}$$

公式(3-2)中$\mathrm{BiLSTM}_{\mathrm{enc}}^{\mathrm{pub}}$为公共编码器，公式(3-3)中$h_{\mathrm{enc,1}}^{\mathrm{pub}},\ldots,h_{\mathrm{enc,T}}^{\mathrm{pub}}$分别为公共编码器每个时间步输出的隐藏状态向量，$H_{\mathrm{enc}}^{\mathrm{pub}}$为指令的共享特征表示，是公共编码器的最终输出，其由双向 LSTM 所有时间步的隐藏状态组成。

梯度反转层后的线性分类器由两层线性变换层组成，激活函数为*LeakyReLU*。线性分类器的目的是使公共编码器提取到混淆特征，分类过程如公式(3-4)所示。

$$\begin{gathered} h=LeakyReLU(W_2(\mathrm{LeakyReLU}(W_1H_{\mathrm{enc}}^{\mathrm{pub}}+b_1))+b_2) \\ \hat{y}=softmax(h) \end{gathered} \tag{3-4}$$

公式(3-4)中h为经过两次线性变换后的输出，$\hat{y}$为线性分类器的分类结果。

(3) 私有特征的提取

私有特征使用私有编码器进行提取，与公共编码器相同，所有私有编码器均采用双向 LSTM 结构，私有编码器使用词嵌入层的输出$E=(e_1,e_2,...,e_{\mathrm{T}})$作为输入，数据集中所有的指令数据均会输入每个私有编码器中。

为了能够使每个私有编码器提取不同意图指令的私有特征表示，本文对私有编码器的输出进行监督学习，使得每个私有编码器能够更好地保留对应意图领域数据的特征，并同时融合与其相关意图指令的特征，保留它们之间的相关性，提高模型的泛化性能。

私有编码器分别提取各个意图数据的私有特征$H_{\mathrm{enc}}^{\mathrm{pri,1}},\ldots,H_{\mathrm{enc}}^{\mathrm{pri,N}}$，如公式(3-5)和公式(3-6)所示。

$$h_{\mathrm{enc,t}}^{\mathrm{pri,n}}=\mathrm{BiLSTM}_{\mathrm{enc}}^{\mathrm{pri,n}}(e_{\mathrm{t}}) \tag{3-5}$$

$$H_{\mathrm{enc}}^{\mathrm{pri,n}}=(h_{\mathrm{enc,1}}^{\mathrm{pri,n}},\ldots,h_{\mathrm{enc,T}}^{\mathrm{pri,n}}) \tag{3-6}$$

公式(3-5)中$\mathrm{n}\in(1,\mathrm{N})$，N为数据集中意图类别数量；公式(3-6)中$H_{\mathrm{enc}}^{\mathrm{pri,n}}\in\mathrm{R}^{\mathrm{T}\times 2\mathrm{D_H}}$，$\mathrm{D_H}$为编码器 LSTM 的隐藏单元大小。

最后，$H_{\mathrm{enc}}^{\mathrm{pri,1}},\ldots,H_{\mathrm{enc}}^{\mathrm{pri,N}}$作为私有编码器的最终输出。

3.2.2 指令特征融合算法

在进行指令特征提取后，这些特征并不能够直接作为下一步任务的输入，需要将

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

它们通过合适的方法进行特征融合，使最终的融合语义特征中包含不同意图间的共享知识和私有知识。且对于私有知识，由于意图之间的相关性程度不同，使得不同意图的特征在进行指令语义特征融合后所占权重会直接影响模型的性能。因此，本文提出动态的特征融合算法将共享特征和私有特征进行融合，使指令特征能够完整、充分地表达不同意图数据之间的关联性和独立性，并为解码器提供良好的特征输入。特征融合过程如下。

(1) 将私有特征进行堆叠操作(stack)，并作为门机制的输入。

由私有编码器得到的 N 组私有特征，其维度均为$R^{T\times 2D_H}$，经过 stack 堆叠操作后，其维度为$R^{T\times 2D_H\times N}$。

(2) 通过门机制对私有编码器进行监督学习，计算得到融合私有特征H_{enc}^{pri}。

本文对特征融合算法的具体数学表示进行了详细的说明。首先，将堆叠后的私有编码器的输出送入门机制，并通过门机制动态地为每个意图分配权重以充分提取其私有特征，从而获得最终的私有特征H_{enc}^{pri}，如公式(3-7)所示。

$$H_{enc}^{pri}=\mathrm{Gate}(\mathrm{stack}(H_{enc}^{pri,1},\ldots,H_{enc}^{pri,N})) \tag{3-7}$$

公式(3-7)中，Gate为门机制，其输入数据维度为$R^{T\times 2D_H\times N}$。具体的，本文提出的门机制通过多层感知器对展平后的堆叠私有特征降维至 N 维，并在该维度上计算 softmax 归一化分数α_i最后，根据归一化分数对私有特征进行加权聚合。加权聚合计算如公式(3-8)所示。

$$\mathrm{Gate}=\sum_{i=1}^{N}\alpha_i H_{enc}^{pri,i} \tag{3-8}$$

公式(3-8)中，α_i为每个意图所对应的注意力权重。此外，在归一化得到α_i之前，本文通过对归一化前的分数矩阵与每个真实意图标签计算交叉熵损失值，从而使私有编码器能够通过相应意图标签对其分别进行训练，并使各个私有编码器也能够提取其他意图领域的知识用于该意图领域。

(3) 将融合私有特征H_{enc}^{pri}与共享特征H_{enc}^{pub}进行融合，融合过程为H_{enc}^{pri}与H_{enc}^{pub}的拼接和降维过程，得到意图融合编码器输出H_{enc}^{f}。

最后，意图融合编码器使用多层感知器将公共享特征与私有特征进行融合，得到共享-私有融合特征H_{enc}^{f}，如公式(3-9)所示。

$$H_{enc}^{f}=W_2(LeakyReLU(W_1[H_{enc}^{pub},H_{enc}^{pri}])) \tag{3-9}$$

公式(3-9)中，W_1，W_2均为多层感知器中线性变换操作的可训练参数，$H_{enc}^{f}\in R^{T\times d}$

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

为共享-私有融合特征。

为了增强指令特征的表达能力以及避免模型退化的问题，本文使用自注意力机制[41]来捕获词嵌入中的上下文感知特征。首先通过使用不同的线性投影参数W_q，W_k，W_v将词嵌入矩阵$E\in R^{T\times d}$(d表示映射的维度)映射到Q，K和V矩阵。注意力权重通过Q和K的点积计算得到，且自注意力的输出$A\in R^{T\times d}$由V矩阵的加权和计算获得，如公式(3-10)所示。

$$A=softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{3-10}$$

公式(3-10)中d_k表示K矩阵的维度，在本文中，d_k与指令的词嵌入维度d大小相同。

最后，将两个特征表示进行连接，作为最终的意图融合编码器输出。如公式(3-11)所示。

$$Output_{enc}=[H^f_{enc}\|A] \tag{3-11}$$

公式(3-11)中，||为拼接操作，$Output_{enc}\in R^{T\times 2d}$为编码器的最终输出，其输出形式定义为$Output_{enc}=(o_1,o_2,\ldots,o_T)$。

3.3 指令意图信息解析

在获取到意图融合编码器的输出特征后，首先执行意图检测任务。本文使用一维卷积与全连接层的串接结构作为意图解码器对指令编码特征进行解码分类。指令文本与图像数据类似，自然语言中同样包含局部相关性，例如单词短语结构中存在的内部相关性等。为了进一步捕获此信息，意图解码器首先在指令编码特征$Output_{enc}$上进行一维卷积操作，然后再经过全连接层线性变换后得到意图的预测输出。

一维卷积是处理序列问题的常用方法，常被应用在在自然语言处理领域的研究当中。一维卷积可以提取序列数据中的局部相关性信息和数据在序列长度方向上的平移不变特征，能够进一步提高特征的表达能力。如图 3-4 为卷积核大小为 3，卷积核数量为 2 的一维卷积操作。

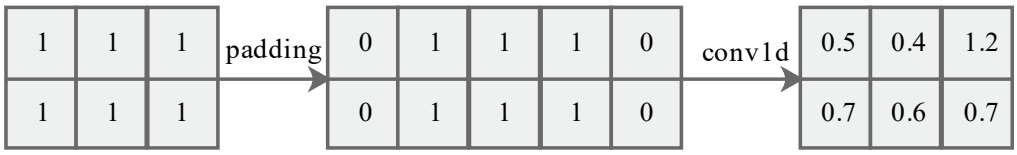

图 3-4 一维卷积在序列数据上的操作

在本文的意图解码器中，一维卷积能够考虑指令特征中的 n 元局部相关性，其

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

中 n 的大小与卷积核大小相同。形式上，卷积块的计算公式可以表述为公式(3-12)。

$$conv_t=ReLU(W_c[o_{t-k/2},\ldots,o_{t-k/2}]+b_c) \tag{3-12}$$

公式(3-12)中，W_c和b_c为模型可训练参数，k为卷积核大小。

但从以往的研究中得知，由于经过卷积后的特征可解释性较差，因此，对于卷积核大小的选择是难以确定的。考虑到 Inception 网络使用卷积核组合的方法[42,43]，本文采用三组不同的卷积核分别对意图融合编码器的输出进行并行卷积运算，使得模型能够捕获不同细粒度的局部特征，从而获得不同的特征表示形式。三种卷积核分别为$conv^1$，$conv^2$和$conv^3$，将这些卷积得到的特征向量拼接，并进行线性变换后得到与意图融合编码器输出张量形状相同的特征。卷积组合特征如公式(3-13)所示。

$$z_t=[conv_t^1,conv_t^2,conv_t^3]W_z \tag{3-13}$$

公式(3-13)中，W_z为线性变换操作中的可训练参数，$z=(z_1,z_2,\ldots z_t,\ldots,z_T)\in R^{T\times 2d}$，$d$与指令的词嵌入向量维度相同。

最后对z进行拉伸操作后得到z'，作为意图线性分类器的输入并预测句子的意图类别，预测过程如公式(3-14)所示。

$$y^I=\sigma(W_{intent}(LeakyReLU(W_c z'+b_c))+b_{intent}) \tag{3-14}$$

公式(3-14)中，W_{intent}，W_c为意图解码器两次线性变换操作的可训练参数，b_{intent}和b_c分别为两次线性变换中的偏置项。$y^I=\{y_1^I,\ldots,y_N^I\}$为指令的意图输出，N是意图标签的个数，$\sigma$为 *sigmoid* 激活函数。

意图解码器取y^I最大值意图索引I作为最终意图类别的输出。

3.4 意图-插槽联合优化方法

意图检测和槽填充任务之间存在极强的相关性，且槽填充任务的性能高度依赖于意图。为了使端到端网络模型获得更好的输出结果，需要对意图检测和槽填充两个任务进行联合推理。考虑到以往的联合模型的性能仍然存在提升的空间，且已有的联合模型中意图数据和插槽数据的联合优化方法已不能满足现阶段性能需要，本文提出了基于图注意力网络的意图-插槽联合交互方法。

相比已有的联合优化方法，该方法不仅考虑了意图信息对插槽信息的指导作用，而且针对意图信息和插槽信息之间的相关性程度的高低进行了建模，进一步提高了模型对意图和插槽显式建模的性能。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

3.4.1 图注意力网络

图神经网络是近年来深度学习领域中受到关注最多的领域之一。图注意力网络(Graph Attention Network, GAT)是一种利用了注意力机制的图卷积神经网络，该网络能够更好地对邻居节点进行聚合[44]。GAT 利用了注意力机制，它通过学习当前节点与邻居节点的相关性权重来对邻居节点进行加权聚合。这使得 GAT 不仅具备更强的鲁棒性，同时也使得模型具备更强的可解释性。

图注意力网络由图注意力层串联组成，对于槽填充任务，给定长度为M的指令序列，其标注的标签之间具有一定的相关性，因此可以在单层的 GAT 中将指令序列表示为具有M个节点的图。单层 GAT 将初始节点特征$\tilde{H}=\{\tilde{h}_1,\ldots,\tilde{h}_M\},\tilde{h}\in R^F$作为输入，并输出新的节点特征$\tilde{H}'=\{\tilde{h}'_1,\ldots,\tilde{h}'_M\},\tilde{h}'\in R^{F'}$，$F$和$F'$分别为输入特征和输出特征的维度大小。GAT 和其他注意力机制类似，它的计算过程分为两步：

首先，对于每个单词节点i，逐个计算它与其邻居节点j (j$\in Neighbor_i$，$Neighbor_i$为节点i的一阶邻居节点)之间的相似系数，并对这些相似系数进行归一化来计算注意力系数α_{ij}，具体运算过程如图 3-5 所示。

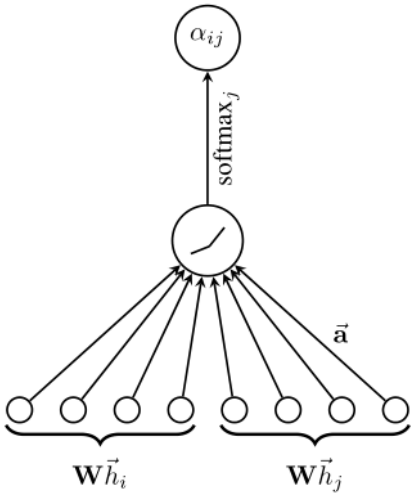

图 3-5 GAT 第一步运算图示

具体的数学表达形式如公式(3-15)和公式(3-16)所示。

$$e_{ij}=a([W\tilde{h}_i||W\tilde{h}_j]),j\in Neighbor_i \tag{3-15}$$

$$\alpha_{ij}=\frac{\exp(LeakyReLU(e_{ij}))}{\sum_{k\in Neighbor_i}\exp(LeakyReLU(e_{ik}))} \tag{3-16}$$

公式(3-15)中，W为共享参数矩阵，通过线性变换将节点的特征进行增维，使特

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

征得到增强。||为拼接函数，$a(\cdot)$为线性映射函数，其能够将拼接后的高维特征映射到实数域。

在槽填充任务中，单词节点之间按照其在序列中的位置与其前后节点互为邻居，且每个单词节点均与意图节点作为邻居，以充分考虑意图信息对插槽的影响。

接下来，根据注意力系数将特征进行加权求和得到节点i的融合了其邻居节点信息的新特征向量。其运算过程如图 3-6 所示。

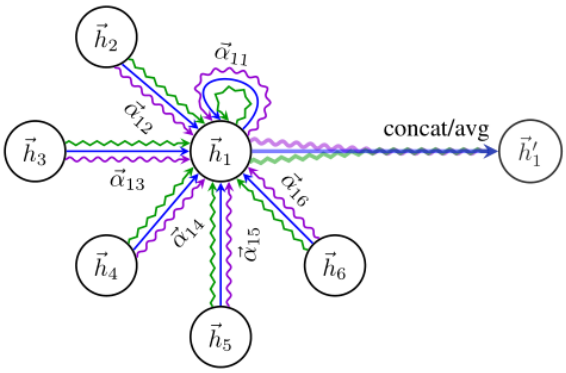

图 3-6 GAT 第二步运算图示

具体数学表达形式如公式(3-17)所示。

$$\tilde{h}_i^{'}=\sigma(\sum_{j\in Neighbor_i}\alpha_{ij}W\tilde{h}_j) \tag{3-17}$$

另外，为了学习到不同注意力空间中的特征表达，使每个单词节点能够更充分地学习到其与邻居节点之间相关特征，本文采用多头注意力机制的形式代替普通注意力机制。如公式(3-18)所示。

$$\tilde{h}_i^{'}(K)=||_{k=1}^{K}\sigma(\sum_{j\in Neighbor_i}\alpha_{ij}^{k}W^{k}\tilde{h}_j) \tag{3-18}$$

公式(3-18)中α_{ij}^{k}为第k个归一化的注意力权重，W^{k}为多头注意力中第k个头的可训练参数，K为多头注意力中头的个数。

3.4.2 意图-插槽联合交互方法

本文使用单向 LSTM 网络对意图融合编码器的输出进行解码，并通过两层图注意力层对意图信息进行融合。在每个时间步下，解码器隐藏状态s_t由前一时间步解码器隐藏状态s_{t-1}，前一时间步的插槽标签分布y_{t-1}^{S}和意图融合编码器的输出o_t计算得到，具体计算过程如公式(3-19)所示。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$s_t=\mathrm{LSTM}(s_{t-1},y_{t-1}^{S},o_t) \tag{3-19}$$

受到图注意力网络的启发，在意图和插槽之间进行交互的过程中，意图和指令序列的插槽均作为 GAT 中的节点，且意图节点作为所有插槽节点的邻居节点。意图-插槽联合交互方法将意图预测索引I和解码器的隐藏状态输出s_t同时输入图注意力网络中，从而显式地利用意图信息来指导对应时刻下插槽标签的预测，用来计算初始特征表示$\widetilde{H}^{[0,t]}=\{s_t,\Phi^{emb}(I)\}\in R^{2\times d}$，其中 $\Phi^{emb}(\cdot)$表示意图的嵌入矩阵。

在意图-插槽联合交互方法中，使用$\tilde{h}_i^{[l,t]}$作为图中第l层中节点i的特征表示，该层的节点由在t时刻的解码器隐藏状态向量和预测的意图嵌入向量组成，$\tilde{h}_0^{[l,t]}$为第l层中的插槽隐藏状态表示。为了显式地利用意图信息，图注意力网络将插槽隐藏状态向量直接与预测的意图向量相连接，第l层中的槽节点表示计算过程如公式(3-20)所示。

$$\tilde{h}_i^{[l,t]}=\sigma(\sum_{j\in Neighbor_i}\alpha_{ij}^{[l,t]}W_h^{[l]}\tilde{h}_i^{[l-1,t]}) \tag{3-20}$$

此时$Neighbor_i$代表解码器隐藏状态节点和预测的意图节点，并且所有节点的更新均可以通过 3.4.1 节图注意力网络中的参数运算公式进行计算得到。

通过两层的意图-槽图注意力交互后，模型在t时刻下得到的最终插槽隐藏状态可表示为$\tilde{h}_0^{[L,t]}$，它在单词级别下捕获相应的意图信息。最后将$\tilde{h}_0^{[L,t]}$用于槽填充任务中，如公式(3-21)所示。

$$y_t^{S}=argmax(softmax(W_s\tilde{h}_0^{[L,t]})) \tag{3-21}$$

公式(3-21)中，y_t^{S}是指令中预测得到的第t个单词的插槽标签。

3.5 本章小结

考虑到传统的意图-插槽联合建模方式存在对指令特征提取能力不足、泛化性能较弱和误差较大的问题，本章提出了一种端到端的基于多编码器的联合意图检测和槽填充特征融合模型。该模型使用深度学习方法，通过多个编码器的方式同时提取不同意图指令中的共享特征和私有特征并融合，然后通过提出的基于图注意力网络的联合交互方法完成意图和插槽信息的交互，依此来提高端到端网络模型的性能，进而更好地完成意图检测和槽填充任务。通过增强指令的特征表达能力和两个任务之间的交互性能，模型能够获得更强的性能、可解释性和泛化能力。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第 4 章 行为动作序列解析方法研究

服务机器人的导航推理能力是影响 HRI 表现的关键因素。近年来，为了能够使人和机器人之间的交互变得更加自然，服务机器人导航问题的研究也逐渐从基于约束性指令的导航转变为基于自然语言指令的导航。而传统的流水线建模方式存在不可避免的误差传播问题，且映射过程不完善，会出现由于指令描述不一致导致的指令与行为动作序列之间的映射关系不一致的问题。随着深度学习的发展，使用端到端的神经网络建模方式受到了大量关注，这种建模方式能够提高了指令解析能力，减小误差传播，解决流水线模型存在的问题。但由于端到端模型的中间过程不可控，自然语言指令解析效果仍然有待提升。

为解决上述问题，本章从解决指令和行为动作序列之间的对齐问题入手，应用端到端的建模方式，提出了基于深度学习的地图-指令双向注意力交互模型，对模型中的双向注意力交互模块进行了详细介绍，并深入分析了模型的有效性。

4.1 地图-指令双向注意力交互模型

在实际应用场景下，人们对同一导航指令的描述会由于参照物的不同而有所不同，如指令“走到走廊尽头右转进入房间”和指令“沿着走廊直走，到第一幅挂画处右转进入房间”，两个指令虽然所描述的目标位置和其对应的行为动作均相同，但由于指令的描述方式不同会导致每个指令块中所包含的行为动作数量不同，这是由自然语言的特性所决定的。

因此，自然语言指令和行为动作序列之间对齐关系的准确映射是使得机器人能够与人类自然交互的关键，也是服务机器人能够准确执行移动操作的必要前提。鉴于此，本文提出了基于深度学习的地图-指令双向注意力交互模型，该模型将自然语言指令和行为动作序列进行端到端的映射，旨在解决传统的非端到端模型出现的自然语言指令和行为动作序列之间映射不一致和误差传播的问题。

4.1.1 模型概述

地图-指令双向注意力交互模型基于 Seq2Seq 模型搭建，由于模型的输入为自然语言指令序列，输出为行为动作序列，因此其仍属于神经网络机器翻译模型的范畴。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

但与语言到语言的机器翻译模型不同，指令和行为动作序列之间的映射关系常常是不确定的，对齐规则难以学习。考虑到这个原因，本文将地图信息进行了适当的表示作为神经网络模型的输入，使得模型在映射到行为动作序列的过程中能够考虑机器人所处环境的信息，将地图中的信息作为知识库在指令映射过程中进行查询。

地图信息的融入使得模型在映射过程中不仅仅参考指令本身到动作序列的对齐关系，还会参考机器人所处环境信息。这样的模型具备更强的映射关系学习能力，更符合人类在接收到一条命令后的执行方式。地图-指令双向注意力交互模型算法整体结构如图 4-1 所示。

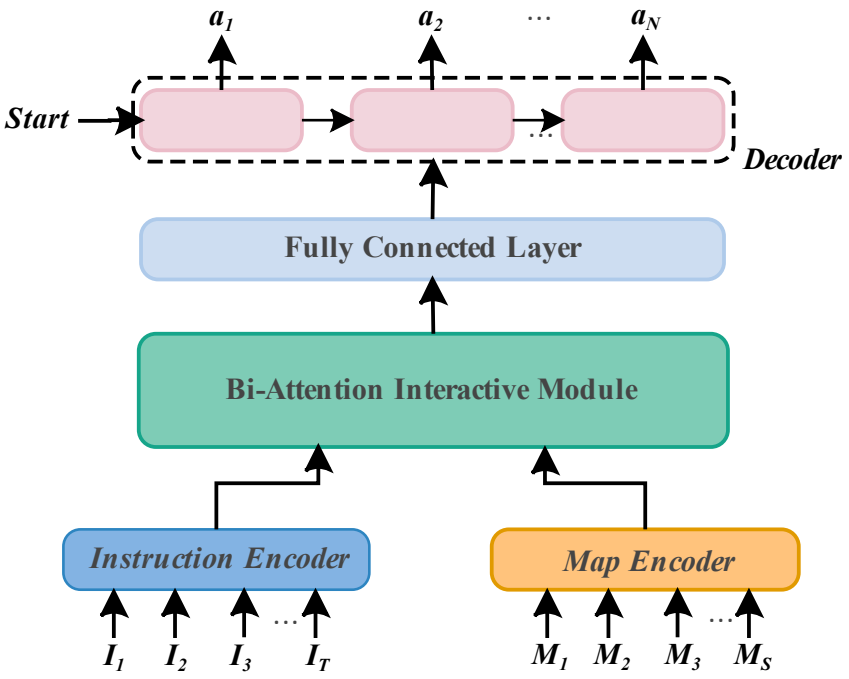

图 4-1 地图-指令双向注意力交互模型

地图-指令双向注意力交互模型基于 Seq2Seq 模型搭建，整体为编码器-解码器结构，为了使模型能够更好地实现指令到行为动作之间的映射，本文提出了双向注意力交互模块(Bi-Attention Interactive Module)来融合机器人所在的环境信息特征，帮助模型完成映射关系的学习。模型整体结构分为输入层、地图-指令编码层、双向注意力交互层、全连接层、解码层、输出层 6 个部分。

(1) 输入层：输入层将地图转换为嵌入表示作为地图编码器的输入，自然语言指令的嵌入表示作为指令编码器的输入。

(2) 地图-指令编码层：地图-指令编码层由 2 个编码器组成，分别为指令编码器和地图编码器，二者均为 LSTM 结构，分别接收指令信息和地图信息，并将其编码

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

为上下文特征表示作为输出。

(3) 双向注意力交互层：双向注意力交互层由两层注意力层构成，第一层注意力层对指令中每个单词与整个地图之间计算权重并计算得到指令的加权特征；第二层注意力层对地图中的每个部分与整个指令序列中单词之间计算权重并计算得到地图的加权特征，两层之间串行连接。

(4) 全连接层：全连接层对特征维度进行压缩，得到最终的融合特征表示。

(5) 解码层：解码层由单向 LSTM 网络构成，在解码阶段的每个时刻，解码器均以全连接层的输出和上一时刻的输出作为解码器的输入，将特征解码为行为动作序列，直至生成停止标识。

(6) 输出层：输出层考虑服务机器人的初始位置和地图的连通性等信息得到最终的行为动作序列。

4.1.2 模型训练及验证过程

在本文提出的地图-指令双向注意力交互模型中，地图信息被表示为(位置节点，行为动作，位置节点)三元组的形式，自然语言指令使用词嵌入向量表示，并将二者作为模型的输入。模型具体训练及验证过程如下。

(1) 将训练集D_{train}中的地图信息和自然语言指令信息转换为嵌入表示；

(2) 将地图信息和自然语言指令和的嵌入表示分别作为指令编码器和地图编码器的输入，经双向 LSTM 网络编码后得到带有上下文信息的指令特征和带有行为动作信息的地图特征；

(3) 将编码器输出特征通过双向注意力交互模块进行交互，使得两种特征信息能够相互融合，得到融合后的特征并将其作为编码器最终隐藏状态向量输出；

(4) 交互模块的输出特征作为全连接层的输入，进行降维操作，得到最终的上下文特征向量；

(5) 上下文特征作为模型解码器的输入，在每个时刻都由上一时刻的行为动作和上下文特征共同决定当前时刻的输出，获得完整的行为动作序列，并与真实序列计算损失值，反向传播更新端到端网络模型的参数；

(6) 使用验证集D_{valid}验证模型性能，最终的模型的选取标准为在验证集上表现最优的模型，并在测试集上进行测试。

模型同时将自然语言导航指令和地图环境信息作为输入，将指令转换为基于地

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

图环境的行为动作序列。如图 4-2 所示，更直观地表现模型具体训练及验证过程。在训练过程中，模型由本文提出的双向注意力交互模块融合地图和指令信息。

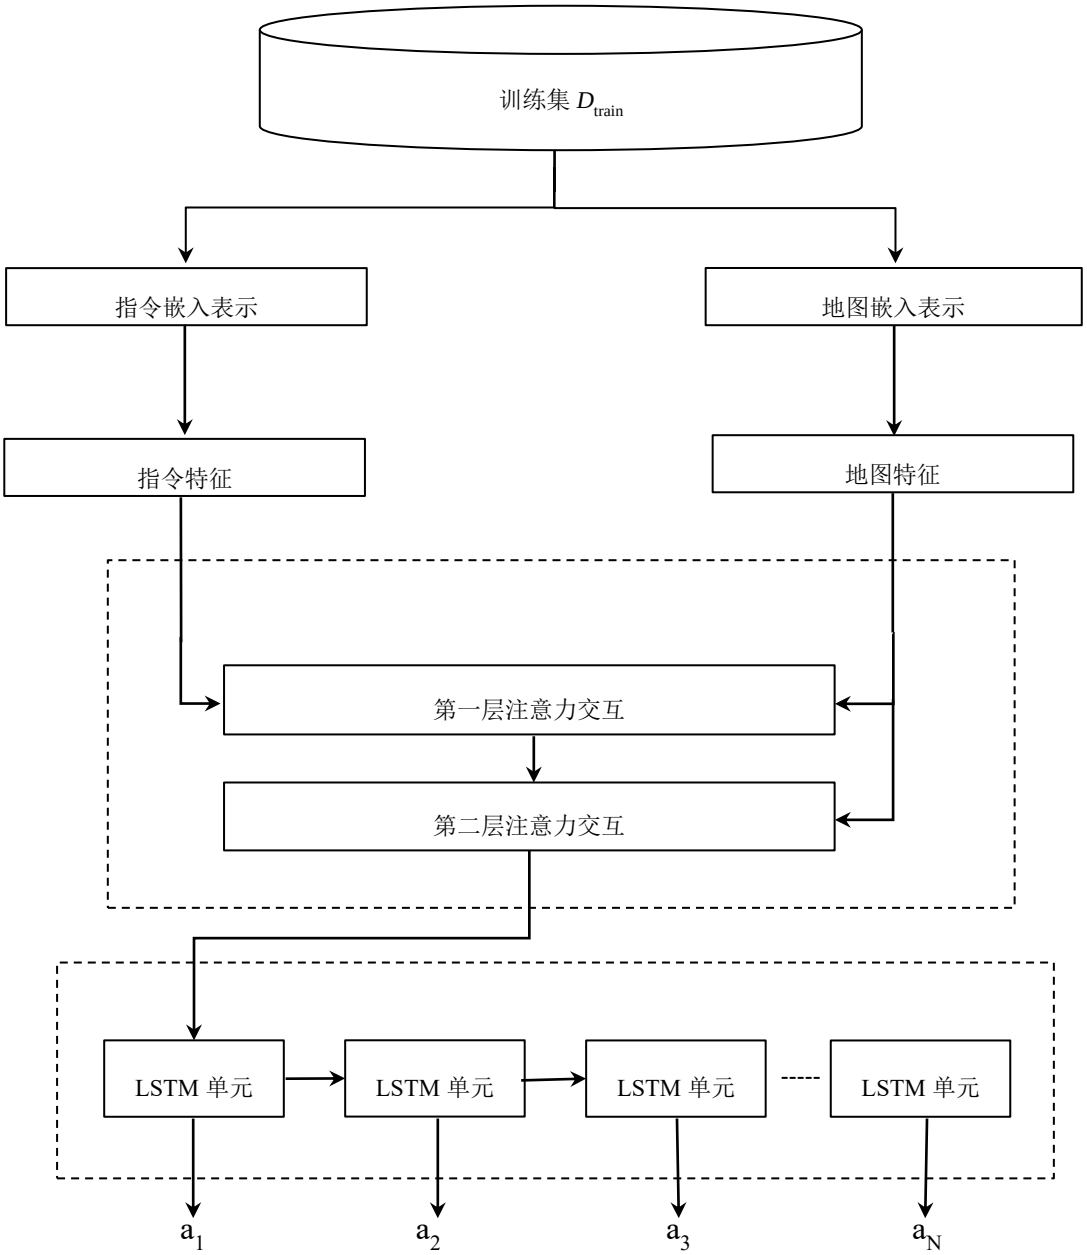

图 4-2 模型训练过程图示

4.2 数据表示方法

在本文提出的模型中，使用自然语言指令作为原始输入，并辅以地图信息输入网络模型中，因此，指令和地图信息的表示形式是至关重要的一个环节，会对端到端网络模型的结果产生很大的影响，尤其是地图信息的表示方法直接影响了最终动作序

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

列的输出准确度。鉴于此，本节对地图数据的表示方法、自然语言指令的表示方法和二者经双向注意力交互后的特征表示进行了详细说明。

4.2.1 地图数据的表示

为了使服务机器人能够准确、自然地将人类发出的自然语言指令转换为机器人可理解的行为动作完成导航任务，并在此期间能够充分地考虑所处环境中的语义特征，需要对整个环境信息进行建模并合理表示。因此，本文采用 Sepúlveda 提出的行为导航图对机器人所处环境进行表示[45]。

行为导航图的表示将地图环境中的关键位置、地标信息以及进行位置之间的移动时所包含的动作融入其中，不仅能够充分利用环境中丰富的语义信息和结构，而且能够学习到位置之间移动时所需要的动作信息。将地图环境转换为行为导航图使得服务机器人不易受到环境中的噪声干扰，增强其导航性能并提高指令和动作序列之间的映射能力。

(1) 地图的转换与规则

为了使地图信息能能够作为额外的先验知识输入到网络模型中，本文将地图表示为行为导航图。行为导航图本质上为一个有向图，在地图环境中，卧室、厨房等房间信息被映射为行为导航图中的节点，房间之间的移动行为被映射为行为导航图中的边。

在实际的导航环境中，通常还会存在如书架、花盆、床、沙发等标志性物体，由于这些标志性物体同样会在自然语言指令中被描述，被人们用于服务机器人导航动作的解析，因此行为导航图中也保存了这些标志性物体的信息。它们由行为导航图中的边进行描述，边中包含了执行该动作会遇到的所有标志性物体。整个地图环境由<*node*,*edge*[*landmarks*],*node*>三元组集合组成，其具体映射关系及地图表示如公式(4-1)所示。

$$\begin{gathered} room \xrightarrow{mapping} node \\ behavior \xrightarrow{mapping} edge \\ maps=\mathrm{set}(<node,edge[landmarks],node>) \end{gathered} \tag{4-1}$$

在行为导航图中，节点表示机器人在导航过程中可以到达的位置，节点之间的边是有向的，每条有向边代表在其连接的两个节点之间移动所需要的行为动作，该行为动作是经过参数化表示简化的行为动作。最终的目标行为动作序列是这样的一组行

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

为动作，能够使机器人从起始节点到达自然语言指令所描述的终点位置。通过三元组对地图进行表示的方法将行为动作信息融合进地图中，使得服务机器人在进行导航时可以充分参考地图中的位置信息和动作信息，从而获得更强的解释指令的能力，也能够应对自然语言指令描述与行为动作序列映射不一致的问题。另外，使用三元组的形式对地图进行表示可以使机器人获得更加复杂的导航行为能力。如图 4-3 和图 4-4 展示了环境地图到行为导航图的映射关系，图 4-3 为原始地图环境，图 4-4 为原始地图环境映射为通过拓扑图表示的行为导航图后的地图环境。

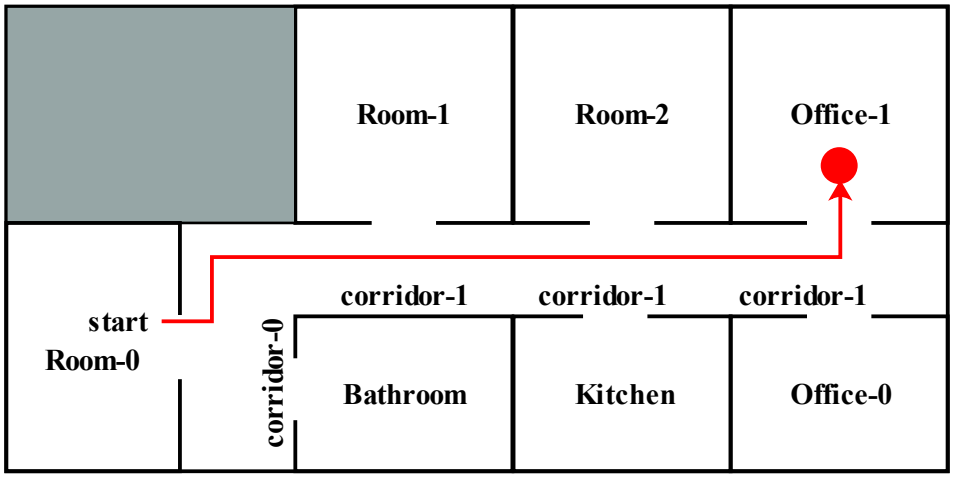

图 4-3 室内环境地图

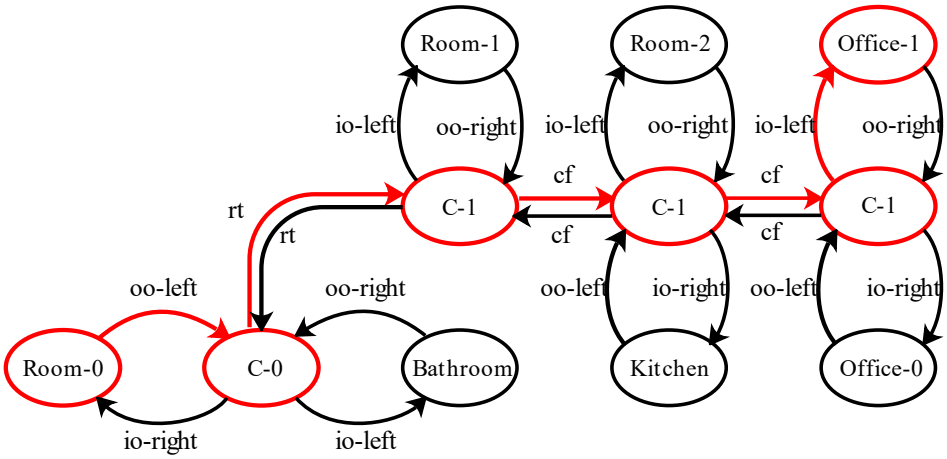

图 4-4 行为导航图

图 4-3 描述了服务机器人的所处环境及其所要执行的导航任务，图中红色路径表示具体的导航路径，图 4-4 中的红色路径描述了从真实环境中到行为导航图映射后所要经过的房间及具体执行动作，具体为：Room-0，oo-left，rt，cf，cf，io-left，Office-1。地图环境的拓扑表示将复杂的真实环境中不确定的动作进行转化，变为仅通过行为动作的排序实现起点到目标点的导航。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

在本文中，服务机器人在室内地图环境中的导航行为动作命令共有 7 种类型，共包含 11 种行为动作，具体如表 4-1 所示。

表 4-1 服务机器人导航行为动作类型

动作类型	具体值
oo<d>	oo-left, oo-right
io<d>	io-left, io-right
oio	oio
<d>t	left-t, right-t
cf	cf
sp	sp
ch<d>	ch-left, ch-right

机器人的行为动作包含了在室内环境中所有的常见行为，动作类型的具体含义如下：

oo<d>：离开当前位置，并转向<d>方向，<d>为 left 或 right；

io<d>：转向<d>方向，并进入该方向上的下一个位置，<d>为 left 或 right；

oio：离开当前位置，不变换方向并直接进入下一个位置；

<d>t：在交点处转向<d>方向，<d>为 left 或 right；

cf：沿走廊直行；

sp：在 T 字形交叉点处直行；

ch<d>：穿过大厅，并转向<d>方向，<d>为 left 或 right。

通过地图环境的转换，行为导航图中既可以包含机器人在节点之间移动所需的动作信息，又可以包含环境中房间之间的位置关系信息以及环境中标志性物体的位置信息，从而使模型能够通过拓扑结构表示地图信息辅助完成指令到行为动作之间的映射任务。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

(2) 地图的特征表示

在将地图环境依照特定规则转换为行为导航图后，必须要将地图信息转换为能够输入到神经网络中的形式，才能对指令的映射进行辅助。考虑到地图信息中各个房间的位置之间的关系以及行为动作的合理性，且地图由三元组集合组成，不同的排序对指令在映射为导航行为动作序列的过程中会存在一定的影响，因此，本文将地图信息作为序列信息进行描述，从而保留地图中的位置信息特征。

对于行为导航图中的每个三元组<*node*,*edge*[*landmarks*],*node*>，其包含了服务机器人可到达的位置信息、位置之间导航的行为动作以及标志性物品信息。其中位置信息的类型数量之和为N，动作和标志性物品类型数量之和为E。本文为这些信息分别创建了两个字典，两个字典分别存储了可到达的位置信息和行为动作信息(包含标志性物品)。

另外，考虑到行为导航图的有向性，因此本文使用独热编码(One-Hot Encoding)对图中的节点和边进行描述，因此对于图中每个三元组，其维度为2N+E。对于每一个地图环境M，可以由公式(4-2)进行描述。

$$M=\{M_1,M_2,M_3,\ldots,M_S\} \tag{4-2}$$

公式(4-2)中，M中的每个元素为图中的节点或边，且$M\in R^{S\times(2N+E)}$；S为环境中的三元组<*node*,*edge*[*landmarks*],*node*>的总和。

地图-指令双向注意力交互模型使用双向 LSTM 网络作为地图编码器的结构独立地为地图信息进行编码，并提取地图中的特征和上下文信息。最后使用双向 LSTM 网络中所有时刻的隐藏状态输出作为最终的地图特征。具体表示如公式(4-3)和公式(4-4)所示。

$$\overline{M}_t=\mathrm{BiLSTM}_M(M_t) \tag{4-3}$$

$$\overline{M}=\{\overline{M}_1,\overline{M}_2,\overline{M}_3,\ldots,\overline{M}_S\} \tag{4-4}$$

公式(4-3)中$\overline{M}_t$为地图编码器在t时刻下的隐藏状态输出；公式(4-4)中$\overline{M}$为完整地图信息的特征表示，且$\overline{M}\in R^{S\times 2H}$，H为地图编码器的 LSTM 单元个数。

最后，$\overline{M}$作为地图编码器的最终输出执行后续操作。

4.2.2 自然语言指令的表示

由于自然语言指令本身的序列特性以及指令中存在的上下文信息，本文仍采取

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

词嵌入的形式对指令进行表示。考虑到本文所使用数据集的大小，可能会导致指令中的单词语义信息表达能力不够强，因此，模型采用预训练的 GloVe 词嵌入来表达指令中的单词语义特征。

GloVe 是一种基于全局词频统计的单词表征工具，它通过大型语料库构建共现矩阵，并依此计算与词向量之间的近似关系，使得词向量能够捕捉到单词之间的相似性等复杂特征[46]，对端到端网络模型的性能有较大的提升。在地图-指令双向注意力交互模型中，使用维度大小为 100 的 GloVe 词向量表达指令单词特征信息。

在本文中，对于每一个自然语言指令单词序列$I=(I_1,I_2,\ldots,I_T)$，首先根据 GloVe 的词典将指令序列中的单词转换为索引形式，接着根据单词索引在 GloVe 词嵌入矩阵中查找对应的词向量，将指令转换为其词嵌入表示形式，如公式(4-5)和公式(4-6)所示。

$$E_t=\mathrm{GloVe}_{\mathrm{emb}}(I_t) \tag{4-5}$$

$$E=(E_1,E_2,E_3,\ldots,E_T) \tag{4-6}$$

公式(4-6)中$E\in \mathrm{R}^{T\times d}$，指令中每个单词均表示为维度为$d$=100的 GloVe 词向量，T 为训练时每批次数据指令序列的最大长度。

与地图编码器相同，地图-指令双向注意力交互模型使用双向 LSTM 网络作为指令编码器的结构单独为自然语言指令信息进行编码，用于提取指令中的上下文语义信息。最后使用双向 LSTM 网络中所有时刻的隐藏状态输出作为最终的指令特征。具体表示如公式(4-7)和公式(4-8)所示。

$$\bar{I}_t=\mathrm{BiLSTM}_{\mathrm{I}}(E_t) \tag{4-7}$$

$$\bar{I}=\{\bar{I}_1,\bar{I}_2,\bar{I}_3,\ldots,\bar{I}_T\} \tag{4-8}$$

公式(4-7)中，$\bar{I}_t$为指令编码器在t时刻下的隐藏状态输出；公式(4-8)中$\bar{I}$为完整指令序列上下文语义特征表示；$\bar{I}\in \mathrm{R}^{T\times 2H}$，H为指令编码器的 LSTM 单元个数。

最后，$\bar{I}$作为指令编码器的最终输出与地图特征$\bar{M}$进行特征的交互。

4.3 地图-指令双向交互算法

为了使端到端网络模型在进行映射过程中能够充分参考地图中的重要特征信息来辅助映射过程，并且获取更充分的融合特征表示，本文提出了地图-指令双向交互算法。该算法不仅计算指令特征相对于地图特征的影响权重，还计算地图特征相对于

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

指令特征的影响权重。通过这样的方式从两个方向考虑地图和指令中较高关注权重的特征信息，依此获得更好的融合特征。

地图-指令双向交互算法由两层注意力机制组成，注意力机制采用目前研究和应用领域使用更广泛的软注意力机制(Soft Attention)，其中第一层注意力交互层通过整个指令序列计算其与行为导航图中的每个三元组之间的相关性；第二层注意力交互层通过整个地图特征计算其与指令中每个单词之间的相关性，最终获得融合了指令特征和地图特征的融合特征。

(1) 第一层注意力交互层

为了了解模型在解析指令每个单词的过程中更关注地图中的哪些位置，模型通过第一层注意力交互层计算构成行为导航图的所有三元组与指令中每个单词之间的相关性。第一层注意力交互层如图 4-5 所示。

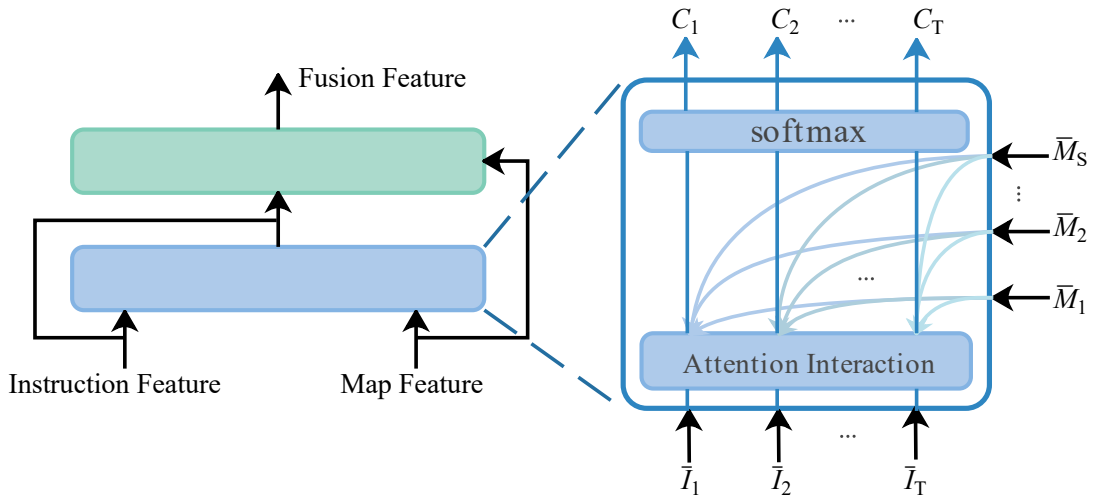

图 4-5 第一层注意力交互层

得到的相关性系数通过归一化操作后得到最终的注意力权重。具体计算过程如公式(4-9)和公式(4-10)所示。

$$e_i=[\bar{I}_i W\bar{M}_1^T,\bar{I}_i W\bar{M}_2^T,\ldots,\bar{I}_i W\bar{M}_S^T] \tag{4-9}$$

$$\alpha_i=softmax(e_i) \tag{4-10}$$

对于指令中的每个单词特征$\bar{I}_i$，均通过注意力机制计算其与地图三元组之间的相似度e_i，公式(4-9)中$e_i\in R^S$，W为注意力层中的可训练参数矩阵，其维度为$R^{2H\times 2H}$。公式(4-10)中的α_i为经过 *softmax* 归一化后的注意力权重。

接着通过将注意力权重向量与地图特征进行点积得到带有地图注意力的指令特

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

征。计算过程如公式(4-11)和公式(4-12)所示。

$$C_i=\sum_{j=1}^{S}\alpha_{ji}\bar{M}_j \tag{4-11}$$

$$C=(C_1,C_2,C_3,\ldots,C_T) \tag{4-12}$$

公式(4-11)中α_{ji}表示地图中第j个三元组特征与指令中单词i之间的注意力权重，$C\in R^{T\times 2H}$。

最后，为了增强原本指令特征中的上下文语义信息并防止模型退化，本文将带有地图注意力的指令特征与原始指令特征进行拼接，并经过全连接层线性变换为原指令特征维度，作为第一层注意力交互层的输出，将其输入至第二层注意力交互层。具体计算过程如公式(4-13)和公式(4-14)所示。

$$F_i=[C_i\|\bar{I}_i] \tag{4-13}$$

$$\bar{F}_i=W_1F_i+b_1 \tag{4-14}$$

公式(4-13)中，F_i为带有地图信息与指令信息的融合指令特征，其维度为4H；公式(4-14)中$\bar{F}_i$为经过线性变换后的融合指令特征，其维度为2H。

(2) 第二层注意力交互层

同样地，为了进一步地得到服务机器人在地图中的位置和指令中每个单词之间的相关性程度，模型通过第二层注意力交互层计算第一层的融合指令特征与行为导航图中每个三元组之间的相关性。第二层注意力交互层如图 4-6 所示。

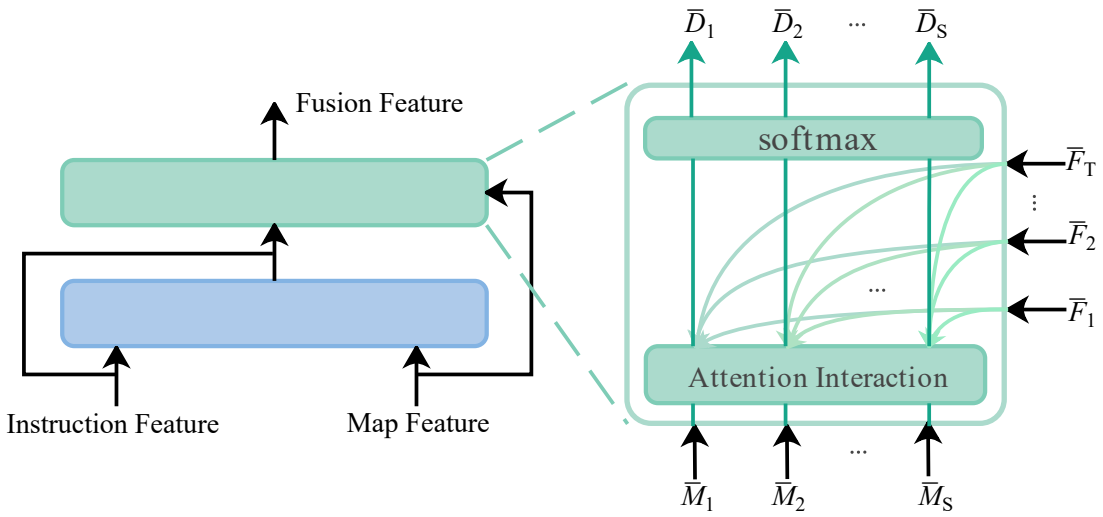

图 4-6 第二层注意力交互层

得到的相关性系数通过归一化操作后得到最终的注意力权重。具体计算过程如

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

公式(4-15)和公式(4-16)所示。

$$\bar{e}_{\mathrm{j}}=[\bar{M}_{\mathrm{j}}W'\bar{F}_{1}^{\mathrm{T}},\bar{M}_{\mathrm{j}}W'\bar{F}_{2}^{\mathrm{T}},\ldots,\bar{M}_{\mathrm{j}}W'\bar{F}_{\mathrm{T}}^{\mathrm{T}}] \tag{4-15}$$

$$\bar{\alpha}_{\mathrm{j}}=softmax(\bar{e}_{\mathrm{j}}) \tag{4-16}$$

公式(4-15)中$\bar{e}_{\mathrm{j}}\in\mathrm{R}^{\mathrm{T}}$，$W'$为注意力层中的可训练参数矩阵，其维度为$\mathrm{R}^{2\mathrm{H}\times2\mathrm{H}}$。公式(4-16)中$\bar{\alpha}_{\mathrm{j}}$为经过 *softmax* 归一化后的注意力权重。

接着通过将注意力权重向量与自然语言指令上下文语义特征表示进行点积得到带有指令注意力的融合特征表示。为了降低注意力所导致的地图信息遗忘，本文将其与地图特征进行拼接后得到双向注意力交互层的最终融合特征输出，最后输入到全连接层中，对特征进行降维。计算过程如公式(4-17)、公式(4-18)和公式(4-19)所示。

$$D_{\mathrm{j}}=\sum_{\mathrm{i}=1}^{\mathrm{L}}\bar{\alpha}_{\mathrm{ji}}\bar{F}_{\mathrm{i}} \tag{4-17}$$

$$B_{\mathrm{j}}=\left[D_{\mathrm{j}}\|\bar{M}_{\mathrm{j}}\right] \tag{4-18}$$

$$\bar{B}_{\mathrm{j}}=W_2B_{\mathrm{j}}+b_2 \tag{4-19}$$

公式(4-17)中$\bar{\alpha}_{\mathrm{ji}}$表示地图中第j个三元组特征与指令中单词i之间的注意力权重，$D_{\mathrm{j}}\in\mathrm{R}^{2\mathrm{H}}$。公式(4-19)中$\bar{B}_{\mathrm{j}}$为解码器的最终输输入，其维度为H。

4.4 行为动作序列提取

地图-指令双向注意力交互模型使用单向 LSTM 网络作为解码器的结构，对双向注意力交互层的输出特征进行解码。在解码阶段的t时刻下，LSTM 单元将上一时刻的解码器隐藏状态和上一时刻下的行为动作预测输出作为输入，得到t时刻下的隐藏状态输出。

在t时刻下，隐藏状态用于与通过全连接层降维后的融合特征进行交互计算，以此将自然语言指令特征和地图特征融入每个解码过程中。此外，为了考虑不同时刻下解码过程中对指令特征和地图特征关注程度的差异，本文使用注意力机制计算每个时刻下对于融合特征矩阵的注意力权重，具体计算过程如公式(4-20)和公式(4-21)所示。

$$\hat{d}_{\mathrm{ti}}=v_a^{\mathrm{T}}tanh(W_1h_{\mathrm{t}}+W_2\bar{B}_{\mathrm{i}}) \tag{4-20}$$

$$d_{\mathrm{t}}=softmax\left(\hat{d}_{\mathrm{t1}},\ldots,\hat{d}_{\mathrm{tS}}\right) \tag{4-21}$$

公式(4-20)中$\bar{B}_{\mathrm{i}}$是融合特征矩阵中的列，i∈[1,S]；公式(4-21)中d_{t}为在t时刻下对

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

融合特征矩阵的注意力权重。通过在每个时刻的解码过程中使用注意力机制，动态地考虑了整个指令和地图信息的相关关系。

接着，计算融合特征矩阵的加权和，并与 LSTM 解码时的隐藏状态进行拼接，最终得到用于计算机器人行为动作的特征向量。计算过程如公式(4-22)和公式(4-23)所示。

$$Z_t=\sum_{i=1}^{S} d_{ti}\overline{B}_i \tag{4-22}$$

$$o_t=W_3[Z_t;h_t] \tag{4-23}$$

公式(4-22)中Z_t为融合特征矩阵的加权和，W_3为参数矩阵，公式(4-23)中o_t为用于预测t时刻下行为动作的特征向量。

最后，通过o_t作为特征向量预测下一步行为动作。如公式(4-24)所示。

$$b_t=argmax(\,softmax\,(o_t)\,) \tag{4-24}$$

公式(4-24)中b_t是解码器在t时刻下预测的行为动作输出。最终以停止标志作为行为动作序列结束的标志，获得完整的行为动作序列。

4.5 本章小结

考虑到传统流水线形式建模的行为动作提取方法面对指令描述的不一致时会出现映射关系不准确的问题，本章应用端到端的建模方式，提出了一种基于深度学习的地图-指令双向注意力交互模型。该模型通过双向注意力交互模块对分别提取指令对地图的相关性特征和地图对指令的相关性特征并融合，使模型能够在生成行为动作序列时能够更充分地考虑地图特征和指令特征，然后通过解码阶段对特征矩阵进行权重计算辅助完成行为动作序列解析过程。通过增强指令特征和地图特征之间的交互，模型能够具备更强的特征表达能力和对齐能力。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第 5 章 实验验证及分析

为了验证第 3 章和第 4 章所提出两个神经网络模型及其算法的有效性，本章通过实验进行了验证，并对实验所使用的数据集、评价指标、对比模型进行了介绍。针对第 3 章提出的联合意图检测和槽填充特征融合模型，本文验证了模型的多编码器结构能够更有效地提取指令的语义特征，且意图-插槽图注意力交互方法能够增强任务性能，并证明了模型具有一定的泛化能力。

针对第 4 章提出的地图-指令双向注意力交互模型，本文验证了双向注意力交互模块的有效性，证明了该模型能够在一定程度上缓解映射不一致的问题，并通过实验结果进行了分析。

5.1 联合意图检测和槽填充特征融合模型实验及分析

5.1.1 实验数据集

为了充分评估模型的性能，本文在 ATIS 和 SNIPS 两个公开数据集上进行了实验和分析，两个数据集的详细信息如表 5-1 所示。

表 5-1 SNIPS 和 ATIS 数据集详细信息

	SNIPS 数据集	ATIS 数据集
词典大小	11241	722
训练集样本数	13084	4478
验证集样本数	700	500
测试集样本数	700	893
插槽数量	72	120
意图数量	7	21

SNIPS 数据集: SNIPS 数据集由来自 snips.ai 的 Coucke 等人收集并创建[47]。它属于个人语音助理命令的领域。与 ATIS 语料库相比，它在词汇量以及意图和插槽的多

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

样性方面更为复杂。该数据集的训练集中有 1,3084 个语句，验证集集中有 700 个语句，测试集中有 700 个语句。整个数据集包含有 72 种插槽标签和 7 个意图类别。意图和插槽的多样性是 SNIPS 数据集的特点。ATIS 中的意图全部与航班信息有关，而 SNIPS 数据集中包含诸如 RateBook 和 PlayMusic 等意图，它们属于完全不同的意图。Goo 等人[15]是该数据集的首次使用者。

ATIS 数据集: ATIS 数据集是由 Hemphill，Godfrey 和 Doddington 创建的航空公司旅行信息系统数据集，该数据集长期以来一直被广泛应用于 SLU 领域的研究[48]。整个数据集的数据均由航空公司航班预订录音组成。其中，训练集包含 4 478 条指令语句，验证集中包含 500 条指令语句，测试集中包含 893 条指令语句。整个数据集包含 120 种插槽标签和 21 个意图类别。

5.1.2 评价指标

为了充分评估模型的性能，本文通过 3 个评估指标对联合意图检测和槽填充特征融合模型进行评价。

(1) 意图检测

本文使用分类准确率来评估模型意图检测任务的性能。在 ATIS 数据集中，有些句子具有多个意图标签，在本文实验中，当所有意图标签全部预测正确时，才将该句子的意图分类结果视为正确。

(2) 槽填充

本文使用 F1 分数来评估模型槽填充任务的性能。F1 分数被定义为精确率和召回率的调和平均值，其能够对模型性能进行综合评价。F1 分数计算如公式(5-1)所示。

$$\mathrm{F1}=\frac{2\times Precision\times Recall}{Precision+Recall} \tag{5-1}$$

公式(5-1)中*Precision*为精确率，*Recall*为召回率。

另外，模型使用句子级别准确率来充分考虑意图检测和槽填充任务的联合性能。当意图检测分类和整个语句所有槽标签全部预测正确时，则将该句子视为预测正确。

5.1.3 实验设计

本文实验在 ATIS 和 SNIPS 数据集下采用相同的参数设置，特征融合编码器中公共编码器和私有编码器的隐藏单元数均为 256。同时，为缓解过拟合现象，模型设

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

置了 L2 正则化参数和 dropout 技术对特征向量进行正则化处理。本文使用 Adam 作为模型的优化器来对模型中的参数进行优化，优化器全部采用默认的超参数，另外，为了更好地控制模型的训练过程，本文设置了早停止参数，规定模型在 30 次迭代内无提升则停止模型训练[49]。在 ATIS 和 SNIPS 数据集下，图注意力层数均为 2。对于所有实验，本文选择在验证集上效果最好的模型，然后在测试集上对其进行评估。

为了充分评估本文提出的联合意图检测和槽填充特征融合模型的性能，本文设计了两组对比实验，实验 1 对模型的意图检测和槽填充性能表现和提出的意图-插槽交互方法进行分析，并将模型与以下端到端基线模型进行了对比实验。

(1) Atten BiRNN 模型

Atten BiRNN 模型由刘冰等人提出，该模型是基于注意力机制的 SF 和 ID 双向 RNN 联合模型，并隐式地对意图和插槽之间的关系进行了建模。

(2) CAPSULE-NLU 模型

CAPSULE-NLU 模型是一种基于胶囊神经网络的模型，该模型通过动态路由协议机制来完成意图检测和槽填充，并提出了一个重路由方案使预测得到的意图进一步提高槽填充的性能。

(3) Joint Multiple ID-SF 模型

Joint Multiple ID-SF 模型由 Gangadharaiah 等人提出，该模型是一个多任务框架，该框架具有用于多个意图检测和槽填充的插槽门控机制。

(4) Slot-Gated 模型

Slot-Gated 模型由郭志文等人提出，该模型显式地对槽填充和意图检测之间的相关性进行了建模，显著提高了模型的表现。

(5) SF-ID 模型

SF-ID 模型由鄂海红等人提出，该模型能够建立意图和插槽之间双向关联关系的 SF-ID 网络，网络中的迭代机制可以使意图检测和槽填充互相促进彼此的性能。

另外，为了验证模型中所提出算法的有效性和模型所具备的泛化性能，本文设置了实验 2。实验 2 将原模型中的多编码器结构改为单编码器结构，单编码器模型为原模型的消融模型，因此没有特征融合模块，并在零样本场景下对原模型和消融模型在 SNIPS 数据集上的槽填充指标进行了评估，以验证模型的泛化能力。本文在 SNIPS 数据集的 7 个不同意图数据上分别进行了实验，每次实验均取出一个意图数据作为验证集和测试集，即目标域；其余 6 个意图的数据作为训练集，即源域。依此来验证

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

算法的有效性。对于目标域数据，实验时在训练集中移除目标域数据，保留源域数据；在验证集和测试集中保留目标域数据，移除源域数据。

5.1.4 实验结果及分析

如表 5-2 和表 5-3 所示，在 SNIPS 数据集和 ATIS 数据集上，本文提出的联合意图检测和槽填充特征融合模型取得了可观的提升。具体来说，在 ATIS 数据集上，对于槽填充任务，本文模型的 F1 分数达到 95.6%，与 SF-ID 模型的槽填充任务性能持平，且与其他基线模型相比有了较高的提升。对于意图检测任务，模型比最佳准确率提高了 1%，在句子级别准确率上相比最高模型提高了 0.6%；在 SNIPS 数据集上，对于槽填充任务，本文模型的 F1 分数达到了 94.3%，相比最佳结果有了 3.8%的提升，对于意图检测任务，本文模型相比最高准确率提升了 0.4%，对于句子级别准确率，我们的提升最大，相比最高准确率模型提升了 7.7%。

实验 1 的结果表明，在意图数量更多但样本数量远远低于 SNIPS 的 ATIS 数据集上，即使每个意图编码器不能够得到充足的数据来训练，模型性能仍然能够基本与 SF-ID 模型相当。此外，在 SNIPS 数据集上性能的提升比在 ATIS 数据集上更为显著，通过分析发现，这是由于 SNIPS 数据集本身意图更加多样化，且意图数量相比 ATIS 更少、训练样本更充足，因此在 SNIPS 数据集上获得了更大的提升。结果显示，联合意图检测和槽填充特征融合模型提出的通过基于图注意力网络的意图-插槽联合交互方法可以更好地利用两个任务之间的相关知识，增强模型性能。

表 5-2 ATIS 数据集实验结果

模型	ATIS		
	Slot(F1)	Intent(Acc)	Overall(Acc)
Atten BiRNN[14]687-688	94.2	91.1	78.9
CAPSULE-NLU[50]	95.2	95.0	83.4
Joint Multiple ID-SF[51]	94.2	95.4	-
Slot-Gated[15]756	94.8	94.1	82.6
SF-ID[16]5470	95.6	96.6	86
Ours	95.6	97.6	86.6

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表 5-3 SNIPS 数据集实验结果

模型	SNIPS		
	Slot(F1)	Intent(Acc)	Overall(Acc)
Atten BiRNN	87.8	96.7	74.1
CAPSULE-NLU	91.8	97.3	80.6
Joint Multiple ID-SF	88.0	97.2	-
Slot-Gated	88.8	97.0	75.5
SF-ID	90.5	97.0	78.4
Ours	94.3	97.4	86.1

另外，考虑到 SNIPS 数据集意图的多样性，本文在 SNIPS 数据集上进行实验 2 的相关实验。具体为将模型的多编码器结构更改为单编码器结构来验证模型的泛化性能，并依据其槽填充任务的评估指标即 F1 分数对模型泛化能力进行评估。实验 2 结果如表 5-4 所示。

实验 2 的结果表明，本文提出的模型在 7 个意图领域均表现出比单编码器结构模型更优秀的性能。所提出的模型在未知意图数据上的表现相比单编码器结构模型更加优秀。这表明，本文提出的通过多编码器提取特征的模型性能要优于仅使用单个编码器的模型来提取隐式意图共享特征的模型。经过分析可知，这是由于单编码器模型忽略了潜在空间中插槽值表示和相关插槽标签之间的约束，导致模型缺乏足够的鲁棒性，而多编码器模型能够将不同意图之间的公共特征和特定意图的私有特征进行组合，从而更好地增强每个意图领域的性能，这也表明了模型成功地学习了如何完成知识的迁移。

除此之外，由实验 2 的结果可知，对于不同意图来说 F1 分数差距较大，这是由于数据集中不同意图领域间的相关性不同导致的，对于不同的目标域，其共享插槽标签与私有插槽标签均存在差异，且受到源域与目标域之间交叉数据量的影响。更具体地说，对于 AddToPlaylist 或 GetWeather 意图，它们与除本身外的其他意图之间的相关性更大，与其他意图之间的共享插槽数量更多，更容易从其他意图中学习到共享知识。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表 5-4 SNIPS 数据集上的零样本实验结果

意图	Zero-Shot(Slot F1)	
	Single-Encoder	Multi-Encoder
RateBook	7.42	13.48
PlayMusic	3.66	6.41
GetWeather	36.65	47.85
AddToPlaylist	33.39	36.36
SearchScreeningEvent	5.74	7.67
SearchCreativeWork	2.92	3.61
BookRestaurant	28.72	34.14

5.2 地图-指令双向注意力交互模型实验及分析

5.2.1 实验数据集

本文使用斯坦福大学提出的导航数据集对地图-指令双向注意力交互模型的性能进行了验证[27]2661-2662。数据集信息如表 5-5 所示。

表 5-5 斯坦福大学导航数据集

	单指令	双指令	总计
训练集	4062	2002	8066
重复测试集	944	34	1012
不重复测试集	962	0	962

该数据集由训练集和测试集组成，其中训练集包含 8066 条自然语言指令，这些指令在包含 6 至 65 个房间的室内环境上构建，并且对这些环境中 6064 条路径上的地标和房间等信息进行了描述，其中 4062 条路径包含 1 个指令描述，2002 条路径包含 2 个指令描述。

测试集包含重复测试集和不重复测试集，重复测试集由 1012 条自然语言指令及

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

其路径构成，其针对训练集中的室内地图环境进行描述，但与训练集中的指令信息不重复，在重复测试集中，944 条路径包含 1 个指令描述，34 条路径包含 2 个指令描述；不重复测试集由 971 条自然语言指令及其路径构成，这些指令对与训练集不同的 12 种新的室内地图环境进行了导航描述，并且每条路径均只有 1 个指令描述。

5.2.2 评价指标

由于目标序列中存在位置节点信息，但当行为动作信息全部正确的情况下，总能够按照正确的路径到达目标点，因此，本文在对模型性能进行评估时仅考虑序列中的行为动作信息。本文使用以下指标对模型的性能进行评价。

(1) 精准匹配度

精准匹配度(Exact Match, EM)用来评价预测行为动作序列与真实行为动作序列之间是否完全匹配。若预测行为动作序列与真实行为动作序列完全匹配，则 EM 的值为 1；若不完全匹配，则 EM 的值为 0。

(2) F1 分数

F1 分数是准确率和召回率的调和平均值，其针对序列预测问题具有较强的可靠性，能够对模型的性能进行更全面的评价。

(3) 编辑距离

编辑距离(Edit Distance, ED)是一种针对两个序列差异化程度的量化指标。在本文中，用于统计预测行为动作序列转换为真实行为动作序列所需要的最少操作次数，包含插入、删除、替换操作等。

(4) 目标匹配度

目标匹配度(Goal Match, GM)用于评估预测得到的行为动作序列所抵达的目标点是否与真实行为动作序列所抵达的目标点相同， GM 值为 1 时表示相同， GM 值为 0 时表示不相同。

5.2.3 实验设计

实验均在斯坦福导航数据集下进行，模型中的编码器和解码器中的 LSTM 单元数量均为 128，层数设置为 1。模型提取 12.5%的训练集作为验证集使用，用于选取合适的超参数。同样，为了缓解过拟合现象，模型设置 dropout 值为 0.5。本文模型中参数的优化选择 Adam 优化器进行优化，优化器中的超参数均为默认值。每批次

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

的指令数据数量为 256 条。对于所有实验结果，本文选择在验证集上效果最好的模型，并依此在两个测试集上进行效果评估。

在实验的设计上，本文除对提出的模型进行实验外，也在基线模型和两个消融模型上对地图-指令双向注意力交互模型及其算法的有效性进行了验证，基线模型和消融模型设计如下。

(1) 基线模型

本文将 Shimizu 等人提出的模型作为基线模型，该模型使用带有注意力机制的序列到序列模型将自然语言指令转化为行为动作序列，并使用深度优先搜索算法寻找与预测行为动作序列相匹配的路径，若没有路径匹配，模型会对预测行为动作序列中的相应标签进行更改，使其转换为有效路径[52]1488-1489。

此外，本文还将 Ashwini 等人提出的模型作为基线模型，该模型使用单向注意力机制，仅计算地图特征与指令中每个单词之间的相关性，将自然语言指令信息和地图信息进行融合，并对行为动作序列进行预测。

(2) 消融模型

为了验证行为导航图在模型中的作用和所提出的地图-指令双向交互算法的作用，并对模型性能进行全面的评估，本文在所提出的模型基础上设计了以下两种消融模型：

第一种消融模型取消了地图编码器模块，使模型仅通过自然语言指令数据来实现行为动作序列的预测，旨在验证地图中的知识对正确预测行为动作序列过程是否具有辅助作用。

第二种消融模型去除了注意力机制，使模型仅通过地图编码器和指令编码器的原始输出特征的拼接来实现行为动作序列的预测，旨在验证注意力机制在模型特征提取过程中的作用。

5.2.4 实验结果及分析

如表 5-6 和表 5-7 所示，在斯坦福大学导航数据集中的重复测试集和不重复测试集上，本文提出的地图-指令双向注意力交互模型均表现出更优越的性能。

具体来说，如表 5-6，在已知的地图环境下，不添加地图信息的模型与添加地图信息但没有注意力机制的模型相比性能更差，尤其是在编辑距离指标上，无地图信息的模型对正确路径的解析仅仅依靠自然语言指令，而添加地图信息但没有注意力机

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

制的模型还能够考虑到机器人所处的环境信息，与指令信息进行联合推理，因此性能更强。Baseline-A 模型与添加地图信息但没有注意力机制的模型相比，在全部指标上均有大幅提升，经过分析可知，地图环境往往是复杂冗余的，一条指令中并不会描述整个地图信息，而注意力机制的加入可以去除掉地图中的冗余信息，使模型对于地图信息的使用更加具有针对性。另外，本文提出的地图-指令双向注意力交互模型与基线模型和消融模型相比均有了明显的提升，尤其是对于 Baseline-A 模型，指标 EM 和 GM 均有 1%左右的提升，这表明，地图特征能够作为知识库为模型在行为动作序列推断过程中提供地图信息，并且在考虑地图信息中的每一部分时也能够优先考虑与其相关的指令信息。

表 5-6 重复测试集实验结果

模型	重复测试集			
	EM↑	F1↑	ED↓	GM↑
Baseline-S[52]1490-1492	25.30	79.83	2.53	26.28
Ablation-without map	38.54	89.19	1.40	38.54
Ablation-without atten	38.24	89.92	1.29	38.24
Baseline-A[27]2664	61.17	93.54	0.75	61.36
Ours	62.25	94.02	0.75	62.35

同样地，如表 5-7，所有基线模型和消融模型在不重复测试集即未知环境中均表现出与已知环境下相同的趋势，再一次验证了本文所提出的地图-指令双向交互算法的有效性。该算法通过将地图和指令特征从两个方向进融合，能够更好地考虑地图和指令中高相关性的特征信息。另外，斯坦福大学导航数据集中的指令信息较长，双向注意力交互算法也能够缓解文本信息长距离依赖丢失的问题。

同时可以发现，在未知环境下，本文提出的模型与使用单向注意力机制的基线模型 Baseline-A 相比，EM 和 GM 相比提升了约 2.5%，相对于已知环境有了更明显的提升，这说明本文提出的模型具备更强的泛化性能。由结果分析可知，地图信息和指令信息的单向交互仍然存在冗余信息，这些冗余信息对于行为动作序列的预测存在干扰，地图-指令双向交互算法通过计算自然语言指令序列与行为导航图中的每个三

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

元组之间的相关性，能够去除掉未知的冗余信息从而得到更加充分的特征，使模型获得更强的泛化性能。通过实验结果不难发现，端到端的神经网络模型能够更充分地利用输入特征中的关键信息，且受到误差的影响更小。

表 5-7 不重复测试集实验结果

模型	不重复测试集			
	EM↑	F1↑	ED↓	GM↑
Baseline-S	25.44	81.38	2.39	25.44
Ablation-without map	31.20	88.16	1.58	31.20
Ablation-without atten	32.65	88.07	1.54	32.65
Baseline-A	41.71	90.22	1.22	41.81
Ours	44.38	90.30	1.23	44.38

5.3 本章小结

本章通过实验验证了本文所提出的端到端神经网络模型的性能和相关算法的有效性。本章对模型所使用的数据集进行了介绍，并说明了模型性能评估指标，通过对比实验验证了联合意图检测和槽填充特征融合模型中特征融合模块和意图-插槽交互方法的有效性，并在未知场景下验证了模型的泛化性能；同时，地图-指令双向注意力交互模型通过消融实验验证了地图信息在行为动作序列推断中的重要作用和本文提出的双向注意力交互算法的优越性能。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

结 论

在家庭服务机器人领域，人与机器人之间的交互过程十分重要，为了使人和机器人之间的交互变得更加自然，如何使机器人对自然语言指令进行更充分地解析和更高效地执行是当前研究的重点。但目前相关的指令解析算法研究并不充分，传统的流水线方法普遍存在泛化性能差、解析为行为动作序列时映射不一致的问题。而随着深度学习的不断发展，使得通过构建端到端神经网络模型来解决这些问题成为可能。因此，本文使用端到端建模的方式来解决目前存在的问题。针对模型泛化能力较差的问题，提出了一种联合意图检测和槽填充特征融合模型，从特征提取的角度入手，通过意图融合编码器算法对数据的语义特征进行更充分地提取，并考虑不同意图数据之间的相关性和独立性，从而提升模型的泛化性能。针对指令描述方式不同导致映射不一致的问题，本文提出了地图-指令双向注意力交互模型，该模型从导航指令入手，将家庭环境信息表示为三元组的形式，将其作为知识库与指令特征进行融合，并通过提出双向注意力交互模块进一步提高特征的表达能力，从而缓解映射不一致的问题。本文研究工作主要在以下三个方面进行了体现。

(1) 为了提高模型的泛化性能，本文提出了基于多编码器的指令特征提取和指令征特征融合方法，并在此基础上提出了基于多编码器的联合意图检测和槽填充特征融合模型，其中指令特征提取方法使用不同的编码器对不同意图的指令分别且同时进行特征提取，提高了模型语义信息提取能力；指令的特征融合方法通过门机制将编码器的输出特征进行融合，使模型能够获得更加丰富、具备更强相关性的语义特征，使之泛化性能得到了增强。

(2) 考虑到意图和插槽信息之间具备强相关性和端到端建模方式信息的高利用率的特性，本文提出了意图-插槽联合交互方法，通过图注意力网络将意图和插槽信息进行联合。该方法将预测得到的意图分类结果作为图注意力层中的节点，并将指令中的所有单词特征作为其邻居节点，通过计算指令中每个单词特征与意图节点的相关性，使意图信息能够指导每个单词的插槽标签的预测。因此，槽填充任务能够充分考虑意图特征信息，并通过计算每个单词与意图之间的相关程度来提高槽填充任务的性能。

(3) 为了解决传统流水线建模方法中不同用户针对同一指令的不同描述导致的

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

映射不一致问题，本文提出了地图-指令双向注意力交互模型。该模型在已有的端到端机器翻译模型基础上构建，将地图表示为拓扑图，并将其抽象为地图语义特征输入到模型中，接着通过提出的双向注意力交互算法将地图信息与自然语言指令进行融合，使模型在进行动作序列生成过程中将能够充分、准确地考虑地图中的知识，从而解决因描述不同导致的映射不一致的问题。

本文按照计划顺利完成了课题的研究内容，在一定程度上解决了现阶段人和机器人交互过程中存在的问题，但受限于时间和本人知识水平，课题仍然存在以下需要改进之处。

(1) 由于 SNIPS 和 ATIS 数据集本身规模并不大，仍属于小规模的数据集，其指令、意图和插槽数量相对有限，因此在未来工作中将在更大型的数据集上进行相关实验和验证本文所提出模型的有效性，并将成果应用于人机对话系统的研究当中。

(2) 在实际家庭环境中，各种物品和杂物等会影响机器人的行进路径和路径推断，未来会考虑加入视觉信息，使模型获得更强的泛化能力。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

参考文献

[1] 毛志贤, 朱晓龙, 韦建军, 等. 家庭服务机器人现状与展望[J]. 机电工程技术, 2021, 335(2): 8-14.

[2] 刘珊, 兰智高. 养老服务机器人的技术发展趋势[J]. 计算机测量与控制, 2019, 27(7): 1-6.

[3] 田红梅, 邱卓英, 李欣, 等. 肢体残疾人康复需求与康复服务发展状况 Logistic 回归分析研究[J]. 中国康复理论与实践, 2020, 26(5): 508-512.

[4] 贺丹, 刘厚莲. 中国人口老龄化发展态势, 影响及应对策略[J]. 中共中央党校 (国家行政学院) 学报, 2019, 23(4): 84-90.

[5] 黄君浩, 贺辉. 基于 LSTM 的眼动行为识别及人机交互应用[J]. 计算机系统应用, 2020, 29(3): 206-212.

[6] 许士锦, 范展滔, 邱生敏, 等. 基于语音识别及自然语言处理对话流的人机智能交互方法研究[J]. 机械与电子, 2021, 79(7): 65-69.

[7] Caroppo A, Leone A, Siciliano P. 用于老年人面部表情识别的深度学习模型和传统机器学习方法的对比研究[J]. 计算机科学技术学报, 2020, 35(5): 1127-1146.

[8] Qin L, Xu X, Che W, et al. Dynamic Fusion Network for Multi-Domain End-to-End Task-Oriented Dialog[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 6344-6354.

[9] Qin L, Xie T, Che W, et al. A Survey on Spoken Language Understanding: Recent Advances and New Frontiers[J]. arXiv preprint arXiv:2103.03095, 2021. 1-8.

[10] HAFFNER P. Optimizing SVMs for complex call classification[C]//Proc. ICASSP-2003. 2003, 1: 632-635.

[11] Wang R, Li Z, Cao J, et al. Convolutional Recurrent Neural Networks for Text Classification[C]//2019 International Joint Conference on Neural Networks (IJCNN). IEEE, 2019: 1-6.

[12] Tang H, Ji D, Zhou Q. End-to-End Masked Graph-based CRF for Joint Slot Filling and Intent Detection[J]. Neurocomputing, 2020, 413: 348-359.

[13] Qi J, Liu X, Tejedor J. Variational Inference-based Dropout in Recurrent Neural Networks for Slot Filling in Spoken Language Understanding[J]. arXiv preprint arXiv:2009.01003, 2020: 1-5.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[14] Liu B, Lane I. Attention-Based Recurrent Neural Network Models for Joint Intent Detection and Slot Filling[J]. Interspeech 2016, 2016: 685-689.

[15] Goo C W, Gao G, Hsu Y K, et al. Slot-Gated Modeling for Joint Slot Filling and Intent Prediction[C]//Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers). 2018: 753-757.

[16] Haihong E, Niu P, Chen Z, et al. A Novel Bi-directional Interrelated Model for Joint Intent Detection and Slot Filling[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 5467-5471.

[17] Qin L, Xu X, Che W, et al. AGIF: An Adaptive Graph-Interactive Framework for Joint Multiple Intent Detection and Slot Filling[C]//Findings of the Association for Computational Linguistics: EMNLP 2020. 2020: 1807-1816.

[18] Kane B, Rossi F, Guinaudeau O, et al. Joint Intent Detection and Slot Filling via CNN-LSTM-CRF[C]//2020 6th IEEE Congress on Information Science and Technology (CiSt). IEEE, 2021: 342-347.

[19] Chang A, Dai A, Funkhouser T, et al. Matterport3D: Learning From RGB-D Data in Indoor Environments[C]//7th IEEE International Conference on 3D Vision, 3DV 2017. Institute of Electrical and Electronics Engineers Inc., 2018: 667-676.

[20] Anderson P, Wu Q, Teney D, et al. Vision-and-Language Navigation: Interpreting Visually-Grounded Navigation Instructions in Real Environments[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 3674-3683.

[21] Wang X, Xiong W, Wang H, et al. Look Before You Leap: Bridging Model-Free and Model-Based Reinforcement Learning for Planned-Ahead Vision-and-Language Navigation[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 37-53.

[22] Fried D, Hu R, Cirik V, et al. Speaker-Follower Models for Vision-and-Language Navigation[C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems. 2018: 3318-3329.

[23] Tan H, Yu L, Bansal M. Learning to Navigate Unseen Environments: Back Translation with Environmental Dropout[C]//Proceedings of NAACL-HLT. 2019: 2610-2621.

[24] Landsiedel C, Rieser V, Walter M, et al. A Review of Spatial Reasoning and Interaction for Real-

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

World Robotics[J]. Advanced Robotics, 2017, 31(5): 222-242.

[25] Chen D, Mooney R. Learning to Interpret Natural Language Navigation Instructions from Observations[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2011, 25(1): 859-865.

[26] Shah P, Fiser M, Faust A, et al. Follownet: Robot Navigation by Following Natural Language Directions with Deep Reinforcement Learning[J]. arXiv preprint arXiv:1805.06150, 2018: 1-7.

[27] Zang X, Pokle A, Vázquez M, et al. Translating Navigation Instructions in Natural Language to a High-Level Plan for Behavioral Robot Navigation[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 2657-2666.

[28] Lubis A R, Nasution M K M, Sitompul O S, et al. The Effect of The TF-IDF Algorithm in Times Series in Forecasting Word on Social Media[J]. Indones. J. Electr. Eng. Comput. Sci., 2021, 22(2): 976.

[29] Yilmaz S, Toklu S. A Deep Learning Analysis on Question Classification Task Using Word2vec representations[J]. Neural Computing and Applications, 2020, 32(7): 2909-2928.

[30] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[J]. ICLR, 2013:1-12.

[31] Mikolov T, Sutskever I, Chen K, et al. Distributed Representations of Words and Phrases and Their Compositionality[C]//Advances in neural information processing systems. 2013: 3111-3119.

[32] Liu S, He T, Dai J. A survey of CRF Algorithm Based Knowledge Extraction of Elementary Mathematics in Chinese[J]. Mobile Networks and Applications, 2021, 26(5): 1891-1903.

[33] Teng L, Yan X, Xie J, et al. Khmer Named Entity Recognition Based on LSTM-CRF Model[M]//Wireless Technology, Intelligent Network Technologies, Smart Services and Applications. Springer, Singapore, 2022: 175-187.

[34] Qin L, Xie T, Che W, et al. A Survey on Spoken Language Understanding: Recent Advances and New Frontiers[C]//IJCAI. 2021: 4577-4584.

[35] Zhang X, Wang H. A Joint Model of Intent Determination and Slot Filling for Spoken Language Understanding[C]//IJCAI. 2016, 16: 2993-2999.

[36] Chen Q, Zhuo Z, Wang W. Bert for Joint Intent Classification and Slot Filling[J]. arXiv preprint arXiv:1902.10909, 2019: 1-6.

[37] Wang Y, Hou Y, Che W, et al. From Static to Dynamic Word Representations: A Survey[J].

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

International Journal of Machine Learning and Cybernetics, 2020: 1-20.

[38] Levit M, Roy D. Interpretation of Spatial Language in a Map Navigation Task[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2007, 37(3): 667-679.

[39] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural computation, 1997, 9(8): 1735-1780.

[40] Xu M, Islam M, Lim C M, et al. Learning domain adaptation with model calibration for surgical report generation in robotic surgery[C]//2021 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2021: 12350-12356.

[41] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[C]//Advances in neural information processing systems. 2017: 5998-6008.

[42] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking The Inception Architecture for Computer Vision[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2818-2826.

[43] Lin J, Sun X, Ma S, et al. Global Encoding for Abstractive Summarization[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2018: 163-169.

[44] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]//International Conference on Learning Representations. 2018: 1-16.

[45] Sepulveda G, Niebles J C, Soto A. A Deep Learning Based Behavioral Approach to Indoor Autonomous Navigation[C]//2018 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2018: 4646-4653.

[46] Pennington J, Socher R, Manning C D. Glove: Global Vectors for Word Representation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.

[47] Coucke A, Saade A, Ball A, et al. Snips Voice Platform: An Embedded Spoken Language Understanding System for Private-by-Design Voice Interfaces[J]. arXiv preprint arXiv:1805.10190, 2018: 1-29.

[48] Hemphill C T, Godfrey J J, Doddington G R. The ATIS Spoken Language Systems Pilot Corpus[C]//Proceedings of the Workshop on Speech and Natural Language. 1990: 96-101.

[49] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[C]//ICLR (Poster). 2015:1-15.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[50] Zhang C, Li Y, Du N, et al. Joint Slot Filling and Intent Detection via Capsule Neural Networks[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 5259-5267.

[51] Gangadharaiah R, Narayanaswamy B. Joint Multiple Intent Detection and Slot Labeling for Goal-Oriented Dialog[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 564-569.

[52] Shimizu N, Haas A. Learning to Follow Navigational Route Instructions[C]//Proceedings of the 21st International Joint Conference on Artificial Intelligence. 2009: 1488-1493.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

攻读硕士学位期间承担的科研任务与主要成果

(一)科研获奖

[1] 孙永派，马迎伟，华北五省(市、自治区)机器人大赛一等奖, 2019.

[2] 孙永派，孙英健，邱梦璐，谢玉潇，全国大学生物联网设计竞赛(华北赛区)特等奖, 2020.

[3] 孙己正，王发超，郭凡，孙永派，孙英健，第 22 届锦江学院杯全国机器人锦标赛一等奖, 2020.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

致谢

三年的时光匆匆走过，我的研究生生活也随着论文的完成画上了句号，回顾这三年的学生生涯，有快乐，有辛酸，再回首这些往事，好似昨天发生过。在燕大的每一分每一秒都还历历在目，而我们却要在这个夏天分别了，虽然不舍，但也十分有幸你们出现在我的生命中，在枯燥的学习生活中挥洒色彩，拥有过你们是我最大的幸运。

首先，我要对我的导师娄凤伟老师、赵逢达老师和李贤善老师衷心地说一声谢谢，感谢你们三年来的辛苦付出和孜孜不倦，感谢你们让我从稚嫩走向成熟。忘不了平时与娄凤伟老师讨论课题的时光，您认真提出建议的神情令我难忘；忘不了每次组会时与赵逢达老师的讨论，您总能准确严谨地指出问题所在；忘不了李贤善老师的和蔼与耐心，让我在这个陌生的城市感受到温暖；也忘不了老师们对我论文的悉心指导，让我在求学的道路上少走了很多弯路。您们对我的关怀还有太多太多，我会将这一点一滴都铭记于心，让它们在我未来的道路上生根发芽，激励我前行。

然后，我要感谢我的室友们，三年来相处的时光虽短暂，但充实，愿我们都能够在未来的日子里闪闪发光；感谢课题室里可爱的伙伴们，同窗三年，研究生生活的大部分时间都是与你们一起度过，于我来说，你们已不再只是同学，更是朋友，愿毕业后的你们能够开心快乐，拥有更加绚烂的未来。

再次，我要感谢我的父母，是你们的悉心培养才有了我的今天，你们用心血和汗水为我铺平前方的道路，你们的辛苦操劳换来了我的一切，你们对我的爱是我奋斗下去的动力，在这里语言太过苍白，千言万语也不能表达出我此刻的心情，衷心地感谢你们，未来定不负你们的期望。

写到这里，我已不知道用何种语言表达此刻的心情，在这离别即将到来之际，最真挚的祝愿送给我的朋友们，无论明天我们身在何处，请永远记得感恩，永远相信自己，我们的青春也永远不会散场。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net